



# Hodnocení kognitivní zátěže v extrémním prostředí

Diplomová práce

Bc. Marek Sokol

vedoucí: Mgr. Ksenia Sedova, Ph.D.

konzultant: Ing. et Ing. Jan Hejda, Ph.D.

Fakulta biomedicínského inženýrství  
ČVUT v Praze

2023

# Kognitivní zátěž

Definice kognitivní zátěže (CL) se v jednotlivých oborech mohou lišit.

- Využitá kapacita pracovní paměti
- Hodnocení kognitivní zátěže



Obrázek: Vztah CL s výkonností<sup>1</sup>

Definice (Chen et al., 2016)

Proměnná, jež určuje míru požadavků kladených úkolem na dostupné mentální zdroje.

<sup>1</sup>HP Labs: Cognitive Load (2021). *What is mental effort and why does it matter?* Accessed: 2023-14-05.



Dopad na životně důležité scénáře (Lagomarsino, 2022)



Lékařské pohotovosti ve vesmíru (Russomano, 2023)



Zásadní vliv na bezpečnost pacientů (Sexton, 2022)



VR terapie s využitím biofeedbacku (Oswald, 2022)

# Relevance hodnocení kognitivní zátěže

*„Hodnocení a snižování kognitivní zátěže by mělo být prioritou oboru strojového učení ve zdravotnictví.<sup>1</sup>“*

- Využití tradičních metod v extrémním prostředí je nepraktické až neproveditelné
- Kritické pro zajištění bezpečnosti a úspěchu během životně důležitých scénářů
- Možnost využití hodnocení biologických signálů

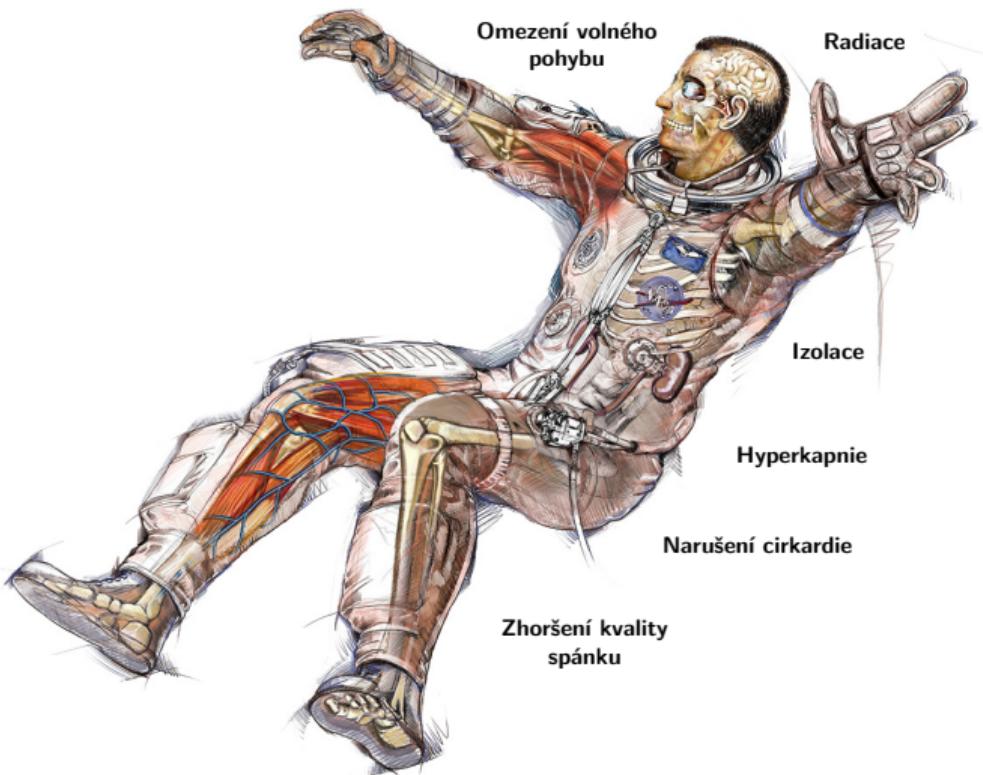
---

<sup>1</sup>D. E. Ehrmann et al. (2022). „Evaluating and reducing cognitive load should be a priority for machine learning in healthcare“. In: *Nature Medicine* 28.7. Accessed: 2023-13-05, s. 1331–1333.

# Dosavadní přístupy

---

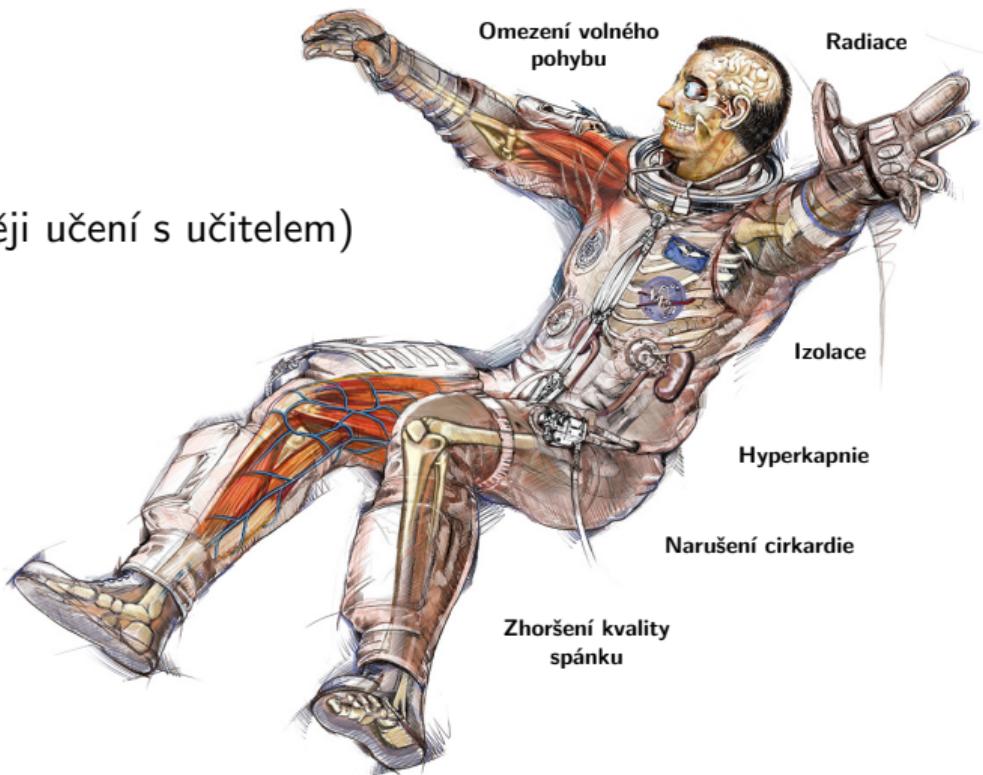
- Dotazníkové metody nebo behaviorální analýza



# Dosavadní přístupy

---

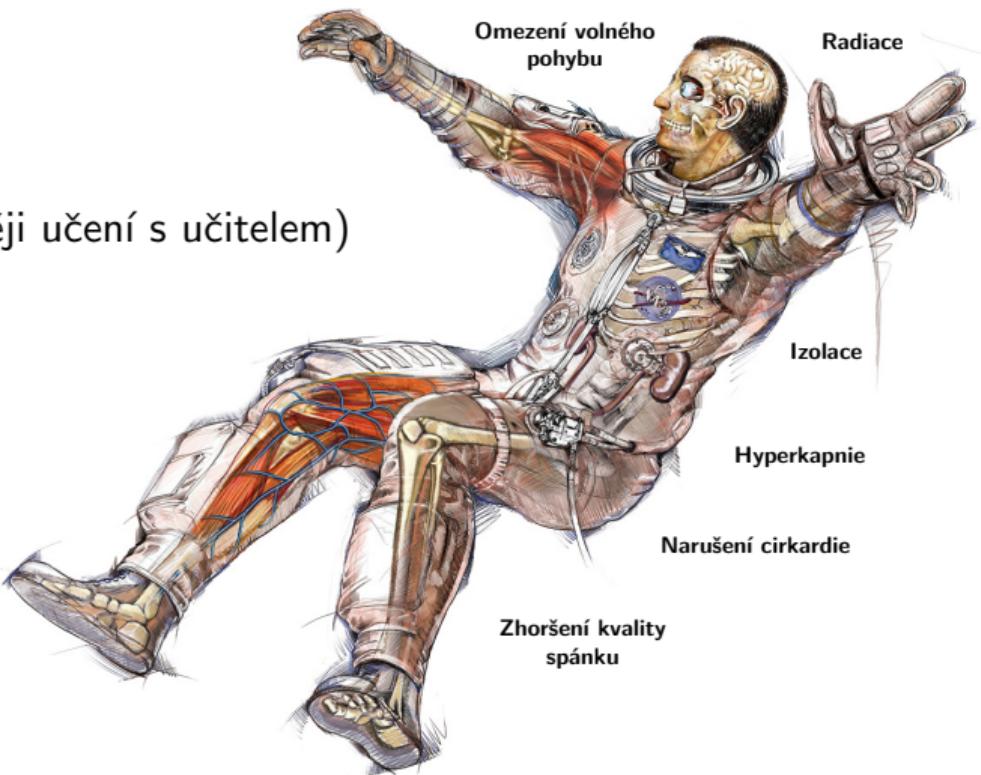
- Dotazníkové metody nebo behaviorální analýza
- „Data-driven“ přístupy (nejčastěji učení s učitelem)
  - nejasná interpretace
  - generalizace v ICE
  - dlouhé časové úseky



# Dosavadní přístupy

---

- Dotazníkové metody nebo behaviorální analýza
- „Data-driven“ přístupy (nejčastěji učení s učitelem)
  - nejasná interpretace
  - generalizace v ICE
  - dlouhé časové úseky
- Metody hlubokého učení
  - množství parametrů
  - nezohledňuje kauzalitu
  - nejasnost určujících faktorů



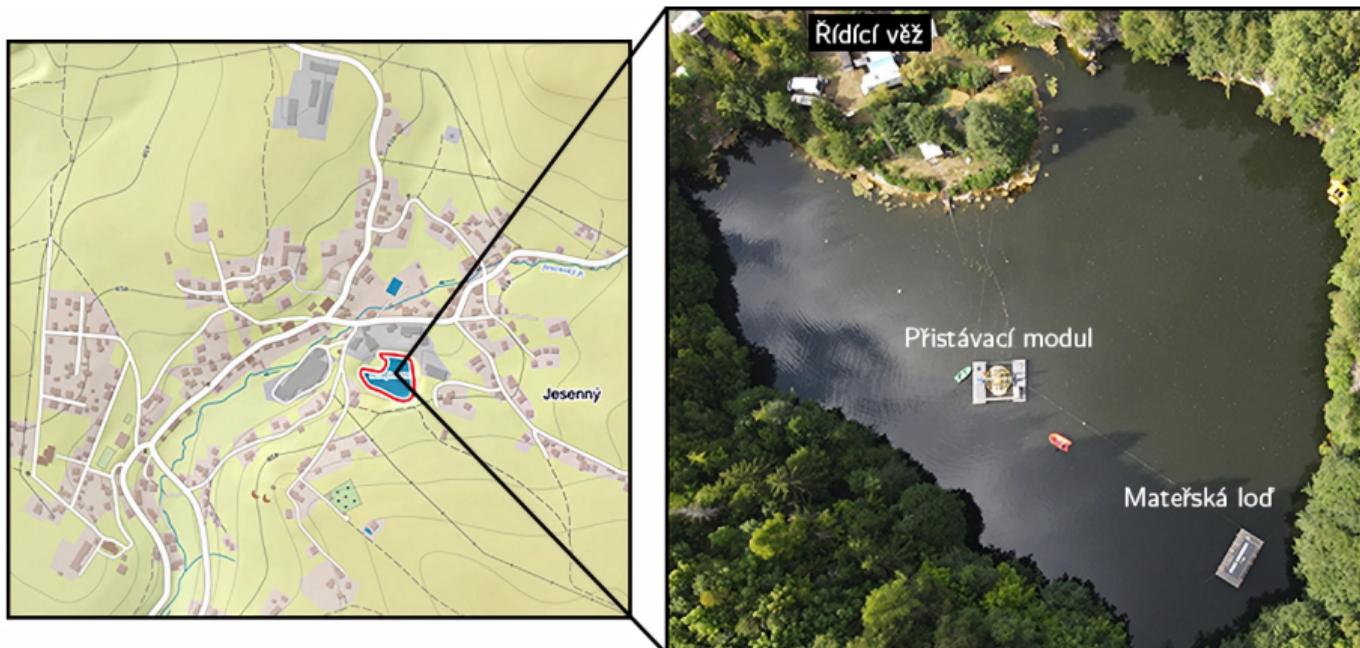
# Cíle práce

---

1. Analýza dat získaných v průběhu analogové mise s využitím časových, frekvenčních a nelineárních parametrů se srovnáním mezi posádky
2. Vyhodnocení vlivu úloh navozujících zvýšenou kognitivní zátěž se srovnáním mezi mateřskou lodí a přistávacím modulem
3. Návrh a realizace metod pro hodnocení kognitivní zátěže

# Experimentální část práce

---

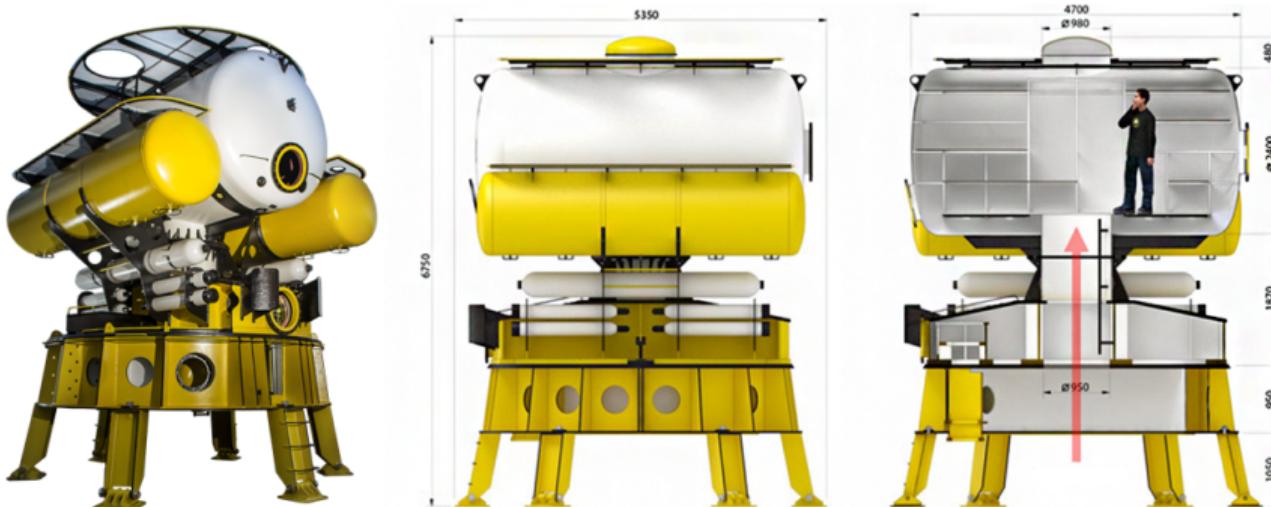


Obrázek: Detail a lokalita lomu v obci Jesenný (zdroj mapového podkladu: Mapy.cz)

# Analogová vesmírná mise DIANA

---

- Simulace přistání na Měsící
- Podvodní laboratoř H03 DeepLab



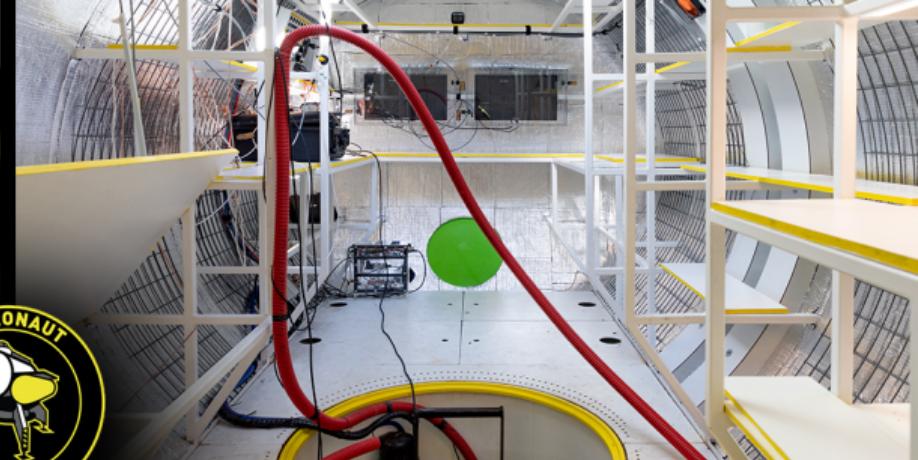
Obrázek: Hlubinná laboratoř H03 DeepLab (zdroj: Hydronaut Project a.s.)



Monitorování v řídící věži



eesa



Odbavený vnitřek habitatu



Snímek z monitorování přistávacího modulu



Noční snímek z monitorování mateřské lodi

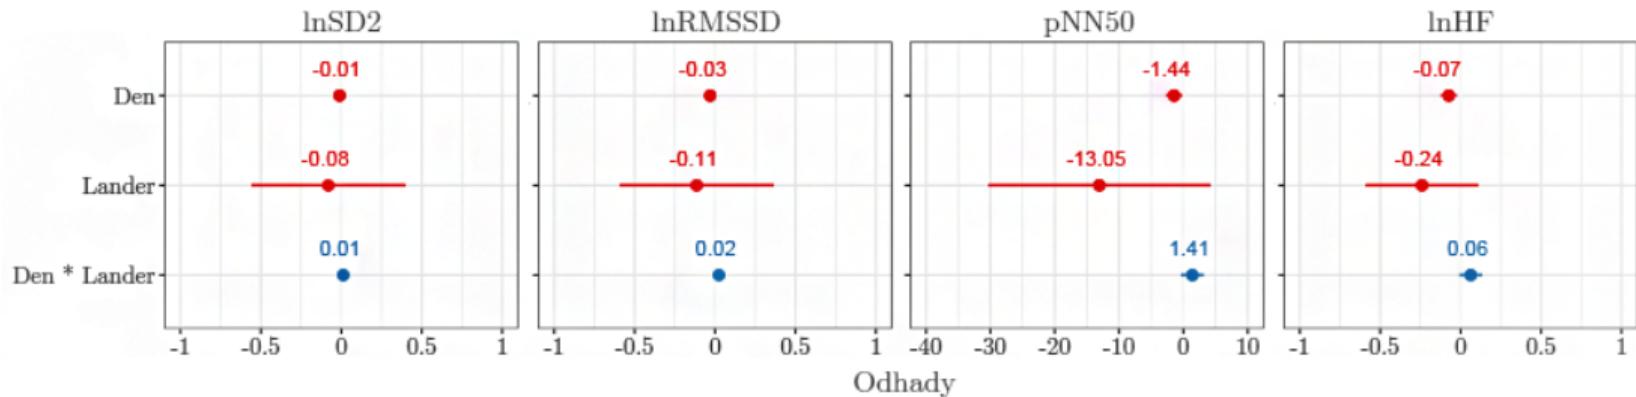
# Cíle práce

---

1. Analýza dat získaných v průběhu analogové mise s využitím časových, frekvenčních a nelineárních parametrů a srovnání mezi posádkami

# Analýza dat mise DIANA

- Popisné statistiky a lineární smíšené modely (LMM)
- Klesající charakter sledovaných veličin napříč misí
- Skupiny MotherShip (mateřská loď) a Lander (přistávací modul)
- Statisticky nevýznamné změny



Obrázek: Vizualizace odhadů koeficientů (fixních efektů) navržených modelů

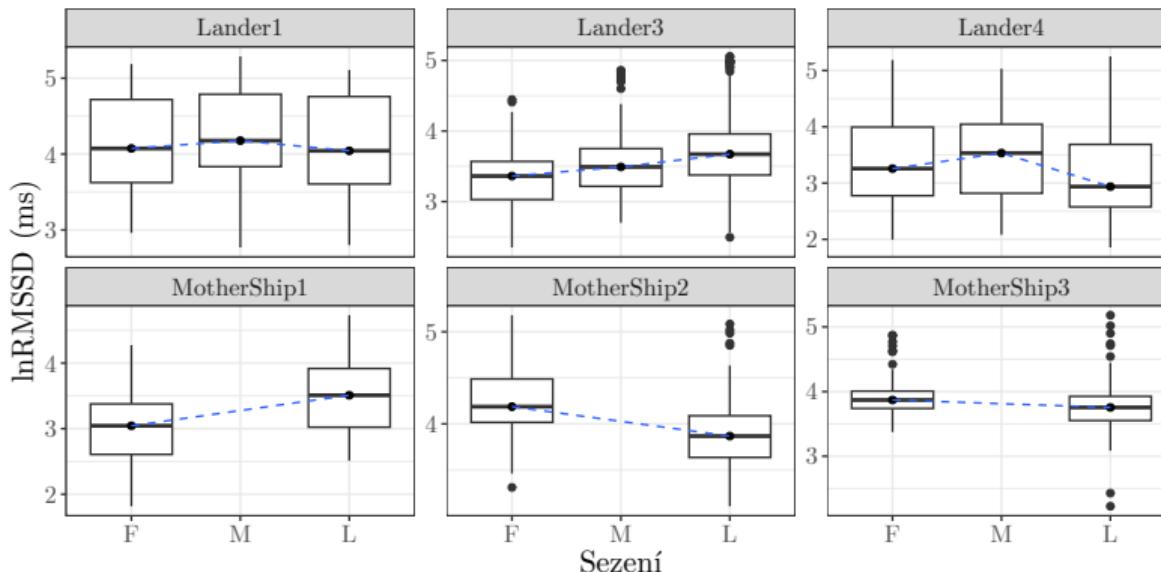
# Cíle práce

---

1. Analýza dat získaných v průběhu analogové mise s využitím časových, frekvenčních a nelineárních parametrů se srovnáním mezi posádkami ✓
2. **Vyhodnocení vlivu úloh navozujících zvýšenou kognitivní zátěž se srovnáním mezi mateřskou lodí a přistávacím modulem**

# Stimulace kognitivní zátěže

- Individuální HRV reakce analogových astronautů



Obrázek: Krabicové grafy pro parametr RMSSD během jednotlivých NPF sezení (vyšší hodnota = menší CL)

# Cíle práce

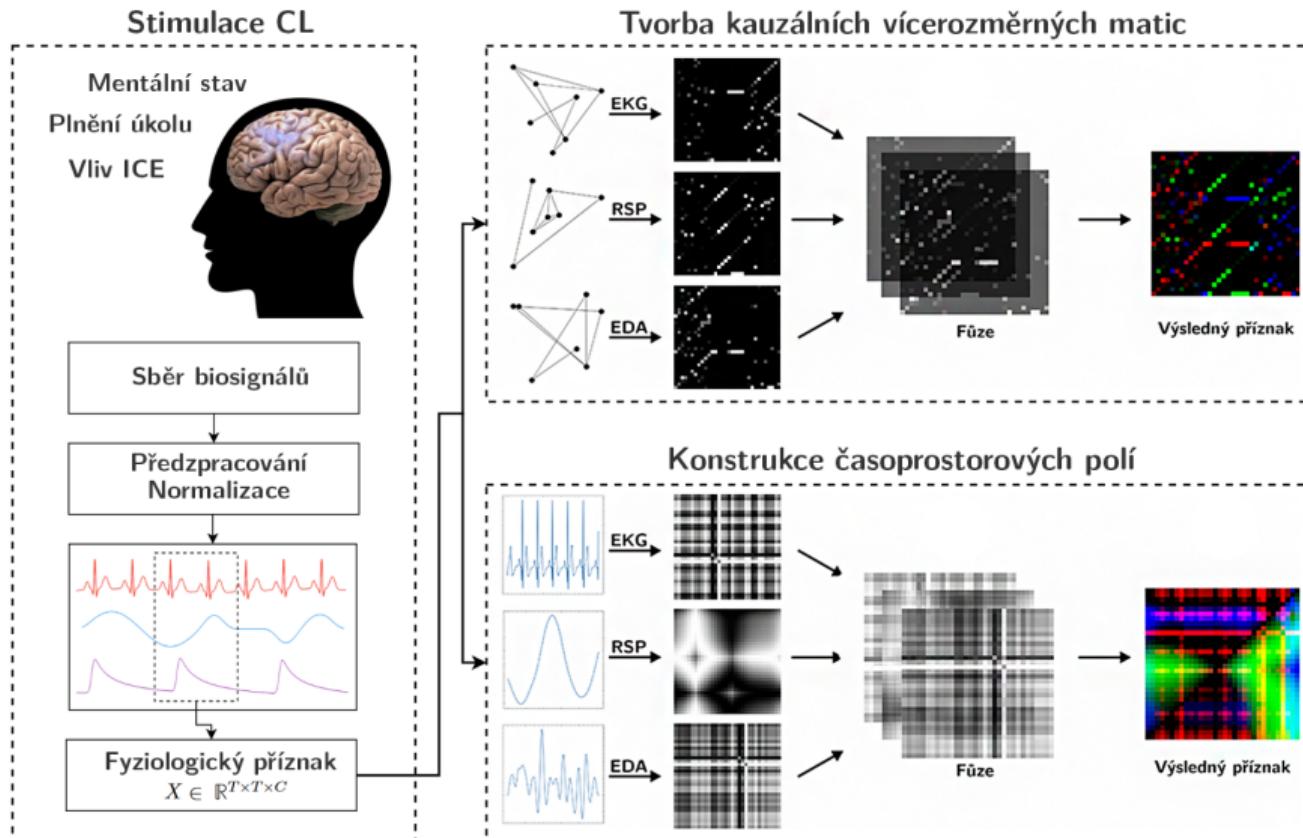
---

1. Analýza dat získaných v průběhu analogové mise s využitím časových, frekvenčních a nelineárních parametrů se srovnáním mezi posádkami ✓
2. Vyhodnocení vlivu úloh navozujících zvýšenou kognitivní zátěž se srovnáním mezi mateřskou lodí a přistávacím modulem ✓
3. **Návrh a realizace metod pro hodnocení kognitivní zátěže**

# Hodnocení kognitivní zátěže

---

- Návrh metody pro hodnocení kognitivní zátěže
- Multimodální řešení s využitím kapsulární neuronové sítě
- Trénování a validace na populárních benchmarkovacích datasetech
- Srovnání se současným stavem



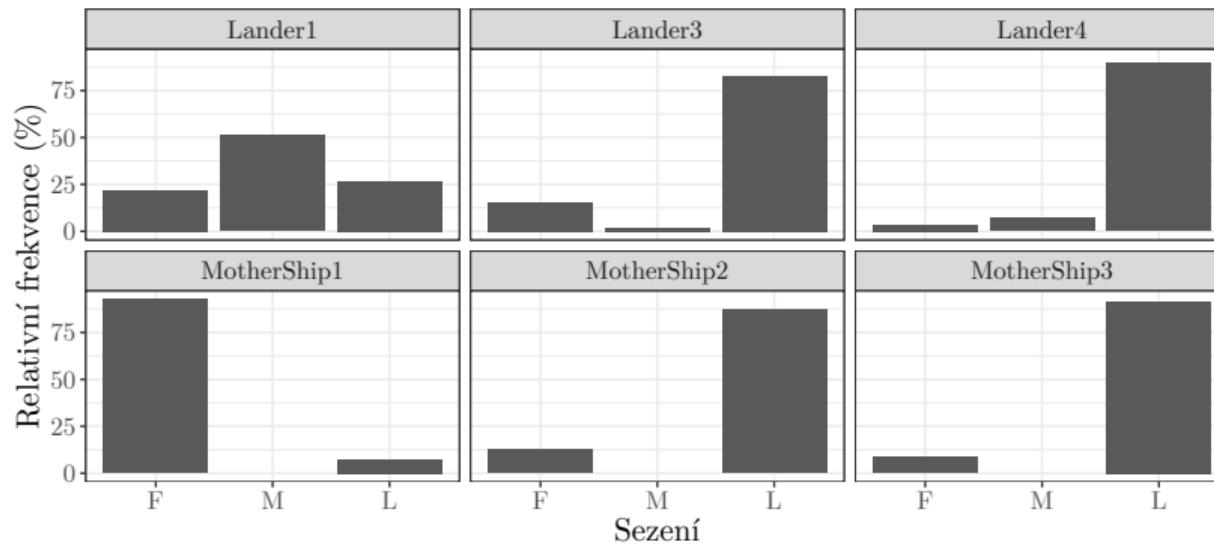
**Obrázek:** Schéma tvorby fyziologických příznaků

**Tabulka:** Výsledky srovnání s dosavadními přístupy

Autor	Dataset	Okno	Test acc.	Rok
Feradov et al.	CLAS	30s	84 %	2020
Ahmad et al.	WESAD	1s	72 %	2021
Garg et al.	WESAD	10s	84 %	2021
Rabbani et al.	WESAD	10s	87 %	2022
Zhu et al.	CLAS	30s	86 %	2022
*Quadrini et al.	WESAD	60s	91 %	2022
Chatterjee et al.	WESAD	30s	94 %	2022
Dair et al.	WESAD	10s	69 %	2023
Rashid et al.	WESAD	30s	93 %	2023
Galarraga et al.	WESAD	20s	90 %	2023
Henry et al.	WESAD	6s	81 %	2023
*Yong et al.	CLAS	5s	75 %	2023
Singh et al.	WESAD	5s	91 %	2023
<b>Autor práce</b>	<b>WESAD</b>	<b>5s</b>	<b>97 %</b>	<b>2023</b>
<b>Autor práce</b>	<b>CLAS</b>	<b>5s</b>	<b>92 %</b>	<b>2023</b>
<b>Autor práce</b>	<b>WESAD</b>	<b>1s</b>	<b>95 %</b>	<b>2023</b>
<b>Autor práce</b>	<b>WESAD</b>	<b>1s</b>	<b>92 %</b>	<b>2023</b>

# Test na datech z mise

- Realizované řešení bylo otestováno na datech z vesmírné analogové mise



**Obrázek:** Relativní frekvence pravděpodobnosti výskytu kognitivní zátěže vyšších než 50 % pro jednotlivá sezení využitím modelu WESAD-5s

# Cíle práce

---

1. Analýza dat získaných v průběhu analogové mise s využitím časových, frekvenčních a nelineárních parametrů se srovnáním mezi posádkami ✓
2. Vyhodnocení vlivu úloh navozujících zvýšenou kognitivní zátěž se srovnáním mezi mateřskou lodí a přistávacím modulem ✓
3. Návrh a realizace metod pro hodnocení kognitivní zátěže ✓

# Souhrn práce

---

- Zpracování a analýza dat získaných v průběhu analogové vesmírné mise
  - Vyhodnocení vlivu úloh navozujících zvýšenou kognitivní zátěž na sledované veličiny
  - Srovnání výsledků na úrovni posádky mateřské lodi a přistávacího modelu
  - Návrh a realizace multimodálního řešení pro hodnocení kognitivní zátěže
- 



Dostupné online: [github.com/sokolmarek/masters-thesis](https://github.com/sokolmarek/masters-thesis)

Rád bych poděkoval společnosti Hydronaut a.s. a Filozofické fakultě Univerzity Palackého v Olomouci za možnost participace na takto mimořádném projektu.



Filozofická  
fakulta  
Univerzita Palackého  
v Olomouci



# Otázky oponenta

---

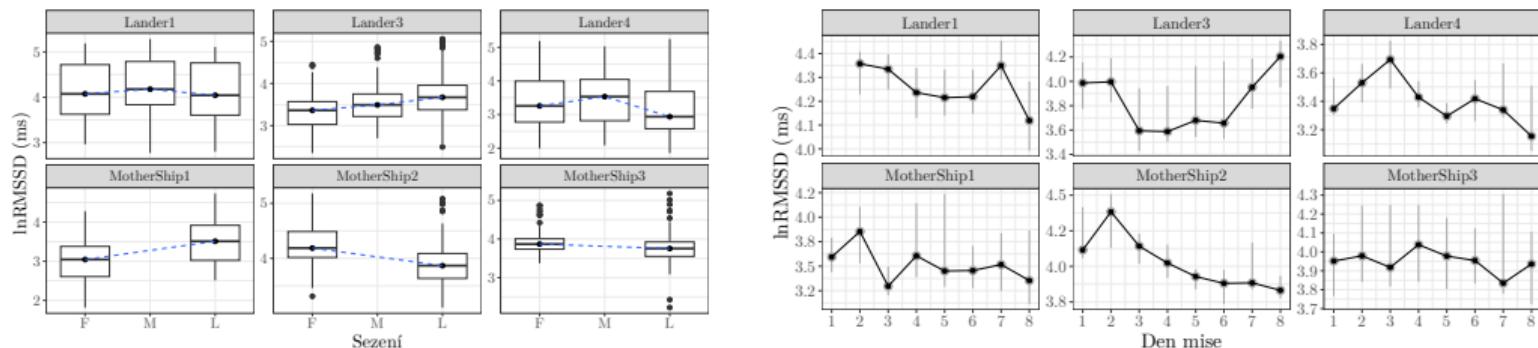
## Otázka #1

V práci uvádíte, že většinu dat jste zpracoval ex post. Tedy například popis mise DIANA není Vámi zvolenou metodou, ale souhrnem projektu realizovaného jinými pracovníky z Univerzity Palackého. Vyjádřete se takto k seznamu metod a výsledků, které z nich jsou skutečně Vaším dílem.

# Otázky oponenta

## Otázka #2

Uveďte, jakým způsobem jste získával data a speciálně, zda k datům měření srdečních parametrů v hyperbarickém prostředí byste ještě mohl získat přístup. Vysvětlete, zda jsou či nejsou výsledky s hyperbarickými daty dostupné a srovnatelné s odděleně zpracovanými normobarickými daty.



**Obrázek:** Ukázka vybraných srovnání parametru RMSSD mezi posádky mateřské lodi (MotherShip) a přistávacího modulu (Lander). Data posádek jsou srovnána konkrétně v kapitole Výsledky na stranách 82–89

# Otázky oponenta

---

## Otázka #3

Posádka při simulované misi ví, že je na zemi a ne ve vesmíru. Úroveň stresu je nižší ve srovnání se skutečnou vesmírnou misí. Šlo by toto nějak extrapolovat na skutečnou vesmírnou misi?



# Grangerova kauzalita

Grangerův test kauzality je statistický test pro určení, zda je jedna časová řada užitečná pro předpověď jiné časové řady.

## Definice (Vícerozměrná Grangerova kauzalita)

Nechť  $X(t) \in \mathbb{R}^{d \times 1}$  pro  $t = 1, \dots, T$  je  $d$ -dimenzionální vícerozměrná časová řada.

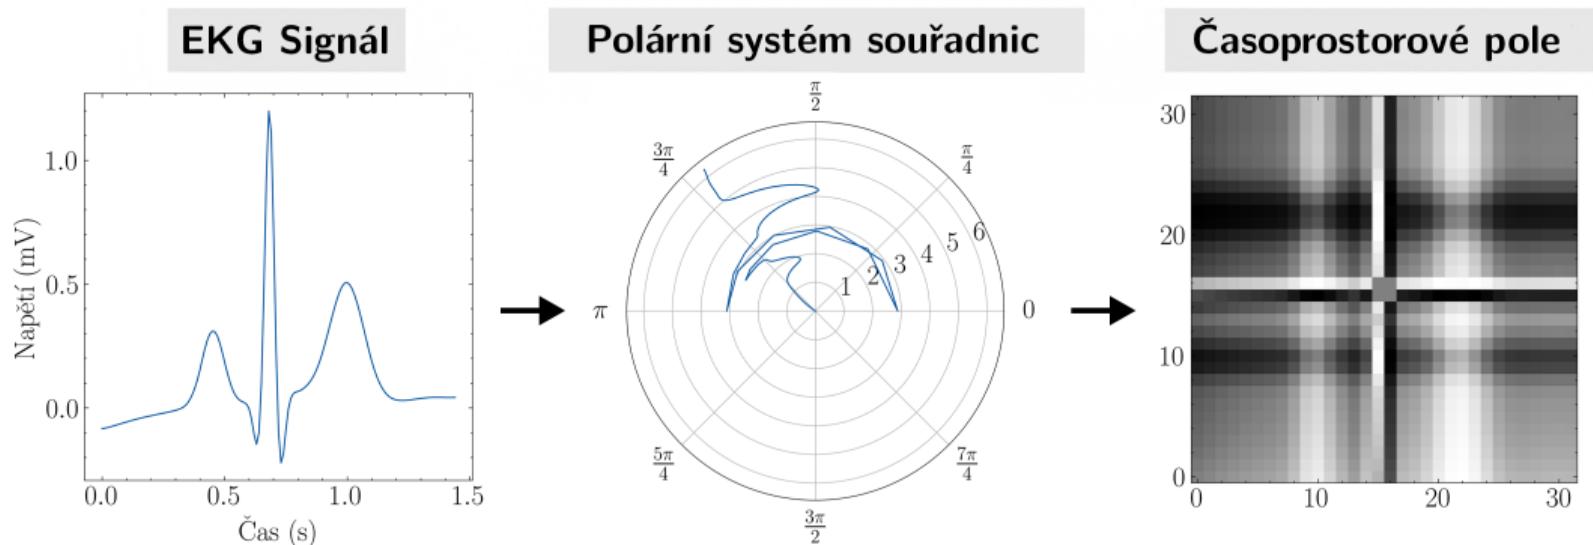
Grangerova kauzalita se provádí pomocí VAR modelu s  $L$  časovými zpožděními takto:

$$X(t) = \sum_{\tau=1}^L A_\tau X(t-\tau) + \varepsilon(t), \quad (1)$$

kde  $A_\tau$  je matice pro každé  $\tau$ . Časová řada  $X_i$  se nazývá Grangerovou přičinou jiné časové řady  $X_j$ , jestliže alespoň jeden z prvků  $A_\tau(j, i)$  pro  $\tau = 1, \dots, L$  je výrazně (statisticky významněji) větší než nula (v absolutní hodnotě).

# Gramian angular fields

„Gramovo úhlové pole“ (GAF) je obraz získaný z časové řady, který představuje určitý druh temporální korelace mezi každou dvojicí hodnot z časové řady.



Obrázek: Ukázka jednotlivých kroků GAF mapování na EKG segmentu

# Gramian angular fields

GAF nejdříve zahrnuje normalizaci na interval  $[-1; 1]$ . Poté jsou data převedeny do polárních souřadnic výpočtem úhlové složky  $\phi_i$  a radiální složky  $r_i$  pro každý vzorek  $\tilde{x}_t$ :

$$\begin{cases} \phi_i = \arccos(\tilde{x}_t), & -1 \leq \tilde{x}_t \leq 1, \tilde{x}_t \in \tilde{X}^i \\ r_i = \frac{t}{N}, & t \in N \end{cases} \quad (2)$$

kde  $t$  je čas vzorku a  $N$  je konstantní faktor pro regulaci rozpětí polárního souřadného systému. Identifikace temporální korelace v rámci různých časových intervalů je dosaženo s ohledem na trigonometrický rozdíl mezi jednotlivými body. Časoprostorový vzor je pak definován následující  $T \times T$  maticí, která je kvazi-Gramovou maticí:

$$GADF = \begin{bmatrix} \sin(\phi_1 - \phi_1) & \sin(\phi_1 - \phi_2) & \cdots & \sin(\phi_1 - \phi_n) \\ \sin(\phi_2 - \phi_1) & \sin(\phi_2 - \phi_2) & \cdots & \sin(\phi_2 - \phi_n) \\ \vdots & \vdots & \ddots & \vdots \\ \sin(\phi_n - \phi_1) & \sin(\phi_n - \phi_2) & \cdots & \sin(\phi_n - \phi_n) \end{bmatrix} \quad (3)$$

# Teorie kopulí

Kopule  $C$  je vícerozměrnou kumulativní distribuční funkcí, jež popisuje závislost mezi jednotlivými marginálními distribucemi a poskytuje způsob, jak modelovat právě společnou distribuci náhodných veličin bez specifikace samotných distribucí těchto veličin. Základem teorie kopulí je Sklarův teorém, který říká, že jakákoli více-dimenzionální distribuce může být zapsána jako kopule aplikovaná na její marginální distribuce:

## Věta (Sklarova věta)

*Nechť  $F$  je vícerozměrná distribuční funkce s marginálními distribucemi  $F_1, F_2, \dots, F_n$ . Pak existuje kopule  $C$  taková, že:*

$$F(x_1, x_2, \dots, x_n) = C(F_1(x_1), F_2(x_2), \dots, F_n(x_n)) \quad (4)$$

*Kopule  $C$  je jednoznačná, pokud marginální distribuce  $F_1, F_2, \dots, F_n$  jsou spojité.*

# Grangerova kauzalita ve smyslu teorie kopulí

---

Pro shrnutí vychází tento model z následujících kroků:

1. Nalezení empirického marginálního rozdělení pro fyziologickou událost  $\hat{F}_i$ .
2. Mapování pozorování do kopula prostoru:  $\hat{f}_i(x_t^i) = \hat{\mu}_i + \hat{\sigma}_i \cdot \Phi^{-1}(\hat{F}_i(x_t^i))$ .
3. Nalezení Grangerovy kauzality v rámci  $\hat{f}_i(x_t^i)$ .

přičemž je dále brán v potaz Winsorizovaný<sup>1</sup> odhad použité distribuční funkce, aby se zabránilo velkým číslům  $\Phi^{-1}(0^+)$ <sup>2</sup> a  $\Phi^{-1}(1^-)$ :

$$\tilde{F}_j = \begin{cases} \delta_n, & \text{if } \hat{F}(x^j) < \delta_n \\ \hat{F}(x^j) & \text{if } \delta_n \leq \hat{F}(x^j) < 1 - \delta_n \\ (1 - \delta_n) & \text{if } \hat{F}(x^j) > 1 - \delta_n. \end{cases} \quad (5)$$

---

<sup>1</sup>Winsorizace je transformace statistických dat omezením extrémních hodnot, aby se snížil vliv případných odlehlych hodnot

<sup>2</sup> $\Phi^{-1}$  je inverzní kumulativní distribuční funkce standardního normálního rozdělení.

# Lasso regularizace

Lasso (Least Absolute Shrinkage and Selection Operator) je široce používaná technika lineární regrese pro výběr a regularizaci proměnných využitím  $\ell_1$  penalizačního členu.

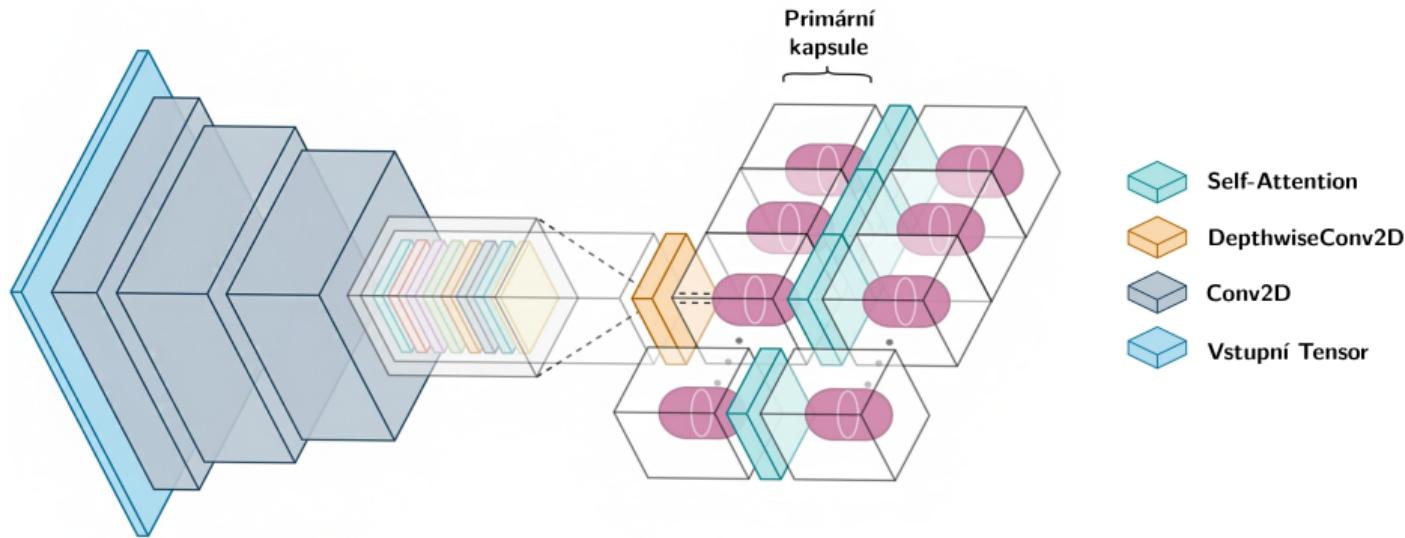
## Definice (LASSO)

Nechť vybraná fyziologická událost  $X^i = \{x_t^i : t = 0, \dots, T\}$ , poté lze získat koeficienty následovně:

$$\hat{\beta}_i(\lambda) = \arg \min_{\beta_i} \left( \sum_{t=1}^T \|x_i^t - X_{t,L}^{Lag} \beta_i\|^2 + \lambda \|\beta_i\|_1 \right), \quad (6)$$

kde  $X_{t,L}^{Lag}$  reprezentuje spojený vektor všech zpožděných pozorování se zpožděním  $L$  až do času  $t$  a  $\lambda$  je penalizační parametr určující míru regularizace koeficientů.  $X_i$  je příčinou  $X_j$ , pokud je alespoň jedna hodnota v  $B$  nenulová na základě statisticky významných testů.

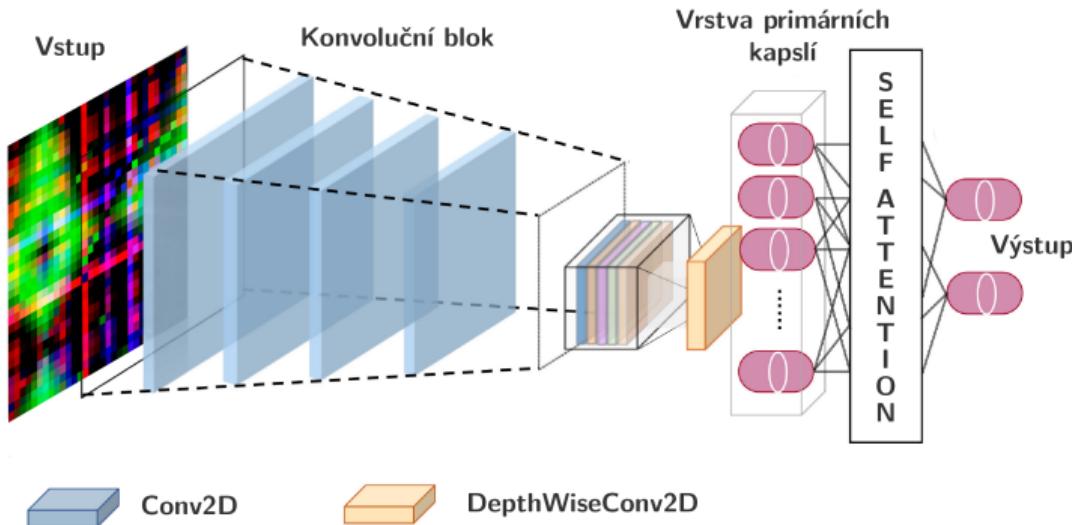
# Kapsulární neuronová síť



**Obrázek:** Schematické znázornění architektury sítě *Efficient-CapsNet* (Upraveno a převzato z<sup>1</sup>)

<sup>1</sup>V. Mazzia et al. (čvc. 2021). „Efficient-CapsNet: capsule network with self-attention routing“. In: *Scientific Reports* 11.11, s. 14634.

# Kapsulární neuronová síť



Obrázek: Schéma navrženého modelu kapsulární neuronové sítě postavené na architektuře Efficient-CapsNet<sup>1</sup>. Každá konvoluční vrstva je v navrženém řešení navíc následována vrstvami: BatchNormalization, MaxPool2D a Dropout (schéma adaptováno podle Wang et al.<sup>2</sup>)

<sup>1</sup>V. Mazzia et al. (čvc. 2021). „Efficient-CapsNet: capsule network with self-attention routing“. In: *Scientific Reports* 11.11, s. 14634.

<sup>2</sup>H. Wang et al. (pros. 2021). „Application of deep learning upon spinal radiographs to predict progression in adolescent idiopathic scoliosis at first clinic visit“. In: *eClinicalMedicine* 42.