



**ČESKÉ VYSOKÉ UČENÍ TECHNICKÉ V PRAZE**

---

**FAKULTA BIOMEDICÍNSKÉHO INŽENÝRSTVÍ**

**Katedra biomedicínské techniky**

**Hodnocení kognitivní zátěže v extrémním prostředí**

**Assessment of cognitive load in extreme environment**

Diplomová práce

Studijní program: Biomedicínské inženýrství

Vedoucí práce: Mgr. Ksenia Sedova, Ph.D.

**Bc. Marek Sokol**

---

**Kladno 2022**

## **Prohlášení**

Prohlašuji, že jsem bakalářskou práci s názvem „Hodnocení kognitivní zátěže v extrémním prostředí“ vypracoval/a samostatně a použil/a k tomu úplný výčet citací použitých pramenů, které uvádím v seznamu přiloženém k bakalářské práci.

Nemám závažný důvod proti užití tohoto školního díla ve smyslu §60 Zákona č.121/2000 Sb., o právu autorském, o právech souvisejících s právem autorským a o změně některých zákonů (autorský zákon), ve znění pozdějších předpisů.

V Kladně .....  
.....  
**Bc. Marek Sokol**

České vysoké učení technické v Praze

Fakulta biomedicínského inženýrství

© 2022 Bc. Marek Sokol. Všechna práva vyhrazena.

*Tato práce vznikla jako školní dílo na Českém vysokém učení technickém v Praze, Fakultě biomedicínského inženýrství. Práce je chráněna právními předpisy a mezinárodními úmluvami o právu autorském a právech souvisejících s právem autorským. K jejímu užití, s výjimkou bezúplatných zákonných licencí a nad rámec oprávnění uvedených v Prohlášení na předchozí straně, je nezbytný souhlas autora.*

## Odkaz na tuto práci

Sokol, Marek. *Hodnocení kognitivní zátěže v extrémním prostředí*. Diplomová práce. Praha: České vysoké učení technické v Praze, Fakulta biomedicínského inženýrství, 2022. Dostupné z: [www.github.com/](https://www.github.com/).

## **Poděkování**

Rád bych poděkoval vedoucí své bakalářské práce, Mgr. Ksenii Sedové, Ph.D. za odborné vedení práce, za pomoc, vstřícnost a rady při zpracování této práce. Dále bych rád poděkoval Ing. et Ing. Janu Hejdovi, Ph.D. za všeestrannou pomoc, množství cenných a inspirativních rad, podnětů a čas, který mi věnoval při řešení dané problematiky. V neposlední řadě děkuji své rodině a všem přátelům, kteří mě při vytváření této práce podpořili.

## **Abstrakt**

**Hodnocení kognitivní zátěže v extrémním prostředí:**

**Klíčová slova**

## **Abstract**

**Assessment of cognitive load in extreme environment:**

**Key words**

# Obsah

<b>Seznam symbolů a zkratek</b>	<b>8</b>
<b>1 Úvod</b>	<b>10</b>
<b>2 Přehled současného stavu</b>	<b>11</b>
2.1 Extrémní prostředí . . . . .	11
2.1.1 Vesmírné explorace . . . . .	12
2.1.2 Analogové mise . . . . .	13
2.1.3 Faktory prostředí a změny CNS . . . . .	15
2.2 Kognitivní neurovědy . . . . .	17
2.2.1 Terminologie . . . . .	17
2.2.2 Kognitivní zátěž . . . . .	18
2.2.3 Fyziologické projevy . . . . .	18
2.2.4 Detekce kognitivní zátěže . . . . .	19
2.3 Neuroviscerální integrace . . . . .	21
2.4 Variabilita srdeční frekvence . . . . .	21
2.4.1 Struktura HRV indexů . . . . .	21
2.5 Periferní biosignály . . . . .	21
2.5.1 Měření biosignálů . . . . .	21
2.5.2 Postupy zpracování . . . . .	21
2.5.3 Elektrodermální aktivita . . . . .	21
2.6 Strojové učení . . . . .	21
2.6.1 Typy systémů strojového učení . . . . .	21
2.6.1.1 Učení s učitelem . . . . .	22
2.6.1.2 Učení bez učitele . . . . .	22
2.6.2 Trénování a testování modelů . . . . .	22
2.6.2.1 Křížová validace . . . . .	23
2.6.2.2 Přeúčení a nedoučení . . . . .	24
2.6.3 Optimalizace hyperparametrů . . . . .	25
2.6.4 Kombinování modelů . . . . .	25
2.6.5 Hodnocení modelů . . . . .	26
2.6.6 Umělé neuronové sítě . . . . .	26
2.6.6.1 Ztrátová funkce . . . . .	27
2.6.6.2 Numerická optimalizace . . . . .	27
2.6.6.3 Aktivační funkce . . . . .	28
2.6.6.4 Regularizace . . . . .	29
<b>3 Cíle práce</b>	<b>31</b>

<b>4 Metody</b>	<b>32</b>
4.1 Projekt Hydronaut . . . . .	32
4.1.1 Mise Diana . . . . .	32
4.1.2 Měření biosignálů . . . . .	32
4.2 Použité technologie a knihovny . . . . .	32
4.2.1 Python a R . . . . .	32
4.2.2 Google Colab a Jupyter Notebook . . . . .	33
4.2.3 Neurokit . . . . .	33
4.2.4 Tidyverse a Easystats . . . . .	33
4.2.5 Scikit-learn, TensorFlow a Keras . . . . .	33
4.2.6 InfluxDB . . . . .	33
4.3 Explorační analýza dat . . . . .	34
4.4 Statistické metody . . . . .	34
<b>5 Výsledky</b>	<b>35</b>
<b>6 Diskuse</b>	<b>36</b>
<b>7 Závěr</b>	<b>37</b>
<b>Bibliografie</b>	<b>38</b>

# Seznam symbolů a zkratek

## Seznam zkratek

Zkratka	Význam
ANN	Umělé neuronové sítě (Artificial Neural Networks)
AURL	Podmořská Výzkumná Laboratoř (Aquarius Undersea Research Laboratory)
CL	Kognitivní zátěž (Cognitive Load)
CLT	Teorie kognitivní zátěže (Cognitive Load Theory)
CNS	Centrální nervová soustava
CSA	Kanadská kosmická agentura (Canadian Space Agency)
CV	Křížová validace (Cross-Validation)
DBSCAN	Hustotní prostorové shlukování aplikací s šumem (Density-Based Spatial Clustering of Applications with Noise)
EDA	Elektrodermální aktivita
EEG	Elektroencefalografie
EFA	Faktorová analýza (Exploratory Factor Analysis)
EKG	Elektrokardiografie
ESA	Evropská kosmická agentura (European Space Agency)
EVA	extravehikulární aktivita
FIU	Mezinárodní Univerzita na Floridě (Florida International University)
fMRI	Funkční magnetická rezonance
GD	Gradientní sestup (Gradient descent)
HDBR	Head-Down Bed Rest
HDBSCAN	Hierarchické hustotní prostorové shlukování aplikací s hlukem (Hierarchical Density-Based Spatial Clustering of Applications with Noise)
HRV	Variabilita srdeční frekvence (Heart Rate Variability)
ICE	Izolované, stísněné a extrémní prostředí (Isolated, Confined and Extreme environment)

Zkratka	Význam
LEO	Nízká oběžná dráha (Low-earth orbit)
ML	Strojové učení (Machine Learning)
MRI	Magnetická rezonance
NASA	Americký Národní úřad pro letectví a vesmír (National Aeronautics and Space Administration)
NEEMO	Operace NASA v extrémním prostředí (NASA Extreme Environment Mission Operations)
NNX0	Počet párů sousedních N–N intervalů, které se od sebe liší o více než Xms (Number of times successive heartbeat intervals exceed Xms)
NPF	Neuropsychofyziologie
PCA	Analýza hlavních komponent (Principal Component Analysis)
pNNX0	Poměr NNX0 k počtu všech N–N intervalů (Proportion of NNX0 divided by the total number of N–N)
RMSSD	Odmocnina průměru umocněných rozdílů po sobě jdoucích N–N intervalů (Root Mean Square of the Successive Differences)
RSP	Respirace
SCR	Odezva kožní vodivosti (Skin Conductance Response)
SWT	Stacionární vlnková transformace (Stationary Wavelet Transform)
TPJ	Temporoparietalní spojení
tSNE	t-distribuované stochastické vkládání sousedů (t-distributed Stochastic Neighbor Embedding)
UMAP	Uniform Manifold Approximation and Projection
ZC	Průchod nuly (Zero Crossing)

# KAPITOLA **1**

---

## **Úvod**

## Přehled současného stavu

Přehled současného stavu je nejprve věnován popisu extrémního prostředí a jeho vlivu na neuropsychofyziologii (NPF) člověka. Dále je na tuto oblast navázáno popisem kognitivní zátěže (CL) v dílké kapitole kognitivních neurověd, která tvoří důležitou část problematiky ročníkového projektu a diplomové práce. Závěr kapitoly je věnován rozboru periferních biosignálů, jejichž znalost a informační obsah jsou nezbytnými kritérii pro hodnocení kognitivní zátěže.

### 2.1 Extrémní prostředí

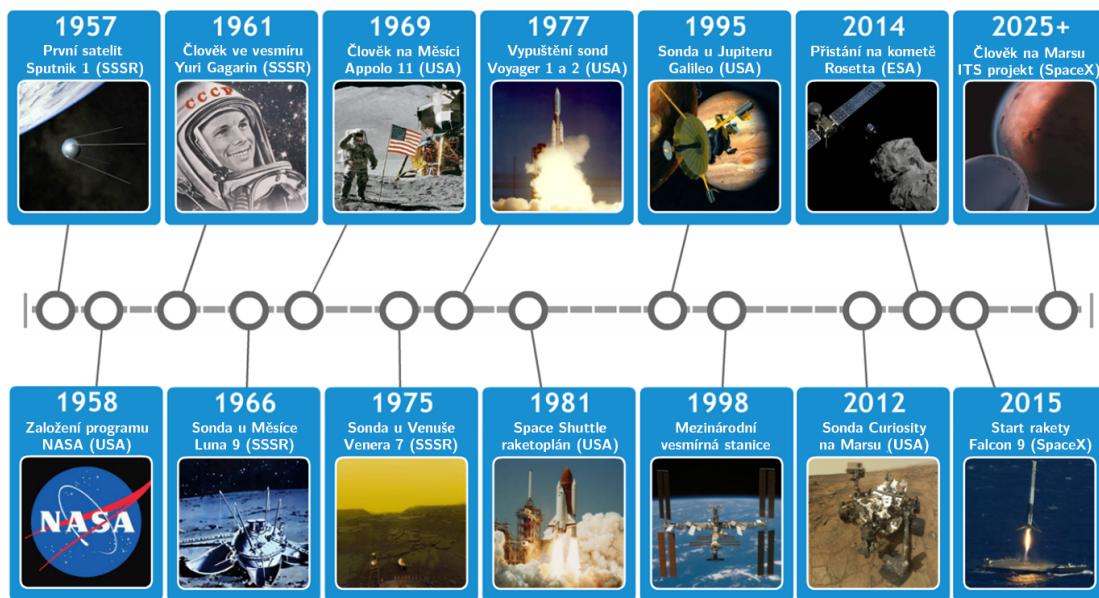
Vzhledem k nejednoznačné definici pojmu „extrémní prostředí“ je potřeba stanovit vhodnou interpretaci v souvislosti s problematikou této práce. Mezi rané definice přispěli Harrison a Connors [1], kteří publikovali, že extrémní prostředí se vyznačuje nebezpečnými a nepřívětivými klimatickými, životními nebo pracovními podmínkami a možnou sociální izolací. Bell et al. [2] definovali extrémní situace jako okolnosti, za kterých má nedostatečný výkon, ať už mentální nebo fyzický, vážné následky (např. časová tíseň, nebo nebezpečí). Všechny tyto koncepty se týkají náročných fyzických nebo mentálních výkonnostních situací, na které se pojí další již formulované pojmy jako krizové situace [3, 4], psychický a fyzický nátlak [5] nebo stres [6]. Další formulace byly již uvedeny v [7–9]. V této práci je na definici extrémního prostředí nahlíženo jako na izolované atypické prostředí, v němž jsou kladený značné nároky na plněné úkoly, které s sebou nesou vysokou míru rizika a katastrofické důsledky při chybném či nedostatečném výkonu.

Současné studie se v rámci tématiky extrémního prostředí často zabývají vlivem izolovaného a stísněného prostředí (ICE, isolated, confined, and extreme) na člověka [9, 10] nebo vlivem různorodých environmentálních podmínek [11–13]. Do výzkumu v této oblasti se začalo aktivně přispívat kolem první poloviny 20. století, což bylo podmíněno vědecko-technologickým pokrokem. Mezi hlavní iniciační milníky patřil vojenský zájem o dlouhodobé ponory jaderných ponorek, na který navázal

podvodní výzkum [14, 15], vznik vesmírných programů (vesmírný závod) a polární výzkum [16, 17]. Pro potřeby této práce je dále detailněji rozebráno extrémní prostředí z hlediska vesmírné explorace, konkrétně dlouhodobých vesmírných letů a analogových vesmírných misí.

### 2.1.1 Vesmírné explorace

Za hlavní hnací historický faktor, který posouval vědeckotechnickou sféru v rámci výzkumu vesmíru rychle kupředu lze považovat tzv. vesmírný závod, jenž začal vypuštěním družice Sputnik 1 Sovětským svazem v roce 1957. Rok poté byl založen Americký Národní úřad pro letectví a vesmír (NASA), což vedlo k prvním vesmírným misím, kterých se později účastnily i posádky. Byl tak vytvořen nový prostor a vzbuzen výzkumný zájem v oblasti analogových vesmírných misí, jelikož otázky ohledně průzkumu vesmíru odhalily spoustu vědomostních nedostatků potřebných pro úspěšný pobyt v kosmu [15]. Nejedná se však ani tolik o technické překážky, ale o nedostatky zejména v oboru neurověd a experimentálního nastavení.



Obrázek 2.1: Časová osa výzkumu vesmíru od Sputniku po Mars (Přeloženo a převzato z [18])

Vzhledem k tomu, že budoucnost výzkumu vesmírné explorace sahá za hranice oběžné dráhy Země [19, 20], je třeba brát v úvahu obtíže budoucích misí, které se budou primárně týkat člověka. Dlouhodobé kosmické lety a mise jsou předmětem mnoha zásadních okolností, jež kladou vysoký a rizikový neuropsychofyziologický nátlak [21]. Extrémní prostředí, komunikační latence a problémy nebo fyziologické změny vlivem vesmírných aspektů [22–24] mohou během dlouhodobých misí překračovat lidské psychické i fyzické hranice a vést ke katastrofickým následkům [21, 25]. Toto riziko se uplatňuje i přestože se v těchto případech skládají posádky

z vybraných trénovaných jedinců (astronautů). Stresory, vnitřní nebo vnější stimuly vznikající při vystavení lidského organizmu mimořádným podmínkám (extrémnímu prostředí) při dlouhodobých vesmírných letech, již popsal Morphew [26]. Zdravotní a výkonnostní rizika lze řešit právě výběrem a výcvikem posádky nebo například návrhem mise a vybavení. Naskytuje se ale také možnost tato rizika predikovat s využitím diagnostických neinvazivních metod, jako funkční magnetická rezonance (fMRI), elektrokardiografie (EKG) aj., spolu s širokými znalostmi lidského nervového systému. Je tedy třeba realizovat experimenty, které pomohou lépe chápout, ne-li přímo definovat NPF vztahy při vlivu extrémního prostředí. Takové experimenty však nemohou probíhat za normálních laboratorních podmínek, jelikož se nejedná o prostředí, které by odráželo skutečné provozní podmínky a účinně napodobilo kosmickou misi [10, 21].

Ke studiu neuropsychofyziologických adaptací člověka vystavenému mikrogravitaci se využívají data zaznamenaná před a po vesmírném letu, kde se také sledují změny jako distribuce tělesných tekutin, hustota kostí nebo úbytek svalové hmoty [27]. Kromě mikrogravitace lze ale mnoho vědeckých otázek týkajících se kognitivních neurověd zodpovědět na Zemi díky vesmírným analogovým misím, které simulují komplexní interakce vznikající během vesmírných misí [10, 21].

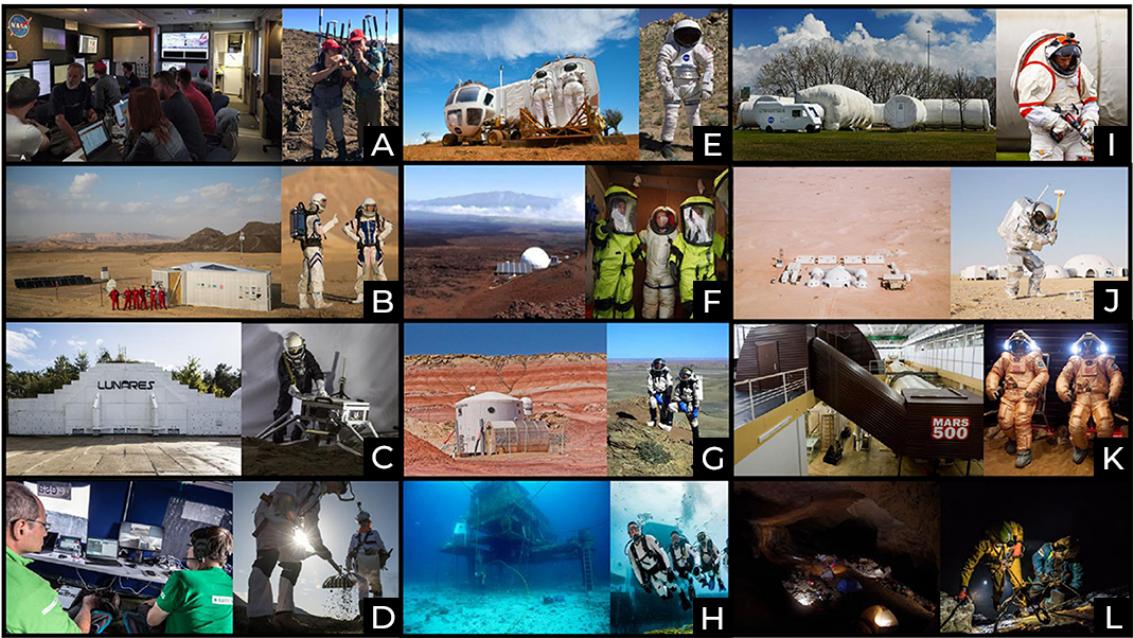
### 2.1.2 Analogové mise

Jak již bylo zmíněno, laboratorní experimenty plně nereprezentují reálné podmínky dlouhodobých kosmických misí, avšak různá analogová prostředí (analogové mise) přinášejí právě tu možnost sledovat a zkoumat NPF člověka v jedinečných situacích [21]. Situace, které napodobují reálné okolnosti budoucích vesmírných misí – přistání kosmické lodi, extravehikulární aktivity (EVA), lékařské zátky aj. – vystavují jedince pozorovatelným změnám například v cirkadiánném<sup>1</sup> rytmu, hladinách stresových hormonů, imunitních funkcích nebo neurokognitivním změnám [10, 11]. Faktory prostředí a jejich vliv na NPF jsou detailněji popsány v následující kapitole.

Přehled několika analogových misí, na jejichž vzniku a vývoji se převážně podílejí: Evropská kosmická agentura (ESA), Státní korporace pro kosmické aktivity (ROSCOMOS), Kanadská kosmická agentura (CSA) a NASA, lze vidět na obrázku 2.2. Každá analogová mise vnikla primárně pro simulaci a studium určitých vlivů vesmírných podmínek nebo k testování specifického vybavení. Antarktické mise slouží k testování astrobiologických hypotéz [21] a studiu dopadů izolace na člověka během extrémních podmínek, které jsou dané drsným polárním podnebím a rozsáhlou tundrou [29, 30]. Významnou misí je projekt Mars-500, kde byla šestičlenná posádka uzavřena 520 dní v napodobenině kosmické lodi pro účely simulace vesmírného letu

---

<sup>1</sup>Cirkadiánní rytmus je biologický rytmus s cyklem trvajícím přibližně jeden den.



**Obrázek 2.2:** Příklady analogových misí. **(A)** NASA BASALT (USA), **(B)** D-MARS (Izrael), **(C)** LUNARES (Polsko), **(D)** ESA/PANGEA (Španělsko), **(E)** NASA/D-RATS (USA), **(F)** HI-SEAS (USA), **(G)** Mars Desert Research Station (USA), **(H)** NASA/NEEMO (USA), **(I)** NDU Habitat (USA), **(J)** OeWF/AMADEE-program (Rakousko, Omán), **(K)** Mars-500 (Rusko), **(L)** ESA/CAVES (Španělsko/Itálie). (Upraveno a převzato z [28])

na Mars. Během této mise došlo k řadě experimentů, které se například zabývaly vlivem fyzického cvičení na aktivitu prefrontální kortextu a kognitivní výkonnost [31] nebo změnami nálady a plazmatických hladin hormonů [32]. Na základě problematiky této práce jsou nadále popsány vybrané podvodní analogové mise.

### Projekt NEEMO

Operace NASA v extrémním prostředí neboli NEEMO (NASA Extreme Environment Mission Operations) jsou analogové vesmírné mise, které probíhají v Mezinárodní Univerzitní Podmořské Výzkumné Laboratoři na Floridě (Florida International University's Aquarius Undersea Research Laboratory, FIU AURL). Podvodní laboratoř s rozlohou zhruba  $43\text{ m}^2$ , umístěná 19 m pod mořskou hladinou přesně nenapodobuje vesmírné podmínky ale stresové faktory spojené s bezpečností, komunikací a technologickou logistikou při dlouhodobých kosmických letech a průzkumu ano. Zároveň zde probíhají testy vybavení a trénování výstupu do vesmíru mimo kosmickou loď [33, 34]. Poslední mise v podvodní laboratoři, NEEMO 23, proběhla v červnu 2019 a byla primárně zaměřena na průzkumné výstupy do vesmíru.

### Projekt Hydronaut

Skromnější verze mobilního podvodního habitatu vznikla i v České Republice za účelem výcviku astronautů Evropské kosmické agentury. Projekt byl představen



**Obrázek 2.3:** Podvodní habitat AURL [35]



**Obrázek 2.4:** Hydronaut H03 DeepLab [36]

roku 2010 a jeho primárním cílem bylo umožňovat menším posádkám dlouhodobý pobyt v hyperbarickém ICE prostředí a simulaci vesmírných scénářů pro potřeby výzkumu. Podvodní stanice Hydronaut je také plně mobilní a lze měnit její umístění. Současná stanice (H03 DeepLab) je vybavena několika systémy pro sledování stavu habitatu a posádky. Jedním ze systémů je Common Tongue, který umožňuje nejen komunikaci s posádkou ale také sledování fyziologických funkcí. V roce 2020 proběhla desetidenní mise (Mission One), která včetně účelu kosmického ICE výzkumu sloužila jako zátěžový test habitatu [37].

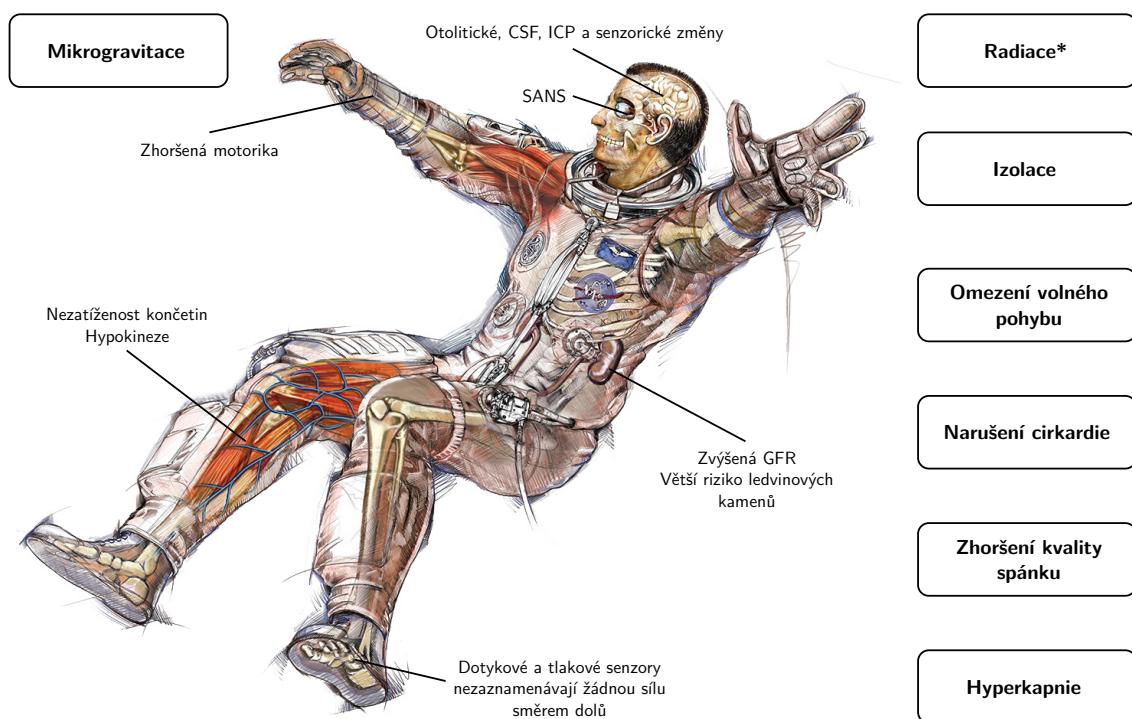
### 2.1.3 Faktory prostředí a změny CNS

Vzhledem k tomu, že vesmír je jedinečné prostředí, je studium změn CNS člověka souvisejících s kosmickými misemi obtížné. Předchozí studie ukázaly, že po letu do vesmíru dochází ke změnám ve vnímání, pohybu, koordinaci a kognici [38]. Mikrogravitace je jedním z hlavních faktorů, které ovlivňují mozek včetně kosmického záření (radiace), izolace nebo hyperkapnie [24]. Důsledky působení mikrogravitace na mozek popsal Torre v [39]. Souhrn faktorů lze vidět na Obrázku 2.5 a jejich počet nasvědčuje, že pozorované NPF změny u astronautů mohou být důsledkem kombinace více stresorů na jednotlivé oblasti mozku [24].

Nedávné MRI studie poukázaly na změny polohy mozku, objemu tkáně, objemu mozkových komor, distribuce a dynamiky mozkomíšního moku, mikrostruktury tkáně a funkční konektivity po letu do vesmíru [40–44]. Přehled MRI studií provedených na amerických astronautech a ruských kosmonautech před a po kosmickém letu se zjištěnými poznatkami byl vypracován v [24]. Mezi tyto studie jako jeden z prvních přispěl Demertzis et al. [43] s objevem snížené konektivity v pravé insule<sup>2</sup>, který se podílí na vestibulárním zpracování a kognitivní kontrole.

<sup>2</sup>Insula neboli insulární kortex je složitá struktura s rozsáhlou sítí korových a podkorových oblastí mozku, které slouží smyslovým, emočním a kognitivním funkcím.

Neurozobrazovací studie na zvířecích modelech a lidech vystavených analogovým vesmírným letům prokázaly změny mozku související s reálným kosmickým letem [44, 45]. Analogové vesmírné mise nacházejí tedy uplatnění při zkoumání vlivů stresorů spojených s vesmírným prostředím na centrální nervovou soustavu (CNS). Při srovnání změn CNS souvisejících s kosmickou misí se změnami pozorovanými u pozemských analogů se naskytuje příležitost do budoucna navrhnout strategie a opatření, které by předcházely nežádaným NPF účinkům. Během analogových misí se podařilo reprodukovat například zjištění spojené se změnami mozkové konektivity, objemu šedé hmoty, dynamiky mozkomíšního moku a objemu mozkových komor [24]. Metoda, která věrně napodobuje podmínky kosmických letů vystavováním subjektů posunu tělních tekutin, odlehčení axiálního tlaku nebo hypokinezi, se nazývá Head-Down Bed Rest (HDBR). Subjekt je během metody na lůžku hlavou dolu, pod určitým náklonem. HDBR zároveň vyvolává podobné změny v mozkové konektivitě, včetně změny konektivity motorických, somatosenzorických a vestibulárních oblastí mozku jako při vesmírných letech [46, 47].



**Obrázek 2.5:** Souhrn stresových faktorů vesmírného ICE prostředí, které mohou ovlivnit mozek během kosmického letu. Radiace\* v tomto případě odkazuje na radiaci v otevřeném kosmickém prostoru, nikoli na nízké oběžné dráze (LEO). (Upraveno a převzato z [24, 48] se souhlasem Beaua Danielse)

Mozek je kromě fyziologických stresorů ovlivněn také dlouhodobým pobytom v ICE prostředí. Po 520denní misi Mars-500 ukázaly snímky participantů pozměněnou mikrostrukturu šedé hmoty v pravém temporoparietalním spojení<sup>3</sup> (TPJ), což je

<sup>3</sup>Temporoparietalní spojení je část mozku, kde se setkávají spánekový a temenní lalok.

přisuzováno vlivu izolovaného prostředí [49]. Během dlouhodobých vesmírných misí mohou mít změny TPJ za následek zhoršení neuropsychofyziologické adaptace člověka na nové ICE prostředí. Další nežádoucí změny byly prokázány v rámci studií antarktických expedic, které demonstrovali snížení objemu šedé hmoty v orbitofrontální kůře, prefrontální kůře a hipokampusu. Vzhledem k povaze antarktického prostředí a expedic lze usuzovat, že jsou tyto změny podmíněné také vlivem ICE [50]. Možné snížení neurogeneze hipokampusu vlivem extrémního prostředí může mít vliv na paměť a sociální interakci členů posádky [24]. Délka kosmické mise či letu také hráje rozdíl, jelikož větší míra změn struktury mozku byla pozorována u dlouhodobých vesmírných misí [42].

## 2.2 Kognitivní neurovědy

Lidský mozek je schopen se neustále přizpůsobovat měnícím se okolnostem a požadavkům prostředí. Astronauti se musí aklimatizovat na zcela nové prostředí podobně jako malé děti procházejí svými vývojovými fázemi. V podmírkách stavu beztíže nebo mikrogravitace dochází mimo jiné k ovlivnění mozkových procesů. Cílem kognitivních neurověd ve vesmíru je pochopit, jak mozek a mysl reagují na tyto jedinečné okolní podmínky. První výzkumy v oblasti neurověd ve vesmíru byly provedeny v roce 1962 během ruské mise Vostok-3. Na Zemi je oproti vesmíru možné díky neurozobrazovacím technikám snadno studovat mozkovou aktivitu a kognitivní funkce. Pro neurovědce i psychology je velmi důležité pochopit základní neurokognitivní a neuropsychologické aspekty kosmického letu. Neefektivní mentální výkon jedince či posádky je známou hrozbou pro vesmírné mise. Pozemský výzkum zdůrazňuje nutnost porozumět kognitivním procesům, jelikož CL zhoršuje kognitivní a percepční motorické schopnosti. Srovnatelné dopady lze předpokládat i při vesmírných misích v náročných ICE podmírkách a simulacích (analogové mise) [39]. Pro potřeby diplomové práce je rozsáhlá kapitola kognitivních neurověd vymezena popisem kognitivní zátěže.

### 2.2.1 Terminologie

Obor kognitivních neurověd se nachází na pomezí psychology a neurověd, ale překrývá se s dalšími obory jako kognitivní a biologická psychology, fyziologie nebo neuropsychologie. Tyto obory často studují podobné procesy ale z jiného pohledu a pomocí jiné metodiky. Synonymem oblasti kognitivních neurověd byl v této práci zvolen termín neuropsychofyziologie pro usnadnění popisu fyziologických změn v důsledku kognitivních procesů. Cílem této práce není rozlišovat mezi jednotlivými obory ale zaměřit se na vědecké otázky z jejich průniků, které jsou spojené s vlivem ICE prostředí na člověka.

## 2.2.2 Kognitivní zátěž

Prvotní pojetí kognitivní zátěže (CL, Cognitive Load) pochází z oblasti výuky a vzdělávání, kterou se intenzivně zabýval Sweller et al. [51–53] kolem přelomu 19. a 20. století. Sweller [51] jako první formuloval teorii kognitivní zátěže (CLT, Cognitive Load Theory), podle které je CL definována jako zvýšené požadavky na ukládání a zpracování informací v pracovní paměti člověka. Chen et al. [54] definoval kognitivní zátěž jako proměnnou, jež určuje míru požadavků kladených úkolem na dostupné mentální zdroje pro zpracování informací. Míra požadavků vychází z vnímané námahy při učení, myšlení a uvažování jakožto ukazatele zatížení pracovní paměti během plnění úkolu. Tato míra zároveň popisuje interakce mezi nároky na zpracování úkolu a lidskou mentální výkonností [55]. Ačkoli se definice kognitivní zátěže v jednotlivých oborech mohou lišit, všechny mají jeden základní prvek: procento využité kapacity lidské pracovní paměti. Na rozdíl od naší smyslové a dlouhodobé paměti, které mohou v podstatě neomezeně zpracovávat informace, je tato kapacita omezená [56].

Chen et al. [54] publikoval, že vysoká kognitivní zátěž (kognitivní přetížení) může mít negativní dopad na výkonnost pracovní paměti. Vliv kognitivní zátěže zároveň ovlivňuje mozkové procesy a kognitivní přetížení pravděpodobně bezprostředně předchází vyhoření [56]. Většina kognitivních funkcí, jako je například selektivní pozornost nebo sebekontrola, závisí na pracovní paměti. Pracovní paměť zahrnuje aktivní krátkodobé ukládání, zpracování a manipulaci s informacemi a její efektivní fungování je kriticky závislé na inhibičních nervových procesech. Nervové středisko pracovní paměti sestává hlavně z distribuované sítě struktur zahrnující prefrontální kortex jako důležité ohnisko. Variabilita srdeční frekvence (HRV) souvisí s aktivitou prefrontální kůry a je inverzně spojena s aktivitou subkortikálních struktur jako je amygdala [57]. Vliv kognitivní zátěže se také promítá do elektrodermální (EDA) a respirační (RSP) aktivity [21]. Díky periferním biologickým signálům se tedy naskytuje jednoduší možnost hodnocení či predikce kognitivních procesů bez nutnosti použití realizačně a finančně náročnějších neurozobrazovacích metod nebo elektroencefalografie (EEG). Detailněji jsou fyziologické změny spojené s vlivem CL popsány v následující sekci.

## 2.2.3 Fyziologické projekty

Z předchozího textu již může být zřejmé, že kognitivní zátěž je velmi úzce spojená s fyziologickými změnami v lidském organismu. U jedince, kde dojde k stimulaci CL, může docházet k řadě změn, například v mozkové aktivitě, krevním tlaku, srdečním rytmu, rychlosti pulzní vlny, dýchaní nebo činnosti potních žláz [55–60]. Vybrané fyziologické funkce, do kterých se po promítá kognitivní zátěž, jsou společně s jejich krátkým popisem a neurobiologickým vztahem uvedeny v Tabulce 2.1. Tabulka zároveň poukazuje na rozdílné vztahy fyziologických parametrů s kognitivní zátěží.

**Tabulka 2.1:** Přehled vybraných nejčastěji studovaných fyziologických změn a stručné teoretické zdůvodnění jejich souvislosti s kognitivní zátěží (Upraveno a převzato z [56])

Fyziologická funkce	Stručný popis a teoretické zdůvodnění předpokládaného vztahu mezi fyziologickým měřením a kognitivní zátěží
EEG	<i>Popis:</i> EEG umožnuje měřit mozkovou aktivitu neinvazivně. Provedení spektrální analýzy naměřených rozdflů elektrických potenciálů umožnuje analyzovat výkon různých frekvenčních pásem, která jsou v signálu <i>Hypotéza:</i> Zvýšení kognitivní zátěže lze měřit zvýšením mozkové aktivity, tj. oscilací v určitém frekvenčním pásmu s větší amplitudou [61]
Eye-tracking	<i>Popis:</i> Měření průměru zornice, latence mrknutí a charakteristik sakád <i>Hypotéza:</i> Sledování očí bylo v předchozích studiích spojeno s kognitivní zátěží prostřednictvím neurobiologických mechanismů, jako je inervace neuronů autonomního nervového systému radiálními vlákny duhovky [62]
EDA	<i>Popis:</i> Elektrodermální aktivita, hodnotí elektrické charakteristiky kůže, aby bylo možné odvodit změny vlivem sympatického nervového systému. <i>Hypotéza:</i> Kognitivní zátěž má vliv na stres nebo vzrušení a vede ke zvýšení kožní vodivosti [63]
Teplota pokožky	<i>Popis:</i> Měření teploty vnějšího povrchu lidského těla <i>Hypotéza:</i> Kognitivní zátěž má vliv na stres nebo vzrušení a vede k vazokonstrikci, což snižuje teplotu kůže [64]
EKG	<i>Popis:</i> Srdeční frekvenci a variabilitu srdeční frekvence lze hodnotit pomocí elektrokardiogramu nebo fotopletysmografie <i>Hypotéza:</i> Tepová frekvence je měřítkem aktivity sympatického i parasympatického autonomního nervového systému. Stres nebo vzrušení způsobí zvýšení krevního tlaku a snížení variabilnosti srdeční frekvence [65, 66]
RSP	<i>Popis:</i> Kognitivní zátěž vede ke zrychlenému dýchání a vyšší minutové ventilaci, přičemž dechová amplituda zůstává stejná <i>Hypotéza:</i> Při soustředění pozornosti nebo plnění náročného úkolu dochází ke změnám v dýchání [67]

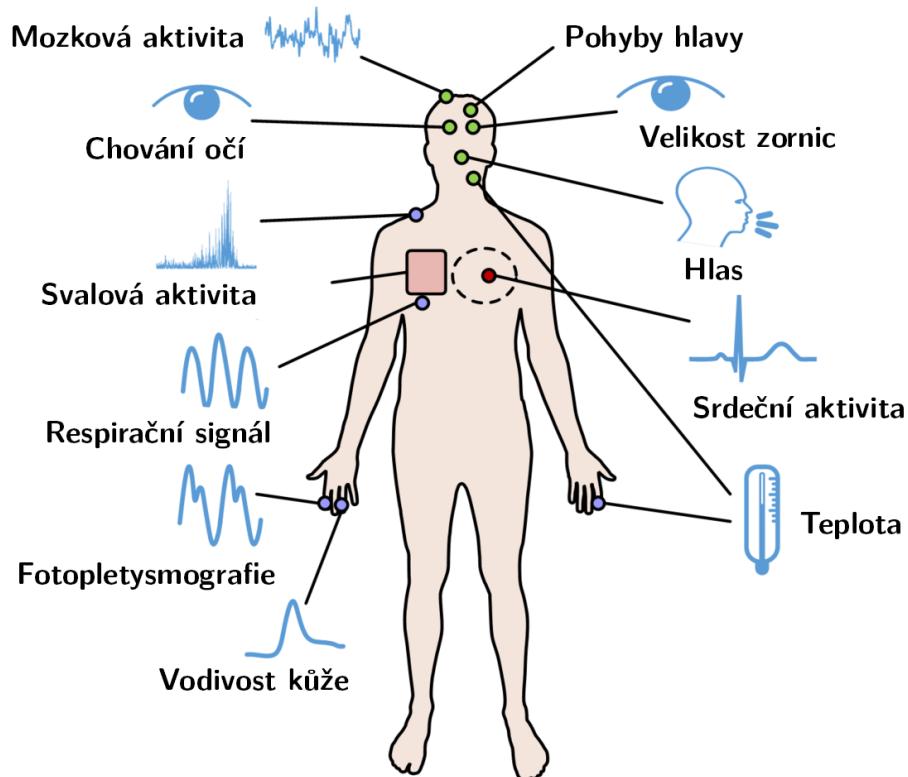
Příkladem rozdílností může být EEG, u kterého je vztah s kognitivní zátěží přímější než u srdeční nebo elektrodermální aktivity. Hodnocení pomocí tohoto biosignálu je tedy v některých případech spolehlivější. Pouze v některých, protože se vychází z předpokladu, že veškeré změny v kognitivních funkcích člověka se odrážejí v jeho fyziologii [56]. To znamená, že žádná měřicí technika nemůže sama o sobě zachytit všechny aspekty kognitivních funkcí nebo o nich jednoznačně vypovídат. Problematika těchto vztahů je nadále rozebírána v kapitolách 2.2.4 a 2.3. Na tuto vícerozměrnou povahu kognitivní zátěže poukázal Kramer et al. [68]. Dále definoval kritéria: citlivost, diagnostičnost, rušivost, spolehlivost a obecnost použití, v rámci kterých bude mít každé fyziologické měření jinou povahu. V případě kognitivní zátěže a její spolehlivém hodnocení z fyziologických projevů je proto vhodný multimodální<sup>4</sup> přístup, který může poskytnout její robustnější reprezentaci [54].

## 2.2.4 Detekce kognitivní zátěže

Detekce kognitivní zátěže pomocí periferních biosignálů patří mezi tři nejčastěji používané způsoby včetně subjektivního hodnocení a hodnocení založené na výkonnosti

<sup>4</sup>Multimodálním přístupem je myšleno využití více biosignálů

jedince. Subjektivní hodnocení vychází z předpokladu, že hodnocený subjekt je schopen vnímat své vlastní kognitivní procesy a informovat o případně kognitivní zátěži nebo o množství vynaloženého mentálního úsilí [69, 70]. K subjektivnímu hodnocení se dále využívají specifické dotazníky, mezi které patří například NASA-TLX [70]. Jedná se o vícerozměrnou stupnici používanou k měření pracovní zátěže operátorů v rámci úkonů, například během vesmírných analogových misí [71]. Tyto metody ale nejsou předmětem této práce a již byly detailně popsány v [70].



Obrázek 2.6: Vybrané proměnné související s CL (Přeloženo a převzato z [72])

Na kognitivní zátěž lze nahlížet jako na multidimenzionální konstrukt, který reprezentuje zátěž vyvinutou na jedince [69]. Zároveň se efekt stimulace kognitivních funkcí u každého jedince projevuje jinak. Nelze tedy vytvořit žádnou univerzální metodu, která by byla schopná stejně spolehlivě detekovat kognitivní zátěž u různých subjektů. Proto se v tomto odvětví nabízí a velmi často využívají metody strojového učení v rámci kterých nachází výhodné uplatnění dříve zmíněný multimodální přístup. Biologická data využívaná pro účely detekce CL lze vidět na Obr. 2.6. Nejčastěji využívaným biosignálem je srdeční aktivita, konkrétně variabilita srdeční frekvence, které se často používá v kombinaci s elektrodermální aktivitou [69].

Z variability srdeční frekvence je však v současnosti možné vypočítat desítky parametrů, se kterými je v těchto úlohách nutné velmi opatrně zacházet. Jednotlivé HRV parametry společně s jejich pravděpodobným významem byly již popsány v [55, 73–75]. Blíže je problematika HRV parametrů popsána v samotné podkapitole 2.4.1.

## 2.3 Neuroviscerální integrace

## 2.4 Variabilita srdeční frekvence

### 2.4.1 Struktura HRV indexů

## 2.5 Periferní biosignály

### 2.5.1 Měření biosignálů

### 2.5.2 Postupy zpracování

### 2.5.3 Elektrodermální aktivita

## 2.6 Strojové učení

Strojové učení (anglicky Machine Learning, ML) představuje odvětví umělé inteligence, které se zaměřuje na vytváření matematických modelů a zvýšení jejich výkonu pomocí využití předchozích zkušeností. Tyto zkušenosti se získávají z dostupných historických dat (trénovacích dat), která se využívají k formulaci pravidel a identifikaci charakteristických rysů nebo vztahů v datech. Proces učení zahrnuje techniky, které vyplývají z oborů informatiky, statistiky, pravděpodobnosti nebo optimalizace. Využití algoritmů strojového učení se neustále rozšiřuje v mnoha oblastech díky rostoucí dostupnosti online dat a snižování nákladů na výpočetní zdroje. Rozsah oblastí použití zahrnuje široké spektrum oborů, včetně zdravotnictví.

Tato kapitola slouží jako úvod do vybraných základních pojmu strojového učení s cílem vytvořit teoretický náhled pro podporu pochopení problematiky v korespondujících částech práce. Detailněji byly principy a náležitosti strojového učení již popsány v literatuře [76–78].

### 2.6.1 Typy systémů strojového učení

Různorodost scénářů strojového učení je charakterizována rozdíly v povaze trénovacích dat, způsobu trénování a kritériích hodnocení. Každý přístup je vhodný pro řešení určité kategorie problémů a představuje své vlastní charakteristické výhody a omezení. V následujících podkapitolách jsou rozebrány primárně dvě nejrozšířenější formy přístupů k učení, tj. učení s učitelem (anglicky Supervised Learning) a učení bez učitele (anglicky Unsupervised Learning).

### 2.6.1.1 Učení s učitelem

Učení s učitelem je typ strojového učení, během kterého se využívají právě taková trénovací data, která mají anotovanou výstupní proměnnou. Úkolem je zde approximovat mapovací funkci  $h$ , která predikuje výstupní proměnnou na základě vstupní proměnné  $X$ . K approximaci mapovací funkce jsou použita označená trénovací data, která se skládají z  $n$  párů vstupních a výstupních proměnných. Cílem je získat přesné predikce jak pro trénovací, tak pro úplně nová data. Formálně lze tedy tvrdit, že hledáme funkci:

$$h : \mathbb{R}^d \rightarrow \mathcal{C} \quad (2.1)$$

tak, že pro každou novou dvojici vstupu a výstupu  $(x, y)$  vybranou z  $\mathcal{P}$  platí  $h(X) \approx y$ , kde  $\mathbb{R}^d$  je  $d$ -rozměrný příznakový prostor a  $\mathcal{C}$  je prostor všech možných anotací. Zároveň předpokládáme, že tyto dvojice pocházejí z neznámého rozdělení  $\mathcal{P}$  [77].

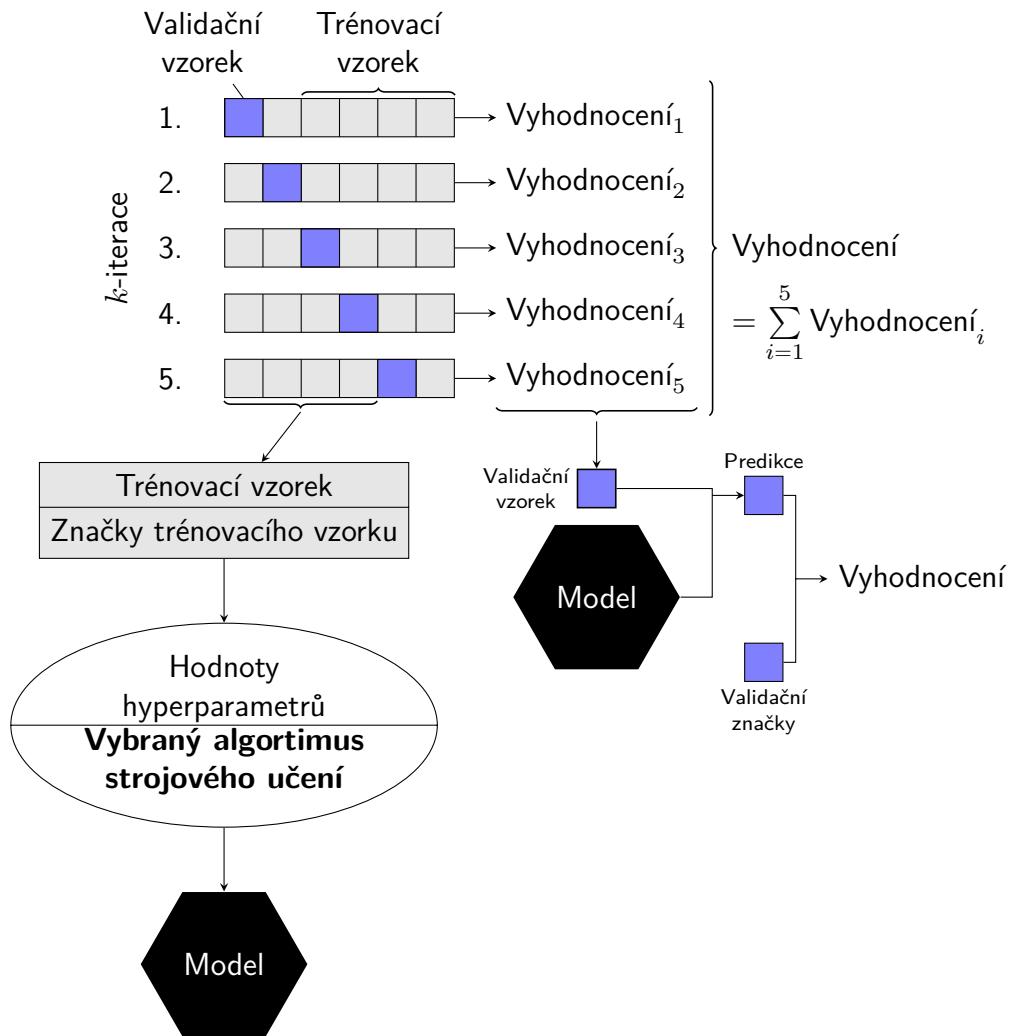
### 2.6.1.2 Učení bez učitele

Cílem učení bez učitele je najít vzory v neanotovaných datech bez definovaného výstupu. Výsledkem tohoto typu učení mohou být struktury nebo vztahy v datech. Vyhodnocování výkonu natrénovaného modelu je v tomto případě, bez označených dat, často náročné. Běžnou úlohou pro tento typ učení je shlukování, které seskupuje podobné data do shluků. Shlukování se používá například pro segmentaci obrazových dat a provádí se pomocí algoritmů, jako je hustotní prostorové shlukování (DBSCAN) nebo k-means.

## 2.6.2 Trénování a testování modelů

Vyhodnocování modelů strojového učení je pro jejich úspěšnost klíčové. Aby bylo zajištěno, že model dokáže efektivně predikovat i nová data, nikoli pouze data využita během jeho trénování, provádí se tzv. *train-test* rozdělení. To zahrnuje ponechání části dat jako testovací množiny, kterou model během trénování nepoužil, a její následné použití k vyhodnocení schopnosti modelu generalizace porovnáním jeho predikce se skutečnými hodnotami.

Běžně se využívá rozdělení trénovací a testovací množiny v poměru 80:20 z náhodně vybraných dat. Dále se někdy využívá validační množina (15-20 % trénovací množiny) pro účely ladění hyperparametrů. Nejúspěšnější model se na základě validační množiny natrénuje pomocí nalezených hyperparametrů. Nakonec se model vyhodnotí na dosud nevyužité testovací množině. Hyperparametry a jejich optimalizace jsou rozebrány v samostatné podkapitole 2.6.3.



**Obrázek 2.7:** Obecné schéma procesu trénování modelu a optimalizací hyperparametrů s využitím k-násobné křížové validace [79]

### 2.6.2.1 Křížová validace

Přístup rozdělení dat z předchozí sekce je efektivní, ale opomíjí jeden problém: existuje mnoho možných kombinací trénovací a testovací sady a tato metoda zkoumá pouze jednu. Data mohla být tedy náhodně rozdělena nereprezentativním způsobem. Odpověď na tento problém je křížová validace (anglicky cross-validation, CV), která eliminuje závislost na rozdělení dat. Cílem křížové validace je vyhodnotit a porovnat výkon různých modelů na stejném datovém souboru a najít tak optimální nastavení hyperparametrů pro daný model.

Křížová validace se skládá ze tří hlavních kroků: rozdělení datového souboru na  $k$  částí, trénování modelu na  $k - 1$  částech dat a vyhodnocování výkonu modelu na zbyvající (validace) části dat. Tyto kroky se opakují  $n$  krát, přičemž každá část dat se použije jednou jako validace. Výsledkem křížové validace je průměrný výkon modelu na všech  $k$  částech validace. Existuje celá řada způsobů provedení křížové

validace: K-Fold, Leave One Out (LOO), Stratified Shuffle Split, Leave P Groups Out, a další, které byly již popsány v [76].

Křížová validace má řadu výhod oproti jiným metodám optimalizace hyperparametrů, jako je například mřížkové nebo náhodné vyhledávání popsané v dalších kapitolách. Mezi tyto výhody patří:

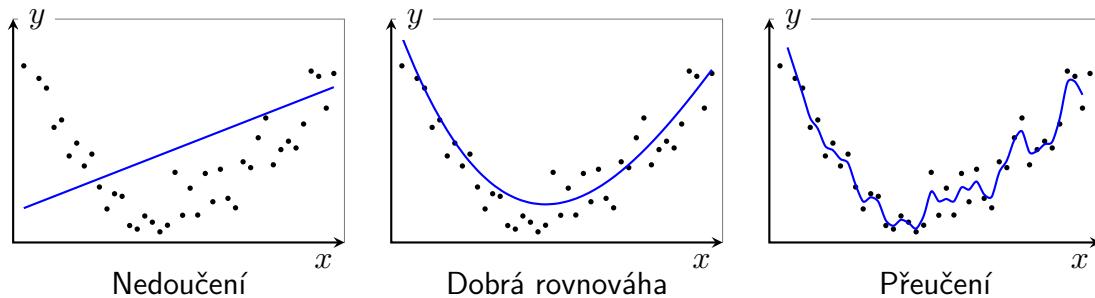
- Objektivní hodnocení výkonu modelu na stejných datech [80].
- Minimalizace rizika přeúčení [81].
- Efektivní využití všech dat k hodnocení výkonu modelu [82].

V praxi se křížová validace často používá pro optimalizaci hyperparametrů nejen jednoho, ale i více modelů současně a následně porovnání jejich výkonu.

### 2.6.2.2 Přeúčení a nedoučení

Přeúčení (anglicky overfitting) a nedoučení (anglicky underfitting) jsou dva hlavní problémy, které se mohou vyskytnout při trénování modelů strojového učení. Tyto problémy ovlivňují schopnost modelu generalizovat na nová data, což způsobuje snížení jeho přesnosti.

K přeúčení dochází, když model příliš pečlivě přizpůsobuje svůj výstup trénovacím datům a nezachycuje skutečné vztahy v datech. Vzniká tak velmi složitý model, což vede k vyššímu rozptylu a snížené vypořídací schopnosti. Přeúčení je charakterizováno výrazným rozdílem mezi výkonností modelu na trénovací a testovací množině, známým jako generalizační mezera (anglicky Generalization Gap). Tento rozdíl je způsoben vysokou schopností modelu zapamatovat si specifické detaily trénovacích dat, místo aby zachycoval požadované vzorce [83].



**Obrázek 2.8:** Příklad nedoučeného modelu s vysokým biasem vlevo, přeúčeného modelu s vysokým rozptylem vpravo a dobře přizpůsobeného modelu uprostřed [84]

Těmto problémům lze předcházet různými způsoby, například:

- Použití vhodných metod regularizace (např. L1 nebo L2 regularizace).

- Použití vhodného algoritmu strojového učení (např. kNN má tendenci k nedoučení, zatímco složité modely jako např. neuronové sítě k přeúčení).
- Použití CV k hodnocení výkonu modelu a optimalizaci hyperparametrů.
- Zvýšení počtu trénovacích dat.

### 2.6.3 Optimalizace hyperparametrů

Ve strojovém učení jsou hyperparametry (HP) nastaveny před trénováním a nejsou určeny učícím algoritmem. Tyto parametry musí být zadány jako vstupy a jejich určení může být stěžejním faktorem, protože různé problémy vyžadují různé přístupy. Proces hledání optimální konfigurace modelu se označuje jako optimalizace hyperparametrů (HPO).

Metoda vyhledávání v mřížce (anglicky Grid Search Method), je běžným způsobem optimalizace hyperparametrů. Definuje sadu diskrétních hodnot pro každý hyperparametr a pro každou kombinaci vyhodnocuje ztrátovou funkci modelu. Za optimální je považována konfigurace s nejnižší validační ztrátou. Počet vyhodnocení však rychle roste s počtem hyperparametrů, tudíž je tato metoda vhodná pouze pro jednoduché modely, u nichž není trénování a hodnocení výpočetně náročné [85].

Alternativou k mřížkovému vyhledávání je náhodné vyhledávání (anglicky Random Search Method). Namísto úplného vyhodnocení všech kombinací jako v předešlé metodě kontroluje pouze určitý počet náhodných vzorků z hyperparametrického prostoru. Tato metoda je efektivnější než prohledávání v mřížce, přičemž poskytuje srovnatelné výsledky [85–87]. Existují i další způsoby HPO mezi které se řadí například bayesovská optimalizace, genetické algoritmy nebo využití neuronových sítí. Jejich využití přichází v úvahu zejména u vysokodimenzionálních problémů [85, 88].

### 2.6.4 Kombinování modelů

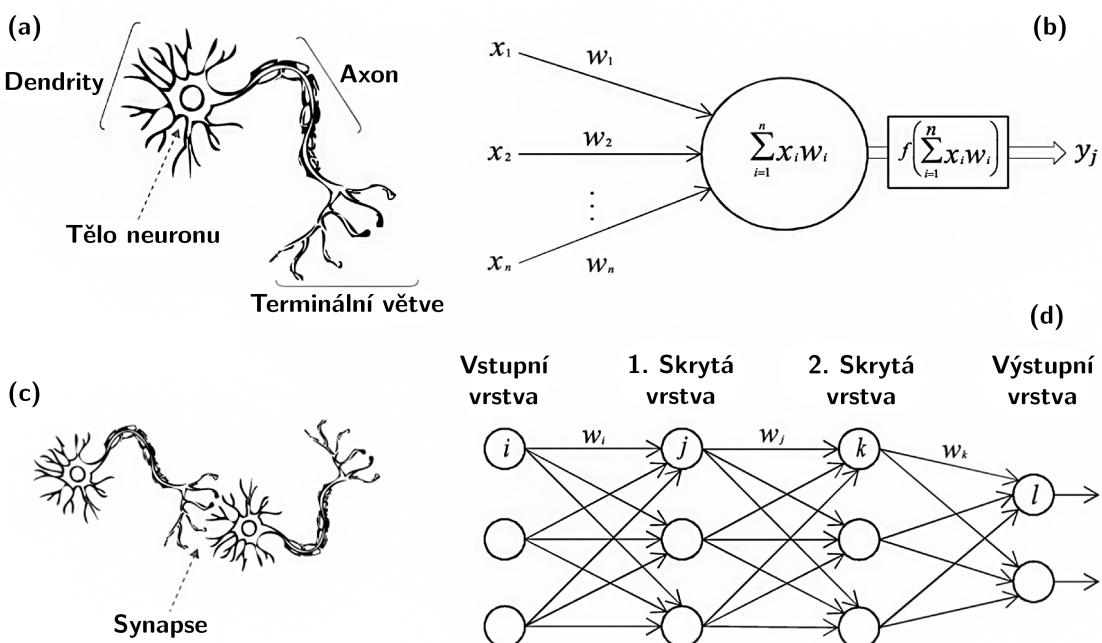
Kombinované modely (anglicky Ensemble Models) skládají předpovědi z více různých základních modelů, aby se zvýšila přesnost predikce. Toho lze dosáhnout zprůměrováním predikce u regrese nebo výběrem nejčastější predikce u klasifikace. Váhu předpovědi každého základního modelu lze upravovat na základě jeho individuální přesnosti. Klíčovým faktorem úspěchu kombinovaných modelů je různorodost a nezávislost základních modelů, které lze dosáhnout pomocí různých trénovacích dat, hyperparametrů nebo algoritmů. Ačkoli tomu tak není vždy, četné studie ukázaly, že kombinované modely často dosahují lepších výsledků než jednotlivé základní modely [89].

## 2.6.5 Hodnocení modelů

K hodnocení modelu lze použít různé metriky v závislosti na dané úloze. Vyhodnocování natrénovaného modelu je klíčovým aspektem procesu strojového učení. Vzhledem k tomu, že se tato práce zabývá především úlohou klasifikace učení s učitelem, nebudou zde popsány všechny hodnotící metriky. Vybrané a použité metriky jsou blíže popsány v samotných metodách, v kapitole ??.

## 2.6.6 Umělé neuronové sítě

Umělé neuronové sítě (anglicky Artificial Neural Networks, ANN) jsou významným nástrojem pro strojové učení a jsou často používány pro řešení složitých úloh, jako jsou klasifikace, regrese, segmentace obrazu a jazykové zpracování. Jedná se výpočetní modely, který napodobují strukturu biologických neuronů. Stejně jako biologické neurony zpracovávají ANN vstupy, přenášejí impulsy a vytvářejí výstupy na základě aktivačních funkcí. Učení probíhá upravováním ANN vah spojení mezi neurony pomocí optimalizačních algoritmů.



**Obrázek 2.9:** Biologický neuron ve srovnání s umělou neuronovou sítí: **(a)** lidský neuron; **(b)** umělý neuron; **(c)** biologická synapse; a **(d)** synapse ANN. (Upraveno a převzato z [90])

V průběhu let se ANN významně rozvinuly a byly použity k řešení široké škály úloh. Dnes hrají umělé neuronové sítě klíčovou roli v různých akademických i komerčních aplikacích při řešení problémů, které jiné metody nezvládají. Historie a základní koncepty ANN, mezi které patří například perceptrony nebo zpětná propagace a gradientní sestup byly již rozebrány v [76–78].

### 2.6.6.1 Ztrátová funkce

Začátkem této podkapitoly o strojovém učení (viz 2.6.1.1) byla definována funkce  $h$ , před jejímž hledáním je potřeba učinit předpoklad o jaký typ funkce se jedná (lineární, polynomická, aj.). Tímto předpokladem vzniká vymezení na určitý prostor hypotéz, označovaný  $\mathcal{H}$ , které velmi ovlivňuje generalizaci.

S vymezením přichází na řadu ztrátová funkce  $L : \mathcal{H} \rightarrow \mathbb{R}$ , jež přiřazuje ztrátu každému  $h \in \mathcal{H}$ . Ztrátu si lze představit jako číslo, které vypovídá o tom jak přesně je nalezená  $h$  approximována vzhledem k použitým datům. Se ztrátovou funkcí tak vzniká nový optimalizační problem:

$$\arg \min_{h \in \mathcal{H}} L(h) = \arg \min_{h \in \mathcal{H}} \frac{1}{n} \sum_{i=1}^n l(\mathbf{x}_i, y|h) \quad (2.2)$$

kde  $L$  je ztráta pro danou  $h$  v rámci používaných dat a  $l$  je ztráta pro dvojici vstupu a výstupu při dané  $h$ . Díky takovému způsobu hodnocení je umožněno modelu se učit. Existuje řada ztrátových funkcí, jejichž použití závisí na typu problému (regrese, klasifikace, aj.). Tyto funkce společně s detailnějším popisem optimalizačního problému již byly popsány v [77].

### 2.6.6.2 Numerická optimalizace

Obecně je numerická optimalizace technika, která se používá k nalezení optimálního řešení výpočetně náročných problémů. Ve strojovém učení se numerická optimalizace často používá k optimalizaci parametrů modelu. V rámci ANN se k optimalizaci vah spojení mezi neurony běžně využívá gradientní sestup (GD) v různých podobách.

---

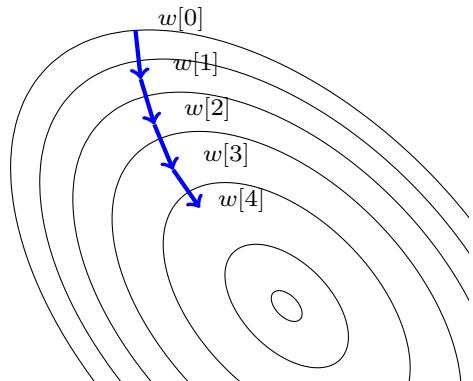
#### Algoritmus 1: Gradientní sestup

---

```

Vstup: váhy  $w_0$ , # iterací  $T$ 
Výstup: konečné váhy  $w_T$ 
1 for  $t \in \{0, \dots T-1\}$  do
2   odhad  $\nabla \mathcal{L}(w_t)$ 
3   výpočet  $\Delta w_t = -\nabla \mathcal{L}(w_t)$ 
4   výběr rychlosti učení  $\gamma$ 
5    $w_{t+1} := w_t + \gamma \Delta w_t$ 
6 end
7 return  $w_T$ 
```

---



Obrázek 2.10: Aktualizace GD [91]

Výše lze vidět obecný popis gradientního sestupu (Algoritmus 1). Jeho cílem je najít minimum funkce tím, že se postupně pohybuje v opačném směru gradientu funkce. Gradient je vektor, který ukazuje směr největšího nárůstu funkce. Při pohybu v opačném směru tohoto vektoru, nastává oblast s největší změnou funkce a lze tedy minimalizovat cílovou funkci. Postupné kroky v opačném směru gradientu funkce vedou k nalezení optimálního řešení. Na Obr. 2.10 je vizualizována

přirozená aktualizace vah gradientního sestupu ve výstupním prostoru (pro náhodně inicializovanou síť). Jednotlivé vrstevnice znázorňují množiny úrovní hodnot ztrátové funkce podél vertikálního a horizontálního směru. Uprostřed vrstevnic se nachází minimum ztrátové funkce. Z algoritmu výše lze aktualizaci vah GD popsat následovně:

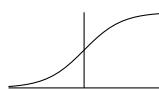
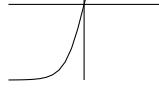
$$w_{t+1} = w_t - \gamma \nabla L(w_t) \quad (2.3)$$

kde  $w_t$  je aktuální hodnota vektoru vah v čase  $t$ ,  $\gamma$  je rychlosť učení (anglicky Learning Rate) a  $\nabla L(w_t)$  je gradient cílové funkce v čase  $t$ . Různé volby rychlosti učení  $\gamma$  a techniky odhadu pro  $\nabla L(w)$  mohou vést k různým implementacím. Gradientní sestup má proto řadu variant, včetně stochastického gradientního sestupu a mini-batch gradientního sestupu, které se liší v způsobu, jakým jsou gradienty vypočítávány a aktualizovány. Tyto algoritmy již popsali Goodfellow et al. v [78].

#### 2.6.6.3 Aktivační funkce

Aktivační funkce jsou jednou z nejdůležitějších součástí ANN. Tyto funkce zpracovávají vstupní signály a generují výstupy neuronů, které se dále šíří do dalších vrstev sítě. Musí také splňovat některé předpoklady jako je diferencovatelnost. Aktivační funkce musí být také nelineární, aby se rozšířil rozsah mapovacích funkcí, které lze approximovat. Existují různé aktivační funkce, které mají své výhody a nevýhody. Jejich výběr je podstatnou součástí procesu optimalizace hyperparametrů [78, 92].

**Tabulka 2.2:** Vybrané aktivační funkce [93]

Název	Funkce	Derivace	Obrázek
Sigmoid	$\sigma(x) = \frac{1}{1+e^{-x}}$	$f'(x) = f(x)(1-f(x))^2$	
Softmax	$f(x) = \frac{e^x}{\sum_i e^x}$	$f'(x) = \frac{e^x}{\sum_i e^x} - \frac{(e^x)^2}{(\sum_i e^x)^2}$	
tanh	$\sigma(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$	$f'(x) = 1 - f(x)^2$	
ReLU	$f(x) = \begin{cases} 0 & \text{if } x < 0 \\ x & \text{if } x \geq 0. \end{cases}$	$f'(x) = \begin{cases} 0 & \text{if } x < 0 \\ 1 & \text{if } x \geq 0. \end{cases}$	

Logistická funkce, neboli sigmoida, je jednou z nejstarších aktivačních funkcí a má tvar S-křivky. Sigmoida má nelineární charakter, což umožňuje neuronové sítě modelovat složité vztahy mezi vstupy a výstupy. Nicméně, sigmoida má některé nevýhody, mezi které patří tzv. „vanishing gradient“, kdy se gradient funkce blíží

nule, což brání učení sítě. Tato funkce také může způsobit saturaci neuronů, což znamená, že se jejich výstupy blíží k hodnotě 0 nebo 1, a brání tak dalšímu učení [92].

Hyperbolická funkce tangens (tanh) je podobná sigmoidě, ale má symetrický tvar s rozsahem mezi -1 a 1. Tanh může být lepší volbou než sigmoida pro určité typy sítí, protože umožňuje výstupy neuronů, které jsou jak kladné, tak záporné [92].

Aktivační funkce ReLU (anglicky Rectified Linear Unit) vrací vstupní hodnotu, pokud je kladná, a nulu, pokud je záporná. Jedná se o velmi populární a efektivní funkci, která umožňuje rychlé učení sítí. Navíc, ReLU může snížit výskyt saturace neuronů a dříve zmíněného problému – „*vanishing gradient*“. Nicméně, tato funkce může mít problém s tzv. „*mrtvými neuronůmi*“, kdy neuron má výstup vždy roven nule a stává se tak neaktivní [92, 94].

Leaky ReLU je modifikace ReLU, která řeší problém „*mrtvých neuronů*“ tím, že má nenulovou hodnotu pro záporné vstupy. Existuje řada dalších aktivačních funkcí, jako je softmax, která se často používá jako aktivační funkce pro poslední vrstvu neuronové sítě a používá se v úlohách klasifikace [92].

#### 2.6.6.4 Regularizace

Z předešlých kapitol vyplývá, že jedním z hlavních cílů učení neuronové sítě je minimalizace chyby predikce. Často ale dochází k přeúčení neuronová sítě, tedy síť se naučí velmi přesně předpovídat data použitá pro trénování, ale ztrácí schopnost generalizace. To je způsobeno tím, že síť se snaží přizpůsobit se každému jednotlivému trénovacímu datovému bodu a následně nedokáže předpovídat data, která se od těch trénovacích liší. K tomuto jevu dochází, protože neuronová síť má příliš mnoho parametrů (viz 2.6.2.2). Řešením tohoto problému je použití regularizace. Regularizace je technika, která snižuje rozptyl modelu sítě, a snaží se tak minimalizovat riziko přeúčení. Existuje několik technik regularizace, z nichž nejčastěji používanými jsou L1 a L2 regularizace, dropout a early stopping.

Metody regularizace L1 a L2 omezují optimalizační metody během procesu minimalizace ztrátové funkce modelu. Tato omezení penalizují váhy, což vede ke zjednodušení modelu. Při L1 regularizaci se k nákladové funkci přidává regularizační člen, který je součtem absolutních hodnot vah. Tento přístup způsobí, že některé znaky jsou považovány za méně důležité a je jim přiřazena nulová váha, čímž se model účinně zjednoduší. Váhy byly dříve indexovány na základě neuronů a vrstev, které spojují. U L2 je zaveden regularizační člen za účelem minimalizace součtu čtverců vah. Tento přístup nevede k vynulování vah, ale snižuje je o faktor úměrný jejich velikosti během každé iterace gradientního sestupu [76, 78].

Dropout je metoda, která náhodně „*vypne*“ některé neurony v síti během trénování, což má za následek omezení relací mezi neurony a snížení rizika přeúčení.

Early stopping je technika, která sleduje vývoj chyby při trénování sítě na validačním datasetu a zastaví trénování, jakmile se chyba na validačním datasetu začne zvyšovat. Umožňuje tak včasné ukončení trénování a minimalizaci rizika přeúčení [76, 78].

# KAPITOLA **3**

---

## **Cíle práce**

Hlavním cílem diplomové práce je návrh a realizace metod pro hodnocení kognitivní zátěže z biosignálů současně s vyhodnocením vlivu extrémního prostředí na její projevy. Hodnocenými biosignály jsou konkrétně elektrická srdeční aktivita, respirační aktivita a elektrodermální aktivita.

Dalším cílem práce je návrh vhodného protokolu studie pro měření v podmírkách analogových misí studujících vliv izolace člověka, který bude vycházet ze současných publikovaných datasetů sledujících vliv kognitivní zátěže na fyziologické signály.

# KAPITOLA 4

## Metody

### 4.1 Projekt Hydronaut

#### 4.1.1 Mise Diana

#### 4.1.2 Měření biosignálů

### 4.2 Použité technologie a knihovny

Obory umělé inteligence, jako strojové učení nebo neuronové sítě, často vyžadují v reálných podmínkách pečlivou přípravu a předzpracování dat nebo sestavení a trénování modelů. V dnešní době však existuje velké množství nástrojů a knihoven, které tyto kroky implementují a značně tak zvyšují efektivitu vývoje patřičných aplikací. Tato kapitola popisuje zásadní nástroje použité pro účely této práce.

#### 4.2.1 Python a R

Mezi nejpopulárnější open-source programovací jazyky v oblasti strojového učení a data science, které byly zároveň použity v této práci, patří Python<sup>5</sup> a R<sup>6</sup>. Pro předzpracování dat, strojové učení a neuronové sítě byl použit Python 3.7 s využitím platformy Google Colab.

Explorační a statistická analýza dat byla realizována prostřednictvím jazyka R (verze 4.2.1, Funny-Looking Kid) na laptopu *HP Spectre x360* s procesorem *i7-8705G*, 32 GB DDR4 RAM a grafickou kartou *RX Vega M GL*. I přestože R není na rozdíl od Pythonu univerzálním vysokoúrovňovým programovacím jazykem a využívá se především pro statistické modelování, je díky bohaté komunitě a velkému množství knihoven nedílnou součástí oblasti strojového učení a data science.

<sup>5</sup><https://www.python.org>

<sup>6</sup><https://www.r-project.org>

## 4.2.2 Google Colab a Jupyter Notebook

Na základě velkého objemu dat ke zpracování bylo využito platformy Google Colab<sup>7</sup>. Jedná se o cloudové interaktivní výpočetní prostředí, které běží na virtuálním stroji a umožňuje vzdálené spuštění kódu s využitím prostředků jako *NVIDIA Tesla V100/P100* s 24 GB VRAM. Jinými slovy jde o hostovanou webovou aplikaci jménem Jupyter Notebook<sup>8</sup>, která umožňuje vytvářet a sdílet dokumenty (zápisníky). Tyto dokumenty jsou rozděleny do buněk, které lze spouštět v libovolném pořadí (live kód), což zajišťuje efektivnější prototypování.

## 4.2.3 Neurokit

Knihovna Neurokit2 [95] poskytuje pokročilé metody pro zpracování a vizualizaci biosignálu. Jednotlivé metody zároveň nabízejí možnost si vybrat z mnoha implementovaných algoritmů, například pro detekci QRS komplexu. V této práci byla knihovna použita pro předzpracování respirační, elektrodermální a srdeční aktivity včetně zpracování HRV.

## 4.2.4 Tidyverse a Easystats

Knihovny tidyverse [96] a easystats [97] rozšiřují jazyk R o mnoho funkcionalit primárně pro potřeby statistického modelování a strojového učení. Usnadňují a zrychlují proces tvorby modelů díky dobře zdokumentovanému ekosystému balíčků. V této práci sloužily knihovny ke statistické analýze velkého souboru dat.

## 4.2.5 Scikit-learn, TensorFlow a Keras

Scikit-learn [98] je balíček jazyka Python pro prediktivní analýzu dat a strojové učení, který byl v této práci použit pro extrakci a normalizaci příznaků. Dále pro porovnávání, validaci a výběr parametrů a modelů.

## 4.2.6 InfluxDB

InfluxDB<sup>9</sup> je open-source platforma poskytující databázi pro časové řady. Zahrnuje rozhraní (API) pro standardní databázové dotazy. Součástí je i grafické uživatelské rozhraní (GUI) s modulárními uživatelskými panely pro monitorování dat v reálném čase. Tato platforma (InfluxDB OSS 2.4) byla využita v rámci experimentální části práce k uchovávání a vizualizaci dat.

---

<sup>7</sup><https://colab.research.google.com>

<sup>8</sup><https://jupyter.org>

<sup>9</sup><https://www.influxdata.com>

### 4.3 Explorační analýza dat

### 4.4 Statistické metody

# KAPITOLA **5**

---

## **Výsledky**

# KAPITOLA 6

---

## Diskuse

KAPITOLA 7

---

**Závěr**

---

## Bibliografie

1. HARRISON, Albert A.; CONNORS, Mary M. Groups in Exotic Environments. In: BERKOWITZ, Leonard (ed.) [online]. Academic Press, 1984, sv. 18, s. 49–87 [cit. 2021-04-08]. *Advances in Experimental Social Psychology*. ISSN 0065-2601. Dostupné z DOI: [https://doi.org/10.1016/S0065-2601\(08\)60142-2](https://doi.org/10.1016/S0065-2601(08)60142-2).
2. BELL, Suzanne T.; FISHER, David M.; BROWN, Shanique G.; MANN, Kristin E. An Approach for Conducting Actionable Research With Extreme Teams. *Journal of Management* [online]. 2018, roč. 44, č. 7, s. 2740–2765 [cit. 2021-04-08]. Dostupné z DOI: [10.1177/0149206316653805](https://doi.org/10.1177/0149206316653805).
3. STACHOWSKI, Alicia A; KAPLAN, Seth A; WALLER, Mary J. The benefits of flexible team interaction during crises. *Journal of Applied Psychology* [online]. 2009, roč. 94, č. 6, s. 1536 [cit. 2021-04-08]. Dostupné z DOI: [10.1037/a0016903](https://doi.org/10.1037/a0016903).
4. YU, Tieying; SENGUL, Metin; LESTER, Richard H. Misery loves company: The spread of negative impacts resulting from an organizational crisis. *Academy of Management Review* [online]. 2008, roč. 33, č. 2, s. 452–472 [cit. 2021-04-08]. Dostupné z DOI: [10.5465/amr.2008.31193499](https://doi.org/10.5465/amr.2008.31193499).
5. GARDNER, Heidi K. Performance pressure as a double-edged sword: Enhancing team motivation but undermining the use of team knowledge. *Administrative Science Quarterly* [online]. 2012, roč. 57, č. 1, s. 1–46 [cit. 2021-04-08]. Dostupné z DOI: [10.1177/0001839212446454](https://doi.org/10.1177/0001839212446454).
6. STAAL, Mark A. Stress, Cognition, and Human Performance: A Literature Review and Conceptual Framework. In: [online]. 2013 [cit. 2021-04-08]. Dostupné z: <https://ntrs.nasa.gov/citations/20060017835>.
7. HANNAH, Sean T.; UHL-BIEN, Mary; AVOLIO, Bruce J.; CAVARRETTA, Fabrice L. A framework for examining leadership in extreme contexts. *The Leadership Quarterly* [online]. 2009, roč. 20, č. 6, s. 897–919 [cit. 2021-06-12]. ISSN 1048-9843. Dostupné z DOI: <https://doi.org/10.1016/j.lequa.2009.09.006>. The Leadership Quarterly Yearly Review of Leadership.
8. HÄLLGREN, Markus; ROULEAU, Linda; ROND, Mark de. A Matter of Life or Death: How Extreme Context Research Matters for Management and Organization Studies. *Academy of Management Annals* [online]. 2018, roč. 12, č. 1, s. 111–153 [cit. 2021-06-15]. Dostupné z DOI: [10.5465/annals.2016.0017](https://doi.org/10.5465/annals.2016.0017).

9. GOLDEN, Simon J.; CHANG, Chu-Hsiang (Daisy); KOZLOWSKI, Steve W.J. Teams in isolated, confined, and extreme (ICE) environments: Review and integration. *Journal of Organizational Behavior* [online]. 2018, roč. 39, č. 6, s. 701–715 [cit. 2021-06-16]. Dostupné z DOI: <https://doi.org/10.1002/job.2288>.
10. PAGEL, J. I.; CHOUKÈR, A. Effects of isolation and confinement on humans-implications for manned space explorations. *Journal of Applied Physiology*. 2016, roč. 120, č. 12, s. 1449–1457. Dostupné z DOI: [10.1152/japplphysiol.00928.2015](https://doi.org/10.1152/japplphysiol.00928.2015). PMID: 26846554.
11. TAYLOR, Lee; WATKINS, Samuel L.; MARSHALL, Hannah; DASCOMBE, Ben J.; FOSTER, Josh. The impact of different environmental conditions on cognitive function: A focused review. *Frontiers in Physiology* [online]. 2016, roč. 6, s. 372 [cit. 2021-06-14]. ISSN 1664042X. Dostupné z DOI: [10.3389/fphys.2015.00372](https://doi.org/10.3389/fphys.2015.00372).
12. WINNARD, Andrew; SCOTT, Jonathan; WATERS, Nathan; VANCE, Martin; CAPLAN, Nick. Effect of Time on Human Muscle Outcomes During Simulated Microgravity Exposure Without Countermeasures—Systematic Review. *Frontiers in Physiology* [online]. 2019, roč. 10 [cit. 2021-04-08]. ISSN 1664042X. Dostupné z DOI: [10.3389/fphys.2019.01046](https://doi.org/10.3389/fphys.2019.01046).
13. ZHANG, Fan; DE DEAR, Richard; HANCOCK, Peter. Effects of moderate thermal environments on cognitive performance: A multidisciplinary review. *Applied Energy* [online]. 2019, roč. 236, s. 760–777 [cit. 2021-04-08]. ISSN 0306-2619. Dostupné z DOI: <https://doi.org/10.1016/j.apenergy.2018.12.005>.
14. MAYNARD, M Travis; KENNEDY, Deanna M; RESICK, Christian J. Teamwork in extreme environments: Lessons, challenges, and opportunities. *Journal of organizational behavior* [online]. 2018, roč. 39, č. 6, s. 695–700 [cit. 2021-06-14]. ISSN 1099-1379. Dostupné z DOI: [10.1002/job.2302](https://doi.org/10.1002/job.2302).
15. DRISKELL, Tripp; SALAS, Eduardo; DRISKELL, James E. Teams in extreme environments: Alterations in team development and teamwork. *Human Resource Management Review* [online]. 2018, roč. 28, s. 434–449 [cit. 2021-06-09]. ISSN 1053-4822. Dostupné z DOI: [10.1016/j.hrmr.2017.01.002](https://doi.org/10.1016/j.hrmr.2017.01.002).
16. WICKMAN, Leslie; TSAI, Annie; WALTERS, Raymond. Isolation and Confinement Issues in Long Duration Spaceflight. In: [online]. 2008, s. 1–9 [cit. 2021-06-12]. Dostupné z DOI: [10.1109/AERO.2008.4526654](https://doi.org/10.1109/AERO.2008.4526654).
17. STUSTER, Jack W. Bold endeavors: behavioral lessons from polar and space exploration. *Gravitational and Space Research* [online]. 2007, roč. 13, č. 2 [cit. 2021-06-14]. Dostupné z: <http://gravitationalandspaceresearch.org/index.php/journal/article/view/244/243>.

18. KALEAGASI, Bartu. *Space Technology under NASA and SpaceX* [online]. 2017. [cit. 2021-06-24]. Dostupné z: <https://bartukaleagasi.files.wordpress.com/2017/01/space-technology-under-nasa-and-spacex.pdf>.
19. SALOTTI, Jean-Marc; HEIDMANN, Richard. Roadmap to a human Mars mission. *Acta Astronautica* [online]. 2014, roč. 104, č. 2, s. 558–564 [cit. 2021-06-16]. ISSN 0094-5765. Dostupné z DOI: <https://doi.org/10.1016/j.actaastro.2014.06.038>. Future of Space Exploration: Towards the Stars.
20. VISCIO, Maria Antonietta; GARGIOLI, Eugenio; HOFFMAN, Jeffrey A.; MAGGIORE, Paolo; MESSIDORO, Andrea; VIOLA, Nicole. A methodology for innovative technologies roadmaps assessment to support strategic decisions for future space exploration. *Acta Astronautica* [online]. 2014, roč. 94, č. 2, s. 813–833 [cit. 2021-06-16]. ISSN 0094-5765. Dostupné z DOI: <https://doi.org/10.1016/j.actaastro.2013.10.004>.
21. MOGILEVER, Nicolette B.; ZUCCARELLI, Lucrezia; BURLES, Ford; IARIA, Giuseppe; STRAPAZZON, Giacomo; BESSONE, Loredana; COFFEY, Emily B.J. Expedition cognition: A review and prospective of subterranean neuroscience with spaceflight applications. *Frontiers in Human Neuroscience* [online]. 2018, roč. 12, s. 407 [cit. 2021-06-15]. ISSN 16625161. Dostupné z DOI: [10.3389/FNHUM.2018.00407](https://doi.org/10.3389/FNHUM.2018.00407).
22. BUGUET, Alain. Sleep under extreme environments: Effects of heat and cold exposure, altitude, hyperbaric pressure and microgravity in space. *Journal of the Neurological Sciences* [online]. 2007, roč. 262, s. 145–152 [cit. 2021-04-08]. ISSN 0022510X. Dostupné z DOI: [10.1016/J.JNS.2007.06.040](https://doi.org/10.1016/J.JNS.2007.06.040).
23. WILLIAMS, David; KUIPERS, Andre; MUKAI, Chiaki; THIRSK, Robert. Acclimation during space flight: Effects on human physiology. *CMAJ* [online]. 2009, roč. 180, s. 1317–1323 [cit. 2021-04-08]. ISSN 14882329. Dostupné z DOI: [10.1503/CMAJ.090628](https://doi.org/10.1503/CMAJ.090628).
24. ROY-O'REILLY, Meaghan; MULAVARA, Ajitkumar; WILLIAMS, Thomas. A review of alterations to the brain during spaceflight and the potential relevance to crew in long-duration space exploration. *npj Microgravity* 2021 7:1 [online]. 2021, roč. 7, č. 1, s. 1–9 [cit. 2021-06-15]. ISSN 2373-8065. Dostupné z DOI: [10.1038/s41526-021-00133-z](https://doi.org/10.1038/s41526-021-00133-z).
25. STRANGMAN, Gary E.; SIPES, Walter; BEVEN, Gary. Human cognitive performance in spaceflight and analogue environments. *Aviation Space and Environmental Medicine* [online]. 2014, roč. 85, s. 1033–1048 [cit. 2021-04-18]. ISSN 00956562. Dostupné z DOI: [10.3357/ASEM.3961.2014](https://doi.org/10.3357/ASEM.3961.2014).
26. MORPHEW, Ephimia. Psychological and human factors in long duration spaceflight. *McGill Journal of Medicine* [online]. 2001, roč. 6, č. 1 [cit. 2021-06-16]. Dostupné z DOI: [10.26443/mjm.v6i1.555](https://doi.org/10.26443/mjm.v6i1.555).

27. STEIN, Thomas P. Weight, muscle and bone loss during space flight: another perspective. *European Journal of Applied Physiology* [online]. 2012, roč. 113, s. 2171–2181 [cit. 2021-06-18]. Dostupné z: <https://link.springer.com/article/10.1007/s00421-012-2548-9>.
28. GROEMER, Gernot; OZDEMIR, Seda. Planetary Analog Field Operations as a Learning Tool. *Frontiers in Astronomy and Space Sciences* [online]. 2020, roč. 7 [cit. 2021-06-19]. ISSN 2296-987X. Dostupné z DOI: 10.3389/fspas.2020.00032.
29. BARKASZI, Irén; TAKÁCS, Endre; CZIGLER, István; BALÁZS, László. Extreme Environment Effects on Cognitive Functions: A Longitudinal Study in High Altitude in Antarctica. *Frontiers in Human Neuroscience* [online]. 2016, roč. 10 [cit. 2021-04-08]. ISSN 1662-5161. Dostupné z DOI: 10.3389/fnhum.2016.00331.
30. LUGG, D.; SHEPANEK, M. Space analogue studies in Antarctica. *Acta Astronautica* [online]. 1999, roč. 44, č. 7, s. 693–699 [cit. 2021-06-19]. ISSN 0094-5765. Dostupné z DOI: [https://doi.org/10.1016/S0094-5765\(99\)00068-5](https://doi.org/10.1016/S0094-5765(99)00068-5). Pacific RIM: A Rapidly Expanding Space Market.
31. SCHNEIDER, Stefan; ABELN, Vera; POPOVA, Julia; FOMINA, Elena; JACUBOWSKI, Amrei; MEEUSEN, Romain; STRÜDER, Heiko K. The influence of exercise on prefrontal cortex activity and cognitive performance during a simulated space flight to Mars (MARS500). *Behavioural Brain Research* [online]. 2013, roč. 236, s. 1–7 [cit. 2021-06-19]. ISSN 0166-4328. Dostupné z DOI: <https://doi.org/10.1016/j.bbr.2012.08.022>.
32. WANG, Yue; JING, Xiaolu; LV, Ke; WU, Bin; BAI, Yanqiang; LUO, Yuejia; CHEN, Shanguang; LI, Yinghui. During the Long Way to Mars: Effects of 520 Days of Confinement (Mars500) on the Assessment of Affective Stimuli and Stage Alteration in Mood and Plasma Hormone Levels. *PLOS ONE* [online]. 2014, roč. 9, č. 4, s. 1–9 [cit. 2021-06-19]. Dostupné z DOI: 10.1371/journal.pone.0087087.
33. TREMBANIS, Arthur C; FORREST, Alex L; MILLER, Douglas C; LIM, Darlene SS; GERNHARDT, Michael L; TODD, William L. Multiplatform ocean exploration: Insights from the NEEMO space analog mission. *Marine Technology Society Journal* [online]. 2012, roč. 46, č. 4, s. 7–19 [cit. 2021-06-20]. Dostupné z DOI: 10.1109/BIA48344.2019.8967457.
34. KOUTNIK, Andrew P.; FAVRE, Michelle E.; NOBOA, Karina; SANCHEZ-GONZALEZ, Marcos A.; MOSS, Sara E.; GOUBRAN, Bishoy; ARI, Csilla; POFF, Angela M.; ROGERS, Chris Q.; DEBLASI, Janine M.; SAMY, Bishoy; MOUSSA, Mark; SERRADOR, Jorge M.; D'AGOSTINO, Dominic P. Human Adaptations to Multiday Saturation on NASA NEEMO. *Frontiers in Physiology*

- [online]. 2021, roč. 11 [cit. 2021-06-20]. ISSN 1664-042X. Dostupné z DOI: 10.3389/fphys.2020.610000.
35. KJELL LINGREN, NASA Astronaut. *NEEMO 22 Photo Gallery* [online]. 2017. [cit. 2021-06-20]. Dostupné z: <https://www.flickr.com/photos/40054892@N06/albums/72157683015049201>.
  36. HYDRONAUT. *H03 DeepLab* [online]. 2020. [cit. 2021-06-23]. Dostupné z: <https://hydronaut.eu/cs>.
  37. SÁZEL, Miloš; BOHÁČEK, Pavel. Saturační potápění – projekt Hydronaut. *Occupational Medicine / Pracovní Lékarství* [online]. 2014, roč. 66, č. 2/3, s. 85–89 [cit. 2021-06-20]. ISSN 00326291. Dostupné z: <https://search.ebscohost.com/login.aspx?direct=true&db=a9h&AN=102280881&site=ehost-live&scope=site>.
  38. MOORE, Steven; DILDA, Valentina; MORRIS, Tiffany; YUNGHER, Don; MACDOUGALL, Hamish; WOOD, Scott. Long-duration spaceflight adversely affects post-landing operator proficiency. *Scientific Reports* [online]. 2019, roč. 9 [cit. 2021-06-23]. Dostupné z DOI: 10.1038/s41598-019-39058-9.
  39. DE LA TORRE, Gabriel G. Cognitive Neuroscience in Space. *Life* [online]. 2014, roč. 4, č. 3, s. 281–294 [cit. 2021-06-23]. ISSN 2075-1729. Dostupné z DOI: 10.3390/life4030281.
  40. OMBERGEN, Angelique Van; JILLINGS, Steven; JEURISSEN, Ben; TOMILOVSKAYA, Elena; RUMSHISKAYA, Alena; LITVINOVA, Liudmila; NOSIKOVA, Inna; PECHENKOVA, Ekaterina; RUKAVISHNIKOV, Ilya; MANKO, Olga; DANYLICHEV, Sergey; RÜHL, R. Maxine; KOZLOVSKAYA, Inessa B.; SUNAERT, Stefan; PARIZEL, Paul M.; SINITSYN, Valentin; LAUREYS, Steven; SIJBERS, Jan; EULENBURG, Peter zu; WUYTS, Floris L. Brain ventricular volume changes induced by long-duration spaceflight. *Proceedings of the National Academy of Sciences* [online]. 2019, roč. 116, č. 21, s. 10531–10536 [cit. 2021-06-23]. Dostupné z DOI: 10.1073/pnas.1820354116.
  41. PECHENKOVA, Ekaterina; NOSIKOVA, Inna; RUMSHISKAYA, Alena; LITVINOVA, Liudmila; RUKAVISHNIKOV, Ilya; MERSHINA, Elena; SINITSYN, Valentin; VAN OMBERGEN, Angelique; JEURISSEN, Ben; JILLINGS, Steven; LAUREYS, Steven; SIJBERS, Jan; GRISHIN, Alexey; CHERNIKOVA, Ludmila; NAUMOV, Ivan; KORNILOVA, Ludmila; WUYTS, Floris L.; TOMILOVSKAYA, Elena; KOZLOVSKAYA, Inessa. Alterations of Functional Brain Connectivity After Long-Duration Spaceflight as Revealed by fMRI. *Frontiers in Physiology* [online]. 2019, roč. 10 [cit. 2021-06-23]. ISSN 1664-042X. Dostupné z DOI: 10.3389/fphys.2019.00761.

42. ROBERTS, Donna; ALBRECHT, Moritz; COLLINS, Heather; ASEMANI, Davud; CHATTERJEE, A.; SPAMPINATO, M.; ZHU, Xun; CHIMOWITZ, Marc; ANTONUCCI, Michael. Effects of Spaceflight on Astronaut Brain Structure as Indicated on MRI. *New England Journal of Medicine* [online]. 2017, roč. 377, s. 1746–1753 [cit. 2021-06-23]. Dostupné z DOI: 10.1056/NEJMoa1705129.
43. DEMERTZI, Athena; VAN OMBERGEN, Angelique; TOMILOVSKAYA, Elena; JEURISSEN, Ben; PECHENKOVA, Ekaterina; DI PERRI, Carol; LITVINOVA, Liudmila; AMICO, Enrico; RUMSHISKAYA, A.; RUKAVISHNIKOV, Ilya; SIJBERS, Jan; SINITSYN, Valentin; KOZLOVSKAYA, Inessa; SUNAERT, Stefan; PARIZEL, Paul; VAN DE HEYNING, Paul; LAUREYS, Steven; WUYTS, Floris. Cortical reorganization in an astronaut's brain after long-duration spaceflight. *Brain structure & function* [online]. 2015, roč. 221 [cit. 2021-06-23]. Dostupné z DOI: 10.1007/s00429-015-1054-3.
44. KRAMER, Larry A.; HASAN, Khader M.; STENGER, Michael B.; SARGSYAN, Ashot; LAURIE, Steven S.; OTTO, Christian; PLOUTZ-SNYDER, Robert J.; MARSHALL-GOEBEL, Karina; RIASCOS, Roy F.; MACIAS, Brandon R. Intracranial Effects of Microgravity: A Prospective Longitudinal MRI Study. *Radiology* [online]. 2020, roč. 295, č. 3, s. 640–648 [cit. 2021-06-23]. Dostupné z DOI: 10.1148/radiol.2020191413. PMID: 32286194.
45. CORREIA, Manning J. Neuronal plasticity: adaptation and readaptation to the environment of space. *Brain Research Reviews* [online]. 1998, roč. 28, č. 1, s. 61–65 [cit. 2021-06-23]. ISSN 0165-0173. Dostupné z DOI: [https://doi.org/10.1016/S0165-0173\(98\)00043-5](https://doi.org/10.1016/S0165-0173(98)00043-5).
46. KOPPELMANS, Vincent; BLOOMBERG, Jacob; MULAVARA, Ajitkumar; SEIDLER, Rachael. Brain structural plasticity with spaceflight. *npj Microgravity* [online]. 2016, roč. 2 [cit. 2021-06-23]. Dostupné z DOI: 10.1038/s41526-016-0001-9.
47. KOPPELMANS, Vincent; BLOOMBERG, Jacob J.; DE DIOS, Yiri E.; WOOD, Scott J.; REUTER-LORENZ, Patricia A.; KOFRMAN, Igor S.; RIASCOS, Roy; MULAVARA, Ajitkumar P.; SEIDLER, Rachael D. Brain plasticity and sensorimotor deterioration as a function of 70 days head down tilt bed rest. *PLOS ONE* [online]. 2017, roč. 12, č. 8, s. 1–23 [cit. 2021-06-23]. Dostupné z DOI: 10.1371/journal.pone.0182236.
48. HODKINSON, P.D.; ANDERTON, R.A.; POSSELT, B.N.; FONG, K.J. An overview of space medicine. *British Journal of Anaesthesia*. 2017, roč. 119, s. i143–i153. ISSN 0007-0912. Dostupné z DOI: <https://doi.org/10.1093/bja/aex336>.

49. BREM, Christian; LUTZ, Jürgen; VOLLMAR, Christian; FEUERECKER, Matthias; STREWE, Claudia; NICHIPORUK, Igor; VASSILIEVA, Galina; SCHELLING, Gustav; CHOUKÉR, Alexander. Changes of brain DTI in healthy human subjects after 520 days isolation and confinement on a simulated mission to Mars. *Life Sciences in Space Research* [online]. 2020, roč. 24, s. 83–90 [cit. 2021-06-23]. ISSN 2214-5524. Dostupné z DOI: <https://doi.org/10.1016/j.lssr.2019.09.004>.
50. STAHN, Alexander; GUNGA, Hanns-Christian; KOHLBERG, Eberhard; GALLINAT, Jürgen; DINGES, David; KÜHN, Simone. Brain Changes in Response to Long Antarctic Expeditions. *New England Journal of Medicine* [online]. 2019, roč. 381, s. 2273–2275 [cit. 2021-06-23]. Dostupné z DOI: 10.1056/NEJMc1904905.
51. SWELLER, John. Cognitive Load During Problem Solving: Effects on Learning. *Cognitive Science* [online]. 1988, roč. 12, č. 2, s. 257–285 [cit. 2021-06-24]. Dostupné z DOI: [https://doi.org/10.1207/s15516709cog1202\\_4](https://doi.org/10.1207/s15516709cog1202_4).
52. SWELLER, John; VAN MERRIENBOER, Jeroen J. G.; PAAS, Fred. Cognitive Architecture and Instructional Design. *Educational Psychology Review* [online]. 1998, roč. 10, s. 251– [cit. 2021-06-24]. Dostupné z DOI: 10.1023/a:1022193728205.
53. SWELLER, J. Cognitive load theory: Recent theoretical advances. *Cognitive Load Theory* [online]. 2010, s. 29–47 [cit. 2021-06-24]. Dostupné z DOI: 10.1017/CBO9780511844744.004.
54. CHEN, Fang; ZHOU, Jianlong; WANG, Yang; YU, Kun; ARSHAD, Syed; KHAWAJI, Ahmad; CONWAY, Dan. *Robust Multimodal Cognitive Load Measurement* [online]. 2016. [cit. 2021-06-24]. ISBN 978-3-319-31698-7. Dostupné z DOI: 10.1007/978-3-319-31700-7.
55. HAAPALAINEN, Eija; KIM, SeungJun; FORLIZZI, Jodi F.; DEY, Anind K. Psycho-Physiological Measures for Assessing Cognitive Load. In: *Proceedings of the 12th ACM International Conference on Ubiquitous Computing* [online]. Copenhagen, Denmark: Association for Computing Machinery, 2010, s. 301–310 [cit. 2021-06-24]. UbiComp '10. ISBN 9781605588438. Dostupné z DOI: 10.1145/1864349.1864395.
56. VANNESTE, Pieter; RAES, Annelies; MORTON, Jessica; BOMBEKE, Klaas; VAN ACKER, Bram; LARMUSEAU, Charlotte; DEPAEPE, Fien; VAN DEN NOORTGATE, Wim. Towards measuring cognitive load through multimodal physiological data. *Cognition, Technology & Work* [online]. 2021, roč. 23 [cit. 2021-06-24]. Dostupné z DOI: 10.1007/s10111-020-00641-0.

57. THAYER, Julian F.; HANSEN, Anita L.; SAUS-ROSE, Evelyn; JOHNSEN, Bjorn Helge. Heart Rate Variability, Prefrontal Neural Function, and Cognitive Performance: The Neurovisceral Integration Perspective on Self-regulation, Adaptation, and Health. *Annals of Behavioral Medicine* [online]. 2009, roč. 37, č. 2, s. 141–153 [cit. 2021-06-24]. ISSN 0883-6612. Dostupné z DOI: 10.1007/s12160-009-9101-z.
58. GJORESKI, Martin; LUSTREK, Mitja; GAMS, Matjaz; GJORESKI, Hristijan. Monitoring stress with a wrist device using context. *Journal of Biomedical Informatics*. 2017, roč. 73. Dostupné z DOI: 10.1016/j.jbi.2017.08.006.
59. DE LA CRUZ, Feliberto; SCHUMANN, Andy; KÖHLER, Stefanie; REICHENBACH, Jürgen; WAGNER, Gerd; BÄR, Karl-Jürgen. The relationship between heart rate and functional connectivity of brain regions involved in autonomic control. *NeuroImage*. 2019, roč. 196. Dostupné z DOI: 10.1016/j.neuroimage.2019.04.014.
60. BROUWER, Anne-Marie; ZANDER, Thorsten; ERP, Jan; KORTELING, J.E. (Hans); BRONKHORST, Adelbert. Using neurophysiological signals that reflect cognitive or affective state: Six recommendations to avoid common pitfalls. *Frontiers in Neuroscience*. 2015, roč. 9. Dostupné z DOI: 10.3389/fnins.2015.00136.
61. ANTONENKO, Pavlo "Pasha; PAAS, Fred; GRABNER, Roland; GOG, Tamara. Using Electroencephalography to Measure Cognitive Load. *Educational Psychology Review*. 2010, roč. 22, s. 425–438. Dostupné z DOI: 10.1007/s10648-010-9130-y.
62. WEL, Pauline; STEENBERGEN, Henk. Pupil dilation as an index of effort in cognitive control tasks: A review. *Psychonomic Bulletin & Review*. 2018, roč. 25. Dostupné z DOI: 10.3758/s13423-018-1432-y.
63. SETZ, Cornelia; ARNRICH, Bert; SCHUMM, Johannes; LA MARCA, Roberto; TRÖSTER, Gerhard; EHLERT, Ulrike. Discriminating Stress From Cognitive Load Using a Wearable EDA Device. *IEEE Transactions on Information Technology in Biomedicine*. 2010, roč. 14, č. 2, s. 410–417. Dostupné z DOI: 10.1109/TITB.2009.2036164.
64. HERBORN, Katherine; GRAVES, James; JEREM, Paul; EVANS, Neil; NAGER, Ruedi; MCCAFFERTY, Dominic; MCKEEGAN, Dorothy. Skin temperature reveals the intensity of acute stress. *Physiology & behavior*. 2015, roč. 152. Dostupné z DOI: 10.1016/j.physbeh.2015.09.032.
65. JERČIĆ, Petar; SENNERSTEN, Charlotte; LINDLEY, Craig. Modeling cognitive load and physiological arousal through pupil diameter and heart rate. *Multimedia Tools and Applications*. 2020, roč. 79. Dostupné z DOI: 10.1007/s11042-018-6518-z.

66. SOLHJOO, Soroosh; HAIGNEY, Mark; MCBEE, Elexis; VAN MERRIENBOER, Jeroen J. G.; SCHUWIRTH, Lambert; ARTINO, Anthony; BATTISTA, Alexis; RATCLIFFE, Temple; LEE, Howard; DURNING, Steven. Heart Rate and Heart Rate Variability Correlate with Clinical Reasoning Performance and Self-Reported Measures of Cognitive Load. *Scientific Reports*. 2019, roč. 9, s. 1–9. Dostupné z DOI: 10.1038/s41598-019-50280-3.
67. GRASSMANN, Mariel; VLEMINCX, Elke; LEUPOLDT, Andreas; MITTELSTÄDT, Justin; VAN DEN BERGH, Omer. Respiratory Changes in Response to Cognitive Load: A Systematic Review. *Neural Plasticity*. 2016, roč. 2016, s. 1–16. Dostupné z DOI: 10.1155/2016/8146809.
68. F., Kramer A. Physiological metrics of mental workload : A review of recent progress. *Multiple-task Performance*. 1991, s. 279–328. Dostupné také z: <https://cir.nii.ac.jp/crid/1572543024796401024>.
69. WANG, Chixiang; GUO, Junqi. A data-driven framework for learners' cognitive load detection using ECG-PPG physiological feature fusion and XGBoost classification. *Procedia Computer Science*. 2019, roč. 147, s. 338–348. ISSN 1877-0509. Dostupné z DOI: 10.1016/j.procs.2019.01.234.
70. SCHNOTZ, Wolfgang; KÜRSCHNER, Christian. A Reconsideration of Cognitive Load Theory. *Educational Psychology Review*. 2007, roč. 19, č. 4, s. 469–508. ISSN 1573-336X. Dostupné z DOI: 10.1007/s10648-007-9053-4.
71. HART, Sandra G. Nasa-Task Load Index (NASA-TLX); 20 Years Later. *Proceedings of the Human Factors and Ergonomics Society Annual Meeting*. 2006, roč. 50, č. 9, s. 904–908. Dostupné z DOI: 10.1177/154193120605000909.
72. GIANNAKAKIS, Giorgos; GRIGORIADIS, Dimitris; GIANNAKAKI, Katerina; SIMANTIRAKI, Olympia; RONIOTIS, Alexandros; TSIKNAKIS, Manolis. Review on Psychological Stress Detection Using Biosignals. *IEEE Transactions on Affective Computing*. 2022, roč. 13, č. 1, s. 440–460. ISSN 1949-3045. Dostupné z DOI: 10.1109/TAFFC.2019.2927337.
73. ROHILA, Ashish; SHARMA, Ambalika. Correlation between heart rate variability features. *2020 7th International Conference on Signal Processing and Integrated Networks, SPIN 2020*. 2020, s. 669–674. ISBN 9781728154756. Dostupné z DOI: 10.1109/SPIN48934.2020.9071381.
74. PHAM, Tam; LAU, Zen Juen; CHEN, S. H. Annabel; MAKOWSKI, Dominique. Heart rate variability in psychology: A review of hrv indices and an analysis tutorial. *Sensors*. 2021, roč. 21, č. 12. ISSN 14248220. Dostupné z DOI: 10.3390/S21123998.

75. BOUNY, Pierre; ARSAC, Laurent M; TOURÉ CUQ, Emma; DESCHODT-ARSAC, Veronique. Entropy and Multifractal-Multiscale Indices of Heart Rate Time Series to Evaluate Intricate Cognitive-Autonomic Interactions. *Entropy (Basel, Switzerland)*. 2021, roč. 23, č. 6. ISSN 1099-4300. Dostupné z DOI: 10.3390/e23060663.
76. GERON, Aurelien. *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems*. 3rd. O'Reilly Media, Inc., 2022. ISBN 9781098125974.
77. MURPHY, Kevin P. *Machine Learning: A Probabilistic Perspective*. The MIT Press, 2012. ISBN 0262018020.
78. GOODFELLOW, Ian; BENGIO, Yoshua; COURVILLE, Aaron. *Deep Learning*. MIT Press, 2016. <http://www.deeplearningbook.org>.
79. *Plot with polygons, ellipses, squares and rectangles* [online]. 2019. [cit. 2022-06-18]. Dostupné z: <https://tex.stackexchange.com/a/507813/289947>.
80. TIBSHIRANI, Robert J; EFRON, Bradley. An introduction to the bootstrap. *Monographs on statistics and applied probability*. 1993, roč. 57, č. 1.
81. ANGUITA, Davide; GHIO, Alessandro; ONETO, Luca; PARRA, Xavier; REYES-ORTIZ, Jorge Luis et al. A public domain dataset for human activity recognition using smartphones. In: *Esann*. 2013, sv. 3, s. 3.
82. KOHAVI, Ron et al. A study of cross-validation and bootstrap for accuracy estimation and model selection. In: *Ijcai*. Montreal, Canada, 1995, sv. 14, s. 1137–1145. Č. 2.
83. GHOJOGH, Benyamin; CROWLEY, Mark. *The Theory Behind Overfitting, Cross Validation, Regularization, Bagging, and Boosting: Tutorial*. arXiv, 2019. Dostupné z DOI: 10.48550/ARXIV.1905.12787.
84. *Adding text to a graphic in tikz* [online]. 2020. [cit. 2022-06-18]. Dostupné z: <https://tex.stackexchange.com/a/562199/289947>.
85. LIASHCHYNKYI, Petro; LIASHCHYNKYI, Pavlo. Grid Search, Random Search, Genetic Algorithm: A Big Comparison for NAS. *CoRR*. 2019, roč. abs/1912.06059. Dostupné z arXiv: 1912.06059.
86. ANGGORO, Dimas Aryo; MUKTI, Salsa Sasmita. Performance Comparison of Grid Search and Random Search Methods for Hyperparameter Tuning in Extreme Gradient Boosting Algorithm to Predict Chronic Kidney Failure. *Int. J. Intell. Eng. Syst.* 2021, roč. 14, č. 6, s. 198–207.
87. BERGSTRA, James; BENGIO, Yoshua. Random search for hyper-parameter optimization. *Journal of machine learning research*. 2012, roč. 13, č. 2.

88. ALIBRAHIM, Hussain; LUDWIG, Simone A. Hyperparameter Optimization: Comparing Genetic Algorithm against Grid Search and Bayesian Optimization. In: *2021 IEEE Congress on Evolutionary Computation (CEC)*. 2021, s. 1551–1559. Dostupné z DOI: [10.1109/CEC45853.2021.9504761](https://doi.org/10.1109/CEC45853.2021.9504761).
89. PARKER, Wendy S. Ensemble modeling, uncertainty and robust predictions. *WIREs Climate Change*. 2013, roč. 4, č. 3, s. 213–223. Dostupné z DOI: <https://doi.org/10.1002/wcc.220>.
90. SUZUKI, Kenji. *Artificial neural networks: Architectures and applications*. BoD–Books on Demand, 2013.
91. *Plotting the gradient descent?* [online]. 2019. [cit. 2022-06-18]. Dostupné z: <https://tex.stackexchange.com/questions/497165/plotting-the-gradient-descent>.
92. SHARMA, Sagar; SHARMA, Simone; ATHAIYA, Anidhya. Activation functions in neural networks. *Towards Data Sci* [online]. 2017, roč. 6, č. 12, s. 310–316 [cit. 2022-06-24]. Dostupné z: [https://www.ijeast.com/papers/310-316\\_Tesma412\\_IJEAST.pdf](https://www.ijeast.com/papers/310-316_Tesma412_IJEAST.pdf).
93. *How to format table with images?* [online]. 2018. [cit. 2022-06-18]. Dostupné z: <https://tex.stackexchange.com/questions/431200/how-to-format-table-with-images>.
94. NAIR, Vinod; HINTON, Geoffrey. Rectified Linear Units Improve Restricted Boltzmann Machines Vinod Nair. In: 2010, sv. 27, s. 807–814.
95. MAKOWSKI, Dominique; PHAM, Tam; LAU, Zen J.; BRAMMER, Jan C.; LESPINASSE, François; PHAM, Hung; SCHÖLZEL, Christopher; CHEN, S. H. Annabel. NeuroKit2: A Python toolbox for neurophysiological signal processing. *Behavior Research Methods*. 2021, roč. 53, č. 4, s. 1689–1696. Dostupné z DOI: [10.3758/s13428-020-01516-y](https://doi.org/10.3758/s13428-020-01516-y).
96. WICKHAM, Hadley; AVERICK, Mara; BRYAN, Jennifer; CHANG, Winston; MCGOWAN, Lucy D'Agostino; FRANÇOIS, Romain; GROLEMUND, Garrett; HAYES, Alex; HENRY, Lionel; HESTER, Jim; KUHN, Max; PEDERSEN, Thomas Lin; MILLER, Evan; BACHE, Stephan Milton; MÜLLER, Kirill; OOMS, Jeroen; ROBINSON, David; SEIDEL, Dana Paige; SPINU, Vitalie; TAKAHASHI, Kohske; VAUGHAN, Davis; WILKE, Claus; WOO, Kara; YUTANI, Hiroaki. Welcome to the tidyverse. *Journal of Open Source Software*. 2019, roč. 4, č. 43, s. 1686. Dostupné z DOI: [10.21105/joss.01686](https://doi.org/10.21105/joss.01686).
97. LÜDECKE, Daniel; BEN-SHACHAR, Mattan S.; PATIL, Indrajeet; WIERNIK, Brenton M.; MAKOWSKI, Dominique. easystats: Framework for Easy Statistical Modeling, Visualization, and Reporting. *CRAN*. 2022. Dostupné také z: <https://easystats.github.io/easystats/>. R package.

98. BUITINCK, Lars; LOUPPE, Gilles; BLONDEL, Mathieu; PEDREGOSA, Fabian; MUELLER, Andreas; GRISEL, Olivier; NICULAE, Vlad; PRETTE-NHOFER, Peter; GRAMFORT, Alexandre; GROBLER, Jaques; LAYTON, Robert; VANDERPLAS, Jake; JOLY, Arnaud; HOLT, Brian; VAROQUAUX, Gaël. API design for machine learning software: experiences from the scikit-learn project. In: *ECML PKDD Workshop: Languages for Data Mining and Machine Learning*. 2013, s. 108–122.