



ČESKÉ VYSOKÉ UČENÍ TECHNICKÉ V PRAZE

FAKULTA BIOMEDICÍNSKÉHO INŽENÝRSTVÍ

Katedra biomedicínské techniky

Hodnocení kognitivní zátěže v extrémním prostředí

Assessment of cognitive load in extreme environment

Diplomová práce

Studijní program: Biomedicínské inženýrství

Vedoucí práce: Mgr. Ksenia Sedova, Ph.D.

Bc. Marek Sokol

Kladno 2022

Prohlášení

Prohlašuji, že jsem bakalářskou práci s názvem „Hodnocení kognitivní zátěže v extrémním prostředí“ vypracoval/a samostatně a použil/a k tomu úplný výčet citací použitých pramenů, které uvádím v seznamu přiloženém k bakalářské práci.

Nemám závažný důvod proti užití tohoto školního díla ve smyslu §60 Zákona č.121/2000 Sb., o právu autorském, o právech souvisejících s právem autorským a o změně některých zákonů (autorský zákon), ve znění pozdějších předpisů.

V Kladně
.....
Bc. Marek Sokol

České vysoké učení technické v Praze

Fakulta biomedicínského inženýrství

© 2022 Bc. Marek Sokol. Všechna práva vyhrazena.

Tato práce vznikla jako školní dílo na Českém vysokém učení technickém v Praze, Fakultě biomedicínského inženýrství. Práce je chráněna právními předpisy a mezinárodními úmluvami o právu autorském a právech souvisejících s právem autorským. K jejímu užití, s výjimkou bezúplatných zákonných licencí a nad rámec oprávnění uvedených v Prohlášení na předchozí straně, je nezbytný souhlas autora.

Odkaz na tuto práci

Sokol, Marek. *Hodnocení kognitivní zátěže v extrémním prostředí*. Diplomová práce. Praha: České vysoké učení technické v Praze, Fakulta biomedicínského inženýrství, 2022. Dostupné z: www.github.com/.

Poděkování

Rád bych poděkoval vedoucí své bakalářské práce, Mgr. Ksenii Sedové, Ph.D. za odborné vedení práce, za pomoc, vstřícnost a rady při zpracování této práce. Dále bych rád poděkoval Ing. et Ing. Janu Hejdovi, Ph.D. za všeestrannou pomoc, množství cenných a inspirativních rad, podnětů a čas, který mi věnoval při řešení dané problematiky. V neposlední řadě děkuji své rodině a všem přátelům, kteří mě při vytváření této práce podpořili.

Abstrakt

Hodnocení kognitivní zátěže v extrémním prostředí:

Klíčová slova

Abstract

Assessment of cognitive load in extreme environment:

Key words

Obsah

Seznam symbolů a zkratek	8
1 Úvod	11
2 Přehled současného stavu	12
2.1 Extrémní prostředí	12
2.1.1 Vesmírné explorace	13
2.1.2 Analogové mise	14
2.1.3 Faktory prostředí a změny CNS	16
2.2 Kognitivní neurovědy	18
2.2.1 Terminologie	18
2.2.2 Kognitivní zátěž	19
2.2.3 Fyziologické projevy	19
2.2.4 Detekce kognitivní zátěže	21
2.3 Neuroviscerální integrace	22
2.3.1 Kognitivní regulace	25
2.4 Variabilita srdeční frekvence	26
2.4.1 Trendy v analýze HRV	27
2.4.2 Struktura HRV indexů	28
2.5 Periferní biosignály	29
2.5.1 Měření biosignálů	30
2.5.2 Postupy zpracování biosignálů	34
2.6 Strojové učení	36
2.6.1 Typy systémů strojového učení	36
2.6.2 Trénování a testování modelů	37
2.6.3 Optimalizace hyperparametrů	39
2.6.4 Kombinování modelů	40
2.6.5 Hodnocení modelů	40
2.6.6 Umělé neuronové sítě	40
3 Cíle práce	45
4 Metody	46
4.1 Mise DIANA	46
4.1.1 Projekt Hydronaut	46
4.1.2 Výběr posádky	46
4.1.3 Popis lokality a podmínky prostředí	46
4.1.4 Hlubinná laboratoř H03 DeepLab	46

4.1.5	Infrastruktura mise	46
4.1.6	Monitorování a měření posádky	46
4.1.7	Studie	46
5	Výsledky	47
6	Diskuse	48
7	Závěr	49
7.1	Budoucí práce	49
	Bibliografie	50

Seznam symbolů a zkratek

Seznam zkratek

Zkratka	Význam
ANN	Umělé neuronové sítě (Artificial neural networks)
ANS	Autonomní nervová soustava (Autonomic nervous system)
AURL	Podmořská Výzkumná Laboratoř (Aquarius Undersea Research Laboratory)
AV	Atrioventrikulární uzel
CAN	Centrální autonomní síť (Central autonomic network)
CeA	Centrální jádro amygdaly (Nucleus amygdalae centralis)
CL	Kognitivní zátěž (Cognitive load)
CLT	Teorie kognitivní zátěže (Cognitive load theory)
CNS	Centrální nervová soustava
CSA	Kanadská kosmická agentura (Canadian Space Agency)
CV	Křížová validace (Cross-validation)
CVLM	Kaudální ventrolaterální medulární jádro (Caudal ventrolateral medullary)
dACC	Dorzální anteriorní cingulární kůra (Dorsal anterior cingulate cortex)
DBSCAN	Hustotní prostorové shlukování aplikací s šumem (Density-based spatial clustering of applications with noise)
DT	rozhodovací stromy (Decision trees)
DVN	Dorzální vagové motorické jádro (Nucleus dorsalis nervi vagi)
EDA	Elektrodermální aktivita
EEG	Elektroencefalografie
EFA	Faktorová analýza (Exploratory factor analysis)
EKG	Elektrokardiografie
ESA	Evropská kosmická agentura (European Space Agency)
EVA	extravehikulární aktivita
FIU	Mezinárodní Univerzita na Floridě (Florida International University)
fMRI	Funkční magnetická rezonance
GD	Gradientní sestup (Gradient descent)

Zkratka	Význam
HDBR	Head-down bed rest
HDBSCAN	Hierarchické hustotní prostorové shlukování aplikací s hlukem (Hierarchical density-based spatial clustering of applications with noise)
HR	Srdeční rytmus (Heart rate)
HRV	Variabilita srdeční frekvence (Heart rate variability)
ICE	Izolované, stísněné a extrémní prostředí (Isolated, confined and extreme environment)
IML	Visceromotorická jádra v segmentech C7–L2 (Nucleus intermediolateralis)
LDA	Gradientní sestup (Linear discriminant analysis)
LEO	Nízká oběžná dráha (Low-earth orbit)
ML	Strojové učení (Machine learning)
mPFC	Mediální prefrontální kůra (Medial prefrontal cortex)
MRI	Magnetická rezonance
NA	Somatomotorické jádro pro n. IX a X. (Nucleus ambiguus)
NASA	Americký Národní úřad pro letectví a vesmír (National Aeronautics and Space Administration)
NEEMO	Operace NASA v extrémním prostředí (NASA Extreme Environment Mission Operations)
NNX0	Počet párů sousedních N–N intervalů, které se od sebe liší o více než Xms (Number of times successive heartbeat intervals exceed Xms)
NPF	Neuropsychofyziologie
NTS	Jádro solitárního traktu (Nucleus tractus solitarius)
NVI	Neuroviscerální integrace (Neurovisceral integration)
pACC	Pregenuální přední cingulární kůra (Pregenual anterior cingulate cortex)
PCA	Analýza hlavních komponent (Principal component analysis)
pCC	Posteriorní cingulární kůra (Posterior cingulate cortex)
pNNX0	Poměr NNX0 k počtu všech N–N intervalů (Proportion of NNX0 divided by the total number of N–N)
PNS	Parasympatický nervový systém
PPG	Fotopletysmografie (Photoplethysmography)

Zkratka	Význam
RMSSD	Odmocnina průměru umocněných rozdílů po sobě jdoucích N–N intervalů (Root mean square of the successive differences)
RSP	Respirace
RVLM	Rostrální ventrolaterální medulární jádro (Rostral ventrolateral medullary)
SA	Sinoatriální uzel
SCL	Úroveň kožní vodivosti (Skin conductance level)
SCR	Odezva kožní vodivosti (Skin conductance response)
SNS	Sympatický nervový systém
SOM	Samoorganizující mapy (Self organizing maps)
SVM	Gradientní sestup (Support vector machines)
SWT	Stacionární vlnková transformace (Stationary wavelet transform)
TPJ	Temporoparietální spojení
tSNE	t-distribuované stochastické vkládání sousedů (t-distributed stochastic neighbor embedding)
UMAP	Uniform Manifold Approximation and Projection
ZC	Průchod nuly (Zero crossing)

KAPITOLA 1

Úvod

Sledování a hodnocení kognitivní zátěže v extrémním prostředí, jako je například vesmír, je nesmírně důležité pro zajištění bezpečnosti a úspěchu jednotlivců a týmů působících v takovém prostředí během náročných a důležitých úkonů. Monitorování kognitivních funkcí pomocí tradičních metod, jako je dotazníkové hodnocení nebo behaviorální analýza, může být v izolovaném, uzavřeném a extrémním prostředí nepraktické až neproveditelné kvůli například komunikačním a časovým omezením. Proto čím dál více vzrůstá zájem o využití periferních biosignálů, jako je například elektrická srdeční aktivita nebo kožní vodivost, k hodnocení kognitivní zátěže v reálném čase. Interpretace těchto biosignálů v souvislosti s kognitivní zátěží je však nejasná a náročná vzhledem k tomu, že se do periferních biosignálů promítají veškeré kognitivní funkce.

Klíčem k pochopení by mohla být inkorporace komplexního modelu neuroviscerální integrace, který předpokládá, že autonomní nervový systém hraje klíčovou roli v regulaci kognitivních procesů a poskytuje teoretický rámec pro pochopení vztahu mezi periferními biosignály s kognitivní zátěží. Obecně tento model předpokládá, že kognitivní zátěž několikaúrovňově moduluje aktivitu autonomního nervového systému, což vede ke změnám periferní fyziologie.

Navzdory potenciálu periferních biosignálů jako indikátorů kognitivní zátěže v extrémních prostředích nadále zůstává při interpretaci jejich vlastností několik problémů. Patří mezi ně individuální rozdíly v charakteru biosignálů, vliv faktorů prostředí a nedostatečná standardizace sběru a analýzy dat. Řešení těchto problémů je zásadní pro vývoj spolehlivých a platných metod kognitivní zátěže.

Tato práce se zabývá využitím periferních biosignálů pro hodnocení kognitivní zátěže v extrémním prostředí. Konkrétně analyzovanými periferními biosignály jsou srdeční, elektrodermální a respirační aktivita. Dále se také práce zabývá s problémy spojenými s interpretací příznaků vybraných biosignálů a navrhoje možná řešení k jejich překonání v souvislosti s modelem neuroviscerální integrace.

Přehled současného stavu

Přehled současného stavu je nejprve věnován popisu extrémního prostředí a jeho vlivu na neuropsychofyziologii (NPF) člověka. Dále je na tuto oblast navázáno popisem kognitivní zátěže (CL) v dílkách kapitole kognitivních neurověd, která společně s navazujícími kapitolami o neuroviscerální integraci a variabilitě srdečního rytmu tvoří důležitou část problematiky ročníkového projektu a diplomové práce. Následně jsou blíže rozebrány periferní biosignály využité v rámci této práce, způsoby jejich měření a zpracování. Jejich znalost a informační obsah jsou nezbytnými kritérii pro hodnocení kognitivní zátěže. Závěr kapitoly tvoří náhled do vybraných teoretických základů strojového učení.

2.1 Extrémní prostředí

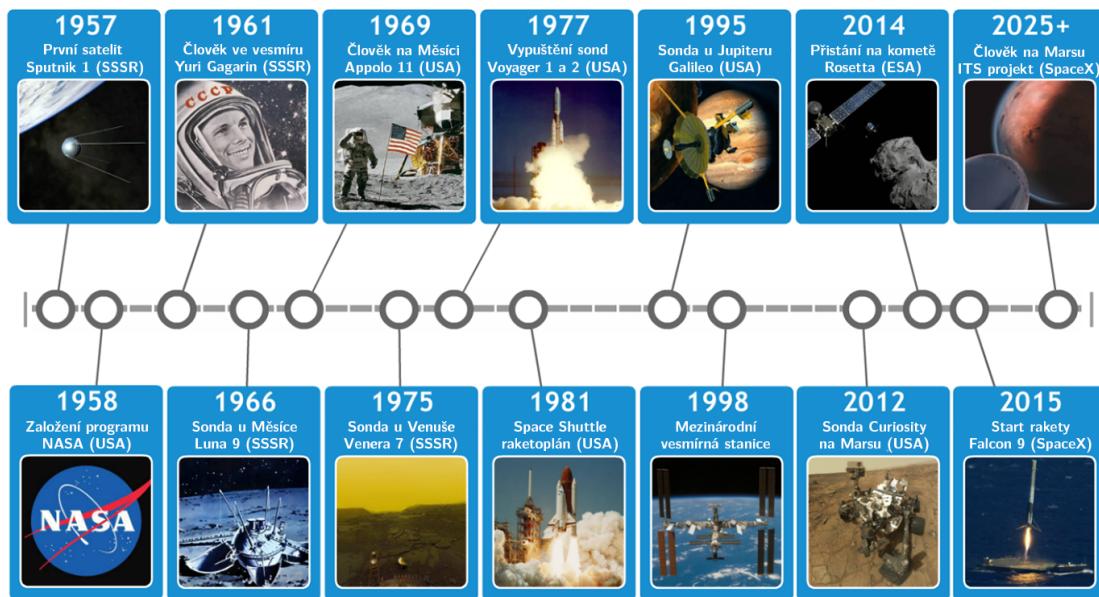
Vzhledem k nejednoznačné definici pojmu „*extrémní prostředí*“ je potřeba stanovit vhodnou interpretaci v souvislosti s problematikou této práce. Mezi rané definice přispěli Harrison a Connors [1], kteří publikovali, že extrémní prostředí se vyznačuje nebezpečnými a nepřívětivými klimatickými, životními nebo pracovními podmínkami a možnou sociální izolací. Bell et al. [2] definovali extrémní situace jako okolnosti, za kterých má nedostatečný výkon, ať už mentální nebo fyzický, vážné následky (např. časová tíseň, nebo nebezpečí). Všechny tyto koncepty se týkají náročných fyzických nebo mentálních výkonnostních situací, na které se pojí další již formulované pojmy jako krizové situace [3, 4], psychický a fyzický nátlak [5] nebo stres [6]. Další formulace byly již uvedeny v [7–9]. V této práci je na definici extrémního prostředí nahlíženo jako na izolované atypické prostředí, v němž jsou kladený značné nároky na plněné úkoly, které s sebou nesou vysokou míru rizika a katastrofické důsledky při chybném či nedostatečném výkonu.

Současně studie se v rámci tématiky extrémního prostředí často zabývají vlivem izolovaného a stísněného prostředí (ICE, isolated, confined, and extreme) na člověka [9, 10] nebo vlivem různorodých environmentálních podmínek [11–13]. Do výzkumu

v této oblasti se začalo aktivně přispívat kolem první poloviny 20. století, což bylo podmíněno vědecko-technologickým pokrokem. Mezi hlavní iniciační milníky patřil vojenský zájem o dlouhodobé ponory jaderných ponorek, na který navázal podvodní výzkum [14, 15], vznik vesmírných programů (vesmírný závod) a polární výzkum [16, 17]. Pro potřeby této práce je dále detailněji rozebráno extrémní prostředí z hlediska vesmírné explorace, konkrétně dlouhodobých vesmírných letů a analogových vesmírných misí.

2.1.1 Vesmírné explorace

Za hlavní hnací historický faktor, který posouval vědecko-technickou sféru v rámci výzkumu vesmíru rychle kupředu lze považovat tzv. vesmírný závod, jenž začal vypuštěním družice Sputnik 1 Sovětským svazem v roce 1957. Rok poté byl založen Americký Národní úřad pro letectví a vesmír (NASA), což vedlo k prvním vesmírným misím, kterých se později účastnily i posádky. Byl tak vytvořen nový prostor a vzbuzen výzkumný zájem v oblasti analogových vesmírných misí, jelikož otázky ohledně průzkumu vesmíru odhalily spoustu vědomostních nedostatků potřebných pro úspěšný pobyt v kosmu [15]. Nejedná se však ani tolik o technické překážky, ale o nedostatky zejména v oboru neurověd a experimentálního nastavení.



Obrázek 2.1: Časová osa výzkumu vesmíru od Sputniku po Mars (Přeloženo a převzato z [18])

Vzhledem k tomu, že budoucnost výzkumu vesmírné explorace sahá za hranice oběžné dráhy Země [19, 20], je třeba brát v úvahu obtíže budoucích misí, které se budou primárně týkat člověka. Dlouhodobé kosmické lety a mise jsou předmětem mnoha zásadních okolností, jež kladou vysoký a rizikový neuropsychofyziologický nátlak [21]. Extrémní prostředí, komunikační latence a problémy nebo fyziologické

změny vlivem vesmírných aspektů [22–24] mohou během dlouhodobých misí překračovat lidské psychické i fyzické hranice a vést ke katastrofickým následkům [21, 25]. Toto riziko se uplatňuje i přestože se v těchto případech skládají posádky z vybraných trénovaných jedinců (astronautů). Stresory, vnitřní nebo vnější stimuly vznikající při vystavení lidského organizmu mimořádným podmínkám (extrémnímu prostředí) při dlouhodobých vesmírných letech, již popsal Morphew [26]. Zdravotní a výkonnostní rizika lze řešit právě výběrem a výcvikem posádky nebo například návrhem mise a vybavení. Naskytuje se ale také možnost tato rizika predikovat s využitím diagnostických neinvazivních metod, jako funkční magnetická rezonance (fMRI), elektrokardiografie (EKG) aj., spolu s širokými znalostmi lidského nervového systému. Je tedy třeba realizovat experimenty, které pomohou lépe chápout, ne-li přímo definovat NPF vztahy při vlivu extrémního prostředí. Takové experimenty však nemohou probíhat za normálních laboratorních podmínek, jelikož se nejedná o prostředí, které by odráželo skutečné provozní podmínky a účinně napodobilo kosmickou misi [10, 21].

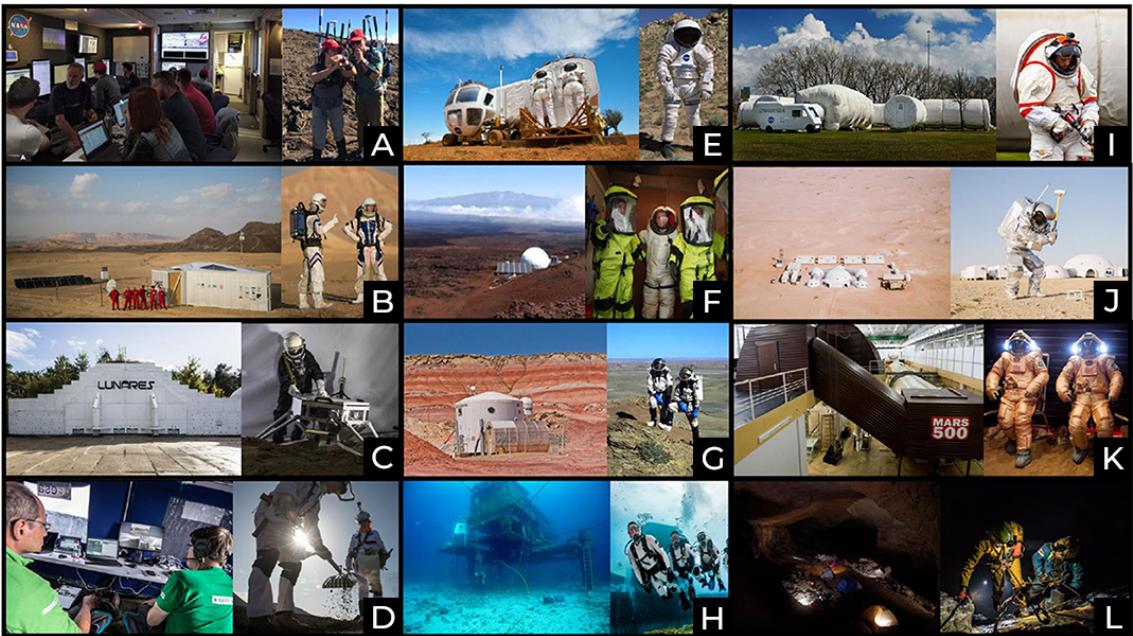
Ke studiu neuropsychofyziologických adaptací člověka vystavenému mikrogravitaci se využívají data zaznamenaná před a po vesmírném letu, kde se také sledují změny jako distribuce tělesných tekutin, hustota kostí nebo úbytek svalové hmoty [27]. Kromě mikrogravitace lze ale mnoho vědeckých otázek týkajících se kognitivních neurověd zodpovědět na Zemi díky vesmírným analogovým misím, které simulují komplexní interakce vznikající během vesmírných misí [10, 21].

2.1.2 Analogové mise

Jak již bylo zmíněno, laboratorní experimenty plně nereprezentují reálné podmínky dlouhodobých kosmických misí, avšak různá analogová prostředí (analogové mise) přinášejí právě tu možnost sledovat a zkoumat NPF člověka v jedinečných situacích [21]. Situace, které napodobují reálné okolnosti budoucích vesmírných misí – přistání kosmické lodi, extravehikulární aktivity (EVA), lékařské zádkroky aj. – vystavují jedince pozorovatelným změnám například v cirkadiáním¹ rytmu, hladinách stresových hormonů, imunitních funkcích nebo neurokognitivním změnám [10, 11]. Faktory prostředí a jejich vliv na NPF jsou detailněji popsány v následující kapitole.

Přehled několika analogových misí, na jejichž vzniku a vývoji se převážně podílejí: Evropská kosmická agentura (ESA), Státní korporace pro kosmické aktivity (ROSCOMOS), Kanadská kosmická agentura (CSA) a NASA, lze vidět na obrázku 2.2. Každá analogová mise vnikla primárně pro simulaci a studium určitých vlivů vesmírných podmínek nebo k testování specifického vybavení. Antarktické mise slouží k testování astrobiologických hypotéz [21] a studiu dopadů izolace na člověka

¹Cirkadiánní rytmus je biologický rytmus s cyklem trvajícím přibližně jeden den.



Obrázek 2.2: Příklady analogových misí. **(A)** NASA BASALT (USA), **(B)** D-MARS (Izrael), **(C)** LUNARES (Polsko), **(D)** ESA/PANGEA (Španělsko), **(E)** NASA/D-RATS (USA), **(F)** HI-SEAS (USA), **(G)** Mars Desert Research Station (USA), **(H)** NASA/NEEMO (USA), **(I)** NDU Habitat (USA), **(J)** OeWF/AMADEE-program (Rakousko, Omán), **(K)** Mars-500 (Rusko), **(L)** ESA/CAVES (Španělsko/Itálie). (Upraveno a převzato z [28])

během extrémních podmínek, které jsou dané drsným polárním podnebím a rozsáhlou tundrou [29, 30]. Významnou misí je projekt Mars-500, kde byla šestičlenná posádka uzavřena 520 dní v napodobenině kosmické lodi pro účely simulace vesmírného letu na Mars. Během této mise došlo k řadě experimentů, které se například zabývaly vlivem fyzického cvičení na aktivitu prefrontální kortextu a kognitivní výkonnost [31] nebo změnami nálady a plazmatických hladin hormonů [32]. Na základě problematiky této práce jsou nadále popsány vybrané podvodní analogové mise.

Projekt NEEMO

Operace NASA v extrémním prostředí neboli NEEMO (NASA Extreme Environment Mission Operations) jsou analogové vesmírné mise, které probíhají v Mezinárodní Univerzitní Podmořské Výzkumné Laboratoři na Floridě (Florida International University's Aquarius Undersea Research Laboratory, FIU AURL). Podvodní laboratoř s rozlohou zhruba 43 m^2 , umístěná 19 m pod mořskou hladinou přesně nenapodobuje vesmírné podmínky ale stresové faktory spojené s bezpečností, komunikací a technologickou logistikou při dlouhodobých kosmických letech a průzkumu ano. Zároveň zde probíhají testy vybavení a trénování výstupu do vesmíru mimo kosmickou loď [33, 34]. Poslední mise v podvodní laboratoři, NEEMO 23, proběhla v červnu 2019 a byla primárně zaměřena na průzkumné výstupy do vesmíru.



Obrázek 2.3: Podvodní habitat AURL [35]



Obrázek 2.4: Hydronaut H03 DeepLab [36]

Projekt Hydronaut

Skromnější verze mobilního podvodního habitatu vznikla i v České Republice za účelem výcviku astronautů Evropské kosmické agentury. Projekt byl představen roku 2010 a jeho primárním cílem bylo umožňovat menším posádkám dlouhodobý pobyt v hyperbarickém ICE prostředí a simulaci vesmírných scénářů pro potřeby výzkumu. Podvodní stanice Hydronaut je také plně mobilní a lze měnit její umístění. Současná stanice (H03 DeepLab) je vybavena několika systémy pro sledování stavu habitatu a posádky. Jedním ze systémů je Common Tongue, který umožňuje nejen komunikaci s posádkou ale také sledování fyziologických funkcí. V roce 2020 proběhla desetidenní mise (Mission One), která včetně účelů kosmického ICE výzkumu sloužila jako zátěžový test habitatu [37].

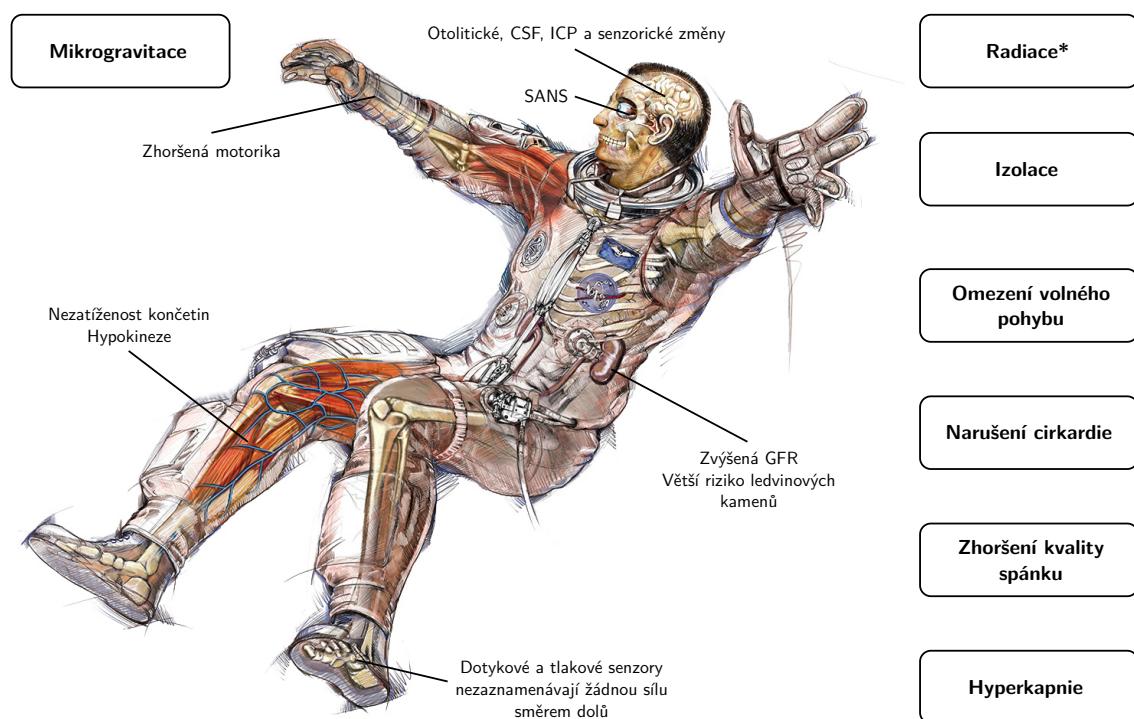
2.1.3 Faktory prostředí a změny CNS

Vzhledem k tomu, že vesmír je jedinečné prostředí, je studium změn CNS člověka souvisejících s kosmickými misemi obtížné. Předchozí studie ukázaly, že po letu do vesmíru dochází ke změnám ve vnímání, pohybu, koordinaci a kognici [38]. Mikrogravitace je jedním z hlavních faktorů, které ovlivňují mozek včetně kosmického záření (radiace), izolace nebo hyperkapnie [24]. Důsledky působení mikrogravitace na mozek popsal Torre v [39]. Souhrn faktorů lze vidět na Obrázku 2.5 a jejich počet nasvědčuje, že pozorované NPF změny u astronautů mohou být důsledkem kombinace více stresorů na jednotlivé oblasti mozku [24].

Nedávné MRI studie poukázaly na změny polohy mozku, objemu tkáně, objemu mozkových komor, distribuce a dynamiky mozkomíšního moku, mikrostruktury tkáně a funkční konektivity po letu do vesmíru [40–44]. Přehled MRI studií provedených na amerických astronautech a ruských kosmonautech před a po kosmickém letu se zjištěnými poznatkami byl vypracován v [24]. Mezi tyto studie jako jeden z prvních

přispěl Demertzi et al. [43] s objevem snížené konektivity v pravé insule², který se podílí na vestibulárním zpracování a kognitivní kontrole.

Neurozobrazovací studie na zvířecích modelech a lidech vystavených analogovým vesmírným letům prokázaly změny mozku související s reálným kosmickým letem [44, 45]. Analogové vesmírné mise nacházejí tedy uplatnění při zkoumání vlivů stresorů spojených s vesmírným prostředím na centrální nervovou soustavu (CNS). Při srovnání změn CNS souvisejících s kosmickou misí se změnami pozorovanými u pozemských analogů se naskytuje příležitost do budoucna navrhnout strategie a opatření, které by předcházely nežádaným NPF účinkům. Během analogových misí se podařilo reprodukovat například zjištění spojené se změnami mozkové konektivity, objemu šedé hmoty, dynamiky mozkomíšního moku a objemu mozkových komor [24]. Metoda, která věrně napodobuje podmínky kosmických letů vystavováním subjektů posunu tělních tekutin, odlehčení axiálního tlaku nebo hypokinezii, se nazývá Head-Down Bed Rest (HDBR). Subjekt je během metody na lůžku hlavou dolu, pod určitým náklonem. HDBR zároveň vyvolává podobné změny v mozkové konektivitě, včetně změny konektivity motorických, somatosenzorických a vestibulárních oblastí mozku jako při vesmírných letech [46, 47].



Obrázek 2.5: Souhrn stresových faktorů vesmírného ICE prostředí, které mohou ovlivnit mozek během kosmického letu. Radiace* v tomto případě odkazuje na radiaci v otevřeném kosmickém prostoru, nikoli na nízké oběžné dráze (LEO). (Upraveno a převzato z [24, 48] se souhlasem Beaua Danielse)

²Insula neboli insulární kortex je složitá struktura s rozsáhlou sítí korových a podkorových oblastí mozku, které slouží smyslovým, emočním a kognitivním funkcím.

Mozek je kromě fyziologických stresorů ovlivněn také dlouhodobým pobytom v ICE prostředí. Po 520denní misi Mars-500 ukázaly snímky participantů pozměněnou mikrostrukturu šedé hmoty v pravém temporoparietálním spojení³ (TPJ), což je přisuzováno vlivu izolovaného prostředí [49]. Během dlouhodobých vesmírných misí mohou mít změny TPJ za následek zhoršení neuropsychofyziologické adaptace člověka na nové ICE prostředí. Další nežádoucí změny byly prokázány v rámci studií antarktických expedic, které demonstrovali snížení objemu šedé hmoty v orbitofrontální kůře, prefrontální kůře a hipokampusu. Vzhledem k povaze antarktického prostředí a expedic lze usuzovat, že jsou tyto změny podmíněné také vlivem ICE [50]. Možné snížení neurogeneze hipokampu vlivem extrémního prostředí může mít vliv na paměť a sociální interakci členů posádky [24]. Délka kosmické mise či letu také hráje rozdíl, jelikož větší míra změn struktury mozku byla pozorována u dlouhodobých vesmírných misí [42].

2.2 Kognitivní neurovědy

Lidský mozek je schopen se neustále přizpůsobovat měnícím se okolnostem a požadavkům prostředí. Astronauti se musí aklimatizovat na zcela nové prostředí podobně jako malé děti procházejí svými vývojovými fázemi. V podmírkách stavu beztíže nebo mikrogravitace dochází mimo jiné k ovlivnění mozkových procesů. Cílem kognitivních neurověd ve vesmíru je pochopit, jak mozek a mysl reagují na tyto jedinečné okolní podmínky. První výzkumy v oblasti neurověd ve vesmíru byly provedeny v roce 1962 během ruské mise Vostok-3. Na Zemi je oproti vesmíru možné díky neurozobrazovacím technikám snadno studovat mozkovou aktivitu a kognitivní funkce. Pro neurovědce i psychology je velmi důležité pochopit základní neurokognitivní a neuropsychologické aspekty kosmického letu. Neefektivní mentální výkon jedince či posádky je známou hrozbou pro vesmírné mise. Pozemský výzkum zdůrazňuje nutnost porozumět kognitivním procesům, jelikož CL zhoršuje kognitivní a percepční motorické schopnosti. Srovnatelné dopady lze předpokládat i při vesmírných misích v náročných ICE podmírkách a simulacích (analogové mise) [39]. Pro potřeby diplomové práce je rozsáhlá kapitola kognitivních neurověd vymezena popisu kognitivní zátěže.

2.2.1 Terminologie

Obor kognitivních neurověd se nachází na pomezí psychology a neurověd, ale překrývá se s dalšími obory jako kognitivní a biologická psychology, fyziologie nebo neuropsychologie. Tyto obory často studují podobné procesy ale z jiného pohledu a pomocí jiné metodiky. Synonymem oblasti kognitivních neurověd byl v této

³Temporoparietální spojení je část mozku, kde se setkávají spánkový a temenní lalok.

práci zvolen termín neuropsychofyziologie pro usnadnění popisu fyziologických změn v důsledku kognitivních procesů. Cílem této práce není rozlišovat mezi jednotlivými obory ale zaměřit se na vědecké otázky z jejich průniků, které jsou spojené s vlivem ICE prostředí na člověka.

2.2.2 Kognitivní zátěž

Prvotní pojetí kognitivní zátěže (CL, Cognitive Load) pochází z oblasti výuky a vzdělávání, kterou se intenzivně zabýval Sweller et al. [51–53] kolem přelomu 19. a 20. století. Sweller [51] jako první formuloval teorii kognitivní zátěže (CLT, Cognitive Load Theory), podle které je CL definována jako zvýšené požadavky na ukládání a zpracování informací v pracovní paměti člověka. Chen et al. [54] definoval kognitivní zátěž jako proměnnou, jež určuje míru požadavků kladených úkolem na dostupné mentální zdroje pro zpracování informací. Míra požadavků vychází z vnímané námahy při učení, myšlení a uvažování jakožto ukazatel zatížení pracovní paměti během plnění úkolu. Tato míra zároveň popisuje interakce mezi nároky na zpracování úkolu a lidskou mentální výkonností [55]. Ačkoli se definice kognitivní zátěže v jednotlivých oborech mohou lišit, všechny mají jeden základní prvek: procento využité kapacity lidské pracovní paměti. Na rozdíl od naší smyslové a dlouhodobé paměti, které mohou v podstatě neomezeně zpracovávat informace, je tato kapacita omezená [56].

Chen et al. [54] publikoval, že vysoká kognitivní zátěž (kognitivní přetížení) může mít negativní dopad na výkonnost pracovní paměti. Vliv kognitivní zátěže zároveň ovlivňuje mozkové procesy a kognitivní přetížení pravděpodobně bezprostředně předchází vyhoření [56]. Většina kognitivních funkcí, jako je například selektivní pozornost nebo sebekontrola, závisí na pracovní paměti. Pracovní paměť zahrnuje aktivní krátkodobé ukládání, zpracování a manipulaci s informacemi a její efektivní fungování je kriticky závislé na inhibičních nervových procesech. Nervové středisko pracovní paměti sestává hlavně z distribuované sítě struktur zahrnující prefrontální kortex jako důležité ohnisko. Variabilita srdeční frekvence (HRV) souvisí s aktivitou prefrontální kůry a je inverzně spojena s aktivitou subkortikálních struktur jako je amygdala [57]. Vliv kognitivní zátěže se také promítá do elektrodermální (EDA) a respirační (RSP) aktivity [21]. Díky periferním biologickým signálům se tedy naskytuje jednoduší možnost hodnocení či predikce kognitivních procesů bez nutnosti použití realizačně a finančně náročnějších neurozobrazovacích metod nebo elektroencefalografie (EEG). Detailněji jsou fyziologické změny spojené s vlivem CL popsány v následující sekci.

2.2.3 Fyziologické projevy

Z předchozího textu již může být zřejmé, že kognitivní zátěž je velmi úzce spojená s fyziologickými změnami v lidském organismu. U jedince, kde dojde k stimulaci CL,

může docházet k řadě změn, například v mozkové aktivitě, krevním tlaku, srdečním rytmu, rychlosti pulzní vlny, dýchaní nebo činnosti potních žláz [55–60]. Vybrané fyziologické funkce, do kterých se po promítá kognitivní zátěž, jsou společně s jejich krátkým popisem a neurobiologickým vztahem uvedeny v Tabulce 2.1. Tabulka zároveň poukazuje na rozdílné vztahy fyziologických parametrů s kognitivní zátěží.

Tabulka 2.1: Přehled vybraných nejčastěji studovaných fyziologických změn a stručné teoretické zdůvodnění jejich souvislosti s kognitivní zátěží (Upraveno a převzato z [56])

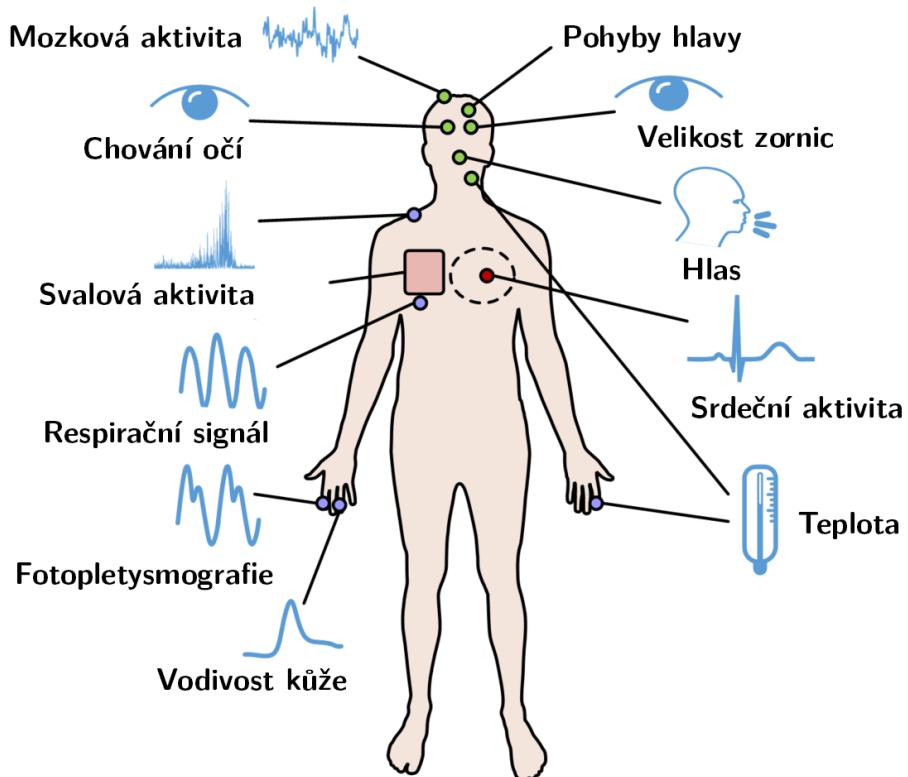
Fyziologická funkce	Stručný popis a teoretické zdůvodnění předpokládaného vztahu mezi fyziologickým měřením a kognitivní zátěží
EEG	<p><i>Popis:</i> EEG umožňuje měřit mozkovou aktivitu neinvazivně. Provedení spektrální analýzy naměřených rozdílů elektrických potenciálů umožnuje analyzovat výkon různých frekvenčních pásem, která jsou v signálu</p> <p><i>Hypotéza:</i> Zvýšení kognitivní zátěže lze měřit zvýšením mozkové aktivity, tj. oscilací v určitém frekvenčním pásmu s větší amplitudou [61]</p>
Eye-tracking	<p><i>Popis:</i> Měření průměru zornice, latence mrknutí a charakteristik sakád</p> <p><i>Hypotéza:</i> Sledování očí bylo v předchozích studiích spojeno s kognitivní zátěží prostřednictvím neurobiologických mechanismů, jako je inervace neuronů autonomního nervového systému radiálními vlákny duhovky [62]</p>
EDA	<p><i>Popis:</i> Elektrodermální aktivity, hodnotí elektrické charakteristiky kůže, aby bylo možné odvodit změny vlivem sympatického nervového systému.</p> <p><i>Hypotéza:</i> Kognitivní zátěž má vliv na stres nebo vzrušení a vede ke zvýšení kožní vodivosti [63]</p>
Teplota pokožky	<p><i>Popis:</i> Měření teploty vnějšího povrchu lidského těla</p> <p><i>Hypotéza:</i> Kognitivní zátěž má vliv na stres nebo vzrušení a vede k vazokonstrikci, což snižuje teplotu kůže [64]</p>
EKG	<p><i>Popis:</i> Srdeční frekvenci a variabilitu srdeční frekvence lze hodnotit pomocí elektrokardiogramu nebo fotopletysmografie</p> <p><i>Hypotéza:</i> Tepová frekvence je měřítkem aktivity sympatického i parasympatického autonomního nervového systému. Stres nebo vzrušení způsobí zvýšení krevního tlaku a snížení variability srdeční frekvence [65, 66]</p>
RSP	<p><i>Popis:</i> Kognitivní zátěž vede ke zrychlenému dýchání a vyšší minutové ventilaci, přičemž dechová amplituda zůstává stejná</p> <p><i>Hypotéza:</i> Při soustředění pozornosti nebo plnění náročného úkolu dochází ke změnám v dýchání [67]</p>

Příkladem rozdílností může být EEG, u kterého je vztah s kognitivní zátěží přímější než u srdeční nebo elektrodermální aktivity. Hodnocení pomocí tohoto biosignálu je tedy v některých případech spolehlivější. Pouze v některých, protože se vychází z předpokladu, že veškeré změny v kognitivních funkcích člověka se odrážejí v jeho fyziologii [56]. To znamená, že žádná měřící technika nemůže sama o sobě zachytit všechny aspekty kognitivních funkcí nebo o nich jednoznačně vypovídat. Problematika těchto vztahů je nadále rozebírána v kapitole 2.3. Na tuto vícerozměrnou povahu kognitivní zátěže poukázal Kramer et al. [68]. Dále definoval kritéria: citlivost, diagnostičnost, rušivost, spolehlivost a obecnost použití, v rámci kterých bude mít každé fyziologické měření jinou povahu. V případě kognitivní zátěže a její spolehlivém hodnocení z fyziologických projevů je proto vhodný multimodální⁴ přístup, který může poskytnout její robustnější reprezentaci [54].

⁴Multimodálním přístupem je myšleno využití více biosignálů.

2.2.4 Detekce kognitivní zátěže

Detekce kognitivní zátěže pomocí periferních biosignálů patří mezi tři nejčastěji používané způsoby včetně subjektivního hodnocení a hodnocení založené na výkonnosti jedince. Subjektivní hodnocení vychází z předpokladu, že hodnocený subjekt je schopen vnímat své vlastní kognitivní procesy a informovat o případné kognitivní zátěži nebo o množství vynaloženého mentálního úsilí [69, 70]. K subjektivnímu hodnocení se dále využívají specifické dotazníky, mezi které patří například NASA-TLX. Jedná se o vícerozměrnou stupnici používanou k měření pracovní zátěže operátorů v rámci úkonů, například během vesmírných analogových misí [71]. Tyto metody ale nejsou předmětem této práce a již byly detailně popsány v [70].



Obrázek 2.6: Vybrané proměnné související s CL (Přeloženo a převzato z [72])

Na kognitivní zátěž lze nahlížet jako na multidimenzionální konstrukt, který reprezentuje zátěž vyvinutou na jedince [69]. Zároveň se efekt stimulace kognitivních funkcí u každého jedince projevuje jinak. Nelze tedy vytvořit žádnou univerzální metodu, která by byla schopná stejně spolehlivě detektovat kognitivní zátěž u různých subjektů. Proto se v tomto odvětví nabízí a velmi často využívají metody strojového učení v rámci kterých nachází výhodné uplatnění dříve zmíněný multimodální přístup. Biologická data využívaná pro účely detekce CL lze vidět na Obr. 2.6.

Vzhledem k tomu, že je strojové učení širokou oblastí, byla tomuto tématu věnována samostatná sekce 2.6. Od roku 2010 je hojně využívána metoda učení s učitelem (viz 2.6.1.1) pro účely klasifikace různých patologických stavů a

symptomů [73]. Nejčastěji využívaným biosignálem je srdeční aktivita, konkrétně variabilita srdeční frekvence, které se často používá v kombinaci s elektrodermální aktivitou [69]. Použité příznaky pro klasifikaci (anglicky features) však hrají důležitou roli při rozlišování základní funkce spojené s jakýmkoli fyziologickým signálem. Z variability srdeční frekvence je v současnosti možné vypočítat desítky parametrů, resp. příznaků, se kterými je v těchto úlohách nutné velmi opatrně zacházet. Jednotlivé HRV parametry společně s jejich pravděpodobným významem byly již popsány v [55, 74–76]. Blíže je problematika HRV parametrů popsána v samotné podkapitole 2.4.2.

Dříve mezi často používané metody pro účely klasifikace patřili hlavně rozhodovací stromy (DT), lineární diskriminační analýza (LDA) nebo metoda podpůrných vektorů (SVM) [73]. Od roku 2018 se ve výzkumu HRV však stále častěji používá hluboké učení, jehož cílem je zlepšit automatickou klasifikaci v reálném čase. Tyto techniky poskytují efektivnější způsob extrakce relevantních informací a zvyšují přesnost klasifikace a současně snižují počet příznaků potřebných pro klasifikaci v reálném čase [77, 78]. O rok později se stalo novým trendem používání technik učení bez učitele pro klasifikaci psychického stresu s využitím technologie autoenkodéru [79]. Dále se mimo jiné začaly hojně používat samoorganizující mapy (SOM), které dokáží efektivně redukovat dimenzionalitu dat a zároveň indikovat nejcennější⁵ příznaky pro klasifikaci kognitivní zátěže s vysokou přesností [80]. Jelikož ale neexistuje žádný konsensus jak předzpracovávat biosignály, jaké využít příznaky nebo z jaké metodiky pro detekci CL vycházet, tak se stále zkouší nejasné variace různých algoritmů se snahou zvýšit skóre predikce. Velkým problémem je také nedostatek veřejně dostupných dat pro tyto účely.

2.3 Neuroviscerální integrace

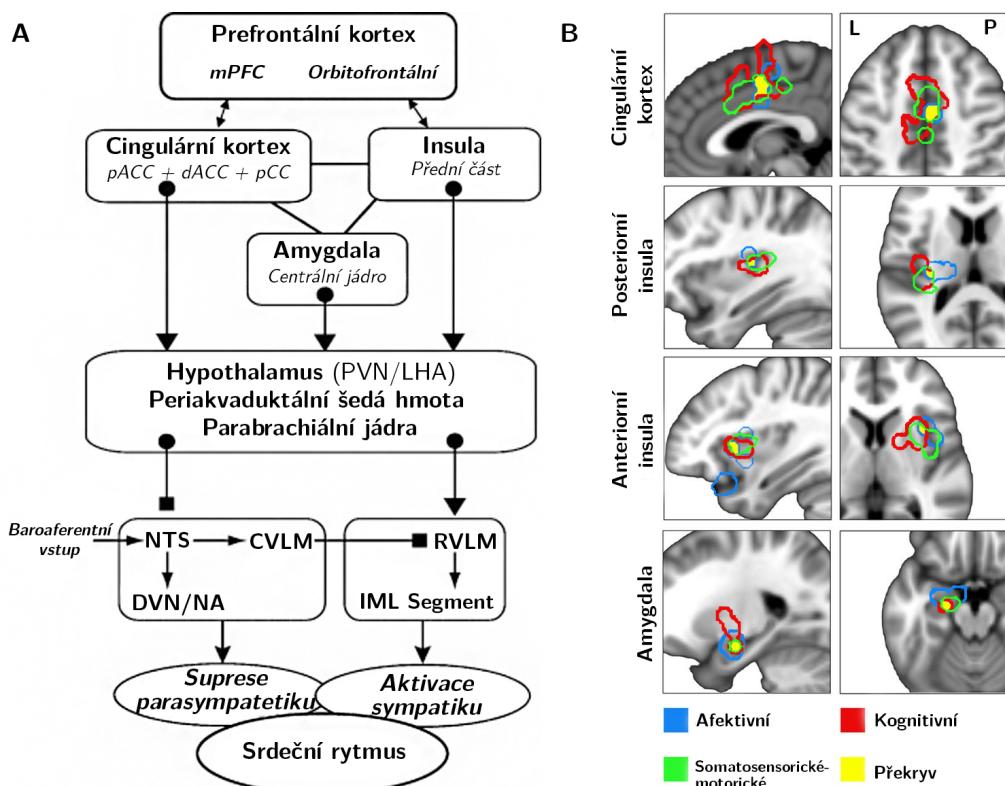
Z minulých kapitol vyplývá, že se veškeré kognitivní funkce člověka promítají zároveň do těch fyziologických. Většina studií, které se věnují detekci a hodnocení kognitivní zátěže však tento větší kontext nebere v úvahu. Díky tomu je nedostatek systematického porovnávání indexů HRV (viz následující kapitola 2.4), což činí interpretaci a vyhodnocování výsledků zdlouhavým a sporným. Problémem je také samozřejmě dříve zmíněný nedostatek dat. Tato kapitola slouží k zasazení úlohy této práce do širšího obrazu a zároveň pro zdůraznění důležitosti problematiky samotné. Dále je zde uveden přehled srdečních regulačních mechanismů v rámci stimulace mozku a úvod do oblasti variability srdečního rytmu.

V současné době existuje mnoho studií, které vypovídají o tom, že parasympatický neboli vagový tonus, souvisí s psychologickými a behaviorálními proměnnými i zdravotním stavem. Studie například odhalily velký počet konzistentních zjištění,

⁵Implikuje jak moc přispívá každý příznak k predikci modelu.

která ukazují, že jedinci s vyšší variabilitou srdeční frekvence mají větší schopnosti v oblasti regulace emocí [81–86] a dosahují lepších výsledků v kognitivních úkolech zahrnujících pozornost, pracovní paměť a inhibiční kontrolu [57, 87–89]. Pokud bychom kategorizovali HRV pouze na dvě úrovně, vyšší a nižší, tak lze postupem let pozorovat množství poznatků z hlediska prognostického významu:

- **vyšší HRV** — *lepší regulace glukózy, lepší funkce osy hypothalamus-nadledviny-hypofýza (HPA), snížení zánětu a snížení rizika mrtvice, kardiovaskulárních onemocnění a úmrtnosti ze všech příčin* [90–93]
- **nižší HRV** — *afektivní poruchy, deprese a úzkost, špatná kardiovaskulární kondice, vyšší riziko infarktu, zvýšená kognitivní zátěž* [94–96]



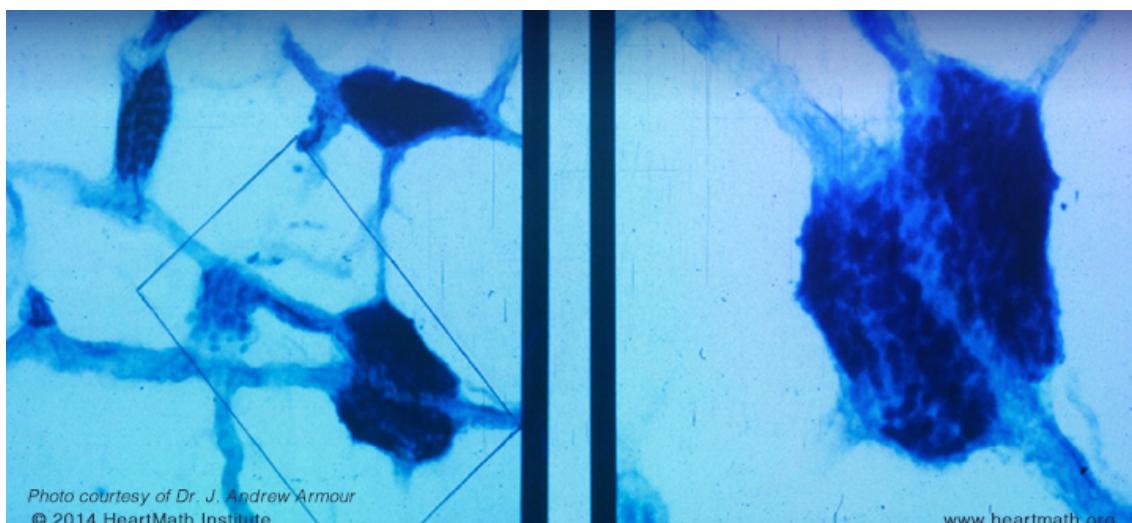
Obrázek 2.7: **(A)** Složené schéma znázorňující dráhy, kterými může prefrontální kůra ovlivňovat řízení srdeční frekvence; **(B)** Jádrové oblasti CAN, jak je odhalila konjunkční analýza⁶ autonomních modulačních oblastí ve třech kategoriích úkolů (barevně označeny). L, levá strana; P, pravá strana (Upraveno a převzato z [97, 98])

Objasnění pozorovaných vztahů mezi HRV a psychologickými/behaviorálními proměnnými může zlepšit porozumění a praktickou využitelnost v nejen medicíně, co se týče mentálního a fyziologického stavu jedince. Model „neuroviscerální integrace“ (NVI), který v roce 2000 navrhli Thayer a Lane [99], je pokusem o integraci poznatků o mentálních stavech, autonomních funkcích a zdravotních výsledcích do jednotného

⁶Společné testování více účinků u jednoho subjektu využitím fMRI.

rámce, jehož středobodem je „centrální autonomní síť“ (CAN) v mozku. CAN je síť vzájemně propojených oblastí mozkových struktur [100]. Hlavní části této sítě ukázali pomocí experimentu Beissner et al. [98] (viz Obr. 2.7B).

Na diagramu 2.7A lze vidět prefrontální, cingulární a insulární kůru, jež tvoří propojenou síť s obousměrnou komunikací s amygdalou. Amygdala je pod tonickou inhibiční kontrolou prostřednictvím prefrontálních vagových drah k interkalárním buňkám v amygdale. Aktivace centrálního jádra amygdaly (CeA) inhibuje jádro solitárního traktu (NTS: plný čtverec), které následně inhibuje inhibiční vstupy kaudálního ventrolaterálního medulárního jádra (CVLM) do rostrálního ventrolaterálního medulárního jádra (RVLM) sympatoexcitačních neuronů (plný čtverec) a současně inhibuje vagové motorické neurony v nucleus ambiguus (NA) a dorzálním vagovém motorickém jádru (DVN). Kromě toho může CeA přímo aktivovat sympatoexcitační neurony v RVLM [97].



Obrázek 2.8: Mikroskopický obraz propojených vnitřních srdečních ganglií v lidském srdci. Tenké, světle modré struktury jsou vícenásobné axony, které ganglie propojují (Převzato z [101] se souhlasem HeartMath Institutu)

Centrální autonomní síť, tvořena preganglioverymi sympatickými a parasympatickými neurony, inervuje srdce prostřednictvím hvězdicových ganglií a n. vagus. Vlivy těchto drah na sinoatriální uzel (SA) jsou hlavním faktorem určujícím HRV. Vzhledem k rozsáhlým aferentním informacím této autonomní sítě se promítá úroveň integrace mezi periferním a centrálním nervovým systémem do HRV a poskytuje kontextově specifickou regulaci srdce. Změny autonomních funkcí, zejména v kognitivních a afektivních souvislostech, odrážejí především vagový vliv, protože časové měřítko změn tonu sympathiku je relativně pomalejší než u tonu parasympatiku [57, 100].

Obrázek 2.7A znázorňuje dráhy, které umožňují prefrontální kůr regulovat srdeční frekvenci a její variabilitu. ANS má jak tonickou excitační, tak inhibiční kontrolu nad HR, kterou může modulovat frontální kůra prostřednictvím CeA. To

umožňuje přesnou regulaci variability srdečního rytmu, která na srdeční úrovni probíhá pomocí intrakardiálních neuronů (viz Obrázek 2.8). Prefrontální kúra rovněž vykonává tonickou inhibiční kontrolu nad těmito obvody, jak dokládá inverzní korelace mezi aktivitou ventromediálního prefrontální a orbitofrontální kortextu a úrovni kožní vodivosti během výchozího stavu mozku⁷. To podporuje současný NVI model a je v souladu s pozorováním, že tyto oblasti jsou deaktivovány během kognitivních úkolů při současném zvýšení hladiny kožní vodivosti [100, 102, 103].

Souhrnně lze říci, že NVI model integruje podstatu periferních fyziologických změn vlivem specifických mozkových struktur do jednotného frameworku, který se tyto adaptivní pochody snaží vysvětlit. Podle Thayera a Lanea [99] je tento framework spojen s psychologickými a fyziologickými procesy prostřednictvím kortikokortikálního neuronálního okruhu, který lze indexovat pomocí HRV. Prefrontální kúra může inhibovat podkorové struktury, což umožňuje organismu účinně reagovat na požadavky prostředí [100]. Model NVI představuje a popisuje víceúrovňovou funkční strukturu vagové kontroly, jejíž kompletní rozbor ale přesahuje rozsah této práce. Jednotlivé úrovně dokládají důkazy o souvislosti mezi HRV a fyziologickou, afektivní a kognitivní regulací. Zbytek kapitoly je proto věnován pouze souhrnu kognitivní regulace. Důkladně byl NVI model rozebrán v literatuře [57, 100, 104].

2.3.1 Kognitivní regulace

Schopnost regulovat pozornost a potlačovat nežádoucí reakce (negativní afektivní stavy) je nezbytná pro přizpůsobení se například právě ICE prostředí. Prefrontální korová aktivita je důležitá pro úkoly vyžadující pracovní paměť, trvalou pozornost, inhibici chování a mentální flexibilitu [100]. Přehledové studie prokázaly, že jedinci s vyšší klidovou HRV dosahovali lepších výsledků při řešení úkolů (n-back test, Stroopův test) vyžadujících exekutivní funkce než jedinci s nižší klidovou HRV [87, 88]. Stres může také zhoršovat kognitivní funkce, přičemž jedinci s nižší klidovou variabilitou vykazovali horší výkonnost při řešení určitých úkolů v podmínkách ohrožení a také větší reakce kortizolu na mírné kognitivní výzvy, které přetrvávaly i v období zotavení, ve srovnání s jedinci s vysokou klidovou HRV [100].

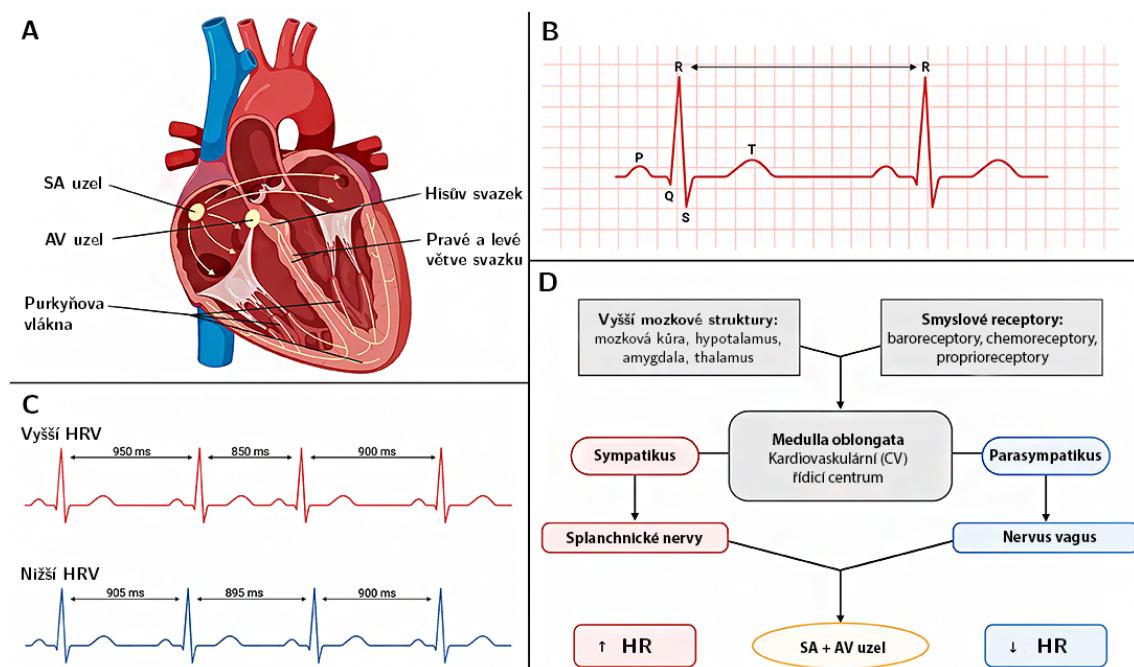
Saus et al. [89] ukázali na realističtějších scénářích zahrnujících policisty, kteří plnili úkoly ve virtuální realitě, že jedinci s vyšší klidovou HRV vykazovali větší situační povědomí a lepší výkon v plnění úkolu. Kromě toho byl tento krátký tréninkový program spojen s menším snížením HRV během plnění úkolu, což naznačuje snížení mentální zátěže. Tyto výsledky naznačují, že jedinci s vyšší klidovou HRV jsou lépe vybaveni pro plnění úkolů, které zahrnují exekutivní a inhibiční funkce, a to jak

⁷Základní stav fyziologického mozku dospělého člověka z hlediska frakce extrakce kyslíku z mozku neboli OEF [102].

v laboratorním, tak v reálném prostředí. Navíc naznačují, že trénink může ovlivnit variabilitu srdečního rytmu a kognitivní výkon.

2.4 Variabilita srdeční frekvence

Variabilita srdeční frekvence (HRV) vypovídá o časové variabilitě mezi jednotlivými srdečními stahy a umožňuje nahlédnout do regulace různých tělesných funkcí autonomním nervovým systémem. Následující kapitola se zabývá způsoby jakými je možné takové nahlédnutí realizovat a zároveň poukazuje na současné nedostatky této problematiky, které je třeba brát v potaz. Nejdříve je ale na místě uvést obecné objasnění vzniku a souvislosti variability srdeční frekvence s funkcionalitou srdce. Regulační pochody autonomního nervového systému spojené s HRV byly popsány v minulé kapitole (zjednodušeně viz Obr. 2.9D).



Obrázek 2.9: **(A)** Převodní systém srdeční; **(B)** Schéma EKG záznamu elektrické aktivity; **(C)** Vysoká vs. nízká variabilita srdeční frekvence; **(D)** Schéma znázorňující různé faktory ovlivňující HR a HRV resp. zjednodušená část NVI modelu (Upraveno a převzato z [105])

Jak již bylo řečeno, HRV lze získat jako časovou diferenci mezi jednotlivými srdečními údery, přičemž úder označujeme jako depolarizaci komor. To je část srdečního cyklu, během které dochází ke genezi QRS komplexu. Aby bylo možné tuto časovou diferenci vypočítat, je potřeba zmíněný komplex detektovat. K tomu se využívá elektrokardiogram neboli záznam elektrické aktivity srdce, na kterém QRS komplex představuje vývoj elektrické aktivace komor myokardu. Srdeční cyklus a anatomie srdce již byly detailně popsány v [106–108]. EKG záznam společně s QRS komplexem lze vidět na ilustraci 2.9B.

K detekci QRS komplexu se primárně využívá jeho pozitivní kmit neboli R vlna, která se v EKG signálu za fyziologických podmínek vyskytuje periodicky, v závislosti na srdečním rytmu, konkrétně na autorytmických buňkách. Tyto srdeční buňky generují stimulační elektrické potenciály, jež iniciují srdeční stah. Hlavními dvěma iniciátory (pacemakerami), určující srdeční frekvenci, jsou sinoatriální (SA) a atrioventrikulární (AV) uzel. Převodní systém srdeční byl již podrobně popsán v [106, 107, 109] a lze vidět na Obr. 2.9A. Za účelem detekce samotné se využívá mnoho algoritmů založených například na: vlnkové nebo Hilbertově transformaci, prahování nebo neuronových sítích. Každý algoritmus zároveň samozřejmě využívá a těží ze svého vlastního způsobu předzpracování EKG. Některé populární algoritmy popsal Porr a Howell v [110]. Fluktuaci časových diferencí mezi po sobě jdoucími R vlny a náležitou změnu HRV lze pozorovat na Obr. 2.9C.

2.4.1 Trendy v analýze HRV

Oblast vývoje problematiky analýzy variability srdečního rytmu je možné rozdělit na několik podskupin. První podskupinu tvoří příznaky použité k analýze. Výběr HRV příznaků (parametrů) hraje významnou roli v rámci mapování vnějších vlivů na funkci biosignálu. Z počátku se využívalo pouze deskriptivní statistiky na řady nasbíraných hodnot srdečního rytmu pro účely odhalení srdečních patologií. Zlom ale nastal v 70. letech 20. století, kdy se k analýze začaly využívat R–R intervaly, a došlo tak k vývoji nových časových parametrů, například RMSSD, pNN50 nebo SDNN, které se stále hojně využívají. Poté přišla na řadu spektrální a nelineární analýza, tedy frekvenční a nelineární parametry, které sebou přinesli i nový vizuální nadhled. V poslední době se používá hlavně časovo-frekvenční analýza, během které se aplikují spektrální metody na specificky dlouhá časová okna a získají se tak frekvenční parametry jako LF (Low Frequency) nebo HF (High Frequency). Je tak umožněno sledování okamžitých změn HRV, což může účinně diagnostikovat například kardiovaskulární onemocnění [73, 101].

Do další podskupiny lze zařadit způsoby měření HRV. Od 90. let 20. století se výzkum HRV rozšířil o analýzu využitím krevního tlaku a dýchání prostřednictvím fotopletysmografie (PPG) a hrudních pásů. Došlo tak k prohloubení HRV výzkumu vzhledem k multimodálnímu přístupu měření. Od roku 2000 se využitím dvanáctisvodového EKG začali v klinické praxi efektivněji analyzovat srdeční patologie. Současně se využívá nositelných technologií (tzv. wearables) v podobě například hodinek na zápěstí, které však často měřené parametry poskytují pouze agregovaně za určité časové úseky. Výhodou je sice jejich mobilita ale na úkor přesnosti poskytovaných dat. Detailní popis zmíněných podskupin společně s dalšími trendy byl již uveden v [73].

Tabulka 2.2: Vybrané parametry z časové a frekvenční oblasti [73]

Parametr	Popis
SDNN	Směrodatná odchylka intervalu mezi dvěma normálními srdečními tepy (NN). NN měří celkový výkon. Snižuje se v reakci na CL
RMSSD	Střední kvadratická hodnota po sobě jdoucích rozdílů mezi normálními srdečními tepy. Primárně se řídí aktivitou PNS
pNN50	Vyjadřuje procento rozdílu spojeného s intervalom NN, který se liší o více než 50 ms. Korelace s aktivitou PNS, RMSSD, HF
SD1	Nelineární proměnné odvozené z Poincarého grafu. Sdílí vysokou korelací s HF, RMSSD. Snižuje se v důsledku CL
SD2	Nelineární proměnné odvozené z Poincarého grafu. Sdílí vysokou korelací s LF. Zvyšuje se v reakci na CL
GSR std	Směrodatná odchylka spojená s elektrodermální aktivitou. Zvyšuje se během CL
GSR mean	Průměrná hodnota získaná měřením rychlosti změn spojených s aktivitou EDA. Zvyšuje se během CL
RSP rate	Představuje frekvenci dýchání, zvýšení respirační frekvence vede ke zvýšení aktivity PNS, VF a snížení LF a aktivity SNS. Zvýšení v reakci na CL
LF	Reprezentuje 0,04–0,15 Hz v rámci PSD ¹ a většinou se používá k označení aktivity SNS ale může specifikovat i aktivitu PNS
HF	Představuje frekvenční rozsah 0,15–0,40 Hz a označuje výhradně aktivitu PNS

¹ Výkonová spektrální hustota (anglicky Power Spectral Density) — vyjadřuje výkon obsažený v určitém intervalu spojitého frekvenčního spektra

2.4.2 Struktura HRV indexů

Vzhledem k popularitě analýzy HRV napříč obory vznikla problematika týkající se interpretace dostupných metrik. Jedním z hlavních problémů je tedy nedostatečné pochopení funkčního vztahu mezi HRV ukazateli a fyziologickými procesy. Také se tyto ukazatele často používají zaměnitelně, což jen přispívá k nejasnostem ohledně jejich skutečného významu (funkce) [111, 112]. Zároveň se často HRV metriky používají kombinovaně. To představuje několik problémů při interpretaci výsledků výzkumu a může být příčinou nekonzistentních výsledků. Dalším problémem je reprodukovatelnost, jelikož různé studie zkoumající stejný jev mohou při popisu vztahu s variabilitou srdeční frekvence vycházet z různých ukazatelů. Také se často nebírá ohled na podobnost a překrývání mnoha těchto ukazatelů. Studie například ukázaly, že indexy v časové a frekvenční oblasti, jako je RMSSD a pNN50, spolu silně korelují a jsou vysoce spojeny s výkonem HF. V důsledku toho lze tyto míry považovat za zaměnitelné při hodnocení parasympatické modulace HRV. Nejasnosti ohledně fyziologických důsledků těchto ukazatelů zvyšují právě náročnost objasnění jejich výsledků [73, 74, 113, 114].

Je také třeba poznamenat, že výpočet RMSSD zahrnuje výpočet rozdílů mezi po sobě jdoucími R–R (N–N) intervaly. V důsledku toho tento index odráží především vysokofrekvenční oscilační vzorce srdečního rytmu a není ovlivněn dlouhodobými změnami. Naproti tomu SDNN, o němž se předpokládá, že zachycuje jak sympathetic, tak parasympatickou aktivitu, je silně spojen s celkovým výkonem ve výkonovém spektru HRV [73, 113–115].

V posledních letech se parametry SD1 a SD2 konvenčně interpretují jako nelineární. Toto tvrzení bylo však znehodnoceno matematickým důkazem, který potvrdil, že metriky RMSSD a SD1 jsou ekvivalentní. Tím pádem studie, které uvádějí tyto dva krátkodobé HRV indexy často vágně dospívají k podobným statistickým výsledkům, aniž by tuto ekvivalence rozpoznaly [74, 116–119].

Některé studie navíc zaznamenaly podobnosti mezi poměrovými parametry SD1/SD2 a LF/HF při hodnocení rovnováhy mezi krátkodobou a dlouhodobou variabilitou srdečního rytmu. Nezohlednění těchto překryvů v analýzách může vést ke statistickým chybám. Ty mohou zahrnovat přílišnou důvěru v závěry (projevující se falešně vysokým počtem parametrů shodujících se s určitým trendem), problémy s kolinearitou (pokud je jako prediktory použito více metrik současně), potenciální nadměrnou korekci (např. prostřednictvím metod úpravy p-hodnoty Bonferronova typu) a zbytečnou složitost výsledků [74, 117, 120–122].

2.5 Periferní biosignály

Včetně elektrické srdeční aktivity, která byla diskutována v minulé sekci a je hlavní zkoumanou proměnnou, se mezi další periferní biosignály zkoumané v této práci řadí také elektrodermální a respirační aktivity. V následující podkapitole jsou tyto periferní biosignály uvedeny do souvislosti s problematikou práce a předchozími kapitolami. Dále je stručný přehled jak lze zkoumané signály zaznamenat a zpracovat.

O elektrodermální aktivitě lze hovořit jako o fyziologickém procesu, úzce spojeném s aktivitou potních žláz v kůži, jež je ovlivňován ANS. Aktivita potních žláz vede ke změnám elektrického odporu kůže. Zvýšením této aktivity tak dochází k poklesu elektrického odporu kůže (zvýšení kožní vodivosti) a naopak [123–125]. Fredrikson et al. [126] ukázali, že EDA je úzce spojená s aktivitou cingulární kůry, sekundární zrakové kůry a pravé inferiorní parietální kůry, přičemž nejsilnější korelace byla pozorována v pravé insulární kůře, která je součástí CAN. Další studie naznačují mnohočetné souvislosti mezi změnami kožní vodivosti a CAN regiony [124, 127–129]. EDA tedy nachází velké uplatnění v neuropsychofyziologickém výzkumu ale stejně jako u HRV se zde vyskytují problémy s interpretací metrik, které z ní vycházejí [130]. Z anatomického, fyziologického a biofyzikálního hlediska byla již elektrodermální aktivita důkladně rozebrána v [123]. Úzkou provázanost kožní vodivosti a kognitivní zátěže s využitím EDA pro její detekci a hodnocení podkládají studie [131–138].

Respirační aktivitou se rozumí proces dýchání, při kterém dochází k výměně kyslíku a oxidu uhličitého mezi plícemi a okolím. Dýchací ústrojí bylo již důkladně popsáno v [139]. Respirační signál jako takový odráží cyklické změny objemu plic během dýchání. Dýchací aktivita je ovlivněna celou řadou faktorů, včetně fyzické aktivity, stresu, emocí a i kognitivních nároků. Například kognitivní úkoly vyžadující

trvalou pozornost nebo vyšší nároky na pracovní paměť mohou zvýšit dechovou námahu a spotřebu kyslíku v mozku. Obecně se amplituda a frekvence dechového signálu zvyšuje s rostoucí kognitivní zátěží [140]. Existuje mnoho studií, které vypovídají o významném vztahu mezi respiračním signálem a CL, avšak oproti srdeční a elektrodermální aktivitě je tento signál mnohem častěji zanedbáván. To může vysvětlovat větší počet protichůdných a negativních studií, které popírají význam RSP při detekci a hodnocení kognitivní zátěže [67, 140].

2.5.1 Měření biosignálů

V následujících sekcích jsou popsány principy měření a postupy zpracování periferních biosignálů, které byly využívány pro účely této diplomové práce. Těmi jsou konkrétně srdeční, elektrodermální a respirační aktivita.

2.5.1.1 Elektrická srdeční aktivita

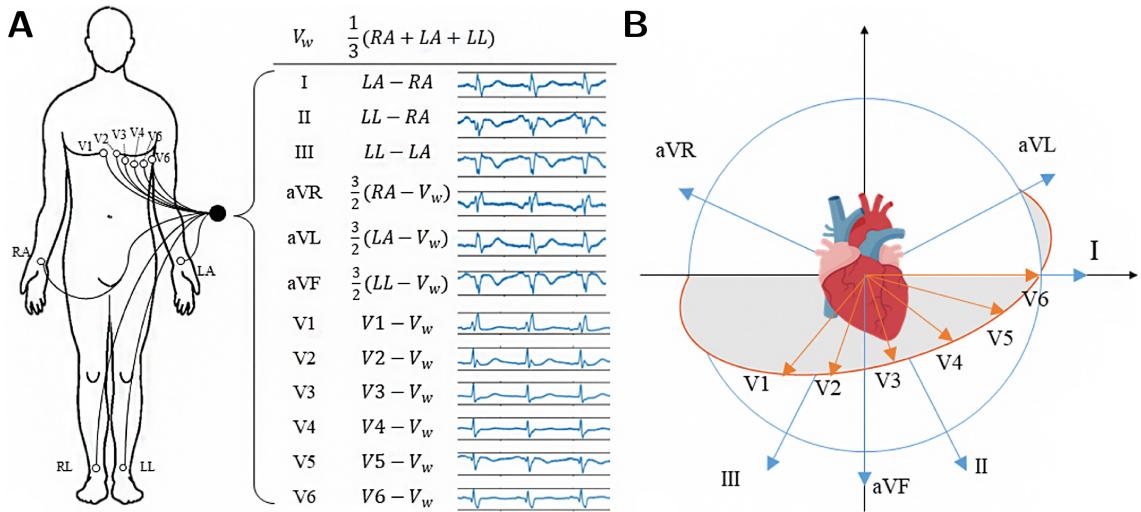
Záznam elektrické srdeční aktivity (elektrokardiogram) je výstupem komplexních fyziologických a technologických procesů. Z fyziologického hlediska je třeba nahlédnout na celulární úroveň, kde díky toku iontů přes buněčné membrány a mezi sousedními buňkami vznikají transmembránové iontové proudy. Geneze těchto proudů je synchronizována díky srdečnímu cyklu, během kterého dochází k tvorbě časově závislého elektrického pole v myokardu. Toto elektrické pole pak podléhá interferenci různých dalších struktur, jako jsou plíce, krev a kosterní svalstvo až kůže. Na kůži jsou poté proudy detekovány elektrodami umístěnými na určitých místech končetin a trupu v takové konfiguraci, aby vytvářely svody, konkrétně bipolární svody [141]. Elektrofyziologie myokardu byla již detailně popsána v [106–109].

Svody zaznamenávají rozdíl potenciálů mezi dvěma elektrodami, přičemž jedna je označována jako kladná a druhá záporná. Bipolární potenciál se následně získává jako rozdíl potenciálů kladné a záporné elektrody. U některých konfigurací je elektricky spojeno více elektrod, které představují záporný člen bipolárního páru, označovaný jako referenční elektroda. Výstupní potenciály elektrod jsou ve finále zesíleny, filtrovány [109, 141].

Jednou z konfigurací je standardní klinické EKG, které zahrnuje záznamy z 12 svodů. Svody v tomto případě sestávají ze standardních končetinových svodů (svody I, II a III), šesti prekordiálních svodů (svody V1 až V6) a ze tří rozšířených (augmentovaných) končetinových svodů⁸ (svody aVR, aVL a aVF) [109, 141].

Standardní končetinové svody. Standardní končetinové svody zachycují rozdíly potenciálů mezi dvěma končetinami. Elektroda na pravé noze slouží jako referenční, snižuje šum a není tak součástí konfigurace svodů. Svody jsou uspořádány do

⁸Prekordiální a rozšířené končetinové elektrody jsou často označované jako „unipolární“ svody.



Obrázek 2.10: Illustrace 12svodového EKG systému. **A)** Prostorové rozmístění 10 elektrod: tři končetinové svody, tři rozšířené končetinové svody a šest prekordiálních (hrudních) svodů, které byly vytvořeny mezi fyzickými elektrodami a virtuální elektrodou známou jako Wilsonův centrální terminál (V_W). **B)** Rozdíly elektrických potenciálů mezi elektrodami odrážejí elektrickou aktivitu srdce z různých prostorových úhlů (Přeloženo a převzato z [142])

trojúhelníku, který se často nazývá jako Einthovenův trojúhelník. Toto uspořádání zajišťuje, že potenciál snímaný ve svodu II odpovídá součtu potenciálů měřených ve svodech I a III [109, 141].

Prekordiální svody a wilsonův centrální terminál. Prekordiální svody se používají k záznamu potenciálu v každém ze šesti určených míst trupu vzhledem k referenci. Na každé místo se umístí aktivní elektroda připojená ke kladnému vstupu záznamového systému. Referenčním vstupem je složená elektroda známá jako Wilsonova centrální svorka, která je vytvořena kombinací výstupu elektrod levé paže (LA), pravé paže (RA) a levé nohy (LL) prostřednictvím odpornů (5000Ω) [109, 141].

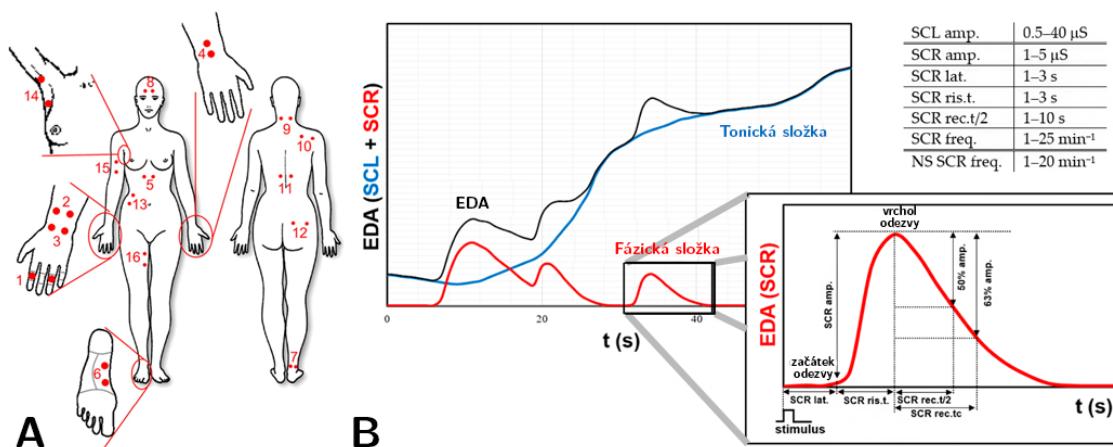
Rozšířené končetinové svody. Jak již bylo zmíněno, třemi augmentovanými svody jsou aVR, aVL a aVF. U svodu aVR je aktivní elektrodou sloužící jako pozitivní vstup elektroda pravé paže, zatímco u svodu aVL je to elektroda levé paže a u svodu aVF elektroda levé nohy. Referenční potenciál je zde vytvořen spojením dvou končetinových elektrod, které se nepoužívají jako aktivní. Účelem tohoto modifikovaného referenčního systému je generovat signál s vyšší amplitudou než při použití Wilsonovy centrální svorky jako referenční elektrody [109, 141].

Další svodové systémy. Byly vyvinuty různé svodové systémy, které umožňují detektovat diagnosticky významné informace, jež nemusí být zachyceny standardním 12svodovým EKG, a zlepšit efektivitu záznamu, přenosu a ukládání EKG. Používají se například levé zadní svody k detekci akutních posterolaterálních infarktů nebo

elektrodová pole o 80 nebo více elektrodách k zobrazení potenciálů povrchu těla jako izopotenciálních map [109, 141]. Přehled dalších svodových systémů včetně nositelných byl popsán v [143–145].

2.5.1.2 Elektrodermální aktivita

V úvodu kapitoly bylo řečeno, že princip měření EDA je založen na skutečnosti, že činnost potních žláz v kůži, která je regulována sympatickým nervovým systémem, vede ke změnám vodivosti kůže. Díky tomu, a jak může vyplývat z minulých kapitol, je měření EDA běžně používanou metodou pro hodnocení fyziologických reakcí souvisejících s emočními a kognitivními procesy.



Obrázek 2.11: A) Možná místa měření kožní vodivosti. **B)** Typická odezva elektrodermální aktivity (Upraveno a převzato z [146, 147])

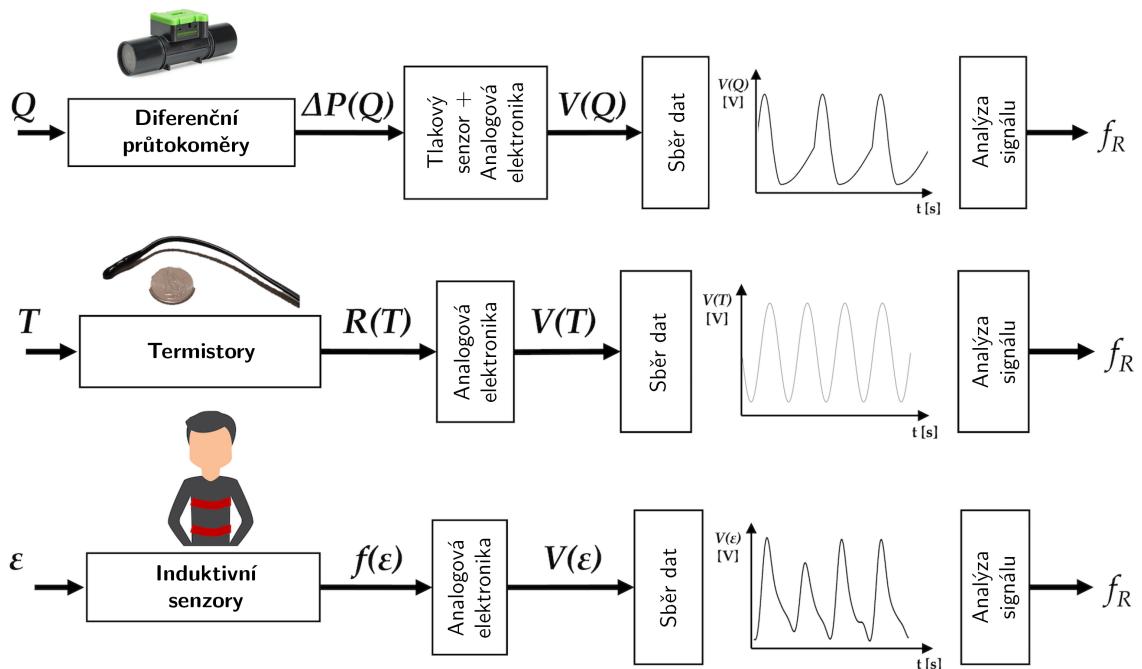
Měření elektrodermální aktivity zahrnuje umístění dvou elektrod na kůži, přičemž jedna měří rozdíly potenciálů mezi dvěma body na kůži a druhá slouží jako referenční elektroda. Elektrody se obvykle umísťují na prsty nebo dlaň ruky, i když lze použít i jiná místa, například chodidla nebo čelo (viz Obr. 2.11A) a měří se elektrická vodivost kůže v reakci na malý stejnosměrný nebo střídavý proud [123, 128].

Z pohledu způsobu měření elektrodermální aktivity lze tedy rozlišovat dvě hlavní kategorie: endosomatická a exosomatická měření. V rámci endosomatického měření se zaznamenává pouze potenciál generovaný kůží bez použití vnějšího zdroje. U exosomatického měření se využívají externí zdroje, jako je právě střídavý nebo stejnosměrný proud přiváděný na kůži. Aplikace konstantního stejnosměrného napětí nebo proudu umožňuje měření vodivosti kůže (resp. odporu kůže podle Ohmova zákona). Pokud se ale aplikuje konstantní střídavé napětí nebo proud, tak lze měřit kožní admitanci (resp. kožní impedanci). Nejpoužívanější metodou pro exosomatická měření je metoda stejnosměrného konstantního napětí, a to primárně díky jednoduššímu procesu vyhodnocování a interpretace než je tomu tak u endosomatického způsobu [123, 128, 148, 149].

Měřená kožní vodivost nebo kožní potenciál se vyjadřují v jednotkách vodivosti (mikrosiemens, μS) a napětí (mV). V naměřeném signálu se odrážejí změny v různých časových škálách, které se běžně dělí na dvě složky: tonickou (SCL) a fázickou (SCR). Tonická složka představuje velikost kožní vodivosti nebo potenciálu v nepřítomnosti sudomotorické nervové aktivity⁹, zatímco ta fázická se týká rychlých změn kožní vodivosti nebo potenciálu jako přímého důsledku sudomotorického vzruchu. Fázická složka je charakterizován nástupem (SCR ris.), dobou nárůstu (SCR ris. t.), amplitudou (SCR amp.) a dobou zotavení (SCR rec. tc.). Na Obr. 2.11 lze vidět průběh EDA složek společně s jejich korespondujícím popisem. Tonické a fázické složky lze oddělit pomocí technik zpracování signálu [123, 128, 148, 149].

2.5.1.3 Respirační aktivita

Pro měření dechové aktivity (resp. dechové frekvence) je k dispozici mnoho metod, od přímého měření ventilace až po nepřímé měření pohybů souvisejících s dýcháním. V této sekci je stručný přehled často používaných metod měření dechové aktivity.



Obrázek 2.12: Různé technologie pro měření dechové frekvence (f_R). Nahoře z kategorie snímačů proudění vzduchu, kde $\Delta P(Q)$ je změna úbytku tlaku způsobená prouděním vzduchu Q . Uprostřed z kategorie snímačů teploty, kde $R(T)$ je změna odporu způsobená vlivem teploty T . Dole z kategorie tenzometrických snímačů, kde $f(\varepsilon)$ je změna odporu způsobená deformačním tlakem ε . $V(X)$ je výstupní napětí (Upraveno a převzato z [150])

Jednou z nejběžnějších metod měření dechové aktivity je přímé měření ventilace. Ventilace je celkový objem vzduchu, který se během každého nádechu přesune

⁹Sudomotorická nervová aktivity se vztahuje k ANS kontrola aktivity potních žláz v reakci na různé environmentální a individuální faktory.

do plic a z plic ven, a lze ji měřit pomocí několika technik včetně spirometrie, pletysmografie, a kapnometrie. Spirometrie měří objem vzduchu, který je vdechován a vydechován, zatímco pletysmografie měří změny tlaku v uzavřené komoře během dýchání. Kapnometrie měří koncentraci oxidu uhličitého ve vydechovaném vzduchu, což úzce souvisí s ventilací. Tyto techniky umožňují přesné měření dechové aktivity, ale mohou být invazivní a vyžadují specializované vybavení [150–152].

Alternativní metodou měření dechové aktivity je nepřímé měření pohybů souvisejících s dýcháním. Tyto pohyby lze detektovat pomocí senzorů umístěných na hrudníku nebo bříše, jako jsou piezoelektrické senzory, tenzometry nebo akcelerometry. Tyto snímače detekují změny tvaru nebo pohybu hrudníku nebo břicha během dýchání a lze je použít k odhadu dechové frekvence a objemu. Tyto metody jsou méně invazivní než přímé měření ventilace a lze je použít v reálném prostředí, avšak u některých populací nebo za určitých podmínek mohou být méně přesné [150–153].

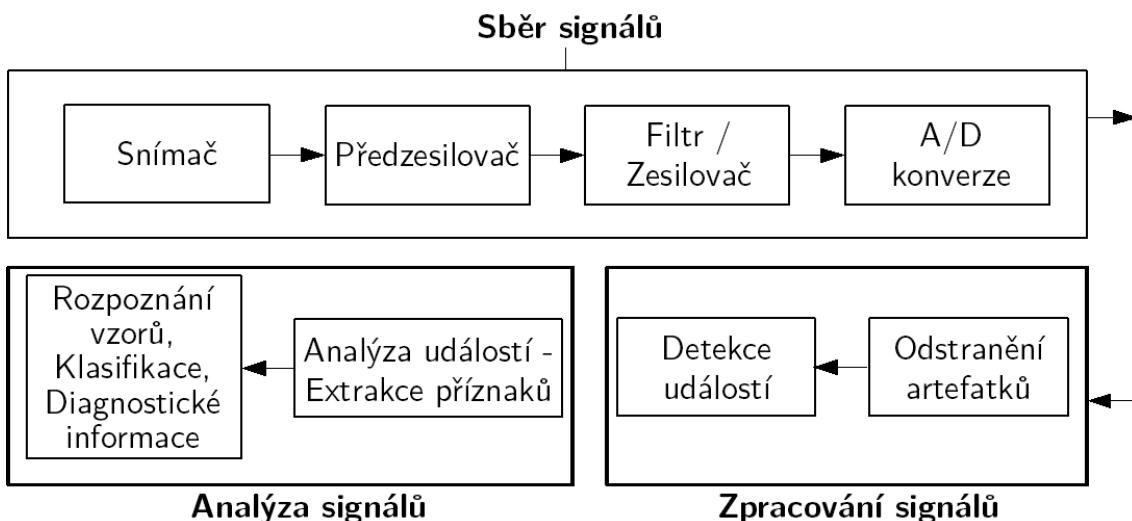
Další nově se objevující metodou měření dechové aktivity je používání nositelných zařízení, jako jsou chytré hodinky, které mohou detektovat změny dechových vzorců pomocí fotopletysmografie nebo akcelerometrie. Fotopletysmografie měří změny objemu krve pomocí světelných senzorů, zatímco akcelerometrie měří pohyb pomocí pohybových senzorů. Tyto metody jsou neinvazivní a lze je použít v přirozeném prostředí s tím, že mohou být omezené ve své přesnosti a preciznosti [150–156].

2.5.2 Postupy zpracování biosignálů

Zpracování biosignálů označuje techniky a postupy používané k získání informací z biosignálů, ke zvýšení jejich kvality a k interpretaci jejich významu. V této sekci je uveden přehled hlavních postupů zpracování biosignálů, včetně jejich akvizice, předzpracování, extrakce příznaků a klasifikace.

Sběr signálu znamená proces záznamu biosignálů z lidského těla pomocí měřicích zařízení, jako jsou senzory nebo elektrody. Kvalita zaznamenaných signálů závisí na různých faktorech, jako je typ a umístění snímačů, odstup signálu od šumu a vzorkovací frekvence. Například signály EKG se zaznamenávají pomocí elektrod a jejich umístění ovlivňuje kvalitu zaznamenaných signálů, protože různé oblasti srdce mohou mít různou sílu nebo frekvenci signálu. Kromě toho se odstup signálu od šumu týká poměru žádoucího signálu a nežádoucího šumu v zaznamenaných signálech. Čím vyšší je poměr signál/šum, tím jsou zaznamenané signály jasnější a spolehlivější. A konečně vzorkovací frekvence označuje frekvenci, s jakou jsou signály vzorkovány nebo digitalizovány. Čím vyšší je vzorkovací frekvence, tím přesnější je digitální reprezentace signálů [157, 158].

Předzpracování se týká postupů používaných k přípravě zaznamenaných signálů pro další analýzu. Mezi postupy předzpracování patří především filtrování signálu. Žádoucí je často navržení takového filtru, který rovnou koriguje kolísání nulové izolinie



Obrázek 2.13: Řetězec procesů od získání biomedicínského signálu po fázi analýzy (Přeloženo a převzato z [158])

a potlačuje nežádoucí artefakty (sítový šum, svalové artefakty, apod.). V některých případech však nestačí pouze frekvenčně selektivní filtrace a volí se jiné přístupy. Zvolený přístup závisí na zdroji a charakteru signálu. Porovnání metod předzpracování srdeční, elektrodermální a respirační aktivity bylo vypracováno v [157, 159–161].

Extrakce příznaků označuje postupy používané k extrakci relevantních informací nebo charakteristik z předzpracovaných signálů. Extrakce příznaků je důležitým krokem při zpracování biosignálů, protože jednak snižuje dimenzionalitu signálů a také zvýrazňuje právě relevantní informace. Z biosignálů lze extrahat různé typy příznaků, například z časové, z frekvenční nebo nelineární oblasti [157, 158]. Krishnan a Athavale popsali trendy v extrakci příznaků biomedicínských signálů v [162].

Klasifikací se rozumí postupy používané k přiřazení značky (anotace) nebo kategorie biosignálu na základě jeho extrahovaných vlastností (příznaků). Klasifikace je dalším důležitým krokem při zpracování biosignálů, protože umožňuje identifikovat vzory nebo trendy v signálech a předpovídat fyziologický stav nebo kondici subjektu [157, 158]. Možnosti využití klasifikace (resp. metod strojového učení) pro biomedicínské aplikace byly popsány v [163–165].

Zpracování biosignálů se potýká s různými problémy a omezeními, jako je variabilita signálů, složitost postupů zpracování a interpretace výsledků. Variabilitou signálů je myšleno, že biosignály se mohou lišit od subjektu k subjektu, od sezení k sezení nebo dokonce v rámci jednoho sezení. Tato variabilita může ovlivnit kvalitu a spolehlivost zaznamenaných signálů a může vyžadovat použití sofistikovanějších metod předzpracování a klasifikaci [157, 158].

2.6 Strojové učení

Strojové učení (anglicky Machine Learning, ML) představuje odvětví umělé inteligence, které se zaměřuje na vytváření matematických modelů a zvyšování jejich přesnosti predikce na základě předchozích zkušeností. Tyto zkušenosti se získávají retrospektivně z dostupných dat (trénovacích dat), která se využívají k formulaci pravidel a identifikaci charakteristických rysů nebo vztahů v datech. Proces učení zahrnuje techniky, které vyplývají z oborů informatiky, statistiky, pravděpodobnosti nebo optimalizace. Využití algoritmů strojového učení se neustále rozšiřuje v mnoha oblastech díky rostoucí dostupnosti online dat a snižování nákladů na výpočetní zdroje. Rozsah oblastí použití zahrnuje široké spektrum oborů, včetně zdravotnictví.

Tato kapitola slouží jako úvod do vybraných základních pojmu strojového učení s cílem vytvořit teoretický náhled pro podporu pochopení problematiky v korespondujících částech práce. Detailněji byly principy a náležitosti strojového učení již popsány v literatuře [166–168].

2.6.1 Typy systémů strojového učení

Různorodost scénářů strojového učení je charakterizována rozdíly v povaze trénovacích dat, způsobu trénování a kritériích hodnocení. Každý přístup je vhodný pro řešení určité kategorie problémů a představuje své vlastní charakteristické výhody a omezení. V následujících podkapitolách jsou rozebrány primárně dvě nejrozšířenější formy přístupů k učení, tj. učení s učitelem (anglicky Supervised Learning) a učení bez učitele (anglicky Unsupervised Learning).

2.6.1.1 Učení s učitelem

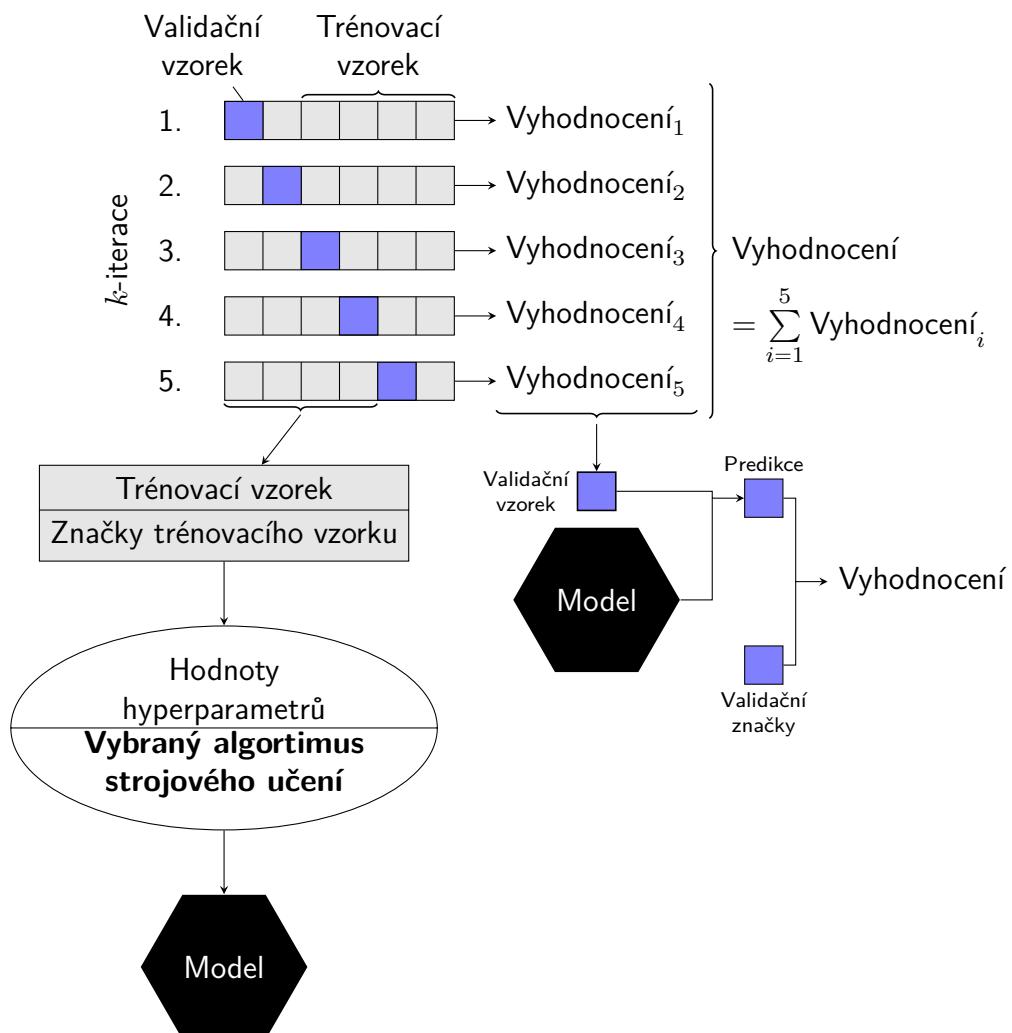
Učení s učitelem je typ strojového učení, během kterého se využívají právě taková trénovací data, která mají anotovanou výstupní proměnnou. Úkolem je zde approximovat mapovací funkci h , která predikuje výstupní proměnnou na základě vstupní proměnné X . K approximaci mapovací funkce jsou použita označená trénovací data, která se skládají z n párů vstupních a výstupních proměnných. Cílem je získat přesné predikce jak pro trénovací, tak pro úplně nová data. Formálně lze tedy tvrdit, že hledáme funkci:

$$h : \mathbb{R}^d \rightarrow \mathcal{C} \quad (2.1)$$

tak, že pro každou novou dvojici vstupu a výstupu (x, y) vybranou z \mathcal{P} platí $h(X) \approx y$, kde \mathbb{R}^d je d -rozměrný příznakový prostor a \mathcal{C} je prostor všech možných anotací. Zároveň předpokládáme, že tyto dvojice pocházejí z neznámého rozdělení \mathcal{P} [167].

2.6.1.2 Učení bez učitele

Cílem učení bez učitele je najít vzory v neanotovaných datech bez definovaného výstupu. Výsledkem tohoto typu učení mohou být struktury nebo vztahy v datech. Vyhodnocování výkonu natrénovaného modelu je v tomto případě, bez označených dat, často náročné. Běžnou úlohou pro tento typ učení je shlukování, které seskupuje podobné data do shluků. Shlukování se používá například pro segmentaci obrazových dat a provádí se pomocí algoritmů, jako je hustotní prostorové shlukování (DBSCAN), k-means nebo hierarchické shlukování.



Obrázek 2.14: Obecné schéma procesu trénování modelu a optimalizací hyperparametrů s využitím k-násobné křížové validace [169]

2.6.2 Trénování a testování modelů

Vyhodnocování modelů strojového učení je pro jejich úspěšnost klíčové. Aby bylo zajištěno, že model dokáže efektivně predikovat i nová data, nikoli pouze data využita během jeho trénování, provádí se tzv. *train-test* rozdelení. To zahrnuje ponechání

části dat jako testovací množiny, kterou model během trénování nepoužil, a její následné použití k vyhodnocení schopnosti modelu generalizace porovnáním jeho predikce se skutečnými hodnotami.

Běžně se využívá rozdelení trénovací a testovací množiny v poměru 80:20 z náhodně vybraných dat. Dále se někdy využívá validační množina (15-20 % trénovací množiny) pro účely ladění hyperparametrů. Nejúspěšnější model se na základě validační množiny natrénuje pomocí nalezených hyperparametrů. Nakonec se model vyhodnotí na dosud nevyužité testovací množině. Hyperparametry a jejich optimalizace jsou rozebrány v samostatné podkapitole 2.6.3.

2.6.2.1 Křížová validace

Přístup rozdelení dat z předchozí sekce je efektivní, ale opomíjí jeden problém: existuje mnoho možných kombinací trénovací a testovací sady a tato metoda zkoumá pouze jednu. Data mohla být tedy náhodně rozdělena nereprezentativním způsobem. Odpověď na tento problém je křížová validace (anglicky cross-validation, CV), která eliminuje závislost na rozdelení dat. Cílem křížové validace je vyhodnotit a porovnat výkon různých modelů na stejném datovém souboru a najít tak optimální nastavení hyperparametrů pro daný model.

Křížová validace se skládá ze tří hlavních kroků: rozdelení datového souboru na k částí, trénování modelu na $k - 1$ částech dat a vyhodnocování výkonu modelu na zbývající (validace) části dat. Tyto kroky se opakují n krát, přičemž každá část dat se použije jednou jako validace. Výsledkem křížové validace je průměrný výkon modelu na všech k částech validace. Existuje celá řada způsobů provedení křížové validace: K-Fold, Leave One Out (LOO), Stratified Shuffle Split, Leave P Groups Out, a další, které byly již popsány v [166].

Křížová validace má řadu výhod oproti jiným metodám optimalizace hyperparametrů, jako je například mřížkové nebo náhodné vyhledávání popsané v dalších kapitolách. Mezi tyto výhody patří:

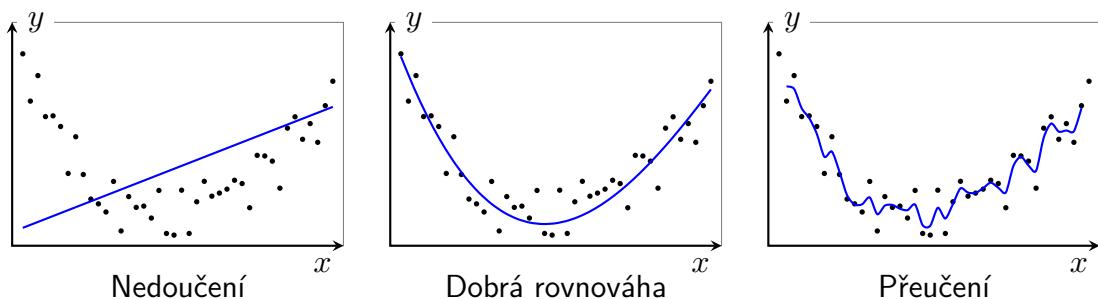
- Objektivní hodnocení výkonu modelu na stejných datech [170].
- Minimalizace rizika přeучení [171].
- Efektivní využití všech dat k hodnocení výkonu modelu [172].

V praxi se křížová validace často používá pro optimalizaci hyperparametrů nejen jednoho, ale i více modelů současně a následně porovnání jejich výkonu.

2.6.2.2 Přeučení a nedoučení

Přeučení (anglicky overfitting) a nedoučení (anglicky underfitting) jsou dva hlavní problémy, které se mohou vyskytnout při trénování modelů strojového učení. Tyto problémy ovlivňují schopnost modelu generalizovat na nová data, což způsobuje snížení jeho přesnosti.

K přeučení dochází, když model příliš pečlivě přizpůsobuje svůj výstup trénovacím datům a nezachycuje skutečné vztahy v datech. Vzniká tak velmi složitý model, což vede k vyššímu rozptylu a snížené vypořídací schopnosti. Přeučení je charakterizováno výrazným rozdílem mezi výkonností modelu na trénovací a testovací množině, známým jako generalizační mezera (anglicky Generalization Gap). Tento rozdíl je způsoben vysokou schopností modelu zapamatovat si specifické detaily trénovacích dat, místo aby zachycoval požadované vzorce [173].



Obrázek 2.15: Příklad nedoučeného modelu s vysokým biasem vlevo, přeučeného modelu s vysokým rozptylem vpravo a dobře přizpůsobeného modelu uprostřed [174]

Těmto problémům lze předcházet různými způsoby, například:

- Použití vhodných metod regularizace (např. L1 nebo L2 regularizace).
- Použití vhodného algoritmu strojového učení (např. kNN má tendenci k nedoučení, zatímco složité modely jako např. neuronové sítě k přeučení).
- Použití CV k hodnocení výkonu modelu a optimalizaci hyperparametrů.
- Zvýšení počtu trénovacích dat.

2.6.3 Optimalizace hyperparametrů

Ve strojovém učení jsou hyperparametry (HP) nastaveny před trénováním a nejsou určeny učícím algoritmem. Tyto parametry musí být zadány jako vstupy a jejich určení může být stěžejním faktorem, protože různé problémy vyžadují různé přístupy. Proces hledání optimální konfigurace modelu se označuje jako optimalizace hyperparametrů (HPO).

Metoda vyhledávání v mřížce (anglicky Grid Search Method), je běžným způsobem optimalizace hyperparametrů. Definuje sadu diskrétních hodnot pro každý hyperparametr a pro každou kombinaci vyhodnocuje ztrátovou funkci modelu. Za optimální je považována konfigurace s nejnižší validační ztrátou. Počet vyhodnocení však rychle roste s počtem hyperparametrů, tudíž je tato metoda vhodná pouze pro jednoduché modely, u nichž není trénování a hodnocení výpočetně náročné [175].

Alternativou k mřížkovému vyhledávání je náhodné vyhledávání (anglicky Random Search Method). Namísto úplného vyhodnocení všech kombinací jako v předešlé metodě kontroluje pouze určitý počet náhodných vzorků z hyperparametrického prostoru. Tato metoda je efektivnější než prohledávání v mřížce, přičemž poskytuje srovnatelné výsledky [175–177]. Existují i další způsoby HPO mezi které se řadí například bayesovská optimalizace, genetické algoritmy nebo využití neuronových sítí. Jejich využití přichází v úvahu zejména u vysokodimenzionálních problémů [175, 178].

2.6.4 Kombinování modelů

Kombinované modely (anglicky Ensemble Models) skládají předpovědi z více různých základních modelů, aby se zvýšila přesnost predikce. Toho lze dosáhnout zprůměrováním predikce u regrese nebo výběrem nejčastější predikce u klasifikace. Váhu předpovědi každého základního modelu lze upravovat na základě jeho individuální přesnosti. Klíčovým faktorem úspěchu kombinovaných modelů je různorodost a nezávislost základních modelů, které lze dosáhnout pomocí různých trénovacích dat, hyperparametrů nebo algoritmů. Ačkoli tomu tak není vždy, četné studie ukázaly, že kombinované modely často dosahují lepších výsledků než jednotlivé základní modely [179].

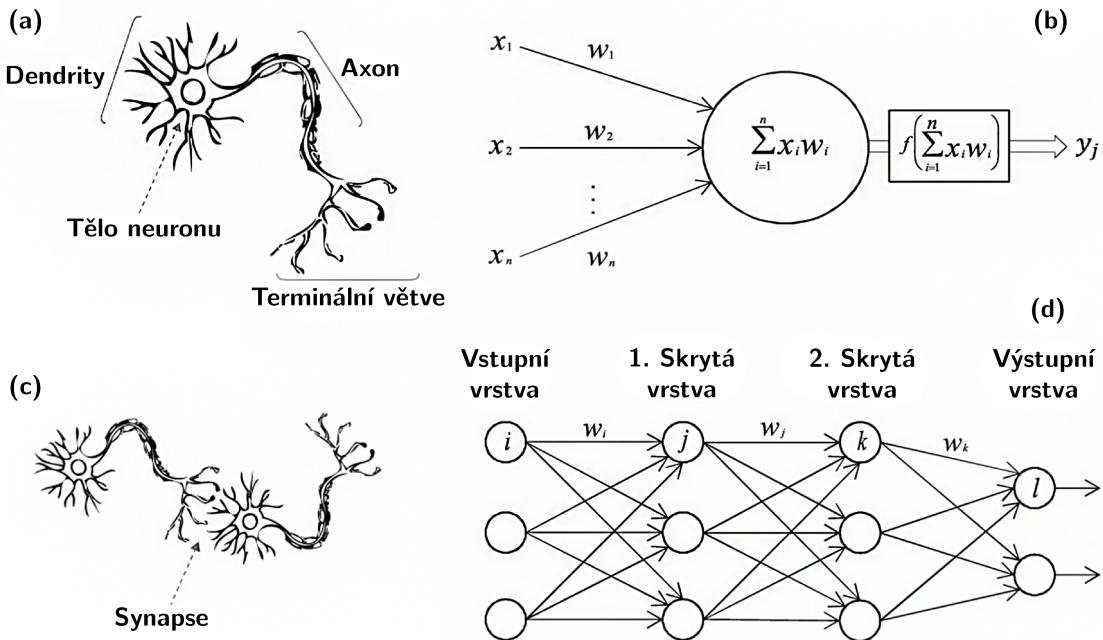
2.6.5 Hodnocení modelů

K hodnocení modelu lze použít různé metriky v závislosti na dané úloze. Vyhodnocování natrénovaného modelu je klíčovým aspektem procesu strojového učení. Vzhledem k tomu, že se tato práce zabývá především úlohou klasifikace učení s učitelem, nebudou zde popsány všechny hodnotící metriky. Vybrané a použité metriky jsou blíže popsány v samotných metodách, v kapitole ??.

2.6.6 Umělé neuronové sítě

Umělé neuronové sítě (anglicky Artificial Neural Networks, ANN) jsou významným nástrojem pro strojové učení a jsou často používány pro řešení složitých úloh, jako jsou klasifikace, regrese, segmentace obrazu a jazykové zpracování. Jedná se výpočetní modely, které napodobují strukturu biologických neuronů. Stejně jako biologické

neurony zpracovávají ANN vstupy, přenášejí impulsy a vytvářejí výstupy na základě aktivačních funkcí. Učení probíhá upravováním ANN vah spojení mezi neurony pomocí optimalizačních algoritmů.



Obrázek 2.16: Biologický neuron ve srovnání s umělou neuronovou sítí: **(a)** lidský neuron; **(b)** umělý neuron; **(c)** biologická synapse; a **(d)** synapse ANN. (Upraveno a převzato z [180])

V průběhu let se ANN významně rozvinuly a byly použity k řešení široké škály úloh. Dnes hrají umělé neuronové sítě klíčovou roli v různých akademických i komerčních aplikacích při řešení problémů, které jiné metody nezvládají. Historie a základní koncepty ANN, mezi které patří například perceptrony nebo zpětná propagace a gradientní sestup byly již rozebrány v [166–168].

2.6.6.1 Ztrátová funkce

Začátkem této podkapitoly o strojovém učení (viz 2.6.1.1) byla definována funkce h , před jejímž hledáním je potřeba učinit předpoklad o jaký typ funkce se jedná (lineární, polynomická, aj.). Tímto předpokladem vzniká vymezení na určitý prostor hypotéz, označovaný \mathcal{H} , které velmi ovlivňuje generalizaci.

S vymezením přichází na řadu ztrátová funkce $L : \mathcal{H} \rightarrow \mathbb{R}$, jež přiřazuje ztrátu každému $h \in \mathcal{H}$. Ztrátu si lze představit jako číslo, které vypovídá o tom jak přesně je nalezená h approximována vzhledem k použitým datům. Se ztrátovou funkcí tak vzniká nový optimalizační problem:

$$\arg \min_{h \in \mathcal{H}} L(h) = \arg \min_{h \in \mathcal{H}} \frac{1}{n} \sum_{i=1}^n l(\mathbf{x}_i, y|h) \quad (2.2)$$

kde L je ztráta pro danou h v rámci používaných dat a l je ztráta pro dvojici vstupu a výstupu při dané h . Díky takovému způsobu hodnocení je umožněno modelu se učit. Existuje řada ztrátových funkcí, jejichž použití závisí na typu problému (regrese, klasifikace, aj.). Tyto funkce společně s detailnějším popisem optimalizačního problému již byly popsány v [167].

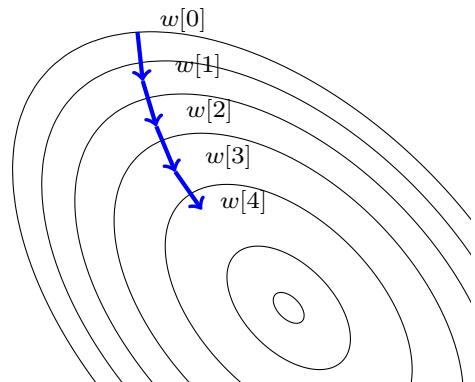
2.6.6.2 Numerická optimalizace

Obecně je numerická optimalizace technika, která se používá k nalezení optimálního řešení výpočetně náročných problémů. Ve strojovém učení se numerická optimalizace často používá k optimalizaci parametrů modelu. V rámci ANN se k optimalizaci vah spojení mezi neurony běžně využívá gradientní sestup (GD) v různých podobách.

Algoritmus 1: Gradientní sestup

```

Vstup: váhy  $w_0$ , # iterací  $T$ 
Výstup: konečné váhy  $w_T$ 
1 for  $t \in \{0, \dots T - 1\}$  do
2   odhad  $\nabla \mathcal{L}(w_t)$ 
3   výpočet  $\Delta w_t = -\nabla \mathcal{L}(w_t)$ 
4   výběr rychlosti učení  $\gamma$ 
5    $w_{t+1} := w_t + \gamma \Delta w_t$ 
6 end
7 return  $w_T$ 
```



Obrázek 2.17: Postup GD [181]

Výše lze vidět obecný popis gradientního sestupu (Algoritmus 1). Jeho cílem je najít minimum funkce tím, že se postupně pohybuje v opačném směru gradientu funkce. Gradient je vektor, který ukazuje směr největšího nárůstu funkce. Při pohybu v opačném směru tohoto vektoru, nastává oblast s největší změnou funkce a lze tedy minimalizovat cílovou funkci. Postupné kroky v opačném směru gradientu funkce vedou k nalezení optimálního řešení. Na Obr. 2.17 je vizualizována přirozená aktualizace vah gradientního sestupu ve výstupním prostoru (pro náhodně inicializovanou síť). Jednotlivé vrstevnice znázorňují množiny úrovní hodnot ztrátové funkce podél vertikálního a horizontálního směru. Uprostřed vrstevnic se nachází minimum ztrátové funkce. Z algoritmu výše lze aktualizaci vah GD popsat následovně:

$$w_{t+1} = w_t - \gamma \nabla L(w_t) \quad (2.3)$$

kde w_t je aktuální hodnota vektoru vah v čase t , γ je rychlosť učení (anglicky Learning Rate) a $\nabla L(w_t)$ je gradient cílové funkce v čase t . Různé volby rychlosti učení γ a techniky odhadu pro $\nabla \mathcal{L}(w)$ mohou vést k různým implementacím. Gradientní sestup má proto řadu variant, včetně stochastického gradientního sestupu a mini-batch gradientního sestupu, které se liší v způsobu, jakým jsou gradienty vypočítávány a aktualizovány. Tyto algoritmy již popsaly Goodfellow et al. v [168].

2.6.6.3 Aktivační funkce

Aktivační funkce jsou jednou z nejdůležitějších součástí ANN. Tyto funkce zpracovávají vstupní signály a generují výstupy neuronů, které se dále šíří do dalších vrstev sítě. Musí také splňovat některé předpoklady jako je diferencovatelnost. Aktivační funkce musí být také nelineární, aby se rozšířil rozsah mapovacích funkcí, které lze approximovat. Existují různé aktivační funkce, které mají své výhody a nevýhody. Jejich výběr je podstatnou součástí procesu optimalizace hyperparametrů [168, 182].

Tabulka 2.3: Vybrané aktivační funkce [183]

Název	Funkce	Derivace	Obrázek
Sigmoid	$\sigma(x) = \frac{1}{1+e^{-x}}$	$f'(x) = f(x)(1-f(x))^2$	
Softmax	$f(x) = \frac{e^x}{\sum_i e^x}$	$f'(x) = \frac{e^x}{\sum_i e^x} - \frac{(e^x)^2}{(\sum_i e^x)^2}$	
tanh	$\sigma(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$	$f'(x) = 1 - f(x)^2$	
ReLU	$f(x) = \begin{cases} 0 & \text{if } x < 0 \\ x & \text{if } x \geq 0. \end{cases}$	$f'(x) = \begin{cases} 0 & \text{if } x < 0 \\ x & \text{if } x \geq 0. \end{cases}$	

Logistická funkce, neboli sigmoida, je jednou z nejstarších aktivačních funkcí a má tvar S-křivky. Sigmoida má nelineární charakter, což umožnuje neuronové síti modelovat složité vztahy mezi vstupy a výstupy. Nicméně, sigmoida má některé nevýhody, mezi které patří tzv. „vanishing gradient“, kdy se gradient funkce blíží nule, což brání učení sítě. Tato funkce také může způsobit saturaci neuronů, což znamená, že se jejich výstupy blíží k hodnotě 0 nebo 1, a brání tak dalšímu učení [182].

Hyperbolická funkce tangens (tanh) je podobná sigmoidě, ale má symetrický tvar s rozsahem mezi -1 a 1. Tanh může být lepší volbou než sigmoida pro určité typy sítí, protože umožňuje výstupy neuronů, které jsou jak kladné, tak záporné [182].

Aktivační funkce ReLU (anglicky Rectified Linear Unit) vrací vstupní hodnotu, pokud je kladná, a nulu, pokud je záporná. Jedná se o velmi populární a efektivní funkci, která umožňuje rychlé učení sítí. Navíc, ReLU může snížit výskyt saturace neuronů a dříve zmíněného problému – „vanishing gradient“. Nicméně, tato funkce může mít problém s tzv. „mrtvými neurony“, kdy neuron má výstup vždy roven nule a stává se tak neaktivní [182, 184].

Leaky ReLU je modifikace ReLU, která řeší problém „mrtvých neuronů“ tím, že má nenulovou hodnotu pro záporné vstupy. Existuje řada dalších aktivačních funkcí,

jako je softmax, která se často používá jako aktivační funkce pro poslední vrstvu neuronové sítě a používá se v úlohách klasifikace [182].

2.6.6.4 Regularizace

Z předešlých kapitol vyplývá, že jedním z hlavních cílů učení neuronové sítě je minimalizace chyby predikce. Často ale dochází k přeúčení neuronová sítě, tedy sít se naučí velmi přesně předpovídat data použitá pro trénování, ale ztrácí schopnost generalizace. To je způsobeno tím, že síť se snaží přizpůsobit se každému jednotlivému trénovacímu datovému bodu a následně nedokáže předpovídat data, která se od těch trénovacích liší. K tomuto jevu dochází, protože neuronová síť má příliš mnoho parametrů (viz 2.6.2.2). Řešením tohoto problému je použití regularizace. Regularizace je technika, která snižuje rozptyl modelu sítě, a snaží se tak minimalizovat riziko přeúčení. Existuje několik technik regularizace, z nichž nejčastěji používanými jsou L1 a L2 regularizace, dropout a early stopping.

Metody regularizace L1 a L2 omezují optimalizační metody během procesu minimalizace ztrátové funkce modelu. Tato omezení penalizují váhy, což vede ke zjednodušení modelu. Při L1 regularizaci se k nákladové funkci přidává regularizační člen, který je součtem absolutních hodnot vah. Tento přístup způsobí, že některé příznaky jsou považovány za méně důležité a je jim přiřazena nulová váha, čímž se model účinně zjednoduší. Váhy byly dříve indexovány na základě neuronů a vrstev, které spojují. U L2 je zaveden regularizační člen za účelem minimalizace součtu čtverců vah. Tento přístup nevede k vynulování vah, ale snižuje je o faktor úměrný jejich velikosti během každé iterace gradientního sestupu [166, 168].

Dropout je metoda, která náhodně „*vypne*“ některé neurony v síti během trénování, což má za následek omezení relací mezi neurony a snížení rizika přeúčení. Early stopping je technika, která sleduje vývoj chyby při trénování sítě na validačním datasetu a zastaví trénování, jakmile se chyba na validačním datasetu začne zvyšovat. Umožňuje tak včasné ukončení trénování a minimalizaci rizika přeúčení [166, 168].

KAPITOLA **3**

Cíle práce

Hlavním cílem diplomové práce je návrh a realizace metod pro hodnocení kognitivní zátěže z biosignálů současně s vyhodnocením vlivu extrémního prostředí na její projevy. Hodnocenými biosignály jsou konkrétně elektrická srdeční aktivita, respirační aktivita a elektrodermální aktivita. Extrémním prostředím je v kontextu diplomové práce myšlena vesmírná analogová mise, během které proběhl sběr dat.

KAPITOLA 4

Metody

4.1 Mise DIANA

4.1.1 Projekt Hydronaut

4.1.2 Výběr posádky

4.1.3 Popis lokality a podmínky prostředí

4.1.4 Hlubinná laboratoř H03 DeepLab

4.1.4.1 Vybavení stanice

4.1.4.2 Řízení stanice a mise

4.1.5 Infrastruktura mise

4.1.5.1 Řídicí věž

4.1.5.2 Povrchová jednotka

4.1.6 Monitorování a měření posádky

4.1.6.1 Měření biosignálů

4.1.7 Studie

KAPITOLA **5**

Výsledky

KAPITOLA 6

Diskuse

KAPITOLA 7

Závěr

7.1 Budoucí práce

Bibliografie

1. HARRISON, Albert A.; CONNORS, Mary M. Groups in Exotic Environments. In: BERKOWITZ, Leonard (ed.) [online]. Academic Press, 1984, sv. 18, s. 49–87 [cit. 2021-04-08]. Advances in Experimental Social Psychology. ISSN 0065-2601. Dostupné z DOI: [https://doi.org/10.1016/S0065-2601\(08\)60142-2](https://doi.org/10.1016/S0065-2601(08)60142-2).
2. BELL, Suzanne T.; FISHER, David M.; BROWN, Shanique G.; MANN, Kristin E. An Approach for Conducting Actionable Research With Extreme Teams. *Journal of Management* [online]. 2018, roč. 44, č. 7, s. 2740–2765 [cit. 2021-04-08]. Dostupné z DOI: <10.1177/0149206316653805>.
3. STACHOWSKI, Alicia A; KAPLAN, Seth A; WALLER, Mary J. The benefits of flexible team interaction during crises. *Journal of Applied Psychology* [online]. 2009, roč. 94, č. 6, s. 1536 [cit. 2021-04-08]. Dostupné z DOI: <10.1037/a0016903>.
4. YU, Tieying; SENGUL, Metin; LESTER, Richard H. Misery loves company: The spread of negative impacts resulting from an organizational crisis. *Academy of Management Review* [online]. 2008, roč. 33, č. 2, s. 452–472 [cit. 2021-04-08]. Dostupné z DOI: <10.5465/amr.2008.31193499>.
5. GARDNER, Heidi K. Performance pressure as a double-edged sword: Enhancing team motivation but undermining the use of team knowledge. *Administrative Science Quarterly* [online]. 2012, roč. 57, č. 1, s. 1–46 [cit. 2021-04-08]. Dostupné z DOI: <10.1177/0001839212446454>.
6. STAAL, Mark A. Stress, Cognition, and Human Performance: A Literature Review and Conceptual Framework. In: [online]. 2013 [cit. 2021-04-08]. Dostupné z: <https://ntrs.nasa.gov/citations/20060017835>.
7. HANNAH, Sean T.; UHL-BIEN, Mary; AVOLIO, Bruce J.; CAVARRETTA, Fabrice L. A framework for examining leadership in extreme contexts. *The Leadership Quarterly* [online]. 2009, roč. 20, č. 6, s. 897–919 [cit. 2021-06-12]. ISSN 1048-9843. Dostupné z DOI: <https://doi.org/10.1016/j.leaqua.2009.09.006>. The Leadership Quarterly Yearly Review of Leadership.

8. HÄLLGREN, Markus; ROULEAU, Linda; ROND, Mark de. A Matter of Life or Death: How Extreme Context Research Matters for Management and Organization Studies. *Academy of Management Annals* [online]. 2018, roč. 12, č. 1, s. 111–153 [cit. 2021-06-15]. Dostupné z DOI: 10.5465/annals.2016.0017.
9. GOLDEN, Simon J.; CHANG, Chu-Hsiang (Daisy); KOZLOWSKI, Steve W.J. Teams in isolated, confined, and extreme (ICE) environments: Review and integration. *Journal of Organizational Behavior* [online]. 2018, roč. 39, č. 6, s. 701–715 [cit. 2021-06-16]. Dostupné z DOI: <https://doi.org/10.1002/job.2288>.
10. PAGEL, J. I.; CHOUKÈR, A. Effects of isolation and confinement on humans—implications for manned space explorations. *Journal of Applied Physiology*. 2016, roč. 120, č. 12, s. 1449–1457. Dostupné z DOI: 10.1152/japplphysiol.00928.2015. PMID: 26846554.
11. TAYLOR, Lee; WATKINS, Samuel L.; MARSHALL, Hannah; DASCOMBE, Ben J.; FOSTER, Josh. The impact of different environmental conditions on cognitive function: A focused review. *Frontiers in Physiology* [online]. 2016, roč. 6, s. 372 [cit. 2021-06-14]. ISSN 1664042X. Dostupné z DOI: 10.3389/fphys.2015.00372.
12. WINNARD, Andrew; SCOTT, Jonathan; WATERS, Nathan; VANCE, Martin; CAPLAN, Nick. Effect of Time on Human Muscle Outcomes During Simulated Microgravity Exposure Without Countermeasures—Systematic Review. *Frontiers in Physiology* [online]. 2019, roč. 10 [cit. 2021-04-08]. ISSN 1664042X. Dostupné z DOI: 10.3389/fphys.2019.01046.
13. ZHANG, Fan; DE DEAR, Richard; HANCOCK, Peter. Effects of moderate thermal environments on cognitive performance: A multidisciplinary review. *Applied Energy* [online]. 2019, roč. 236, s. 760–777 [cit. 2021-04-08]. ISSN 0306-2619. Dostupné z DOI: <https://doi.org/10.1016/j.apenergy.2018.12.005>.
14. MAYNARD, M Travis; KENNEDY, Deanna M; RESICK, Christian J. Teamwork in extreme environments: Lessons, challenges, and opportunities. *Journal of organizational behavior* [online]. 2018, roč. 39, č. 6, s. 695–700 [cit. 2021-06-14]. ISSN 1099-1379. Dostupné z DOI: 10.1002/JOB.2302.
15. DRISKELL, Tripp; SALAS, Eduardo; DRISKELL, James E. Teams in extreme environments: Alterations in team development and teamwork. *Human Resource Management Review* [online]. 2018, roč. 28, s. 434–449 [cit. 2021-06-09]. ISSN 1053-4822. Dostupné z DOI: 10.1016/J.HRMR.2017.01.002.
16. WICKMAN, Leslie; TSAI, Annie; WALTERS, Raymond. Isolation and Confinement Issues in Long Duration Spaceflight. In: [online]. 2008, s. 1–9 [cit. 2021-06-12]. Dostupné z DOI: 10.1109/AERO.2008.4526654.

17. STUSTER, Jack W. Bold endeavors: behavioral lessons from polar and space exploration. *Gravitational and Space Research* [online]. 2007, roč. 13, č. 2 [cit. 2021-06-14]. Dostupné z: <http://gravitationalandspaceresearch.org/index.php/journal/article/view/244/243>.
18. KALEAGASI, Bartu. *Space Technology under NASA and SpaceX* [online]. 2017. [cit. 2021-06-24]. Dostupné z: <https://bartukaleagasi.files.wordpress.com/2017/01/space-technology-under-nasa-and-spacex.pdf>.
19. SALOTTI, Jean-Marc; HEIDMANN, Richard. Roadmap to a human Mars mission. *Acta Astronautica* [online]. 2014, roč. 104, č. 2, s. 558–564 [cit. 2021-06-16]. ISSN 0094-5765. Dostupné z DOI: <https://doi.org/10.1016/j.actaastro.2014.06.038>. Future of Space Exploration: Towards the Stars.
20. VISCIO, Maria Antonietta; GARGIOLI, Eugenio; HOFFMAN, Jeffrey A.; MAGGIORE, Paolo; MESSIDORO, Andrea; VIOLA, Nicole. A methodology for innovative technologies roadmaps assessment to support strategic decisions for future space exploration. *Acta Astronautica* [online]. 2014, roč. 94, č. 2, s. 813–833 [cit. 2021-06-16]. ISSN 0094-5765. Dostupné z DOI: <https://doi.org/10.1016/j.actaastro.2013.10.004>.
21. MOGILEVER, Nicolette B.; ZUCCARELLI, Lucrezia; BURLES, Ford; IARIA, Giuseppe; STRAPAZZON, Giacomo; BESSONE, Loredana; COFFEY, Emily B.J. Expedition cognition: A review and prospective of subterranean neuroscience with spaceflight applications. *Frontiers in Human Neuroscience* [online]. 2018, roč. 12, s. 407 [cit. 2021-06-15]. ISSN 16625161. Dostupné z DOI: [10.3389/FNHUM.2018.00407](https://doi.org/10.3389/FNHUM.2018.00407).
22. BUGUET, Alain. Sleep under extreme environments: Effects of heat and cold exposure, altitude, hyperbaric pressure and microgravity in space. *Journal of the Neurological Sciences* [online]. 2007, roč. 262, s. 145–152 [cit. 2021-04-08]. ISSN 0022510X. Dostupné z DOI: [10.1016/J.JNS.2007.06.040](https://doi.org/10.1016/J.JNS.2007.06.040).
23. WILLIAMS, David; KUIPERS, Andre; MUKAI, Chiaki; THIRSK, Robert. Acclimation during space flight: Effects on human physiology. *CMAJ* [online]. 2009, roč. 180, s. 1317–1323 [cit. 2021-04-08]. ISSN 14882329. Dostupné z DOI: [10.1503/CMAJ.090628](https://doi.org/10.1503/CMAJ.090628).
24. ROY-O'REILLY, Meaghan; MULAVARA, Ajitkumar; WILLIAMS, Thomas. A review of alterations to the brain during spaceflight and the potential relevance to crew in long-duration space exploration. *npj Microgravity* 2021 7:1 [online]. 2021, roč. 7, č. 1, s. 1–9 [cit. 2021-06-15]. ISSN 2373-8065. Dostupné z DOI: [10.1038/s41526-021-00133-z](https://doi.org/10.1038/s41526-021-00133-z).

25. STRANGMAN, Gary E.; SIPES, Walter; BEVEN, Gary. Human cognitive performance in spaceflight and analogue environments. *Aviation Space and Environmental Medicine* [online]. 2014, roč. 85, s. 1033–1048 [cit. 2021-04-18]. ISSN 00956562. Dostupné z DOI: 10.3357/ASEM.3961.2014.
26. MORPHEW, Ephimia. Psychological and human factors in long duration spaceflight. *McGill Journal of Medicine* [online]. 2001, roč. 6, č. 1 [cit. 2021-06-16]. Dostupné z DOI: 10.26443/mjm.v6i1.555.
27. STEIN, Thomas P. Weight, muscle and bone loss during space flight: another perspective. *European Journal of Applied Physiology* [online]. 2012, roč. 113, s. 2171–2181 [cit. 2021-06-18]. Dostupné z: <https://link.springer.com/article/10.1007/s00421-012-2548-9>.
28. GROEMER, Gernot; OZDEMIR, Seda. Planetary Analog Field Operations as a Learning Tool. *Frontiers in Astronomy and Space Sciences* [online]. 2020, roč. 7 [cit. 2021-06-19]. ISSN 2296-987X. Dostupné z DOI: 10.3389/fspas.2020.00032.
29. BARKASZI, Irén; TAKÁCS, Endre; CZIGLER, István; BALÁZS, László. Extreme Environment Effects on Cognitive Functions: A Longitudinal Study in High Altitude in Antarctica. *Frontiers in Human Neuroscience* [online]. 2016, roč. 10 [cit. 2021-04-08]. ISSN 1662-5161. Dostupné z DOI: 10.3389/fnhum.2016.00331.
30. LUGG, D.; SHEPANEK, M. Space analogue studies in Antarctica. *Acta Astronautica* [online]. 1999, roč. 44, č. 7, s. 693–699 [cit. 2021-06-19]. ISSN 0094-5765. Dostupné z DOI: [https://doi.org/10.1016/S0094-5765\(99\)00068-5](https://doi.org/10.1016/S0094-5765(99)00068-5). Pacific RIM: A Rapidly Expanding Space Market.
31. SCHNEIDER, Stefan; ABELN, Vera; POPOVA, Julia; FOMINA, Elena; JACUBOWSKI, Amrei; MEEUSEN, Romain; STRÜDER, Heiko K. The influence of exercise on prefrontal cortex activity and cognitive performance during a simulated space flight to Mars (MARS500). *Behavioural Brain Research* [online]. 2013, roč. 236, s. 1–7 [cit. 2021-06-19]. ISSN 0166-4328. Dostupné z DOI: <https://doi.org/10.1016/j.bbr.2012.08.022>.
32. WANG, Yue; JING, Xiaolu; LV, Ke; WU, Bin; BAI, Yanqiang; LUO, Yuejia; CHEN, Shanguang; LI, Yinghui. During the Long Way to Mars: Effects of 520 Days of Confinement (Mars500) on the Assessment of Affective Stimuli and Stage Alteration in Mood and Plasma Hormone Levels. *PLOS ONE* [online]. 2014, roč. 9, č. 4, s. 1–9 [cit. 2021-06-19]. Dostupné z DOI: 10.1371/journal.pone.0087087.

33. TREMBANIS, Arthur C; FORREST, Alex L; MILLER, Douglas C; LIM, Darlene SS; GERNHARDT, Michael L; TODD, William L. Multiplatform ocean exploration: Insights from the NEEMO space analog mission. *Marine Technology Society Journal* [online]. 2012, roč. 46, č. 4, s. 7–19 [cit. 2021-06-20]. Dostupné z DOI: 10.1109/BIA48344.2019.8967457.
34. KOUTNIK, Andrew P.; FAVRE, Michelle E.; NOBOA, Karina; SANCHEZ-GONZALEZ, Marcos A.; MOSS, Sara E.; GOUBRAN, Bishoy; ARI, Csilla; POFF, Angela M.; ROGERS, Chris Q.; DEBLASI, Janine M.; SAMY, Bishoy; MOUSSA, Mark; SERRADOR, Jorge M.; D'AGOSTINO, Dominic P. Human Adaptations to Multiday Saturation on NASA NEEMO. *Frontiers in Physiology* [online]. 2021, roč. 11 [cit. 2021-06-20]. ISSN 1664-042X. Dostupné z DOI: 10.3389/fphys.2020.610000.
35. KJELL LINGREN, NASA Astronaut. *NEEMO 22 Photo Gallery* [online]. 2017. [cit. 2021-06-20]. Dostupné z: <https://www.flickr.com/photos/40054892@N06/albums/72157683015049201>.
36. HYDRONAUT. *H03 DeepLab* [online]. 2020. [cit. 2021-06-23]. Dostupné z: <https://hydronaut.eu/cs>.
37. SÁZEL, Miloš; BOHÁČEK, Pavel. Saturační potápění – projekt Hydronaut. *Occupational Medicine / Pracovní Lékarství* [online]. 2014, roč. 66, č. 2/3, s. 85–89 [cit. 2021-06-20]. ISSN 00326291. Dostupné z: <https://search.ebscohost.com/login.aspx?direct=true&db=a9h&AN=102280881&site=ehost-live&scope=site>.
38. MOORE, Steven; DILDA, Valentina; MORRIS, Tiffany; YUNGHER, Don; MACDOUGALL, Hamish; WOOD, Scott. Long-duration spaceflight adversely affects post-landing operator proficiency. *Scientific Reports* [online]. 2019, roč. 9 [cit. 2021-06-23]. Dostupné z DOI: 10.1038/s41598-019-39058-9.
39. DE LA TORRE, Gabriel G. Cognitive Neuroscience in Space. *Life* [online]. 2014, roč. 4, č. 3, s. 281–294 [cit. 2021-06-23]. ISSN 2075-1729. Dostupné z DOI: 10.3390/life4030281.
40. OMBERGEN, Angelique Van; JILLINGS, Steven; JEURISSEN, Ben; TOMILOVSKAYA, Elena; RUMSHISKAYA, Alena; LITVINOVA, Liudmila; NOSIKOVA, Inna; PECHENKOVA, Ekaterina; RUKAVISHNIKOV, Ilya; MANKO, Olga; DANYLICHEV, Sergey; RÜHL, R. Maxine; KOZLOVSKAYA, Inessa B.; SUNAERT, Stefan; PARIZEL, Paul M.; SINITSYN, Valentin; LAUREYS, Steven; SIJBERS, Jan; EULENBURG, Peter zu; WUYTS, Floris L. Brain ventricular volume changes induced by long-duration spaceflight. *Proceedings of the National Academy of Sciences* [online]. 2019, roč. 116, č. 21, s. 10531–10536 [cit. 2021-06-23]. Dostupné z DOI: 10.1073/pnas.1820354116.

41. PECHENKOVA, Ekaterina; NOSIKOVA, Inna; RUMSHISKAYA, Alena; LITVINOVA, Liudmila; RUKAVISHNIKOV, Ilya; MERSHINA, Elena; SINITSYN, Valentin; VAN OMBERGEN, Angelique; JEURISSEN, Ben; JILLINGS, Steven; LAUREYS, Steven; SIJBERS, Jan; GRISHIN, Alexey; CHERNIKOVA, Ludmila; NAUMOV, Ivan; KORNILOVA, Ludmila; WUYTS, Floris L.; TOMILOVSKAYA, Elena; KOZLOVSKAYA, Inessa. Alterations of Functional Brain Connectivity After Long-Duration Spaceflight as Revealed by fMRI. *Frontiers in Physiology* [online]. 2019, roč. 10 [cit. 2021-06-23]. ISSN 1664-042X. Dostupné z DOI: 10.3389/fphys.2019.00761.
42. ROBERTS, Donna; ALBRECHT, Moritz; COLLINS, Heather; ASEMANI, Davud; CHATTERJEE, A.; SPAMPINATO, M.; ZHU, Xun; CHIMOWITZ, Marc; ANTONUCCI, Michael. Effects of Spaceflight on Astronaut Brain Structure as Indicated on MRI. *New England Journal of Medicine* [online]. 2017, roč. 377, s. 1746–1753 [cit. 2021-06-23]. Dostupné z DOI: 10.1056/NEJMoa1705129.
43. DEMERTZI, Athena; VAN OMBERGEN, Angelique; TOMILOVSKAYA, Elena; JEURISSEN, Ben; PECHENKOVA, Ekaterina; DI PERRI, Carol; LITVINOVA, Liudmila; AMICO, Enrico; RUMSHISKAYA, A.; RUKAVISHNIKOV, Ilya; SIJBERS, Jan; SINITSYN, Valentin; KOZLOVSKAYA, Inessa; SUNAERT, Stefan; PARIZEL, Paul; VAN DE HEYNING, Paul; LAUREYS, Steven; WUYTS, Floris. Cortical reorganization in an astronaut's brain after long-duration spaceflight. *Brain structure & function* [online]. 2015, roč. 221 [cit. 2021-06-23]. Dostupné z DOI: 10.1007/s00429-015-1054-3.
44. KRAMER, Larry A.; HASAN, Khader M.; STENGER, Michael B.; SARGSYAN, Ashot; LAURIE, Steven S.; OTTO, Christian; PLOUTZ-SNYDER, Robert J.; MARSHALL-GOEBEL, Karina; RIASCOS, Roy F.; MACIAS, Brandon R. Intracranial Effects of Microgravity: A Prospective Longitudinal MRI Study. *Radiology* [online]. 2020, roč. 295, č. 3, s. 640–648 [cit. 2021-06-23]. Dostupné z DOI: 10.1148/radiol.2020191413. PMID: 32286194.
45. CORREIA, Manning J. Neuronal plasticity: adaptation and readaptation to the environment of space. *Brain Research Reviews* [online]. 1998, roč. 28, č. 1, s. 61–65 [cit. 2021-06-23]. ISSN 0165-0173. Dostupné z DOI: [https://doi.org/10.1016/S0165-0173\(98\)00043-5](https://doi.org/10.1016/S0165-0173(98)00043-5).
46. KOPPELMANS, Vincent; BLOOMBERG, Jacob; MULAVARA, Ajitkumar; SEIDLER, Rachael. Brain structural plasticity with spaceflight. *npj Microgravity* [online]. 2016, roč. 2 [cit. 2021-06-23]. Dostupné z DOI: 10.1038/s41526-016-0001-9.
47. KOPPELMANS, Vincent; BLOOMBERG, Jacob J.; DE DIOS, Yiri E.; WOOD, Scott J.; REUTER-LORENZ, Patricia A.; KOFMAN, Igor S.;

- RIASCOS, Roy; MULAVARA, Ajitkumar P.; SEIDLER, Rachael D. Brain plasticity and sensorimotor deterioration as a function of 70 days head down tilt bed rest. *PLOS ONE* [online]. 2017, roč. 12, č. 8, s. 1–23 [cit. 2021-06-23]. Dostupné z DOI: [10.1371/journal.pone.0182236](https://doi.org/10.1371/journal.pone.0182236).
48. HODKINSON, P.D.; ANDERTON, R.A.; POSSELT, B.N.; FONG, K.J. An overview of space medicine. *British Journal of Anaesthesia*. 2017, roč. 119, s. i143–i153. ISSN 0007-0912. Dostupné z DOI: <https://doi.org/10.1093/bja/aex336>.
49. BREM, Christian; LUTZ, Jürgen; VOLLMAR, Christian; FEUERECKER, Matthias; STREWE, Claudia; NICHIPORUK, Igor; VASSILIEVA, Galina; SCHELLING, Gustav; CHOUKÉR, Alexander. Changes of brain DTI in healthy human subjects after 520 days isolation and confinement on a simulated mission to Mars. *Life Sciences in Space Research* [online]. 2020, roč. 24, s. 83–90 [cit. 2021-06-23]. ISSN 2214-5524. Dostupné z DOI: <https://doi.org/10.1016/j.lssr.2019.09.004>.
50. STAHN, Alexander; GUNGA, Hanns-Christian; KOHLBERG, Eberhard; GALLINAT, Jürgen; DINGES, David; KÜHN, Simone. Brain Changes in Response to Long Antarctic Expeditions. *New England Journal of Medicine* [online]. 2019, roč. 381, s. 2273–2275 [cit. 2021-06-23]. Dostupné z DOI: [10.1056/NEJMc1904905](https://doi.org/10.1056/NEJMc1904905).
51. SWELLER, John. Cognitive Load During Problem Solving: Effects on Learning. *Cognitive Science* [online]. 1988, roč. 12, č. 2, s. 257–285 [cit. 2021-06-24]. Dostupné z DOI: https://doi.org/10.1207/s15516709cog1202_4.
52. SWELLER, John; VAN MERRIENBOER, Jeroen J. G.; PAAS, Fred. Cognitive Architecture and Instructional Design. *Educational Psychology Review* [online]. 1998, roč. 10, s. 251– [cit. 2021-06-24]. Dostupné z DOI: [10.1023/a:1022193728205](https://doi.org/10.1023/a:1022193728205).
53. SWELLER, J. Cognitive load theory: Recent theoretical advances. *Cognitive Load Theory* [online]. 2010, s. 29–47 [cit. 2021-06-24]. Dostupné z DOI: [10.1017/CBO9780511844744.004](https://doi.org/10.1017/CBO9780511844744.004).
54. CHEN, Fang; ZHOU, Jianlong; WANG, Yang; YU, Kun; ARSHAD, Syed; KHAWAJI, Ahmad; CONWAY, Dan. *Robust Multimodal Cognitive Load Measurement* [online]. 2016. [cit. 2021-06-24]. ISBN 978-3-319-31698-7. Dostupné z DOI: [10.1007/978-3-319-31700-7](https://doi.org/10.1007/978-3-319-31700-7).
55. HAAPALAINEN, Eija; KIM, SeungJun; FORLIZZI, Jodi F.; DEY, Anind K. Psycho-Physiological Measures for Assessing Cognitive Load. In: *Proceedings of the 12th ACM International Conference on Ubiquitous Computing* [online]. Copenhagen, Denmark: Association for Computing Machinery, 2010, s. 301–

- 310 [cit. 2021-06-24]. UbiComp '10. ISBN 9781605588438. Dostupné z DOI: 10.1145/1864349.1864395.
56. VANNESTE, Pieter; RAES, Annelies; MORTON, Jessica; BOMBEKE, Klaas; VAN ACKER, Bram; LARMUSEAU, Charlotte; DEPAEPE, Fien; VAN DEN NOORTGATE, Wim. Towards measuring cognitive load through multimodal physiological data. *Cognition, Technology & Work* [online]. 2021, roč. 23 [cit. 2021-06-24]. Dostupné z DOI: 10.1007/s10111-020-00641-0.
 57. THAYER, Julian F.; HANSEN, Anita L.; SAUS-ROSE, Evelyn; JOHNSEN, Bjorn Helge. Heart Rate Variability, Prefrontal Neural Function, and Cognitive Performance: The Neurovisceral Integration Perspective on Self-regulation, Adaptation, and Health. *Annals of Behavioral Medicine* [online]. 2009, roč. 37, č. 2, s. 141–153 [cit. 2021-06-24]. ISSN 0883-6612. Dostupné z DOI: 10.1007/s12160-009-9101-z.
 58. GJORESKI, Martin; LUSTREK, Mitja; GAMS, Matjaz; GJORESKI, Hristijan. Monitoring stress with a wrist device using context. *Journal of Biomedical Informatics*. 2017, roč. 73. Dostupné z DOI: 10.1016/j.jbi.2017.08.006.
 59. DE LA CRUZ, Feliberto; SCHUMANN, Andy; KÖHLER, Stefanie; REICHENBACH, Jürgen; WAGNER, Gerd; BÄR, Karl-Jürgen. The relationship between heart rate and functional connectivity of brain regions involved in autonomic control. *NeuroImage*. 2019, roč. 196. Dostupné z DOI: 10.1016/j.neuroimage.2019.04.014.
 60. BROUWER, Anne-Marie; ZANDER, Thorsten; ERP, Jan; KORTELING, J.E. (Hans); BRONKHORST, Adelbert. Using neurophysiological signals that reflect cognitive or affective state: Six recommendations to avoid common pitfalls. *Frontiers in Neuroscience*. 2015, roč. 9. Dostupné z DOI: 10.3389/fnins.2015.00136.
 61. ANTONENKO, Pavlo "Pasha; PAAS, Fred; GRABNER, Roland; GOG, Tamara. Using Electroencephalography to Measure Cognitive Load. *Educational Psychology Review*. 2010, roč. 22, s. 425–438. Dostupné z DOI: 10.1007/s10648-010-9130-y.
 62. WEL, Pauline; STEENBERGEN, Henk. Pupil dilation as an index of effort in cognitive control tasks: A review. *Psychonomic Bulletin & Review*. 2018, roč. 25. Dostupné z DOI: 10.3758/s13423-018-1432-y.
 63. SETZ, Cornelia; ARNRICH, Bert; SCHUMM, Johannes; LA MARCA, Roberto; TRÖSTER, Gerhard; EHLERT, Ulrike. Discriminating Stress From Cognitive Load Using a Wearable EDA Device. *IEEE Transactions on Information Technology in Biomedicine*. 2010, roč. 14, č. 2, s. 410–417. Dostupné z DOI: 10.1109/TITB.2009.2036164.

64. HERBORN, Katherine; GRAVES, James; JEREM, Paul; EVANS, Neil; NAGER, Ruedi; MCCAFFERTY, Dominic; MCKEEGAN, Dorothy. Skin temperature reveals the intensity of acute stress. *Physiology & behavior*. 2015, roč. 152. Dostupné z DOI: 10.1016/j.physbeh.2015.09.032.
65. JERČIĆ, Petar; SENNERSTEN, Charlotte; LINDLEY, Craig. Modeling cognitive load and physiological arousal through pupil diameter and heart rate. *Multimedia Tools and Applications*. 2020, roč. 79. Dostupné z DOI: 10.1007/s11042-018-6518-z.
66. SOLHJOO, Soroosh; HAIGNEY, Mark; MCBEE, Elexis; VAN MERRIENBOER, Jeroen J. G.; SCHUWIRTH, Lambert; ARTINO, Anthony; BATTISTA, Alexis; RATCLIFFE, Temple; LEE, Howard; DURNING, Steven. Heart Rate and Heart Rate Variability Correlate with Clinical Reasoning Performance and Self-Reported Measures of Cognitive Load. *Scientific Reports*. 2019, roč. 9, s. 1–9. Dostupné z DOI: 10.1038/s41598-019-50280-3.
67. GRASSMANN, Mariel; VLEMINCX, Elke; LEUPOLDT, Andreas; MITTELSTÄDT, Justin; VAN DEN BERGH, Omer. Respiratory Changes in Response to Cognitive Load: A Systematic Review. *Neural Plasticity*. 2016, roč. 2016, s. 1–16. Dostupné z DOI: 10.1155/2016/8146809.
68. F., Kramer A. Physiological metrics of mental workload : A review of recent progress. *Multiple-task Performance*. 1991, s. 279–328. Dostupné také z: <https://cir.nii.ac.jp/crid/1572543024796401024>.
69. WANG, Chixiang; GUO, Junqi. A data-driven framework for learners' cognitive load detection using ECG-PPG physiological feature fusion and XGBoost classification. *Procedia Computer Science*. 2019, roč. 147, s. 338–348. ISSN 1877-0509. Dostupné z DOI: 10.1016/j.procs.2019.01.234.
70. SCHNOTZ, Wolfgang; KÜRSCHNER, Christian. A Reconsideration of Cognitive Load Theory. *Educational Psychology Review*. 2007, roč. 19, č. 4, s. 469–508. ISSN 1573-336X. Dostupné z DOI: 10.1007/s10648-007-9053-4.
71. HART, Sandra G. Nasa-Task Load Index (NASA-TLX); 20 Years Later. *Proceedings of the Human Factors and Ergonomics Society Annual Meeting*. 2006, roč. 50, č. 9, s. 904–908. Dostupné z DOI: 10.1177/154193120605000909.
72. GIANNAKAKIS, Giorgos; GRIGORIADIS, Dimitris; GIANNAKAKI, Katerina; SIMANTIRAKI, Olympia; RONIOTIS, Alexandros; TSIKNAKIS, Manolis. Review on Psychological Stress Detection Using Biosignals. *IEEE Transactions on Affective Computing*. 2022, roč. 13, č. 1, s. 440–460. ISSN 1949-3045. Dostupné z DOI: 10.1109/TAFFC.2019.2927337.

-
73. ISHAQUE, Syem; KHAN, Naimul; KRISHNAN, Sri. Trends in Heart-Rate Variability Signal Analysis. *Frontiers in Digital Health* [online]. 2021, roč. 3 [cit. 2023-02-23]. Dostupné z: <https://www.frontiersin.org/articles/10.3389/fdgth.2021.639444>.
74. ROHILA, Ashish; SHARMA, Ambalika. Correlation between heart rate variability features. *2020 7th International Conference on Signal Processing and Integrated Networks, SPIN 2020*. 2020, s. 669–674. ISBN 9781728154756. Dostupné z DOI: 10.1109/SPIN48934.2020.9071381.
75. PHAM, Tam; LAU, Zen Juen; CHEN, S. H. Annabel; MAKOWSKI, Dominique. Heart rate variability in psychology: A review of hrv indices and an analysis tutorial. *Sensors*. 2021, roč. 21, č. 12. ISSN 14248220. Dostupné z DOI: 10.3390/S21123998.
76. BOUNY, Pierre; ARSAC, Laurent M; TOURÉ CUQ, Emma; DESCHODT-ARSAC, Veronique. Entropy and Multifractal-Multiscale Indices of Heart Rate Time Series to Evaluate Intricate Cognitive-Autonomic Interactions. *Entropy (Basel, Switzerland)*. 2021, roč. 23, č. 6. ISSN 1099-4300. Dostupné z DOI: 10.3390/e23060663.
77. HWANG, Bosun; YOU, Jiwoo; VAESSEN, Thomas; MYIN-GERMEYS, Inez; PARK, Cheolsoo; ZHANG, Byoung-Tak. Deep ECGNet: An Optimal Deep Learning Framework for Monitoring Mental Stress Using Ultra Short-Term ECG Signals. *Telemedicine journal and e-health : the official journal of the American Telemedicine Association* [online]. 2018, roč. 24 10, s. 753–772 [cit. 2023-02-23]. Dostupné z: <https://www.liebertpub.com/doi/full/10.1089/tmj.2017.0250>.
78. HE, Jiayuan; LI, Ke; LIAO, Xiaoli; ZHANG, Ping; JIANG, Ning. Real-Time Detection of Acute Cognitive Stress Using a Convolutional Neural Network From Electrocardiographic Signal. *IEEE Access* [online]. 2019, roč. 7, s. 42710–42717 [cit. 2023-02-23]. Dostupné z DOI: 10.1109/ACCESS.2019.2907076.
79. OSKOOEI, Ali; CHAU, Sophie Mai; WEISS, Jonas R. M.; SRIDHAR, Arvind; MART'INEZ, Mar'ia Rodr'iguez; MICHEL, Bruno. DeStress: Deep Learning for Unsupervised Identification of Mental Stress in Firefighters from Heart-rate Variability (HRV) Data. *ArXiv* [online]. 2019, roč. abs/1911.13213 [cit. 2023-02-23]. Dostupné z: <https://arxiv.org/abs/1911.13213>.
80. CHO, Dongrae; HAM, Jinsil; OH, Jooyoung; PARK, Jeanho; KIM, Sayup; LEE, Nak-Kyu; LEE, Boreom. Detection of Stress Levels from Biosignals Measured in Virtual Reality Environments Using a Kernel-Based Extreme Learning Machine. *Sensors* [online]. 2017, roč. 17, č. 10, s. 2435 [cit. 2023-02-23]. ISSN 1424-8220. Dostupné z DOI: 10.3390/s17102435.

81. APPELHANS, Bradley M.; LUECKEN, Linda J. Heart Rate Variability as an Index of Regulated Emotional Responding. *Review of General Psychology*. 2006, roč. 10, č. 3, s. 229–240. ISSN 1089-2680. Dostupné z DOI: 10.1037/1089-2680.10.3.229.
82. BUTLER, Emily A.; WILHELM, Frank H.; GROSS, James J. Respiratory sinus arrhythmia, emotion, and emotion regulation during social interaction. *Psychophysiology*. 2006, roč. 43, č. 6, s. 612–622. ISSN 1469-8986. Dostupné z DOI: 10.1111/j.1469-8986.2006.00467.x.
83. INGJALDSSON, Jon T; LABERG, Jon C; THAYER, Julian F. Reduced heart rate variability in chronic alcohol abuse: relationship with negative mood, chronic thought suppression, and compulsive drinking. *Biological Psychiatry*. 2003, roč. 54, č. 12, s. 1427–1436. ISSN 0006-3223. Dostupné z DOI: 10.1016/S0006-3223(02)01926-1.
84. LANE, Richard D. Neural Substrates of Implicit and Explicit Emotional Processes: A Unifying Framework for Psychosomatic Medicine. *Psychosomatic Medicine*. 2008, roč. 70, č. 2, s. 214. ISSN 0033-3174. Dostupné z DOI: 10.1097/PSY.0b013e3181647e44.
85. MELZIG, Christiane A.; WEIKE, Almut I.; HAMM, Alfons O.; THAYER, Julian F. Individual differences in fear-potentiated startle as a function of resting heart rate variability: Implications for panic disorder. *International Journal of Psychophysiology*. 2009, roč. 71, č. 2, s. 109–117. ISSN 0167-8760. Dostupné z DOI: 10.1016/j.ijpsycho.2008.07.013.
86. THAYER, Julian F.; BROSSCHOT, Jos F. Psychosomatics and psychopathology: looking up and down from the brain. *Psychoneuroendocrinology*. 2005, roč. 30, č. 10, s. 1050–1058. ISSN 0306-4530. Dostupné z DOI: 10.1016/j.psyneuen.2005.04.014.
87. HANSEN, Anita Lill; JOHNSEN, Bjørn Helge; THAYER, Julian F. Vagal influence on working memory and attention. *International Journal of Psychophysiology*. 2003, roč. 48, č. 3, s. 263–274. ISSN 0167-8760. Dostupné z DOI: 10.1016/S0167-8760(03)00073-4.
88. JOHNSEN, Bjørn Helge; THAYER, Julian F; LABERG, Jon C; WORMNES, Bjørn; RAADAL, Magne; SKARET, Erik; KVALE, Gerd; BERG, Einar. Attentional and physiological characteristics of patients with dental anxiety. *Journal of Anxiety Disorders*. 2003, roč. 17, č. 1, s. 75–87. ISSN 0887-6185. Dostupné z DOI: 10.1016/S0887-6185(02)00178-0.
89. SAUS, Evelyn-Rose; JOHNSEN, Bjørn Helge; EID, Jarle; RIISEM, Per Ketil; ANDERSEN, Rune; THAYER, Julian F. The Effect of Brief Situational Awareness Training in a Police Shooting Simulator: An Experimental Study.

- Military Psychology.* 2006, roč. 18, č. sup1, S3–S21. ISSN 0899-5605. Dostupné z DOI: 10.1207/s15327876mp1803s_2.
90. BROSSCHOT, Jos F.; VAN DIJK, Eduard; THAYER, Julian F. Daily worry is related to low heart rate variability during waking and the subsequent nocturnal sleep period. *International Journal of Psychophysiology.* 2007, roč. 63, č. 1, s. 39–47. ISSN 0167-8760. Dostupné z DOI: 10.1016/j.ijpsycho.2006.07.016.
91. LIAO, Duanping; CARNETHON, Mercedes; EVANS, Gregory W.; CASCIO, Wayne E.; HEISS, Gerardo. Lower Heart Rate Variability Is Associated With the Development of Coronary Heart Disease in Individuals With Diabetes: The Atherosclerosis Risk in Communities (ARIC) Study. *Diabetes.* 2002, roč. 51, č. 12, s. 3524–3531. ISSN 0012-1797. Dostupné z DOI: 10.2337/diabetes.51.12.3524.
92. THAYER, J. F.; FISCHER, J. E. Heart rate variability, overnight urinary norepinephrine and C-reactive protein: evidence for the cholinergic anti-inflammatory pathway in healthy human adults. *Journal of Internal Medicine.* 2009, roč. 265, č. 4, s. 439–447. ISSN 1365-2796. Dostupné z DOI: 10.1111/j.1365-2796.2008.02023.x.
93. THAYER, Julian F.; LANE, Richard D. The role of vagal function in the risk for cardiovascular disease and mortality. *Biological Psychology.* 2007, roč. 74, č. 2, s. 224–242. ISSN 0301-0511. Dostupné z DOI: 10.1016/j.biopsych.2005.11.013.
94. GORMAN, Jack M.; SLOAN, Richard P. Heart rate variability in depressive and anxiety disorders. *American Heart Journal.* 2000, roč. 140, č. 4, Supplement, S77–S83. ISSN 0002-8703. Dostupné z DOI: 10.1067/mhj.2000.109981.
95. KEMP, Andrew H.; QUINTANA, Daniel S. The relationship between mental and physical health: Insights from the study of heart rate variability. *International Journal of Psychophysiology.* 2013, roč. 89, č. 3, s. 288–296. ISSN 0167-8760. Dostupné z DOI: 10.1016/j.ijpsycho.2013.06.018.
96. KEMP, Andrew H.; QUINTANA, Daniel S.; FELMINGHAM, Kim L.; MATTHEWS, Slade; JELINEK, Herbert F. Depression, Comorbid Anxiety Disorders, and Heart Rate Variability in Physically Healthy, Unmedicated Patients: Implications for Cardiovascular Risk. *PLOS ONE.* 2012, roč. 7, č. 2, e30777. ISSN 1932-6203. Dostupné z DOI: 10.1371/journal.pone.0030777.
97. GIANAROS, PJ. Brain-body pathways to cardiovascular disease risk. In: *Herbert Weiner Early Career Award Lecture, 66th Annual Meeting of the American Psychosomatic Society, Baltimore, MD, March.* 2008.

98. BEISSNER, Florian; MEISSNER, Karin; BÄR, Karl-Jürgen; NAPADOW, Vitaly. The Autonomic Brain: An Activation Likelihood Estimation Meta-Analysis for Central Processing of Autonomic Function. *Journal of Neuroscience*. 2013, roč. 33, č. 25, s. 10503–10511. ISSN 0270-6474, ISSN 1529-2401. Dostupné z DOI: 10.1523/JNEUROSCI.1103-13.2013.
99. THAYER, Julian F; LANE, Richard D. A model of neurovisceral integration in emotion regulation and dysregulation. *Journal of Affective Disorders*. 2000, roč. 61, č. 3, s. 201–216. ISSN 0165-0327. Dostupné z DOI: 10.1016/S0165-0327(00)00338-4.
100. THAYER, Julian F.; LANE, Richard D. Claude Bernard and the heart–brain connection: Further elaboration of a model of neurovisceral integration. *Neuroscience & Biobehavioral Reviews*. 2009, roč. 33, č. 2, s. 81–88. ISSN 0149-7634. Dostupné z DOI: 10.1016/J.NEUBIOREV.2008.08.004.
101. SHAFFER, Fred; MCCRATY, Rollin; ZERR, Christopher L. A healthy heart is not a metronome: an integrative review of the hearts anatomy and heart rate variability. *Frontiers in psychology*. 2014, roč. 5, s. 1040. ISSN 1664-1078. Dostupné z DOI: 10.3389/fpsyg.2014.01040.
102. RAICHLE, Marcus E.; MACLEOD, Ann Mary; SNYDER, Abraham Z.; POWERS, William J.; GUSNARD, Debra A.; SHULMAN, Gordon L. A default mode of brain function. *Proceedings of the National Academy of Sciences*. 2001, roč. 98, č. 2, s. 676–682. Dostupné z DOI: 10.1073/pnas.98.2.676.
103. NAGAI, Y; CRITCHLEY, H. D; FEATHERSTONE, E; TRIMBLE, M. R; DOLAN, R. J. Activity in ventromedial prefrontal cortex covaries with sympathetic skin conductance level: a physiological account of a “default mode” of brain function. *NeuroImage*. 2004, roč. 22, č. 1, s. 243–251. ISSN 1053-8119. Dostupné z DOI: 10.1016/j.neuroimage.2004.01.019.
104. SMITH, Ryan; THAYER, Julian F.; KHALSA, Sahib S.; LANE, Richard D. The hierarchical basis of neurovisceral integration. *Neuroscience & Biobehavioral Reviews*. 2017, roč. 75, s. 274–296. ISSN 0149-7634. Dostupné z DOI: 10.1016/J.NEUBIOREV.2017.02.003.
105. LUJAN, Matthew R.; PEREZ-POZUELO, Ignacio; GRANDNER, Michael A. Past, Present, and Future of Multisensory Wearable Technology to Monitor Sleep and Circadian Rhythms. *Frontiers in Digital Health*. 2021, roč. 3. ISSN 2673-253X. Dostupné také z: <https://www.frontiersin.org/articles/10.3389/fdgth.2021.721919>.
106. ŠTEJFA, Miloš. *Kardiologie: 3., přepracované a doplněné vydání*. 1. elektronické vydání. Grada, 2006. ISBN 978-80-247-7034-5.

107. WEINHAUS, Anthony J.; ROBERTS, Kenneth P. Anatomy of the Human Heart. In: *Handbook of Cardiac Anatomy, Physiology, and Devices* [online]. Totowa, NJ: Humana Press, 2005, s. 51–79 [cit. 2021-02-27]. ISBN 978-1-58829-443-2. Dostupné z DOI: [10.1007/978-1-59259-835-9_4](https://doi.org/10.1007/978-1-59259-835-9_4).
108. ČIHÁK, Radomír. Anatomie 3. In: Třetí, upravené a doplněné vydání. Praha: Grada, 2016, s. 7–79. ISBN 9788024756363.
109. GOLDBERGER, Ary L.; GOLDBERGER, Zachary D.; SHVILKIN, Alexei. Goldberger's Clinical Electrocardiography: A Simplified Approach. In: 9th edition. Philadelphia: Elsevier Inc., 2017. ISBN 9780323508773.
110. PORR, Bernd; HOWELL, Luis. R-peak detector stress test with a new noisy ECG database reveals significant performance differences amongst popular detectors. *bioRxiv* [online]. 2019 [cit. 2023-02-24]. Dostupné z DOI: [10.1101/722397](https://doi.org/10.1101/722397).
111. FATISSON, Julien; OSWALD, Victor; LALONDE, François. Influence diagram of physiological and environmental factors affecting heart rate variability: an extended literature overview. *Heart International*. 2016, roč. 11, e32–e40.
112. HAYANO, Junichiro; YUDA, Emi. Pitfalls of assessment of autonomic function by heart rate variability. *Journal of physiological anthropology*. 2019, roč. 38, č. 1, s. 1–8.
113. BIGGER, J.Thomas; ALBRECHT, Paul; STEINMAN, Richard C.; ROLNITZKY, Linda M.; FLEISS, Joseph L.; COHEN, Richard J. Comparison of time- and frequency domain-based measures of cardiac parasympathetic activity in Holter recordings after myocardial infarction. *The American Journal of Cardiology*. 1989, roč. 64, č. 8, s. 536–538. ISSN 0002-9149. Dostupné z DOI: [https://doi.org/10.1016/0002-9149\(89\)90436-0](https://doi.org/10.1016/0002-9149(89)90436-0).
114. MALIK, M.; CAMM, A. J.; BIGGER, J. T.; BREITHARDT, G.; CERUTTI, S.; COHEN, R. J.; COUMEL, P.; FALLEN, E. L.; KENNEDY, H. L.; KLEIGER, R. E.; LOMBARDI, F.; MALLIANI, A.; MOSS, A. J.; ROTTMAN, J. N.; SCHMIDT, G.; SCHWARTZ, P. J.; SINGER, D. H. Heart rate variability. Standards of measurement, physiological interpretation, and clinical use. *European Heart Journal*. 1996, roč. 17, č. 3, s. 354–381. ISSN 0195668X. Dostupné z DOI: [10.1093/oxfordjournals.eurheartj.a014868](https://doi.org/10.1093/oxfordjournals.eurheartj.a014868).
115. ACHARYA, U. Rajendra; JOSEPH, K. Paul; KANNATHAL, N.; LIM, Choo Min; SURI, Jasjit S. Heart rate variability: A review. *Medical and Biological Engineering and Computing*. 2006, roč. 44, č. 12, s. 1031–1051. ISSN 01400118. Dostupné z DOI: [10.1007/s11517-006-0119-0](https://doi.org/10.1007/s11517-006-0119-0).

116. CICCONE, Anthony B.; SIEDLIK, Jacob A.; WECHT, Jill M.; DECKERT, Jake A.; NGUYEN, Nhuquynh D.; WEIR, Joseph P. Reminder: RMSSD and SD1 are identical heart rate variability metrics. *Muscle & Nerve*. 2017, roč. 56, č. 4, s. 674–678. Dostupné z DOI: <https://doi.org/10.1002/mus.25573>.
117. PHAM, Tam; LAU, Zen Juen; SH ANNABEL CHEN, PhD; MAKOWSKI, Dominique. *Unveiling the Structure of Heart Rate Variability (HRV) Indices: A Data-driven Meta-clustering Approach*. PsyArXiv, [b.r.]. Dostupné z DOI: 10.31234/OSF.IO/MWA6X.
118. LEITE, Marcelli R; RAMOS, Ercy Mara C; KALVA-FILHO, Carlos A; RODRIGUES, Fernanda Maria M; FREIRE, Ana Paula CF; TACAO, Guilherme Y; TOLEDO, Alessandra C de; CECÍLIO, Michel J; VANDERLEI, Luiz Carlos M; RAMOS, Dionei. Correlation between heart rate variability indexes and aerobic physiological variables in patients with COPD. *Respirology*. 2015, roč. 20, č. 2, s. 273–278.
119. PENG, Rong-Chao; ZHOU, Xiao-Lin; LIN, Wan-Hua; ZHANG, Yuan-Ting. Extraction of heart rate variability from smartphone photoplethysmograms. *Computational and mathematical methods in medicine*. 2015, roč. 2015.
120. DORMANN, Carsten F; ELITH, Jane; BACHER, Sven; BUCHMANN, Carsten; CARL, Gudrun; CARRÉ, Gabriel; MARQUÉZ, Jaime R García; GRUBER, Bernd; LAFOURCADE, Bruno; LEITÃO, Pedro J et al. Collinearity: a review of methods to deal with it and a simulation study evaluating their performance. *Ecography*. 2013, roč. 36, č. 1, s. 27–46.
121. GUZIK, Przemyslaw; PISKORSKI, Jaroslaw; AWAN, Kokab; KRAUZE, Tomasz; FITZPATRICK, Michael; BARANCHUK, Adrian. Obstructive sleep apnea and heart rate asymmetry microstructure during sleep. *Clinical Autonomic Research*. 2013, roč. 23, s. 91–100.
122. BRENNAN, Michael; PALANISWAMI, Marimuthu; KAMEN, Peter. Poincaré plot interpretation using a physiological model of HRV based on a network of oscillators. *American Journal of Physiology-Heart and Circulatory Physiology*. 2002, roč. 283, č. 5, H1873–H1886. Dostupné z DOI: 10.1152/ajpheart.00405.2000. PMID: 12384465.
123. BOUCSEIN, Wolfram. Electrodermal activity: Second edition. *Electrodermal Activity: Second Edition*. 2012, roč. 9781461411260, s. 1–618. ISBN 9781461411260. Dostupné z DOI: 10.1007/978-1-4614-1126-0.
124. CRITCHLEY, Hugo D. Electrodermal responses: What happens in the brain. *Neuroscientist*. 2002, roč. 8, č. 2, s. 132–142. ISSN 10738584. Dostupné z DOI: 10.1177/107385840200800209.

125. TRONSTAD, Christian; AMINI, Maryam; BACH, Dominik R; MARTINSEN, Ørjan G. Current trends and opportunities in the methodology of electrodermal activity measurement. *Physiological Measurement*. 2022, roč. 43, č. 2, 02TR01. ISSN 0967-3334. Dostupné z DOI: [10.1088/1361-6579/AC5007](https://doi.org/10.1088/1361-6579/AC5007).
126. FREDRIKSON, Mats; FURMARK, Tomas; OLSSON, Maria Tillfors; FISCHER, Håkan; ANDERSSON, Jesper; LÄNGSTRÖM, Bengt. Functional neuroanatomical correlates of electrodermal activity: A positron emission tomographic study. *Psychophysiology*. 1998, roč. 35, č. 2, s. 179–185. ISSN 1469-8986, ISSN 0048-5772. Dostupné z DOI: [10.1111/1469-8986.3520179](https://doi.org/10.1111/1469-8986.3520179).
127. BUCHWALD, Mikolaj; KUPINSKI, Szymo; BYKOWSKI, Adam; MARCINKOWSKA, Joanna; RATAJCZYK, Dawid; JUKIEWICZ, Marcin. Electrodermal activity as a measure of cognitive load: A methodological approach. *Signal Processing - Algorithms, Architectures, Arrangements, and Applications Conference Proceedings, SPA*. 2019, roč. 2019-September, s. 175–179. ISBN 9788362065363. ISSN 23260319. Dostupné z DOI: [10.23919/SPA.2019.8936745](https://doi.org/10.23919/SPA.2019.8936745).
128. CARUELLE, Delphine; GUSTAFSSON, Anders; SHAMS, Poja; LERVIK-OLSEN, Line. The use of electrodermal activity (EDA) measurement to understand consumer emotions – A literature review and a call for action. *Journal of Business Research*. 2019, roč. 104, s. 146–160. ISSN 01482963. Dostupné z DOI: [10.1016/J.JBUSRES.2019.06.041](https://doi.org/10.1016/J.JBUSRES.2019.06.041).
129. SÁNCHEZ-REOLID, Roberto; LÓPEZ, María T.; FERNÁNDEZ-CABALLERO, Antonio. Machine Learning for Stress Detection from Electrodermal Activity: A Scoping Review. 2020. Dostupné z DOI: [10.20944/PREPRINTS202011.0043.V1](https://doi.org/10.20944/PREPRINTS202011.0043.V1).
130. BLECHERT, Jens; PEYK, Peter; LIEDLGRUBER, Michael; WILHELM, Frank H. ANSLAB: Integrated multichannel peripheral biosignal processing in psychophysiological science. *Behavior Research Methods*. 2016, roč. 48, č. 4, s. 1528–1545. ISSN 1554-3528. Dostupné z DOI: [10.3758/s13428-015-0665-1](https://doi.org/10.3758/s13428-015-0665-1).
131. BAHAUDDIN SIKDER, Md Saif Bin; MD. SALIMULLAH, Shah; AHMED, Inkeyad; HOSSAIN, Delowar; RAJIB, Moshiul Alam; WADUD, Kishwar. Galvanic Skin Response Based Cognitive Load Measurement for Online Exams. *2021 5th International Conference on Electrical Information and Communication Technology, EICT 2021*. 2021. ISBN 9781665409063. Dostupné z DOI: [10.1109/EICT54103.2021.9733564](https://doi.org/10.1109/EICT54103.2021.9733564).
132. GHADERYAN, Peyvand; ABBASI, Ataollah; EBRAHIMI, Afshin. Time-varying singular value decomposition analysis of electrodermal activity: A novel method of cognitive load estimation. *Measurement*. 2018, roč. 126,

- s. 102–109. ISSN 0263-2241. Dostupné z DOI: 10.1016/J.MEASUREMENT.2018.05.015.
133. HOSSAIN, Delowar; SALIMULLAH, Shah Md; CHOWDHURY, Abrar Nayeem; NESHAD HASAN, Syed Md; KABIR, Erfan; MAHMUDI, Rahi; ISLAM, Mahbubul. Measurement of cognitive load for writing tasks using galvanic skin response. *ACM International Conference Proceeding Series*. 2019, s. 122–126. ISBN 9781450376990. Dostupné z DOI: 10.1145/3362966.3362976.
134. NOURBAKHSH, Nargess; WANG, Yang; CHEN, Fang; CALVO, Rafael A. Using Galvanic Skin Response for Cognitive Load Measurement in Arithmetic and Reading Tasks. *Proceedings of the 24th Australian Computer-Human Interaction Conference on - OzCHI '12*. 2012. ISBN 9781450314381. Dostupné z DOI: 10.1145/2414536.
135. PAAS, Fred; TUOVINEN, Juhani E.; TABBERS, Huib; VAN GERVEN, Pascal W.M. Cognitive load measurement as a means to advance cognitive load theory. *Educational Psychologist*. 2003, roč. 38, č. 1, s. 63–71. ISSN 00461520. Dostupné z DOI: 10.1207/S15326985EP3801_8.
136. POSADA-QUINTERO, Hugo F.; FLORIAN, John P.; ORJUELA-CAÑÓN, Alvaro D.; CHON, Ki H. Electrodermal activity is sensitive to cognitive stress under water. *Frontiers in Physiology*. 2018, roč. 8, č. JAN, s. 1128. ISSN 1664042X. Dostupné z DOI: 10.3389/FPHYS.2017.01128/BIBTEX.
137. SHI, Yu; RUIZ, Natalie; TAIB, Ronnie; CHOI, Eric; CHEN, Fang. Galvanic skin response (GSR) as an index of cognitive load. *Conference on Human Factors in Computing Systems - Proceedings*. 2007, s. 2651–2656. ISBN 1595936424. Dostupné z DOI: 10.1145/1240866.1241057.
138. SHIMOMURA, Yoshihiro; YODA, Takumi; SUGIURA, Koji; HORIGUCHI, Akinori; IWANAGA, Koichi; KATSUURA, Tetsuo. Use of frequency domain analysis of skin conductance for evaluation of mental workload. *Journal of Physiological Anthropology*. 2008, roč. 27, č. 4, s. 173–177. ISSN 18806791. Dostupné z DOI: 10.2114/JPA2.27.173.
139. KARA ROGERS SENIOR EDITOR, B.S. *The Respiratory System*. Britannica Educational Pub., 2010. The Human Body. ISBN 978-1-61530-147-8. Dostupné také z: <https://books.google.cz/books?id=jo5ETXP1WGYC>.
140. AYRES, Paul; LEE, Joy Yeonjoo; PAAS, Fred; MERRIËNBOER, Jeroen J. G. van. The Validity of Physiological Measures to Identify Differences in Intrinsic Cognitive Load. *Frontiers in Psychology*. 2021, roč. 12. ISSN 1664-1078. Dostupné také z: <https://www.frontiersin.org/articles/10.3389/fpsyg.2021.702538>.

141. MIRVIS, David M; GOLDBERGER, Ary L. Electrocardiography. *Heart disease*. 2001, roč. 1, s. 82–128. Dostupné také z: <http://www.doctor33.it/cont/download-center-files/17519/cap-electrocardiography-x20968allp1.pdf>.
142. YAO, Qihang; WANG, Ruxin; FAN, Xiaomao; LIU, Jikui; LI, Ye. Multi-class Arrhythmia detection from 12-lead varied-length ECG using Attention-based Time-Incremental Convolutional Neural Network. *Information Fusion*. 2020, roč. 53, s. 174–182. ISSN 1566-2535. Dostupné z DOI: [10.1016/j.inffus.2019.06.024](https://doi.org/10.1016/j.inffus.2019.06.024).
143. BAIG, Mirza Mansoor; GHOLAMHOSSEINI, Hamid; CONNOLLY, Martin J. A comprehensive survey of wearable and wireless ECG monitoring systems for older adults. *Medical & Biological Engineering & Computing*. 2013, roč. 51, č. 5, s. 485–495. ISSN 1741-0444. Dostupné z DOI: [10.1007/s11517-012-1021-6](https://doi.org/10.1007/s11517-012-1021-6).
144. MAJUMDER, Sumit; CHEN, Leon; MARINOV, Ognian; CHEN, Chih-Hung; MONDAL, Tapas; DEEN, M. Jamal. Noncontact Wearable Wireless ECG Systems for Long-Term Monitoring. *IEEE Reviews in Biomedical Engineering*. 2018, roč. 11, s. 306–321. ISSN 1941-1189. Dostupné z DOI: [10.1109/RBME.2018.2840336](https://doi.org/10.1109/RBME.2018.2840336).
145. SERHANI, Mohamed Adel; T. EL KASSABI, Hadeel; ISMAIL, Heba; NUJUM NAVAZ, Alramzana. ECG Monitoring Systems: Review, Architecture, Processes, and Key Challenges. *Sensors*. 2020, roč. 20, č. 66, s. 1796. ISSN 1424-8220. Dostupné z DOI: [10.3390/s20061796](https://doi.org/10.3390/s20061796).
146. DOOREN, Marieke van; VRIES, J. J. G. (Gert-Jan) de; JANSSEN, Joris H. Emotional sweating across the body: Comparing 16 different skin conductance measurement locations. *Physiology & Behavior*. 2012, roč. 106, č. 2, s. 298–304. ISSN 0031-9384. Dostupné z DOI: [10.1016/j.physbeh.2012.01.020](https://doi.org/10.1016/j.physbeh.2012.01.020).
147. VAVRINSKY, Erik; STOPJAKOVA, Viera; KOPANI, Martin; KOSNACOVA, Helena. The Concept of Advanced Multi-Sensor Monitoring of Human Stress. *Sensors*. 2021, roč. 21, č. 1010, s. 3499. ISSN 1424-8220. Dostupné z DOI: [10.3390/s21103499](https://doi.org/10.3390/s21103499).
148. LI, Shanshi; SUNG, Billy; LIN, Yuxia; MITAS, Ondrej. Electrodermal activity measure: A methodological review. *Annals of Tourism Research*. 2022, roč. 96, s. 103460. ISSN 0160-7383. Dostupné z DOI: [10.1016/j.annals.2022.103460](https://doi.org/10.1016/j.annals.2022.103460).
149. POSADA-QUINTERO, Hugo F.; CHON, Ki H. Innovations in Electrodermal Activity Data Collection and Signal Processing: A Systematic Review. *Sensors*. 2020, roč. 20, č. 22, s. 479. ISSN 1424-8220. Dostupné z DOI: [10.3390/s20020479](https://doi.org/10.3390/s20020479).

150. MASSARONI, Carlo; NICOLÒ, Andrea; LO PRESTI, Daniela; SACCHETTI, Massimo; SILVESTRI, Sergio; SCHENA, Emiliano. Contact-Based Methods for Measuring Respiratory Rate. *Sensors*. 2019, roč. 19, č. 44, s. 908. ISSN 1424-8220. Dostupné z DOI: [10.3390/s19040908](https://doi.org/10.3390/s19040908).
151. MASSARONI, Carlo; NICOLÒ, Andrea; SACCHETTI, Massimo; SCHENA, Emiliano. Contactless Methods for Measuring Respiratory Rate: A Review. *IEEE Sensors Journal*. 2021, roč. 21, č. 11, s. 12821–12839. ISSN 15581748. Dostupné z DOI: [10.1109/JSEN.2020.3023486](https://doi.org/10.1109/JSEN.2020.3023486).
152. LIU, Haipeng; ALLEN, John; ZHENG, Dingchang; CHEN, Fei. Recent development of respiratory rate measurement technologies. *Physiological Measurement*. 2019, roč. 40, č. 7, 07TR01. ISSN 0967-3334. Dostupné z DOI: [10.1088/1361-6579/ab299e](https://doi.org/10.1088/1361-6579/ab299e).
153. DE FAZIO, Roberto; STABILE, Marco; DE VITTORIO, Massimo; VE-LÁZQUEZ, Ramiro; VISCONTI, Paolo. An Overview of Wearable Piezo-resistive and Inertial Sensors for Respiration Rate Monitoring. *Electronics*. 2021, roč. 10, č. 1717, s. 2178. ISSN 2079-9292. Dostupné z DOI: [10.3390/electronics10172178](https://doi.org/10.3390/electronics10172178).
154. LEUBE, Julian; ZSCHOCKE, Johannes; KLUGE, Maria; PELIKAN, Luise; GRAF, Antonia; GLOS, Martin; MÜLLER, Alexander; BARTSCH, Ronny P.; PENZEL, Thomas; KANTELHARDT, Jan W. Reconstruction of the respiratory signal through ECG and wrist accelerometer data. *Scientific Reports*. 2020, roč. 10, č. 11, s. 14530. ISSN 2045-2322. Dostupné z DOI: [10.1038/s41598-020-71539-0](https://doi.org/10.1038/s41598-020-71539-0).
155. NAM, Seungyoon; BAUTISTA, John Lorenzo; HAHM, Chanyoung; SHIN, Hyunsoon. Recognition of Respiratory Instability using a Photoplethysmography of Wrist-watch type Wearable Device. *IEIE Transactions on Smart Processing & Computing*. 2022, roč. 11, č. 2, s. 97–104.
156. ZSCHOCKE, Johannes; LEUBE, Julian; GLOS, Martin; SEMYACHKINA-GLUSHKOVSAYA, Oxana; PENZEL, Thomas; BARTSCH, Ronny P.; KANTELHARDT, Jan W. Reconstruction of Pulse Wave and Respiration From Wrist Accelerometer During Sleep. *IEEE Transactions on Biomedical Engineering*. 2022, roč. 69, č. 2, s. 830–839. ISSN 1558-2531. Dostupné z DOI: [10.1109/TBME.2021.3107978](https://doi.org/10.1109/TBME.2021.3107978).
157. ESCABÍ, Monty A. 10 - BIOSIGNAL PROCESSING. In: *Introduction to Biomedical Engineering (Second Edition)*. Ed. ENDERLE, John D.; BLANCHARD, Susan M.; BRONZINO, Joseph D. Boston: Academic Press, 2005, s. 549–625. Biomedical Engineering. ISBN 978-0-12-238662-6. Dostupné z DOI: [10.1016/B978-0-12-238662-6.50012-4](https://doi.org/10.1016/B978-0-12-238662-6.50012-4).

158. KARAGIANNIS, Alexandros; CONSTANTINOU, Philip; VOUYIOUKAS, Demosthenes; KARAGIANNIS, Alexandros; CONSTANTINOU, Philip; VOUYIOUKAS, Demosthenes. *Biomedical Time Series Processing and Analysis Methods: The Case of Empirical Mode Decomposition*. IntechOpen, 2011. ISBN 978-953-307-555-6. Dostupné z DOI: 10.5772/20906.
159. KHODADAD, D.; NORDEBO, S.; MÜLLER, B.; WALDMANN, A.; YERWORTH, R.; BECHER, T.; FRERICHS, I.; SOPHOCLEOUS, L.; KAAM, A. van; MIEDEMA, M.; SEIFNARAGHI, N.; BAYFORD, R. Optimized breath detection algorithm in electrical impedance tomography. *Physiological Measurement*. 2018, roč. 39, č. 9, s. 094001. ISSN 0967-3334. Dostupné z DOI: 10.1088/1361-6579/aad7e6.
160. POWER, Jonathan D.; LYNCH, Charles J.; DUBIN, Marc J.; SILVER, Benjamin M.; MARTIN, Alex; JONES, Rebecca M. Characteristics of respiratory measures in young adults scanned at rest, including systematic changes and “missed” deep breaths. *NeuroImage*. 2020, roč. 204, s. 116234. ISSN 1053-8119. Dostupné z DOI: 10.1016/j.neuroimage.2019.116234.
161. SUBRAMANIAN, Sandya; BARBIERI, Riccardo; BROWN, Emery N. A Systematic Method for Preprocessing and Analyzing Electrodermal Activity. In: *2019 41st Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC)*. 2019, s. 6902–6905. ISSN 1558-4615. Dostupné z DOI: 10.1109/EMBC.2019.8857757.
162. KRISHNAN, Sridhar; ATHAVALE, Yashodhan. Trends in biomedical signal feature extraction. *Biomedical Signal Processing and Control*. 2018, roč. 43, s. 41–63. ISSN 1746-8094. Dostupné z DOI: 10.1016/j.bspc.2018.02.008.
163. FOSTER, Kenneth R.; KOPROWSKI, Robert; SKUFCA, Joseph D. Machine learning, medical diagnosis, and biomedical engineering research - commentary. *BioMedical Engineering OnLine*. 2014, roč. 13, č. 1, s. 94. ISSN 1475-925X. Dostupné z DOI: 10.1186/1475-925X-13-94.
164. KORDING, Konrad Paul; BENJAMIN, Ari S.; FARHOODI, Roozbeh; GLASER, Joshua I. *The Roles of Machine Learning in Biomedical Science*. National Academies Press (US), 2018. Dostupné také z: <https://www.ncbi.nlm.nih.gov/books/NBK481619/>.
165. STRZELECKI, Michał; BADURA, Paweł. Machine Learning for Biomedical Application. *Applied Sciences*. 2022, roč. 12, č. 44, s. 2022. ISSN 2076-3417. Dostupné z DOI: 10.3390/app12042022.
166. GERON, Aurelien. *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems*. 3rd. O'Reilly Media, Inc., 2022. ISBN 9781098125974.

167. MURPHY, Kevin P. *Machine Learning: A Probabilistic Perspective*. The MIT Press, 2012. ISBN 0262018020.
168. GOODFELLOW, Ian; BENGIO, Yoshua; COURVILLE, Aaron. *Deep Learning*. MIT Press, 2016. <http://www.deeplearningbook.org>.
169. *Plot with polygons, ellipses, squares and rectangles* [online]. 2019. [cit. 2022-06-18]. Dostupné z: <https://tex.stackexchange.com/a/507813/289947>.
170. EFRON, Bradley; TIBSHIRANI, R. J. *An Introduction to the Bootstrap*. 1st edition. New York: Chapman a Hall/CRC, 1993. ISBN 978-0-412-04231-7.
171. ANGUITA, Davide; GHIO, Alessandro; ONETO, Luca; PARRA, Xavier; REYES-ORTIZ, Jorge Luis et al. A public domain dataset for human activity recognition using smartphones. In: *Esann*. 2013, sv. 3, s. 3.
172. KOHAVI, Ron. A study of cross-validation and bootstrap for accuracy estimation and model selection. In: *Proceedings of the 14th international joint conference on Artificial intelligence - Volume 2*. San Francisco, CA, USA: Morgan Kaufmann Publishers Inc., 1995, s. 1137–1143. IJCAI'95. ISBN 978-1-55860-363-9.
173. GHOJOGH, Benyamin; CROWLEY, Mark. *The Theory Behind Overfitting, Cross Validation, Regularization, Bagging, and Boosting: Tutorial*. arXiv, 2019. Dostupné z DOI: [10.48550/ARXIV.1905.12787](https://doi.org/10.48550/ARXIV.1905.12787).
174. *Adding text to a graphic in tikz* [online]. 2020. [cit. 2022-06-18]. Dostupné z: <https://tex.stackexchange.com/a/562199/289947>.
175. LIASHCHYNSKYI, Petro; LIASHCHYNSKYI, Pavlo. Grid Search, Random Search, Genetic Algorithm: A Big Comparison for NAS. *CoRR*. 2019, roč. abs/1912.06059. Dostupné z arXiv: [1912.06059](https://arxiv.org/abs/1912.06059).
176. ANGGORO, Dimas Aryo; MUKTI, Salsa Sasmita. Performance Comparison of Grid Search and Random Search Methods for Hyperparameter Tuning in Extreme Gradient Boosting Algorithm to Predict Chronic Kidney Failure. *Int. J. Intell. Eng. Syst.* 2021, roč. 14, č. 6, s. 198–207.
177. BERGSTRA, James; BENGIO, Yoshua. Random search for hyper-parameter optimization. *The Journal of Machine Learning Research*. 2012, roč. 13, č. null, s. 281–305. ISSN 1532-4435.
178. ALIBRAHIM, Hussain; LUDWIG, Simone A. Hyperparameter Optimization: Comparing Genetic Algorithm against Grid Search and Bayesian Optimization. In: *2021 IEEE Congress on Evolutionary Computation (CEC)*. 2021, s. 1551–1559. Dostupné z DOI: [10.1109/CEC45853.2021.9504761](https://doi.org/10.1109/CEC45853.2021.9504761).

-
179. PARKER, Wendy S. Ensemble modeling, uncertainty and robust predictions. *WIREs Climate Change*. 2013, roč. 4, č. 3, s. 213–223. Dostupné z DOI: <https://doi.org/10.1002/wcc.220>.
 180. SUZUKI, Kenji. *Artificial Neural Networks - Architectures and Applications*. 2013. ISBN 978-953-51-0935-8. Dostupné z DOI: 10.5772/3409.
 181. *Plotting the gradient descent?* [online]. 2019. [cit. 2022-06-18]. Dostupné z: <https://tex.stackexchange.com/questions/497165/plotting-the-gradient-descent>.
 182. SHARMA, Sagar; SHARMA, Simone; ATHAIYA, Anidhya. Activation functions in neural networks. *Towards Data Sci* [online]. 2017, roč. 6, č. 12, s. 310–316 [cit. 2022-06-24]. Dostupné z: <https://www.ijeast.com/papers/310-316,Tesma412,IJEAST.pdf>.
 183. *How to format table with images?* [online]. 2018. [cit. 2022-06-18]. Dostupné z: <https://tex.stackexchange.com/questions/431200/how-to-format-table-with-images>.
 184. NAIR, Vinod; HINTON, Geoffrey E. Rectified linear units improve restricted boltzmann machines. In: *Proceedings of the 27th International Conference on International Conference on Machine Learning*. Madison, WI, USA: Omnipress, 2010, s. 807–814. ICML’10. ISBN 978-1-60558-907-7. Dostupné také z: <https://dl.acm.org/doi/10.5555/3104322.3104425>.