



ČESKÉ VYSOKÉ UČENÍ TECHNICKÉ V PRAZE

FAKULTA BIOMEDICÍNSKÉHO INŽENÝRSTVÍ

Katedra biomedicínské techniky

Hodnocení kognitivní zátěže v extrémním prostředí

Assessment of cognitive load in extreme environment

Diplomová práce

Studijní program: Biomedicínské inženýrství

Vedoucí práce: Mgr. Ksenia Sedova, Ph.D.

Bc. Marek Sokol

Kladno 2022

Prohlášení

Prohlašuji, že jsem diplomovou práci s názvem „Hodnocení kognitivní zátěže v extrémním prostředí“ vypracoval/a samostatně a použil/a k tomu úplný výčet citací použitých pramenů, které uvádím v seznamu přiloženém k diplomové práci.

Nemám závažný důvod proti užití tohoto školního díla ve smyslu §60 Zákona č.121/2000 Sb., o právu autorském, o právech souvisejících s právem autorským a o změně některých zákonů (autorský zákon), ve znění pozdějších předpisů.

V Kladně
.....
Bc. Marek Sokol

České vysoké učení technické v Praze

Fakulta biomedicínského inženýrství

© 2022 Bc. Marek Sokol. Všechna práva vyhrazena.

Tato práce vznikla jako školní dílo na Českém vysokém učení technickém v Praze, Fakultě biomedicínského inženýrství. Práce je chráněna právními předpisy a mezinárodními úmluvami o právu autorském a právech souvisejících s právem autorským. K jejímu užití, s výjimkou bezúplatných zákonných licencí a nad rámec oprávnění uvedených v Prohlášení na předchozí straně, je nezbytný souhlas autora.

Odkaz na tuto práci

Sokol, Marek. *Hodnocení kognitivní zátěže v extrémním prostředí*. Diplomová práce. Praha: České vysoké učení technické v Praze, Fakulta biomedicínského inženýrství, 2022. Dostupné z: www.github.com/.

Poděkování

Rád bych poděkoval vedoucí své diplomové práce, Mgr. Ksenii Sedové, Ph.D. za odborné vedení práce, za pomoc, vstřícnost a rady při zpracování této práce. Dále bych rád poděkoval Ing. et Ing. Janu Hejdovi, Ph.D. za všeestrannou pomoc, množství cenných a inspirativních rad, podnětů a čas, který mi věnoval při řešení dané problematiky. V neposlední řadě děkuji své rodině a všem přátelům, kteří mě při vytváření této práce podpořili.

Abstrakt

Hodnocení kognitivní zátěže v extrémním prostředí:

Klíčová slova

Abstract

Assessment of cognitive load in extreme environment:

Key words

Obsah

Seznam symbolů a zkratek	9
1 Úvod	13
2 Přehled současného stavu	15
2.1 Extrémní prostředí	15
2.1.1 Vesmírné explorace	16
2.1.2 Analogové mise	17
2.1.3 Faktory prostředí a změny CNS	19
2.2 Kognitivní neurovědy	21
2.2.1 Terminologie	21
2.2.2 Kognitivní zátěž	22
2.2.3 Fyziologické projevy	22
2.2.4 Detekce kognitivní zátěže	24
2.3 Neuroviscerální integrace	25
2.3.1 Kognitivní regulace	28
2.4 Variabilita srdeční frekvence	29
2.4.1 Trendy v analýze HRV	30
2.4.2 Struktura HRV indexů	31
2.5 Periferní biosignály	32
2.5.1 Měření biosignálů	33
2.5.2 Postupy zpracování biosignálů	37
2.6 Strojové učení	39
2.6.1 Typy systémů strojového učení	39
2.6.2 Trénování a testování modelů	40
2.6.3 Optimalizace hyperparametrů	42
2.6.4 Kombinování modelů	43
2.6.5 Hodnocení modelů	43
2.6.6 Umělé neuronové sítě	43
3 Cíle práce	48
4 Metody	49
4.1 Mise DIANA	49
4.1.1 Projekt Hydronaut	49
4.1.2 Výběr posádky	49
4.1.3 Posádka pro misi DIANA	50
4.1.4 Popis lokality a podmínky prostředí	50

4.1.5	Hlubinná laboratoř H03 DeepLab	51
4.1.6	Infrastruktura mise	52
4.1.7	Neuropsychofyziologická baterie	53
4.1.8	Monitorování a měření posádky	54
4.1.9	Studie	56
4.2	Použité datasety	56
4.2.1	WESAD	56
4.2.2	CLAS	57
4.2.3	Data z vesmírné analogové mise DIANA	58
4.3	Zpracování biosignálů	58
4.3.1	Zpracování elektrické srdeční aktivity	58
4.3.2	Zpracování respirační aktivity	60
4.3.3	Zpracování elektrodermální aktivity	60
4.4	Zpracování a analýza dat z mise DIANA	61
4.4.1	Zpracování exportovaných segmentů biosignálů	62
4.4.2	Čistění dat	62
4.4.3	Sledované veličiny	62
4.4.4	Analýza dat mise	63
4.4.5	Statistické modelování	63
4.5	Explorační analýza a předzpracování datasetů	64
4.5.1	Předzpracování datasetů	64
4.5.2	Explorace dat	65
4.5.3	Augmentace dat využitím SMOTE-Tomek	66
4.6	Hodnocení CL využitím vícerozměrných časoprostorových kauzálních vzorů	67
4.6.1	Formulace problému	67
4.6.2	Tvorba kauzálních vícerozměrných matic	68
4.6.3	Konstrukce časoprostorových polí	70
4.6.4	Kapsulární neuronová síť	71
4.6.5	Self-attention směrování	73
4.6.6	Marginální ztrátová funkce	73
4.6.7	Trénování a evaluace modelů	74
4.7	Statistické metody	74
4.7.1	Lineární smíšené modely	74
4.7.2	Grangerova kauzalita	75
4.7.3	Lasso regrese	76
4.7.4	Teorie kopulí	76
4.7.5	Metriky hodnocení v strojovém učení	77
5	Výsledky	80
5.1	Srovnání QRS detektorů	80

5.2	Analýza dat z mise DIANA	81
5.2.1	Sledované veličiny během NPF stimulace	83
5.2.2	Statistické modelování	86
5.3	Modely pro hodnocení kognitivní zátěže	88
5.3.1	Hodnocení přesnosti modelů pro WESAD	89
5.3.2	Hodnocení přesnosti modelů pro CLAS	90
5.3.3	Hodnocení přesnosti modelů pro sjednocená data	91
5.3.4	Srovnání na úrovni použitých modalit	92
5.3.5	Srovnání se současným stavem	92
5.3.6	Testování na datech z mise DIANA	93
6	Diskuse	94
7	Závěr	95
7.1	Budoucí práce	95
	Bibliografie	96

Seznam symbolů a zkratek

Seznam zkratek

Zkratka	Význam
AIC	Akaikeho informační kritérium (Akaike information criterion)
ANN	Umělé neuronové sítě (Artificial neural networks)
ANS	Autonomní nervová soustava (Autonomic nervous system)
AUC	Plocha pod křivkou (Area under the curve)
AURL	Podmořská Výzkumná Laboratoř (Aquarius Undersea Research Laboratory)
AV	Atrioventrikulární uzel
CAN	Centrální autonomní síť (Central autonomic network)
CDF	Kumulativní distribuční funkce (Cumulative distribution function)
CeA	Centrální jádro amygdaly (Nucleus amygdalae centralis)
CL	Kognitivní zátěž (Cognitive load)
CLT	Teorie kognitivní zátěže (Cognitive load theory)
CNS	Centrální nervová soustava
CP	Capula Granger
CSA	Kanadská kosmická agentura (Canadian Space Agency)
CV	Křížová validace (Cross-validation)
CVLM	Kaudální ventrolaterální medulární jádro (Caudal ventrolateral medullary)
dACC	Dorzální anteriorní cingulární kúra (Dorsal anterior cingulate cortex)
DBSCAN	Hustotní prostorové shlukování aplikací s šumem (Density-based spatial clustering of applications with noise)
DT	rozhodovací stromy (Decision trees)
DVN	Dorzální vagové motorické jádro (Nucleus dorsalis nervi vagi)
EDA	Elektrodermální aktivita
EDR	Respirace odvozená z EKG (ECG-Derived Respiration)
EEG	Elektroencefalografie
EFA	Faktorová analýza (Exploratory factor analysis)
EFPA	Evropská federace psychologických asociací
EKG	Elektrokardiografie
ESA	Evropská kosmická agentura (European Space Agency)

Zkratka	Význam
EVA	Extravehikulární aktivita
FBMI	Fakulta biomedicínského inženýrství
FF UPOL	Filozofická fakulta Univerzity Palackého v Olomouci
FIU	Mezinárodní Univerzita na Floridě (Florida International University)
fMRI	Funkční magnetická rezonance
FPR	Falešně pozitivní míra (False positive rate)
GADF	Gramian angular difference fields
GAF	Gramian angular fields
GC	Grangerova kauzalita (Granger causality)
GD	Gradientní sestup (Gradient descent)
HDBR	Head-down bed rest
HR	Srdeční rytmus (Heart rate)
HRV	Variabilita srdeční frekvence (Heart rate variability)
ICE	Izolované, stísněné a extrémní prostředí (Isolated, confined and extreme environment)
IML	Visceromotorická jádra v segmentech C7–L2 (Nucleus intermediolateralis)
Lasso	Least absolute shrinkage and selection operator
LDA	Gradientní sestup (Linear discriminant analysis)
LEO	Nízká oběžná dráha (Low-earth orbit)
LMM	Linearní smíšené modely (Linear mixed models)
LR	Rychlosť učení (Learning rate)
ML	Strojové učení (Machine learning)
mPFC	Mediální prefrontální kůra (Medial prefrontal cortex)
MRI	Magnetická rezonance
NA	Somatomotorické jádro pro n. IX a X. (Nucleus ambiguus)
NASA	Americký Národní úřad pro letectví a vesmír (National Aeronautics and Space Administration)
NEEMO	Operace NASA v extrémním prostředí (NASA Extreme Environment Mission Operations)
NNX0	Počet párů sousedních N–N intervalů, které se od sebe liší o více než Xms (Number of times successive heartbeat intervals exceed Xms)

Zkratka	Význam
NPF	Neuropsychofyziologie
NTS	Jádro solitárního traktu (Nucleus tractus solitarius)
NVI	Neuroviscerální integrace (Neurovisceral integration)
pACC	Pregenuální přední cingulární kůra (Pregenual anterior cingulate cortex)
PCA	Analýza hlavních komponent (Principal component analysis)
pCC	Posteriorní cingulární kůra (Posterior cingulate cortex)
pNNX0	Poměr NNX0 k počtu všech N–N intervalů (Proportion of NNX0 divided by the total number of N–N)
PNS	Parasympatický nervový systém
PPG	Fotopletysmografie (Photoplethysmography)
RMSSD	Odmocnina průměru umocněných rozdílů po sobě jdoucích N–N intervalů (Root mean square of the successive differences)
ROC	Receiver operating characteristic curve
RSP	Respirační aktvitita
RVLM	Rostrální ventrolaterální medulární jádro (Rostral ventrolateral medullary)
SA	Sinoatriální uzel
SCL	Úroveň kožní vodivosti (Skin conductance level)
SCR	Odezva kožní vodivosti (Skin conductance response)
SMOTE	Synthetic Minority Oversampling Technique
SNS	Sympatický nervový systém
SOM	Samoorganizující mapy (Self organizing maps)
SVM	Gradientní sestup (Support vector machines)
SWT	Stacionární vlnková transformace (Stationary wavelet transform)
TNR	Pravdivě negativní míra (True negative rate)
TPJ	Temporoparietální spojení
TPR	Pravdivě pozitivní míra (True positive rate)
tSNE	t-distribuované stochastické sdružování (t-distributed stochastic neighbor embedding)
UMAP	Uniform Manifold Approximation and Projection
VAR	Model vektorové autoregresie (Vector autoregressive model)

Zkratka **Význam**

ZC	Průchod nuly (Zero crossing)
----	------------------------------

KAPITOLA 1

Úvod

Sledování a hodnocení kognitivní zátěže v extrémním prostředí, jako je například vesmír, je kritické pro zajištění bezpečnosti a úspěchu jednotlivců a týmů působících v takovém prostředí během náročných a důležitých úkonů. Monitorování kognitivních funkcí pomocí tradičních metod, jako je dotazníkové hodnocení nebo behaviorální analýza, může být v izolovaném, uzavřeném a extrémním prostředí nepraktické až neproveditelné kvůli například komunikačním a časovým omezením. Proto cím dál více vzniklá zájem o využití periferních biosignálů, jako je například elektrická srdeční nebo elektrodermální aktivita, k hodnocení kognitivní zátěže v reálném čase.

Paradigma většiny dosavadních přístupů detekce těží primárně z extrahovaných příznaků v podobě statistických ukazatelů nebo často například parametrů vypočtených z variability srdeční frekvence. Interpretace těchto parametrů v souvislosti s kognitivní zátěží je však nejasná a náročná vzhledem k tomu, že se do periferních biosignálů promítají veškeré kognitivní funkce. Velké množství těchto parametrů také vyžaduje poměrně dlouhé časové úseky pro jejich výpočet a jsou velmi citlivé na různorodé typy artefaktů.

Jako klíčem k interpretaci těchto vztahů se jeví inkorporace komplexního modelu neuroviscerální integrace, který vychází ze skutečnosti, že autonomní nervový systém hraje klíčovou roli v regulaci periferní fyziologie a poskytuje teoretický rámec pro pochopení vztahů mezi periferními biosignály s kognitivními funkcemi. Obecně tento model předpokládá, že kognitivní zátěž několikaúrovňově moduluje aktivitu autonomního nervového systému, což vede právě ke změnám periferní fyziologie. Rozklíčování interpretace takovým způsobem by ale vyžadovalo velké množství patřičně popsaných dat, bylo velmi časově náročné a pravděpodobně by trpělo nedostatečnou generalizací.

Nedostatky předešlého přístupu překonávají metody hlubokého učení, jejichž vstupem jsou samotné biosignály, ze kterých jsou potřebné příznaky pro účely detekce kognitivní zátěže extrahovány automaticky. Takové typy detektorů jsou často robustní

a schopny v datech nalézt nespočetné množství relací. Ve výsledku je tedy pro účely rozpoznání kognitivní zátěže extrahováno a použito ohromné množství parametrů. Nevýhodou tohoto přístupu je tím pádem často vysoká výpočetní náročnost, a zároveň jeho prisma, které nijak nezohledňuje kauzalitu mezi použitými fyziologickými příznaky, naopak vychází z předpokladu jejich nezávislosti. Tento fakt znovu činí interpretaci a determinismus zásadních okolností v rámci hodnocení kognitivní zátěže stěžejními. Obecně se mezi další problémy také řadí například individuální rozdíly v charakteru biosignálů, vliv faktorů prostředí nebo nedostatečná standardizace sběru a analýzy dat. Řešení těchto problémů je také zásadní pro vývoj spolehlivých a platných metod pro hodnocení kognitivní zátěže.

Tato práce představuje nový způsob hodnocení kognitivní zátěže pomocí takzvaných vícerozměrných časoprostorových kauzálních vzorů společně s využitím kapsulární sítě. Tyto vzory zachycují temporální příčinné relace a umožňují unikátní kódování specifického kognitivního stavu v podobě charakteristické konfigurace v prostorové doméně.

Přehled současného stavu

Přehled současného stavu je nejprve věnován popisu extrémního prostředí a jeho vlivu na neuropsychofyziologii (dále jen „NPF“) člověka. Dále je na tuto oblast navázáno popisem kognitivní zátěže (CL) v dílčí kapitole kognitivních neurověd, která společně s navazujícími kapitolami o neuroviscerální integraci a variabilitě srdečního rytmu tvoří důležitou část problematiky ročníkového projektu a diplomové práce. Následně jsou blíže rozebrány periferní biosignály využité v rámci této práce, způsoby jejich měření a zpracování. Jejich znalost a informační obsah jsou nezbytnými kritérii pro hodnocení kognitivní zátěže. Závěr kapitoly tvoří náhled do vybraných teoretických základů strojového učení.

2.1 Extrémní prostředí

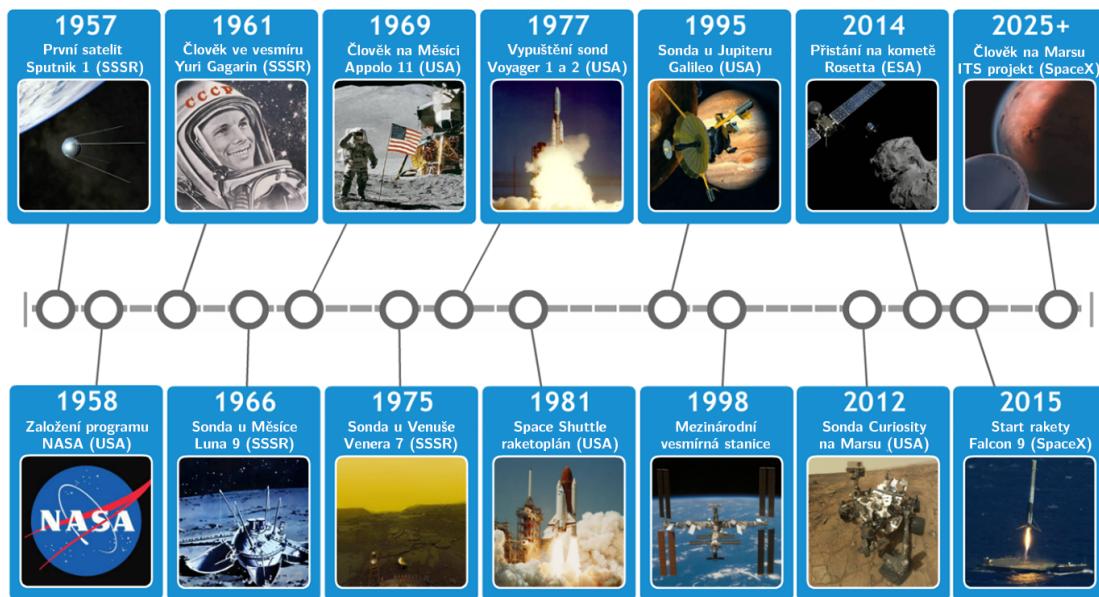
Vzhledem k nejednoznačné definici pojmu „*extrémní prostředí*“ je potřeba stanovit vhodnou interpretaci v souvislosti s problematikou této práce. Mezi rané definice přispěli Harrison a Connors [1], kteří publikovali, že extrémní prostředí se vyznačuje nebezpečnými a nepřívětivými klimatickými, životními nebo pracovními podmínkami a možnou sociální izolací. Bell et al. [2] definovali extrémní situace jako okolnosti, za kterých má nedostatečný výkon, ať už mentální nebo fyzický, vážné následky (např. časová tíseň, nebo nebezpečí). Všechny tyto koncepty se týkají náročných fyzických nebo mentálních výkonnostních situací, na které se pojí další již formulované pojmy jako mimořádné situace [3, 4], psychický a fyzický nátlak [5] nebo stres [6]. Další formulace byly již uvedeny v [7–9]. V této práci je na definici extrémního prostředí nahlíženo jako na izolované atypické prostředí, v němž jsou kladený značné nároky na plněné úkoly, které s sebou nesou vysokou míru rizika a katastrofické důsledky při chybném či nedostatečném výkonu.

Současně studie se v rámci tématiky extrémního prostředí často zabývají vlivem izolovaného a stísněného prostředí (ICE, isolated, confined, and extreme) na člověka [9, 10] nebo vlivem různorodých environmentálních podmínek [11–13]. Do výzkumu

v této oblasti se začalo aktivně přispívat kolem první poloviny 20. století, což bylo podmíněno vědecko-technologickým pokrokem. Mezi hlavní iniciační milníky patřil vojenský zájem o dlouhodobé ponory jaderných ponorek, na který navázal podvodní výzkum [14, 15], vznik vesmírných programů (vesmírný závod) a polární výzkum [16, 17]. Pro potřeby této práce je dále detailněji rozebráno extrémní prostředí z hlediska vesmírné explorace, konkrétně dlouhodobých vesmírných letů a analogových vesmírných misí.

2.1.1 Vesmírné explorace

Za hlavní hnací historický faktor, který posouval vědecko-technickou sféru v rámci výzkumu vesmíru rychle kupředu lze považovat tzv. vesmírný závod, jenž začal vypuštěním družice Sputnik 1 Sovětským svazem v roce 1957. Rok poté byl založen Americký Národní úřad pro letectví a vesmír (NASA), což vedlo k prvním vesmírným misím, kterých se později účastnily i posádky. Byl tak vytvořen nový prostor a vzbuzen výzkumný zájem v oblasti analogových vesmírných misí, jelikož otázky ohledně průzkumu vesmíru odhalily spoustu vědomostních nedostatků potřebných pro úspěšný pobyt v kosmu [15]. Nejedná se však ani tolík o technické překážky, ale o nedostatky zejména v oboru neurověd a experimentálního nastavení.



Obrázek 2.1: Časová osa výzkumu vesmíru od Sputniku po Mars (Přeloženo a převzato z [18])

Vzhledem k tomu, že budoucnost výzkumu vesmírné explorace sahá za hranice oběžné dráhy Země [19, 20], je třeba brát v úvahu obtíže budoucích misí, které se budou primárně týkat člověka. Dlouhodobé kosmické lety a mise jsou předmětem mnoha zásadních okolností, jež kladou vysoký a rizikový neuropsychofyziologický nátlak [21]. Extrémní prostředí, komunikační latence a problémy nebo fyziologické

změny vlivem vesmírných aspektů [22–24] mohou během dlouhodobých misí překračovat lidské psychické i fyzické hranice a vést ke katastrofickým následkům [21, 25]. Toto riziko se uplatňuje i přestože se v těchto případech skládají posádky z vybraných trénovaných jedinců (astronautů). Stresory, vnitřní nebo vnější stimuly vznikající při vystavení lidského organizmu mimořádným podmínkám (extrémnímu prostředí) při dlouhodobých vesmírných letech, již popsal Morphew [26]. Zdravotní a výkonnostní rizika lze řešit právě výběrem a výcvikem posádky nebo například návrhem mise a vybavení. Naskytuje se ale také možnost tato rizika predikovat s využitím diagnostických neinvazivních metod, jako funkční magnetická rezonance (fMRI), elektrokardiografie (EKG) aj., spolu s širokými znalostmi lidského nervového systému. Je tedy třeba realizovat experimenty, které pomohou lépe chápout, ne-li přímo definovat NPF vztahy při vlivu extrémního prostředí. Takové experimenty však nemohou probíhat za normálních laboratorních podmínek, jelikož se nejedná o prostředí, které by odráželo skutečné provozní podmínky a účinně napodobilo kosmickou misi [10, 21].

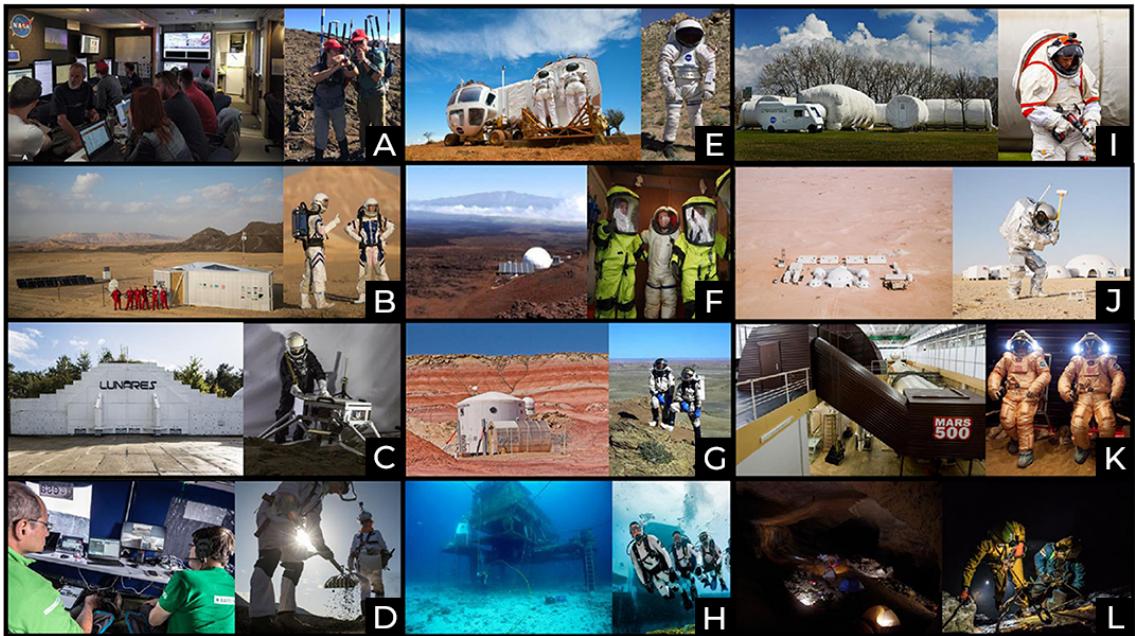
Ke studiu neuropsychofyziologických adaptací člověka vystavenému mikrogravitaci se využívají data zaznamenaná před a po vesmírném letu, kde se také sledují změny jako distribuce tělesných tekutin, hustota kostí nebo úbytek svalové hmoty [27]. Kromě mikrogravitace lze mnoho vědeckých otázek týkajících se kognitivních neuronů zodpovědět i na Zemi díky vesmírným analogovým misím, které simulují komplexní interakce vznikající během vesmírných misí [10, 21].

2.1.2 Analogové mise

Jak již bylo zmíněno, laboratorní experimenty plně nereprezentují reálné podmínky dlouhodobých kosmických misí, avšak různá analogová prostředí (analogové mise) přinášejí právě tu možnost sledovat a zkoumat NPF člověka v jedinečných situacích [21]. Situace, které napodobují reálné okolnosti budoucích vesmírných misí – přistání kosmické lodi, extravehikulární aktivity (EVA), lékařské zádkroky aj. – vystavují jedince pozorovatelným změnám například v cirkadiáním¹ rytmu, hladinách stresových hormonů, imunitních funkcích nebo neurokognitivním změnám [10, 11]. Faktory prostředí a jejich vliv na NPF jsou detailněji popsány v následující kapitole.

Přehled několika analogových misí, na jejichž vzniku a vývoji se převážně podílejí: Evropská kosmická agentura (ESA), Státní korporace pro kosmické aktivity (ROSCOMOS), Kanadská kosmická agentura (CSA) a NASA, lze vidět na obrázku 2.2. Každá analogová mise vnikla primárně pro simulaci a studium určitých vlivů vesmírných podmínek nebo k testování specifického vybavení. Antarktické mise slouží k testování astrobiologických hypotéz [21] a studiu dopadů izolace na člověka

¹Cirkadiánní rytmus je biologický rytmus s cyklem trvajícím přibližně jeden den.



Obrázek 2.2: Příklady analogových misí. **(A)** NASA BASALT (USA), **(B)** D-MARS (Izrael), **(C)** LUNARES (Polsko), **(D)** ESA/PANGEA (Španělsko), **(E)** NASA/D-RATS (USA), **(F)** HI-SEAS (USA), **(G)** Mars Desert Research Station (USA), **(H)** NASA/NEEMO (USA), **(I)** NDU Habitat (USA), **(J)** OeWF/AMADEE-program (Rakousko, Omán), **(K)** Mars-500 (Rusko), **(L)** ESA/CAVES (Španělsko/Itálie). (Upraveno a převzato z [28])

během extrémních podmínek, které jsou dané drsným polárním podnebím a rozsáhlou tundrou [29, 30]. Významnou misí je projekt Mars-500, kde byla šestičlenná posádka uzavřena 520 dní v napodobenině kosmické lodi pro účely simulace vesmírného letu na Mars. Během této mise došlo k řadě experimentů, které se například zabývaly vlivem fyzického cvičení na aktivitu prefrontální kortextu a kognitivní výkonnost [31] nebo změnami nálady a plazmatických hladin hormonů [32]. Na základě problematiky této práce jsou nadále popsány vybrané podvodní analogové mise.

Projekt NEEMO

Operace NASA v extrémním prostředí neboli NEEMO (NASA Extreme Environment Mission Operations) jsou analogové vesmírné mise, které probíhají v Mezinárodní Univerzitní Podmořské Výzkumné Laboratoři na Floridě (Florida International University's Aquarius Undersea Research Laboratory, FIU AURL). Podvodní laboratoř s rozlohou zhruba 43 m^2 , umístěná 19 m pod mořskou hladinou přesně nenapodobuje vesmírné podmínky ale stresové faktory spojené s bezpečností, komunikací a technologickou logistikou při dlouhodobých kosmických letech a průzkumu ano. Zároveň zde probíhají testy vybavení a trénování výstupu do vesmíru mimo kosmickou loď [33, 34]. Poslední mise v podvodní laboratoři, NEEMO 23, proběhla v červnu 2019 a byla primárně zaměřena na průzkumné výstupy do vesmíru.



Obrázek 2.3: Podvodní habitat AURL [35]



Obrázek 2.4: Hydronaut H03 DeepLab [36]

Projekt Hydronaut

Skromnější verze mobilního podvodního habitatu vznikla i v České Republice za účelem výcviku astronautů Evropské kosmické agentury. Projekt byl představen roku 2010 a jeho primárním cílem bylo umožňovat menším posádkám dlouhodobý pobyt v hyperbarickém ICE prostředí a simulaci vesmírných scénářů pro potřeby výzkumu. Podvodní stanice Hydronaut je také plně mobilní a lze měnit její umístění. Současná stanice (H03 DeepLab) je vybavena několika systémy pro sledování stavu habitatu a posádky. Jedním ze systémů je Common Tongue, který umožňuje nejen komunikaci s posádkou ale také sledování fyziologických funkcí. V roce 2020 proběhla desetidenní mise (Mission One), která včetně účelů kosmického ICE výzkumu sloužila jako zátěžový test habitatu [37].

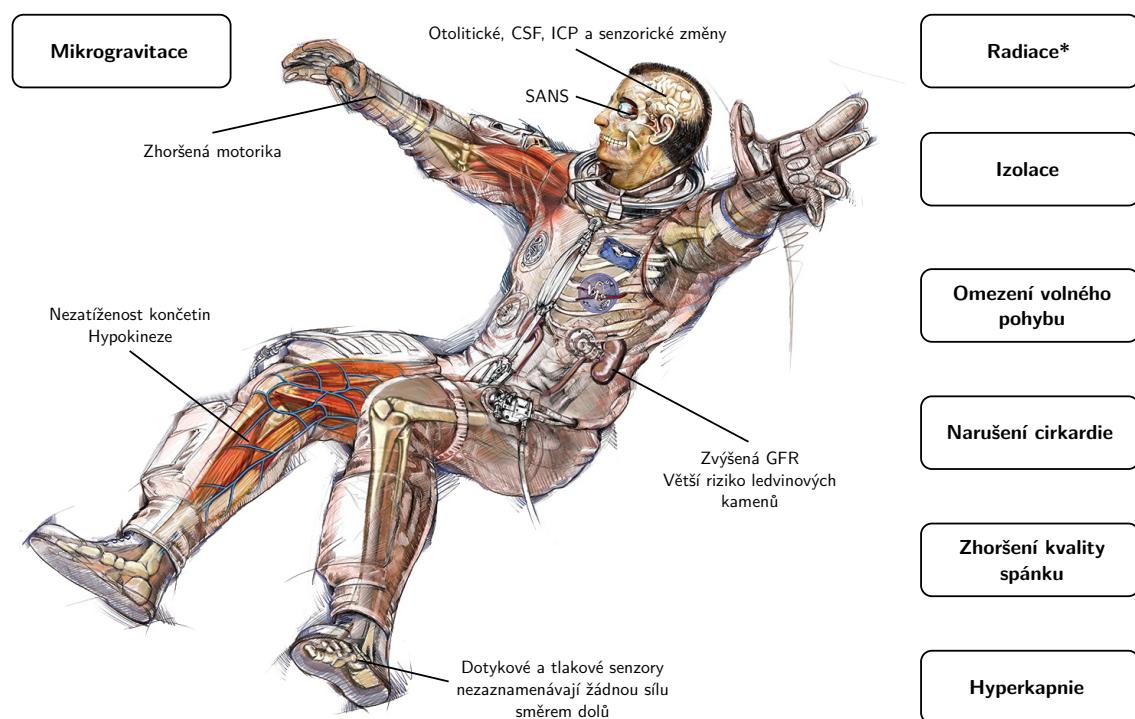
2.1.3 Faktory prostředí a změny CNS

Vzhledem k tomu, že vesmír je jedinečné prostředí, je studium změn CNS člověka souvisejících s kosmickými misemi obtížné. Předchozí studie ukázaly, že po letu do vesmíru dochází ke změnám ve vnímání, pohybu, koordinaci a kognici [38]. Mikrogravitace je jedním z hlavních faktorů, které ovlivňují mozek včetně kosmického záření (radiace), izolace nebo hyperkapnie [24]. Důsledky působení mikrogravitace na mozek popsal Torre v [39]. Souhrn faktorů lze vidět na Obrázku 2.5 a jejich počet nasvědčuje, že pozorované NPF změny u astronautů mohou být důsledkem kombinace více stresorů na jednotlivé oblasti mozku [24].

Nedávné MRI studie poukázaly na změny polohy mozku, objemu tkáně, objemu mozkových komor, distribuce a dynamiky mozkomíšního moku, mikrostruktury tkáně a funkční konektivity po letu do vesmíru [40–44]. Přehled MRI studií provedených na amerických astronautech a ruských kosmonautech před a po kosmickém letu se zjištěnými poznatkami byl vypracován v [24]. Mezi tyto studie jako jeden z prvních

přispěl Demertzi et al. [43] s objevem snížené konektivity v pravé insule², který se podílí na vestibulárním zpracování a kognitivní kontrole.

Neurozobrazovací studie na zvířecích modelech a lidech vystavených analogovým vesmírným letům prokázaly změny mozku související s reálným kosmickým letem [44, 45]. Analogové vesmírné mise nacházejí tedy uplatnění při zkoumání vlivů stresorů spojených s vesmírným prostředím na centrální nervovou soustavu (CNS). Při srovnání změn CNS souvisejících s kosmickou misí se změnami pozorovanými u pozemských analogů se naskytuje příležitost do budoucna navrhnout strategie a opatření, které by předcházely nežádaným NPF účinkům. Během analogových misí se podařilo reprodukovat například zjištění spojené se změnami mozkové konektivity, objemu šedé hmoty, dynamiky mozkomíšního moku a objemu mozkových komor [24]. Metoda, která věrně napodobuje podmínky kosmických letů vystavováním subjektů posunu tělních tekutin, odlehčení axiálního tlaku nebo hypokinezii, se nazývá Head-Down Bed Rest (HDBR). Subjekt je během metody na lůžku hlavou dolu, pod určitým náklonem. HDBR zároveň vyvolává podobné změny v mozkové konektivitě, včetně změny konektivity motorických, somatosenzorických a vestibulárních oblastí mozku jako při vesmírných letech [46, 47].



Obrázek 2.5: Souhrn stresových faktorů vesmírného ICE prostředí, které mohou ovlivnit mozek během kosmického letu. Radiace* v tomto případě odkazuje na radiaci v otevřeném kosmickém prostoru, nikoli na nízké oběžné dráze (LEO). (Upraveno a převzato z [24, 48] se souhlasem Beaua Danielse)

²Insula neboli insulární kortex je složitá struktura s rozsáhlou sítí korových a podkorových oblastí mozku, které slouží smyslovým, emočním a kognitivním funkcím.

Mozek je kromě fyziologických stresorů ovlivněn také dlouhodobým pobytom v ICE prostředí. Po 520denní misi Mars-500 ukázaly snímky participantů pozměněnou mikrostrukturu šedé hmoty v pravém temporoparietálním spojení³ (TPJ), což je přisuzováno vlivu izolovaného prostředí [49]. Během dlouhodobých vesmírných misí mohou mít změny TPJ za následek zhoršení neuropsychofyziologické adaptace člověka na nové ICE prostředí. Další nežádoucí změny byly prokázány v rámci studií antarktických expedic, které demonstrovali snížení objemu šedé hmoty v orbitofrontální kůře, prefrontální kůře a hipokampusu. Vzhledem k povaze antarktického prostředí a expedic lze usuzovat, že jsou tyto změny podmíněné také vlivem ICE [50]. Možné snížení neurogeneze hipokampu vlivem extrémního prostředí může mít vliv na paměť a sociální interakci členů posádky [24]. Délka kosmické mise či letu také hráje rozdíl, jelikož větší míra změn struktury mozku byla pozorována u dlouhodobých vesmírných misí [42].

2.2 Kognitivní neurovědy

Lidský mozek je schopen se neustále přizpůsobovat měnícím se okolnostem a požadavkům prostředí. Astronauti se musí aklimatizovat na zcela nové prostředí podobně jako malé děti procházejí svými vývojovými fázemi. V podmírkách stavu beztíže nebo mikrogravitace dochází mimo jiné k ovlivnění mozkových procesů. Cílem kognitivních neurověd ve vesmíru je pochopit, jak mozek a mysl reagují na tyto jedinečné okolní podmínky. První výzkumy v oblasti neurověd ve vesmíru byly provedeny v roce 1962 během ruské mise Vostok-3. Na Zemi je oproti vesmíru možné díky neurozobrazovacím technikám snadno studovat mozkovou aktivitu a kognitivní funkce. Pro neurovědce i psychology je velmi důležité pochopit základní neurokognitivní a neuropsychologické aspekty kosmického letu. Neefektivní mentální výkon jedince či posádky je známou hrozbou pro vesmírné mise. Pozemský výzkum zdůrazňuje nutnost porozumět kognitivním procesům, jelikož CL zhoršuje kognitivní a percepční motorické schopnosti. Srovnatelné dopady lze předpokládat i při vesmírných misích v náročných ICE podmírkách a simulacích (analogové mise) [39]. Pro potřeby diplomové práce je rozsáhlá kapitola kognitivních neurověd vymezena popisu kognitivní zátěže.

2.2.1 Terminologie

Obor kognitivních neurověd se nachází na pomezí psychology a neurověd, ale překrývá se s dalšími obory jako kognitivní a biologická psychology, fyziologie nebo neuropsychologie. Tyto obory často studují podobné procesy ale z jiného pohledu a pomocí jiné metodiky. Synonymem oblasti kognitivních neurověd byl v této

³Temporoparietální spojení je část mozku, kde se setkávají spánkový a temenní lalok.

práci zvolen termín neuropsychofyziologie pro usnadnění popisu fyziologických změn v důsledku kognitivních procesů. Cílem této práce není rozlišovat mezi jednotlivými obory ale zaměřit se na vědecké otázky z jejich průniků, které jsou spojené s vlivem ICE prostředí na člověka.

2.2.2 Kognitivní zátěž

Prvotní pojetí kognitivní zátěže (CL, Cognitive Load) pochází z oblasti výuky a vzdělávání, kterou se intenzivně zabýval Sweller et al. [51–53] kolem přelomu 19. a 20. století. Sweller [51] jako první formuloval teorii kognitivní zátěže (CLT, Cognitive Load Theory), podle které je CL definována jako zvýšené požadavky na ukládání a zpracování informací v pracovní paměti člověka. Chen et al. [54] definoval kognitivní zátěž jako proměnnou, jež určuje míru požadavků kladených úkolem na dostupné mentální zdroje pro zpracování informací. Míra požadavků vychází z vnímané námahy při učení, myšlení a uvažování jakožto ukazatel zatížení pracovní paměti během plnění úkolu. Tato míra zároveň popisuje interakce mezi nároky na zpracování úkolu a lidskou mentální výkonností [55]. Ačkoli se definice kognitivní zátěže v jednotlivých oborech mohou lišit, všechny mají jeden základní prvek: procento využité kapacity lidské pracovní paměti. Na rozdíl od naší smyslové a dlouhodobé paměti, které mohou v podstatě neomezeně zpracovávat informace, je tato kapacita omezená [56].

Chen et al. [54] publikoval, že vysoká kognitivní zátěž (kognitivní přetížení) může mít negativní dopad na výkonnost pracovní paměti. Vliv kognitivní zátěže zároveň ovlivňuje mozkové procesy a kognitivní přetížení pravděpodobně bezprostředně předchází vyhoření [56]. Většina kognitivních funkcí, jako je například selektivní pozornost nebo sebekontrola, závisí na pracovní paměti. Pracovní paměť zahrnuje aktivní krátkodobé ukládání, zpracování a manipulaci s informacemi a její efektivní fungování je kriticky závislé na inhibičních nervových procesech. Nervové středisko pracovní paměti sestává hlavně z distribuované sítě struktur zahrnující prefrontální kortex jako důležité ohnisko. Variabilita srdeční frekvence (HRV) souvisí s aktivitou prefrontální kůry a je inverzně spojena s aktivitou subkortikálních struktur jako je amygdala [57]. Vliv kognitivní zátěže se také promítá do elektrodermální (EDA) a respirační (RSP) aktivity [21]. Díky periferním biologickým signálům se tedy naskytuje jednoduší možnost hodnocení či predikce kognitivních procesů bez nutnosti použití realizačně a finančně náročnějších neurozobrazovacích metod nebo elektroencefalografie (EEG). Detailněji jsou fyziologické změny spojené s vlivem CL popsány v následující sekci.

2.2.3 Fyziologické projevy

Z předchozího textu již může být zřejmé, že kognitivní zátěž je velmi úzce spojená s fyziologickými změnami v lidském organismu. U jedince, kde dojde k stimulaci CL,

může docházet k řadě změn, například v mozkové aktivitě, krevním tlaku, srdečním rytmu, rychlosti pulzní vlny, dýchaní nebo činnosti potních žláz [55–60]. Vybrané fyziologické funkce, do kterých se po promítá kognitivní zátěž, jsou společně s jejich krátkým popisem a neurobiologickým vztahem uvedeny v Tabulce 2.1. Tabulka zároveň poukazuje na rozdílné vztahy fyziologických parametrů s kognitivní zátěží.

Tabulka 2.1: Přehled vybraných nejčastěji studovaných fyziologických změn a stručné teoretické zdůvodnění jejich souvislosti s kognitivní zátěží (Upraveno a převzato z [56])

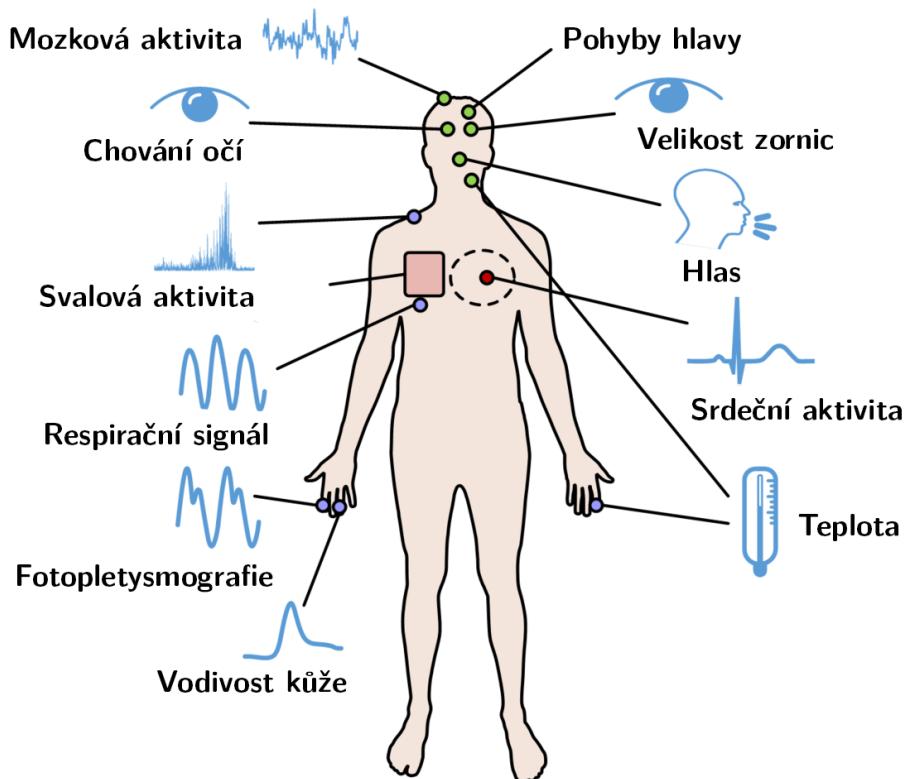
Fyziologická funkce	Stručný popis a teoretické zdůvodnění předpokládaného vztahu mezi fyziologickým měřením a kognitivní zátěží
EEG	<p><i>Popis:</i> EEG umožňuje měřit mozkovou aktivitu neinvazivně. Provedení spektrální analýzy naměřených rozdílů elektrických potenciálů umožnuje analyzovat výkon různých frekvenčních pásem, která jsou v signálu</p> <p><i>Hypotéza:</i> Zvýšení kognitivní zátěže lze měřit zvýšením mozkové aktivity, tj. oscilací v určitém frekvenčním pásmu s větší amplitudou [61]</p>
Eye-tracking	<p><i>Popis:</i> Měření průměru zornice, latence mrknutí a charakteristik sakád</p> <p><i>Hypotéza:</i> Sledování očí bylo v předchozích studiích spojeno s kognitivní zátěží prostřednictvím neurobiologických mechanismů, jako je inervace neuronů autonomního nervového systému radiálními vlákny duhovky [62]</p>
EDA	<p><i>Popis:</i> Elektrodermální aktivity, hodnotí elektrické charakteristiky kůže, aby bylo možné odvodit změny vlivem sympatického nervového systému.</p> <p><i>Hypotéza:</i> Kognitivní zátěž má vliv na stres nebo vzrušení a vede ke zvýšení kožní vodivosti [63]</p>
Teplota pokožky	<p><i>Popis:</i> Měření teploty vnějšího povrchu lidského těla</p> <p><i>Hypotéza:</i> Kognitivní zátěž má vliv na stres nebo vzrušení a vede k vazokonstrikci, což snižuje teplotu kůže [64]</p>
EKG	<p><i>Popis:</i> Srdeční frekvenci a variabilitu srdeční frekvence lze hodnotit pomocí elektrokardiogramu nebo fotopletysmografie</p> <p><i>Hypotéza:</i> Tepová frekvence je měřítkem aktivity sympatického i parasympatického autonomního nervového systému. Stres nebo vzrušení způsobí zvýšení krevního tlaku a snížení variability srdeční frekvence [65, 66]</p>
RSP	<p><i>Popis:</i> Kognitivní zátěž vede ke zrychlenému dýchání a vyšší minutové ventilaci, přičemž dechová amplituda zůstává stejná</p> <p><i>Hypotéza:</i> Při soustředění pozornosti nebo plnění náročného úkolu dochází ke změnám v dýchání [67]</p>

Příkladem rozdílností může být EEG, u kterého je vztah s kognitivní zátěží přímější než u srdeční nebo elektrodermální aktivity. Hodnocení pomocí tohoto biosignálu je tedy v některých případech spolehlivější. Pouze v některých, protože se vychází z předpokladu, že veškeré změny v kognitivních funkcích člověka se odrážejí v jeho fyziologii [56]. To znamená, že žádná měřící technika nemůže sama o sobě zachytit všechny aspekty kognitivních funkcí nebo o nich jednoznačně vypovídat. Problematika těchto vztahů je nadále rozebírána v kapitole 2.3. Na tuto vícerozměrnou povahu kognitivní zátěže poukázal Kramer et al. [68]. Dále definoval kritéria: citlivost, diagnostičnost, rušivost, spolehlivost a obecnost použití, v rámci kterých bude mít každé fyziologické měření jinou povahu. V případě kognitivní zátěže a její spolehlivém hodnocení z fyziologických projevů je proto vhodný multimodální⁴ přístup, který může poskytnout její robustnější reprezentaci [54].

⁴Multimodálním přístupem je myšleno využití více biosignálů.

2.2.4 Detekce kognitivní zátěže

Detekce kognitivní zátěže pomocí periferních biosignálů patří mezi tři nejčastěji používané způsoby včetně subjektivního hodnocení a hodnocení založené na výkonnosti jedince. Subjektivní hodnocení vychází z předpokladu, že hodnocený subjekt je schopen vnímat své vlastní kognitivní procesy a informovat o případné kognitivní zátěži nebo o množství vynaloženého mentálního úsilí [69, 70]. K subjektivnímu hodnocení se dále využívají specifické dotazníky, mezi které patří například NASA-TLX. Jedná se o vícerozměrnou stupnici používanou k měření pracovní zátěže operátorů v rámci úkonů, například během vesmírných analogových misí [71]. Tyto metody ale nejsou předmětem této práce a již byly detailně popsány v [70].



Obrázek 2.6: Vybrané proměnné související s CL (Přeloženo a převzato z [72])

Na kognitivní zátěž lze nahlížet jako na multidimenzionální konstrukt, který reprezentuje zátěž vyvinutou na jedince [69]. Zároveň se efekt stimulace kognitivních funkcí u každého jedince projevuje jinak. Nelze tedy vytvořit žádnou univerzální metodu, která by byla schopná stejně spolehlivě detektovat kognitivní zátěž u různých subjektů. Proto se v tomto odvětví nabízí a velmi často využívají metody strojového učení v rámci kterých nachází výhodné uplatnění dříve zmíněný multimodální přístup. Biologická data využívaná pro účely detekce CL lze vidět na Obr. 2.6.

Vzhledem k tomu, že je strojové učení širokou oblastí, byla tomuto tématu věnována samostatná sekce 2.6. Od roku 2010 je hojně využívána metoda učení s učitelem (viz 2.6.1.1) pro účely klasifikace různých patologických stavů a

symptomů [73]. Nejčastěji využívaným biosignálem je srdeční aktivita, konkrétně variabilita srdeční frekvence, které se často používá v kombinaci s elektrodermální aktivitou [69]. Použité příznaky pro klasifikaci (anglicky features) však hrají důležitou roli při rozlišování základní funkce spojené s jakýmkoli fyziologickým signálem. Z variability srdeční frekvence je v současnosti možné vypočítat desítky parametrů, resp. příznaků, se kterými je v těchto úlohách nutné velmi opatrně zacházet. Jednotlivé HRV parametry společně s jejich pravděpodobným významem byly již popsány v [55, 74–76]. Blíže je problematika HRV parametrů popsána v samotné podkapitole 2.4.2.

Dříve mezi často používané metody pro účely klasifikace patřili hlavně rozhodovací stromy (DT), lineární diskriminační analýza (LDA) nebo metoda podpůrných vektorů (SVM) [73]. Od roku 2018 se ve výzkumu HRV však stále častěji používá hluboké učení, jehož cílem je zlepšit automatickou klasifikaci v reálném čase. Tyto techniky poskytují efektivnější způsob extrakce relevantních informací a zvyšují přesnost klasifikace a současně snižují počet příznaků potřebných pro klasifikaci v reálném čase [77, 78]. O rok později se stalo novým trendem používání technik učení bez učitele pro klasifikaci psychického stresu s využitím technologie autoenkodéru [79]. Dále se mimo jiné začaly hojně používat samoorganizující mapy (SOM), které dokáží efektivně redukovat dimenzionalitu dat a zároveň indikovat nejcennější⁵ příznaky pro klasifikaci kognitivní zátěže s vysokou přesností [80]. Jelikož ale neexistuje žádný konsensus jak předzpracovávat biosignály, jaké využít příznaky nebo z jaké metodiky pro detekci CL vycházet, tak se stále zkouší nejasné variace různých algoritmů se snahou zvýšit skóre predikce. Velkým problémem je také nedostatek veřejně dostupných dat pro tyto účely.

2.3 Neuroviscerální integrace

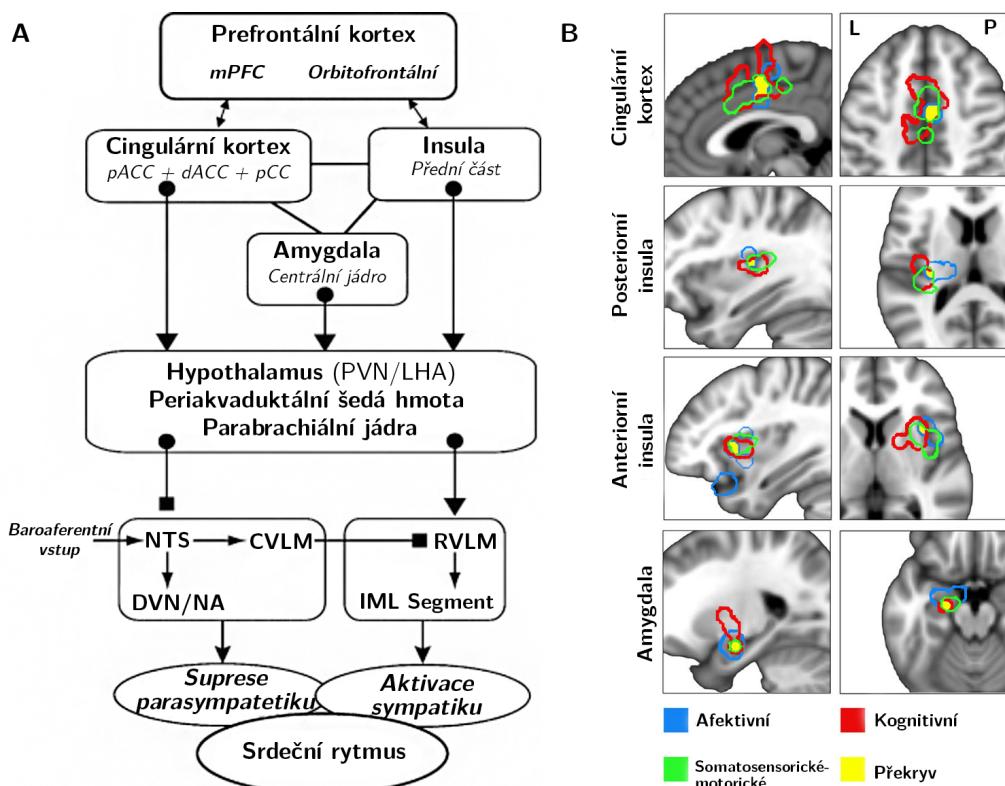
Z minulých kapitol vyplývá, že se veškeré kognitivní funkce člověka promítají zároveň do těch fyziologických. Většina studií, které se věnují detekci a hodnocení kognitivní zátěže však tento větší kontext nebere v úvahu. Díky tomu je nedostatek systematického porovnávání indexů HRV (viz následující kapitola 2.4), což činí interpretaci a vyhodnocování výsledků zdlouhavým a sporným. Problémem je také samozřejmě dříve zmíněný nedostatek dat. Tato kapitola slouží k zasazení úlohy této práce do širšího obrazu a zároveň pro zdůraznění důležitosti problematiky samotné. Dále je zde uveden přehled srdečních regulačních mechanismů v rámci stimulace mozku a úvod do oblasti variability srdečního rytmu.

V současné době existuje mnoho studií, které vypovídají o tom, že parasympatický neboli vagový tonus, souvisí s psychologickými a behaviorálními proměnnými i zdravotním stavem. Studie například odhalily velký počet konzistentních zjištění,

⁵Implikuje jak moc přispívá každý příznak k predikci modelu.

která ukazují, že jedinci s vyšší variabilitou srdeční frekvence mají větší schopnosti v oblasti regulace emocí [81–86] a dosahují lepších výsledků v kognitivních úkolech zahrnujících pozornost, pracovní paměť a inhibiční kontrolu [57, 87–89]. Pokud bychom kategorizovali HRV pouze na dvě úrovně, vyšší a nižší, tak lze postupem let pozorovat množství poznatků z hlediska prognostického významu:

- **vyšší HRV** — *lepší regulace glukózy, lepší funkce osy hypothalamus-nadledviny-hypofýza (HPA), snížení zánětu a snížení rizika mrtvice, kardiovaskulárních onemocnění a úmrtnosti ze všech příčin* [90–93]
- **nižší HRV** — *afektivní poruchy, deprese a úzkost, špatná kardiovaskulární kondice, vyšší riziko infarktu, zvýšená kognitivní zátěž* [94–96]



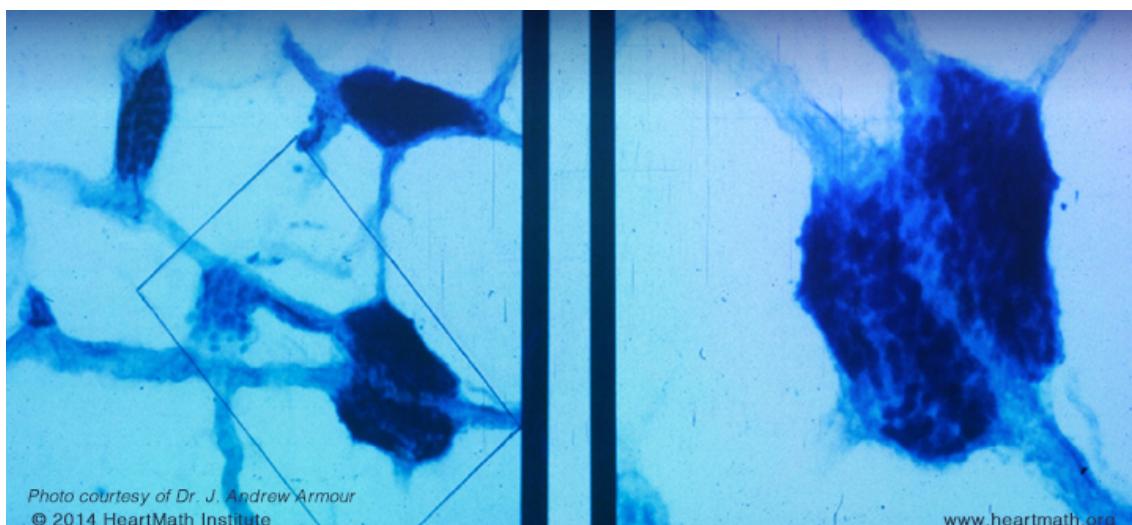
Obrázek 2.7: (A) Složené schéma znázorňující dráhy, kterými může prefrontální kůra ovlivňovat řízení srdeční frekvence; (B) Jádrové oblasti CAN, jak je odhalila konjunkční analýza⁶ autonomních modulačních oblastí ve třech kategoriích úkolů (barevně označeny). L, levá strana; P, pravá strana (Upraveno a převzato z [97, 98])

Objasnění pozorovaných vztahů mezi HRV a psychologickými/behaviorálními proměnnými může zlepšit porozumění a praktickou využitelnost v nejen medicíně, co se týče mentálního a fyziologického stavu jedince. Model „neuroviscerální integrace“ (NVI), který v roce 2000 navrhli Thayer a Lane [99], je pokusem o integraci poznatků o mentálních stavech, autonomních funkcích a zdravotních výsledcích do jednotného

⁶Společné testování více účinků u jednoho subjektu využitím fMRI.

rámce, jehož středobodem je „centrální autonomní síť“ (CAN) v mozku. CAN je síť vzájemně propojených oblastí mozkových struktur [100]. Hlavní části této sítě ukázali pomocí experimentu Beissner et al. [98] (viz Obr. 2.7B).

Na diagramu 2.7A lze vidět prefrontální, cingulární a insulární kůru, jež tvoří propojenou síť s obousměrnou komunikací s amygdalou. Amygdala je pod tonickou inhibiční kontrolou prostřednictvím prefrontálních vagových drah k interkalárním buňkám v amygdale. Aktivace centrálního jádra amygdaly (CeA) inhibuje jádro solitárního traktu (NTS: plný čtverec), které následně inhibuje inhibiční vstupy kaudálního ventrolaterálního medulárního jádra (CVLM) do rostrálního ventrolaterálního medulárního jádra (RVLM) sympatoexcitačních neuronů (plný čtverec) a současně inhibuje vagové motorické neurony v nucleus ambiguus (NA) a dorzálním vagovém motorickém jádru (DVN). Kromě toho může CeA přímo aktivovat sympatoexcitační neurony v RVLM [97].



Obrázek 2.8: Mikroskopický obraz propojených vnitřních srdečních ganglií v lidském srdci. Tenké, světle modré struktury jsou vícenásobné axony, které ganglie propojují (Převzato z [101] se souhlasem HeartMath Institutu)

Centrální autonomní síť, tvořena preganglioverymi sympatickými a parasympatickými neurony, inervuje srdce prostřednictvím hvězdicových ganglií a n. vagus. Vlivy těchto drah na sinoatriální uzel (SA) jsou hlavním faktorem určujícím HRV. Vzhledem k rozsáhlým aferentním informacím této autonomní sítě se promítá úroveň integrace mezi periferním a centrálním nervovým systémem do HRV a poskytuje kontextově specifickou regulaci srdce. Změny autonomních funkcí, zejména v kognitivních a afektivních souvislostech, odrážejí především vagový vliv, protože časové měřítko změn tonu sympathiku je relativně pomalejší než u tonu parasympatiku [57, 100].

Obrázek 2.7A znázorňuje dráhy, které umožňují prefrontální kůr regulovat srdeční frekvenci a její variabilitu. ANS má jak tonickou excitační, tak inhibiční kontrolu nad HR, kterou může modulovat frontální kůra prostřednictvím CeA. To

umožňuje přesnou regulaci variability srdečního rytmu, která na srdeční úrovni probíhá pomocí intrakardiálních neuronů (viz Obrázek 2.8). Prefrontální kúra rovněž vykonává tonickou inhibiční kontrolu nad těmito obvody, jak dokládá inverzní korelace mezi aktivitou ventromediálního prefrontální a orbitofrontální kortextu a úrovni kožní vodivosti během výchozího stavu mozku⁷. To podporuje současný NVI model a je v souladu s pozorováním, že tyto oblasti jsou deaktivovány během kognitivních úkolů při současném zvýšení hladiny kožní vodivosti [100, 102, 103].

Souhrnně lze říci, že NVI model integruje podstatu periferních fyziologických změn vlivem specifických mozkových struktur do jednotného frameworku, který se tyto adaptivní pochody snaží vysvětlit. Podle Thayera a Lanea [99] je tento framework spojen s psychologickými a fyziologickými procesy prostřednictvím kortikokortikálního neuronálního okruhu, který lze indexovat pomocí HRV. Prefrontální kúra může inhibovat podkorové struktury, což umožňuje organismu účinně reagovat na požadavky prostředí [100]. Model NVI představuje a popisuje víceúrovňovou funkční strukturu vagové kontroly, jejíž kompletní rozbor ale přesahuje rozsah této práce. Jednotlivé úrovně dokládají důkazy o souvislosti mezi HRV a fyziologickou, afektivní a kognitivní regulací. Zbytek kapitoly je proto věnován pouze souhrnu kognitivní regulace. Důkladně byl NVI model rozebrán v literatuře [57, 100, 104].

2.3.1 Kognitivní regulace

Schopnost regulovat pozornost a potlačovat nežádoucí reakce (negativní afektivní stavy) je nezbytná pro přizpůsobení se například právě ICE prostředí. Prefrontální korová aktivita je důležitá pro úkoly vyžadující pracovní paměť, trvalou pozornost, inhibici chování a mentální flexibilitu [100]. Přehledové studie prokázaly, že jedinci s vyšší klidovou HRV dosahovali lepších výsledků při řešení úkolů (n-back test, Stroopův test) vyžadujících exekutivní funkce než jedinci s nižší klidovou HRV [87, 88]. Stres může také zhoršovat kognitivní funkce, přičemž jedinci s nižší klidovou variabilitou vykazovali horší výkonnost při řešení určitých úkolů v podmínkách ohrožení a také větší reakce kortizolu na mírné kognitivní výzvy, které přetrvávaly i v období zotavení, ve srovnání s jedinci s vysokou klidovou HRV [100].

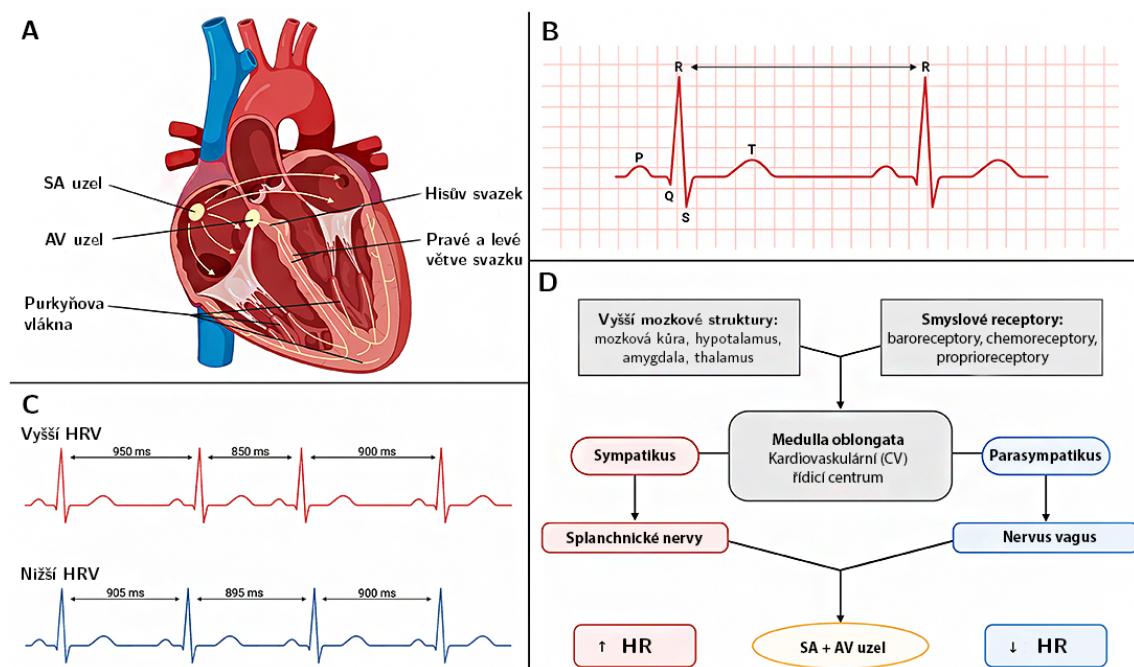
Saus et al. [89] ukázali na realističtějších scénářích zahrnujících policisty, kteří plnili úkoly ve virtuální realitě, že jedinci s vyšší klidovou HRV vykazovali větší situační povědomí a lepší výkon v plnění úkolu. Kromě toho byl tento krátký tréninkový program spojen s menším snížením HRV během plnění úkolu, což naznačuje snížení mentální zátěže. Tyto výsledky naznačují, že jedinci s vyšší klidovou HRV jsou lépe vybaveni pro plnění úkolů, které zahrnují exekutivní a inhibiční funkce, a to jak

⁷Základní stav fyziologického mozku dospělého člověka z hlediska frakce extrakce kyslíku z mozku neboli OEF [102].

v laboratorním, tak v reálném prostředí. Navíc naznačují, že trénink může ovlivnit variabilitu srdečního rytmu a kognitivní výkon.

2.4 Variabilita srdeční frekvence

Variabilita srdeční frekvence (HRV) vypovídá o časové variabilitě mezi jednotlivými srdečními stahy a umožňuje nahlédnout do regulace různých tělesných funkcí autonomním nervovým systémem. Následující kapitola se zabývá způsoby jakými je možné takové nahlédnutí realizovat a zároveň poukazuje na současné nedostatky této problematiky, které je třeba brát v potaz. Nejdříve je ale na místě uvést obecné objasnění vzniku a souvislosti variability srdeční frekvence s funkcionalitou srdce. Regulační pochody autonomního nervového systému spojené s HRV byly popsány v minulé kapitole (zjednodušeně viz Obr. 2.9D).



Obrázek 2.9: **(A)** Převodní systém srdeční; **(B)** Schéma EKG záznamu elektrické aktivity; **(C)** Vysoká vs. nízká variabilita srdeční frekvence; **(D)** Schéma znázorňující různé faktory ovlivňující HR a HRV resp. zjednodušená část NVI modelu (Upraveno a převzato z [105])

Jak již bylo řečeno, HRV lze získat jako časovou diferenci mezi jednotlivými srdečními údery, přičemž úder označujeme jako depolarizaci komor. To je část srdečního cyklu, během které dochází ke genezi QRS komplexu. Aby bylo možné tuto časovou diferenci vypočítat, je potřeba zmíněný komplex detektovat. K tomu se využívá elektrokardiogram neboli záznam elektrické aktivity srdce, na kterém QRS komplex představuje vývoj elektrické aktivace komor myokardu. Srdeční cyklus a anatomie srdce již byly detailně popsány v [106–108]. EKG záznam společně s QRS komplexem lze vidět na ilustraci 2.9B.

K detekci QRS komplexu se primárně využívá jeho pozitivní kmit neboli R vlna, která se v EKG signálu za fyziologických podmínek vyskytuje periodicky, v závislosti na srdečním rytmu, konkrétně na autorytmických buňkách. Tyto srdeční buňky generují stimulační elektrické potenciály, jež iniciují srdeční stah. Hlavními dvěma iniciátory (pacemakerami), určující srdeční frekvenci, jsou sinoatriální (SA) a atrioventrikulární (AV) uzel. Převodní systém srdeční byl již podrobně popsán v [106, 107, 109] a lze vidět na Obr. 2.9A. Za účelem detekce samotné se využívá mnoho algoritmů založených například na: vlnkové nebo Hilbertově transformaci, prahování nebo neuronových sítích. Každý algoritmus zároveň samozřejmě využívá a těží ze svého vlastního způsobu předzpracování EKG. Některé populární algoritmy popsal Porr a Howell v [110]. Fluktuaci časových diferencí mezi po sobě jdoucími R vlny a náležitou změnu HRV lze pozorovat na Obr. 2.9C.

2.4.1 Trendy v analýze HRV

Oblast vývoje problematiky analýzy variability srdečního rytmu je možné rozdělit na několik podskupin. První podskupinu tvoří příznaky použité k analýze. Výběr HRV příznaků (parametrů) hraje významnou roli v rámci mapování vnějších vlivů na funkci biosignálu. Z počátku se využívalo pouze deskriptivní statistiky na řady nasbíraných hodnot srdečního rytmu pro účely odhalení srdečních patologií. Zlom ale nastal v 70. letech 20. století, kdy se k analýze začaly využívat R–R intervaly, a došlo tak k vývoji nových časových parametrů, například RMSSD, pNN50 nebo SDNN, které se stále hojně využívají. Poté přišla na řadu spektrální a nelineární analýza, tedy frekvenční a nelineární parametry, které sebou přinesli i nový vizuální nadhled. V poslední době se používá hlavně časovo-frekvenční analýza, během které se aplikují spektrální metody na specificky dlouhá časová okna a získají se tak frekvenční parametry jako LF (Low Frequency) nebo HF (High Frequency). Je tak umožněno sledování okamžitých změn HRV, což může účinně diagnostikovat například kardiovaskulární onemocnění [73, 101].

Do další podskupiny lze zařadit způsoby měření HRV. Od 90. let 20. století se výzkum HRV rozšířil o analýzu využitím krevního tlaku a dýchání prostřednictvím fotopletysmografie (PPG) a hrudních pásů. Došlo tak k prohloubení HRV výzkumu vzhledem k multimodálnímu přístupu měření. Od roku 2000 se využitím dvanáctisvodového EKG začali v klinické praxi efektivněji analyzovat srdeční patologie. Současně se využívá nositelných technologií (tzv. wearables) v podobě například hodinek na zápěstí, které však často měřené parametry poskytují pouze agregovaně za určité časové úseky. Výhodou je sice jejich mobilita ale na úkor přesnosti poskytovaných dat. Detailní popis zmíněných podskupin společně s dalšími trendy byl již uveden v [73].

Tabulka 2.2: Vybrané parametry z časové a frekvenční oblasti [73]

Parametr	Popis
SDNN	Směrodatná odchylka intervalu mezi dvěma normálními srdečními tepy (NN). NN měří celkový výkon. Snižuje se v reakci na CL
RMSSD	Střední kvadratická hodnota po sobě jdoucích rozdílů mezi normálními srdečními tepy. Primárně se řídí aktivitou PNS
pNN50	Vyjadřuje procento rozdílu spojeného s intervalom NN, který se liší o více než 50 ms. Korelace s aktivitou PNS, RMSSD, HF
SD1	Nelineární proměnné odvozené z Poincarého grafu. Sdílí vysokou korelací s HF, RMSSD. Snižuje se v důsledku CL
SD2	Nelineární proměnné odvozené z Poincarého grafu. Sdílí vysokou korelací s LF. Zvyšuje se v reakci na CL
GSR std	Směrodatná odchylka spojená s elektrodermální aktivitou. Zvyšuje se během CL
GSR mean	Průměrná hodnota získaná měřením rychlosti změn spojených s aktivitou EDA. Zvyšuje se během CL
RSP rate	Představuje frekvenci dýchání, zvýšení respirační frekvence vede ke zvýšení aktivity PNS, VF a snížení LF a aktivity SNS. Zvýšení v reakci na CL
LF	Reprezentuje 0,04–0,15 Hz v rámci PSD ¹ a většinou se používá k označení aktivity SNS ale může specifikovat i aktivitu PNS
HF	Představuje frekvenční rozsah 0,15–0,40 Hz a označuje výhradně aktivitu PNS

¹ Výkonová spektrální hustota (anglicky Power Spectral Density) — vyjadřuje výkon obsažený v určitém intervalu spojitého frekvenčního spektra

2.4.2 Struktura HRV indexů

Vzhledem k popularitě analýzy HRV napříč obory vznikla problematika týkající se interpretace dostupných metrik. Jedním z hlavních problémů je tedy nedostatečné pochopení funkčního vztahu mezi HRV ukazateli a fyziologickými procesy. Také se tyto ukazatele často používají zaměnitelně, což jen přispívá k nejasnostem ohledně jejich skutečného významu (funkce) [111, 112]. Zároveň se často HRV metriky používají kombinovaně. To představuje několik problémů při interpretaci výsledků výzkumu a může být příčinou nekonzistentních výsledků. Dalším problémem je reprodukovatelnost, jelikož různé studie zkoumající stejný jev mohou při popisu vztahu s variabilitou srdeční frekvence vycházet z různých ukazatelů. Také se často nebore ohled na podobnost a překrývání mnoha těchto ukazatelů. Studie například ukázaly, že indexy v časové a frekvenční oblasti, jako je RMSSD a pNN50, spolu silně korelují a jsou vysoko spojeny s výkonem HF. V důsledku toho lze tyto míry považovat za zaměnitelné při hodnocení parasympatické modulace HRV. Nejasnosti ohledně fyziologických důsledků těchto ukazatelů zvyšují právě náročnost objasnění jejich výsledků [73, 74, 113, 114].

Je také třeba poznamenat, že výpočet RMSSD zahrnuje výpočet rozdílů mezi po sobě jdoucími R–R (N–N) intervaly. V důsledku toho tento index odráží především vysokofrekvenční oscilační vzorce srdečního rytmu a není ovlivněn dlouhodobými změnami. Naproti tomu SDNN, o němž se předpokládá, že zachycuje jak sympathetic, tak parasympatickou aktivitu, je silně spojen s celkovým výkonem ve výkonovém spektru HRV [73, 113–115].

V posledních letech se parametry SD1 a SD2 konvenčně interpretují jako nelineární. Toto tvrzení bylo však znehodnoceno matematickým důkazem, který potvrdil, že metriky RMSSD a SD1 jsou ekvivalentní. Tím pádem studie, které uvádějí tyto dva krátkodobé HRV indexy často vágně dospívají k podobným statistickým výsledkům, aniž by tuto ekvivalence rozpoznaly [74, 116–119].

Některé studie navíc zaznamenaly podobnosti mezi poměrovými parametry SD1/SD2 a LF/HF při hodnocení rovnováhy mezi krátkodobou a dlouhodobou variabilitou srdečního rytmu. Nezohlednění těchto překryvů v analýzách může vést ke statistickým chybám. Ty mohou zahrnovat přílišnou důvěru v závěry (projevující se falešně vysokým počtem parametrů shodujících se s určitým trendem), problémy s kolinearitou (pokud je jako prediktory použito více metrik současně), potenciální nadměrnou korekci (např. prostřednictvím metod úpravy p-hodnoty Bonferronova typu) a zbytečnou složitost výsledků [74, 117, 120–122].

2.5 Periferní biosignály

Včetně elektrické srdeční aktivity, která byla diskutována v minulé sekci a je hlavní zkoumanou proměnnou, se mezi další periferní biosignály zkoumané v této práci řadí také elektrodermální a respirační aktivity. V následující podkapitole jsou tyto periferní biosignály uvedeny do souvislosti s problematikou práce a předchozími kapitolami. Dále je stručný přehled jak lze zkoumané signály zaznamenat a zpracovat.

O elektrodermální aktivitě lze hovořit jako o fyziologickém procesu, úzce spojeném s aktivitou potních žláz v kůži, jež je ovlivňován ANS. Aktivita potních žláz vede ke změnám elektrického odporu kůže. Zvýšením této aktivity tak dochází k poklesu elektrického odporu kůže (zvýšení kožní vodivosti) a naopak [123–125]. Fredrikson et al. [126] ukázali, že EDA je úzce spojená s aktivitou cingulární kůry, sekundární zrakové kůry a pravé inferiorní parietální kůry, přičemž nejsilnější korelace byla pozorována v pravé insulární kůře, která je součástí CAN. Další studie naznačují mnohočetné souvislosti mezi změnami kožní vodivosti a CAN regiony [124, 127–129]. EDA tedy nachází velké uplatnění v neuropsychofyziologickém výzkumu ale stejně jako u HRV se zde vyskytují problémy s interpretací metrik, které z ní vycházejí [130]. Z anatomického, fyziologického a biofyzikálního hlediska byla již elektrodermální aktivita důkladně rozebrána v [123]. Úzkou provázanost kožní vodivosti a kognitivní zátěže s využitím EDA pro její detekci a hodnocení podkládají studie [131–138].

Respirační aktivitou se rozumí proces dýchání, při kterém dochází k výměně kyslíku a oxidu uhličitého mezi plícemi a okolím. Dýchací ústrojí bylo již důkladně popsáno v [139]. Respirační signál jako takový odráží cyklické změny objemu plic během dýchání. Dýchací aktivita je ovlivněna celou řadou faktorů, včetně fyzické aktivity, stresu, emocí a i kognitivních nároků. Například kognitivní úkoly vyžadující

trvalou pozornost nebo vyšší nároky na pracovní paměť mohou zvýšit dechovou námahu a spotřebu kyslíku v mozku. Obecně se amplituda a frekvence dechového signálu zvyšuje s rostoucí kognitivní zátěží [140]. Existuje mnoho studií, které vypovídají o významném vztahu mezi respiračním signálem a CL, avšak oproti srdeční a elektrodermální aktivitě je tento signál mnohem častěji zanedbáván. To může vysvětlovat větší počet protichůdných a negativních studií, které popírají význam RSP při detekci a hodnocení kognitivní zátěže [67, 140].

2.5.1 Měření biosignálů

V následujících sekcích jsou popsány principy měření a postupy zpracování periferních biosignálů, které byly využívány pro účely této diplomové práce. Těmi jsou konkrétně srdeční, elektrodermální a respirační aktivita.

2.5.1.1 Elektrická srdeční aktivita

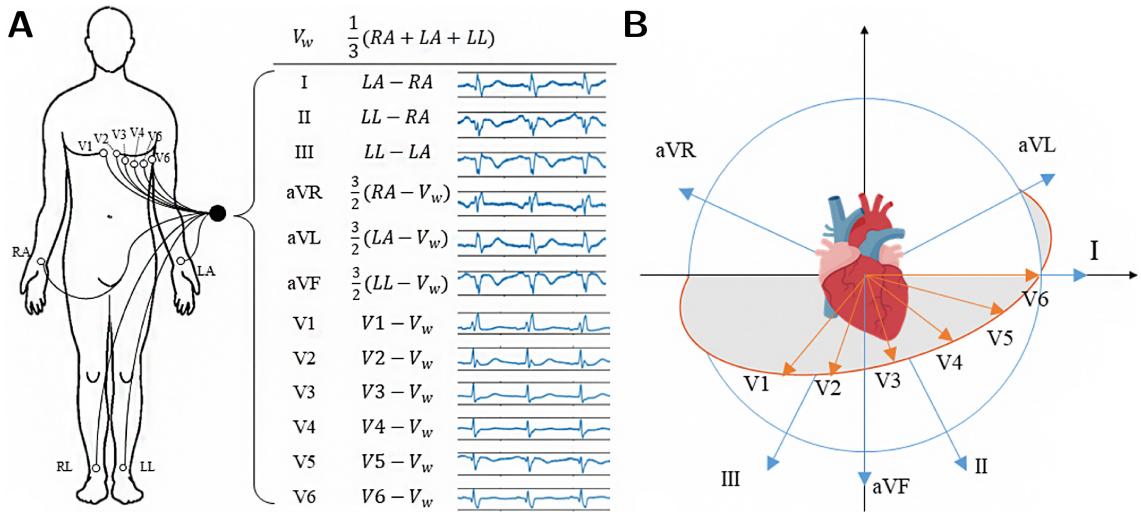
Záznam elektrické srdeční aktivity (elektrokardiogram) je výstupem komplexních fyziologických a technologických procesů. Z fyziologického hlediska je třeba nahlédnout na celulární úroveň, kde díky toku iontů přes buněčné membrány a mezi sousedními buňkami vznikají transmembránové iontové proudy. Geneze těchto proudů je synchronizována díky srdečnímu cyklu, během kterého dochází k tvorbě časově závislého elektrického pole v myokardu. Toto elektrické pole pak podléhá interferenci různých dalších struktur, jako jsou plíce, krev a kosterní svalstvo až kůže. Na kůži jsou poté proudy detekovány elektrodami umístěnými na určitých místech končetin a trupu v takové konfiguraci, aby vytvářely svody, konkrétně bipolární svody [141]. Elektrofyziologie myokardu byla již detailně popsána v [106–109].

Svody zaznamenávají rozdíl potenciálů mezi dvěma elektrodami, přičemž jedna je označována jako kladná a druhá záporná. Bipolární potenciál se následně získává jako rozdíl potenciálů kladné a záporné elektrody. U některých konfigurací je elektricky spojeno více elektrod, které představují záporný člen bipolárního páru, označovaný jako referenční elektroda. Výstupní potenciály elektrod jsou ve finále zesíleny, filtrovány [109, 141].

Jednou z konfigurací je standardní klinické EKG, které zahrnuje záznamy z 12 svodů. Svody v tomto případě sestávají ze standardních končetinových svodů (svody I, II a III), šesti prekordiálních svodů (svody V1 až V6) a ze tří rozšířených (augmentovaných) končetinových svodů⁸ (svody aVR, aVL a aVF) [109, 141].

Standardní končetinové svody. Standardní končetinové svody zachycují rozdíly potenciálů mezi dvěma končetinami. Elektroda na pravé noze slouží jako referenční, snižuje šum a není tak součástí konfigurace svodů. Svody jsou uspořádány do

⁸Prekordiální a rozšířené končetinové elektrody jsou často označované jako „unipolární“ svody.



Obrázek 2.10: Illustrace 12svodového EKG systému. **A)** Prostorové rozmístění 10 elektrod: tři končetinové svody, tři rozšířené končetinové svody a šest prekordiálních (hrudních) svodů, které byly vytvořeny mezi fyzickými elektrodami a virtuální elektrodou známou jako Wilsonův centrální terminál (V_w). **B)** Rozdíly elektrických potenciálů mezi elektrodami odrážejí elektrickou aktivitu srdce z různých prostorových úhlů (Přeloženo a převzato z [142])

trojúhelníku, který se často nazývá jako Einthovenův trojúhelník. Toto uspořádání zajišťuje, že potenciál snímaný ve svodu II odpovídá součtu potenciálů měřených ve svodech I a III [109, 141].

Prekordiální svody a wilsonův centrální terminál. Prekordiální svody se používají k záznamu potenciálu v každém ze šesti určených míst trupu vzhledem k referenci. Na každé místo se umístí aktivní elektroda připojená ke kladnému vstupu záznamového systému. Referenčním vstupem je složená elektroda známá jako Wilsonova centrální svorka, která je vytvořena kombinací výstupu elektrod levé paže (LA), pravé paže (RA) a levé nohy (LL) prostřednictvím odporů (5000Ω) [109, 141].

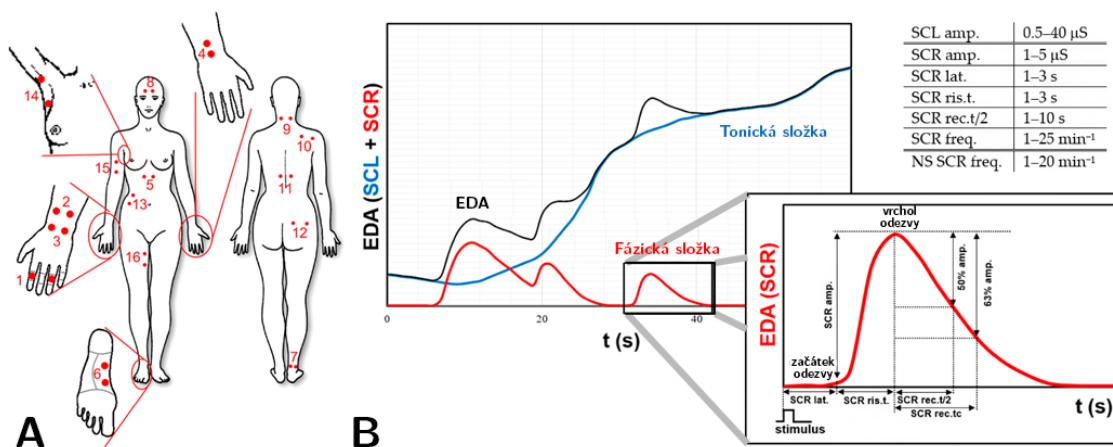
Rozšířené končetinové svody. Jak již bylo zmíněno, třemi augmentovanými svody jsou aVR, aVL a aVF. U svodu aVR je aktivní elektrodou sloužící jako pozitivní vstup elektroda pravé paže, zatímco u svodu aVL je to elektroda levé paže a u svodu aVF elektroda levé nohy. Referenční potenciál je zde vytvořen spojením dvou končetinových elektrod, které se nepoužívají jako aktivní. Účelem tohoto modifikovaného referenčního systému je generovat signál s vyšší amplitudou než při použití Wilsonovy centrální svorky jako referenční elektrody [109, 141].

Další svodové systémy. Byly vyvinuty různé svodové systémy, které umožňují detektovat diagnosticky významné informace, jež nemusí být zachyceny standardním 12svodovým EKG, a zlepšit efektivitu záznamu, přenosu a ukládání EKG. Používají se například levé zadní svody k detekci akutních posterolaterálních infarktů nebo

elektrodová pole o 80 nebo více elektrodách k zobrazení potenciálů povrchu těla jako izopotenciálních map [109, 141]. Přehled dalších svodových systémů včetně nositelných byl popsán v [143–145].

2.5.1.2 Elektrodermální aktivita

V úvodu kapitoly bylo řečeno, že princip měření EDA je založen na skutečnosti, že činnost potních žláz v kůži, která je regulována sympatickým nervovým systémem, vede ke změnám vodivosti kůže. Díky tomu, a jak může vyplývat z minulých kapitol, je měření EDA běžně používanou metodou pro hodnocení fyziologických reakcí souvisejících s emočními a kognitivními procesy.



Obrázek 2.11: A) Možná místa měření kožní vodivosti. **B)** Typická odezva elektrodermální aktivity (Upraveno a převzato z [146, 147])

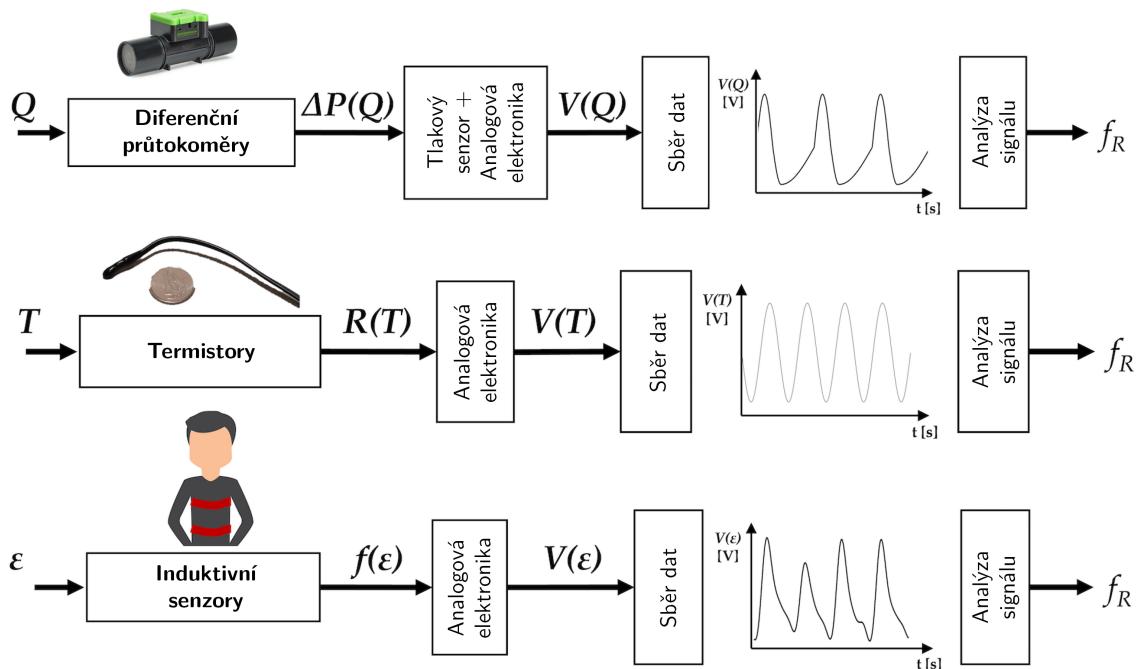
Měření elektrodermální aktivity zahrnuje umístění dvou elektrod na kůži, přičemž jedna měří rozdíly potenciálů mezi dvěma body na kůži a druhá slouží jako referenční elektroda. Elektrody se obvykle umísťují na prsty nebo dlaň ruky, i když lze použít i jiná místa, například chodidla nebo čelo (viz Obr. 2.11A) a měří se elektrická vodivost kůže v reakci na malý stejnosměrný nebo střídavý proud [123, 128].

Z pohledu způsobu měření elektrodermální aktivity lze tedy rozlišovat dvě hlavní kategorie: endosomatická a exosomatická měření. V rámci endosomatického měření se zaznamenává pouze potenciál generovaný kůží bez použití vnějšího zdroje. U exosomatického měření se využívají externí zdroje, jako je právě střídavý nebo stejnosměrný proud přiváděný na kůži. Aplikace konstantního stejnosměrného napětí nebo proudu umožňuje měření vodivosti kůže (resp. odporu kůže podle Ohmova zákona). Pokud se ale aplikuje konstantní střídavé napětí nebo proud, tak lze měřit kožní admitanci (resp. kožní impedanci). Nejpoužívanější metodou pro exosomatická měření je metoda stejnosměrného konstantního napětí, a to primárně díky jednoduššímu procesu vyhodnocování a interpretace než je tomu tak u endosomatického způsobu [123, 128, 148, 149].

Měřená kožní vodivost nebo kožní potenciál se vyjadřují v jednotkách vodivosti (mikrosiemens, μS) a napětí (mV). V naměřeném signálu se odrážejí změny v různých časových škálách, které se běžně dělí na dvě složky: tonickou (SCL) a fázickou (SCR). Tonická složka představuje velikost kožní vodivosti nebo potenciálu v nepřítomnosti sudomotorické nervové aktivity⁹, zatímco ta fázická se týká rychlých změn kožní vodivosti nebo potenciálu jako přímého důsledku sudomotorického vzruchu. Fázická složka je charakterizován nástupem (SCR ris.), dobou nárůstu (SCR ris. t.), amplitudou (SCR amp.) a dobou zotavení (SCR rec. tc.). Na Obr. 2.11 lze vidět průběh EDA složek společně s jejich korespondujícím popisem. Tonické a fázické složky lze oddělit pomocí technik zpracování signálu [123, 128, 148, 149].

2.5.1.3 Respirační aktivita

Pro měření dechové aktivity (resp. dechové frekvence) je k dispozici mnoho metod, od přímého měření ventilace až po nepřímé měření pohybů souvisejících s dýcháním. V této sekci je stručný přehled často používaných metod měření dechové aktivity.



Obrázek 2.12: Různé technologie pro měření dechové frekvence (f_R). Nahoře z kategorie snímačů proudění vzduchu, kde $\Delta P(Q)$ je změna úbytku tlaku způsobená prouděním vzduchu Q . Uprostřed z kategorie snímačů teploty, kde $R(T)$ je změna odporu způsobená vlivem teploty T . Dole z kategorie tenzometrických snímačů, kde $f(\varepsilon)$ je změna odporu způsobená deformačním tlakem ε . $V(X)$ je výstupní napětí (Upraveno a převzato z [150])

Jednou z nejběžnějších metod měření dechové aktivity je přímé měření ventilace. Ventilace je celkový objem vzduchu, který se během každého nádechu přesune

⁹Sudomotorická nervová aktivity se vztahuje k ANS kontrolé aktivity potních žláz v reakci na různé environmentální a individuální faktory.

do plic a z plic ven, a lze ji měřit pomocí několika technik včetně spirometrie, pletysmografie, a kapnometrie. Spirometrie měří objem vzduchu, který je vdechován a vydechován, zatímco pletysmografie měří změny tlaku v uzavřené komoře během dýchání. Kapnometrie měří koncentraci oxidu uhličitého ve vydechovaném vzduchu, což úzce souvisí s ventilací. Tyto techniky umožňují přesné měření dechové aktivity, ale mohou být invazivní a vyžadují specializované vybavení [150–152].

Alternativní metodou měření dechové aktivity je nepřímé měření pohybů souvisejících s dýcháním. Tyto pohyby lze detektovat pomocí senzorů umístěných na hrudníku nebo bříše, jako jsou piezoelektrické senzory, tenzometry nebo akcelerometry. Tyto snímače detekují změny tvaru nebo pohybu hrudníku nebo břicha během dýchání a lze je použít k odhadu dechové frekvence a objemu. Tyto metody jsou méně invazivní než přímé měření ventilace a lze je použít v reálném prostředí, avšak u některých populací nebo za určitých podmínek mohou být méně přesné [150–153].

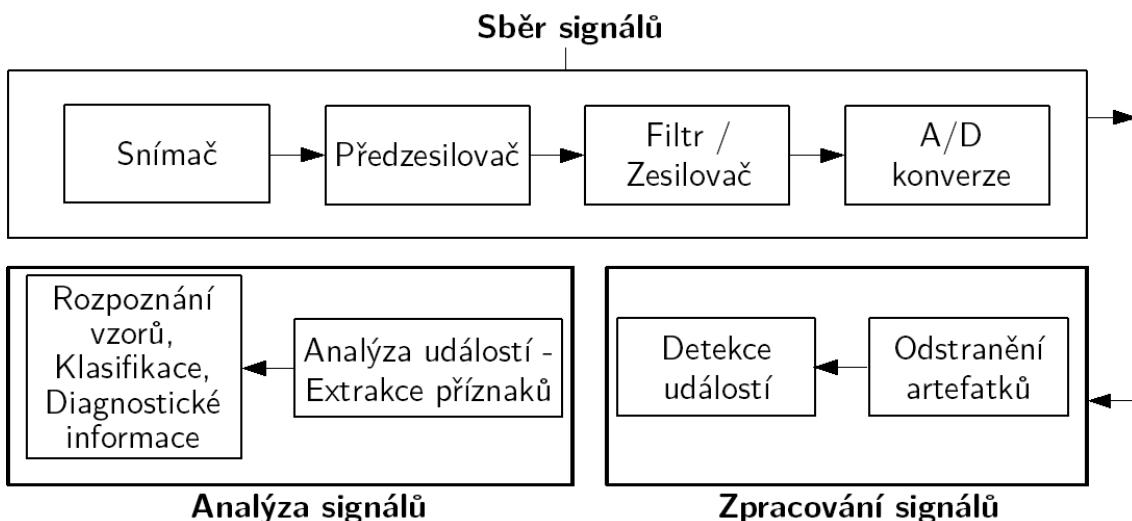
Další nově se objevující metodou měření dechové aktivity je používání nositelných zařízení, jako jsou chytré hodinky, které mohou detektovat změny dechových vzorců pomocí fotopletysmografie nebo akcelerometrie. Fotopletysmografie měří změny objemu krve pomocí světelných senzorů, zatímco akcelerometrie měří pohyb pomocí pohybových senzorů. Tyto metody jsou neinvazivní a lze je použít v přirozeném prostředí s tím, že mohou být omezené ve své přesnosti a preciznosti [150–156].

2.5.2 Postupy zpracování biosignálů

Zpracování biosignálů označuje techniky a postupy používané k získání informací z biosignálů, ke zvýšení jejich kvality a k interpretaci jejich významu. V této sekci je uveden přehled hlavních postupů zpracování biosignálů, včetně jejich akvizice, předzpracování, extrakce příznaků a klasifikace.

V návaznosti na předchozí sekci, sběr signálu znamená tedy proces záznamu biosignálů z lidského těla pomocí měřicích zařízení, jako jsou senzory nebo elektrody. Kvalita zaznamenaných signálů závisí na různých faktorech, jako je typ a umístění snímačů, odstup signálu od šumu a vzorkovací frekvence. Například signály EKG se zaznamenávají pomocí elektrod a jejich umístění ovlivňuje kvalitu zaznamenaných signálů, protože různé oblasti srdce mohou mít různou sílu nebo frekvenci signálu. Kromě toho se odstup signálu od šumu týká poměru žádoucího signálu a nežádoucího šumu v zaznamenaných signálech. Čím vyšší je poměr signál/šum, tím jsou zaznamenané signály jasnější a spolehlivější. A konečně vzorkovací frekvence označuje frekvenci, s jakou jsou signály vzorkovány nebo digitalizovány. Čím vyšší je vzorkovací frekvence, tím přesnější je digitální reprezentace signálů [157, 158].

Předzpracování se týká postupů používaných k přípravě zaznamenaných signálů pro další analýzu. Mezi postupy předzpracování patří především filtrování signálu. Žádoucí je často navržení takového filtru, který rovnou koriguje kolísání nulové izolinie



Obrázek 2.13: Řetězec procesů od získání biomedicínského signálu po fázi analýzy (Přeloženo a převzato z [158])

a potlačuje nežádoucí artefakty (sítový šum, svalové artefakty, apod.). V některých případech však nestačí pouze frekvenčně selektivní filtrace a volí se jiné přístupy. Zvolený přístup závisí na zdroji a charakteru signálu. Porovnání metod předzpracování srdeční, elektrodermální a respirační aktivity bylo vypracováno v [157, 159–161].

Extrakce příznaků označuje postupy používané k extrakci relevantních informací nebo charakteristik z předzpracovaných signálů. Extrakce příznaků je důležitým krokem při zpracování biosignálů, protože jednak snižuje dimenzionalitu signálů a také zvýrazňuje právě relevantní informace. Z biosignálů lze extrahat různé typy příznaků, například z časové, z frekvenční nebo nelineární oblasti [157, 158]. Krishnan a Athavale popsali trendy v extrakci příznaků biomedicínských signálů v [162].

Klasifikací se rozumí postupy používané k přiřazení značky (anotace) nebo kategorie biosignálu na základě jeho extrahovaných vlastností (příznaků). Klasifikace je dalším důležitým krokem při zpracování biosignálů, protože umožňuje identifikovat vzory nebo trendy v signálech a předpovídat fyziologický stav nebo kondici subjektu [157, 158]. Možnosti využití klasifikace (resp. metod strojového učení) pro biomedicínské aplikace byly popsány v [163–165].

Zpracování biosignálů se potýká s různými problémy a omezeními, jako je variabilita signálů, složitost postupů zpracování a interpretace výsledků. Variabilitou signálů je myšleno, že biosignály se mohou lišit od subjektu k subjektu, od sezení k sezení nebo dokonce v rámci jednoho sezení. Tato variabilita může ovlivnit kvalitu a spolehlivost zaznamenaných signálů a může vyžadovat použití sofistikovanějších metod předzpracování a klasifikaci [157, 158].

2.6 Strojové učení

Strojové učení (anglicky Machine Learning, ML) představuje odvětví umělé inteligence, které se zaměřuje na vytváření matematických modelů a zvyšování jejich přesnosti predikce na základě předchozích zkušeností. Tyto zkušenosti se získávají retrospektivně z dostupných dat (trénovacích dat), která se využívají k formulaci pravidel a identifikaci charakteristických rysů nebo vztahů v datech. Proces učení zahrnuje techniky, které vyplývají z oborů informatiky, statistiky, pravděpodobnosti nebo optimalizace. Využití algoritmů strojového učení se neustále rozšiřuje v mnoha oblastech díky rostoucí dostupnosti online dat a snižování nákladů na výpočetní zdroje. Rozsah oblastí použití zahrnuje široké spektrum oborů, včetně zdravotnictví.

Tato kapitola slouží jako úvod do vybraných základních pojmu strojového učení s cílem vytvořit teoretický náhled pro podporu pochopení problematiky v korespondujících částech práce. Detailněji byly principy a náležitosti strojového učení již popsány v literatuře [166–168].

2.6.1 Typy systémů strojového učení

Různorodost scénářů strojového učení je charakterizována rozdíly v povaze trénovacích dat, způsobu trénování a kritériích hodnocení. Každý přístup je vhodný pro řešení určité kategorie problémů a představuje své vlastní charakteristické výhody a omezení. V následujících podkapitolách jsou rozebrány primárně dvě nejrozšířenější formy přístupů k učení, tj. učení s učitelem (anglicky Supervised Learning) a učení bez učitele (anglicky Unsupervised Learning).

2.6.1.1 Učení s učitelem

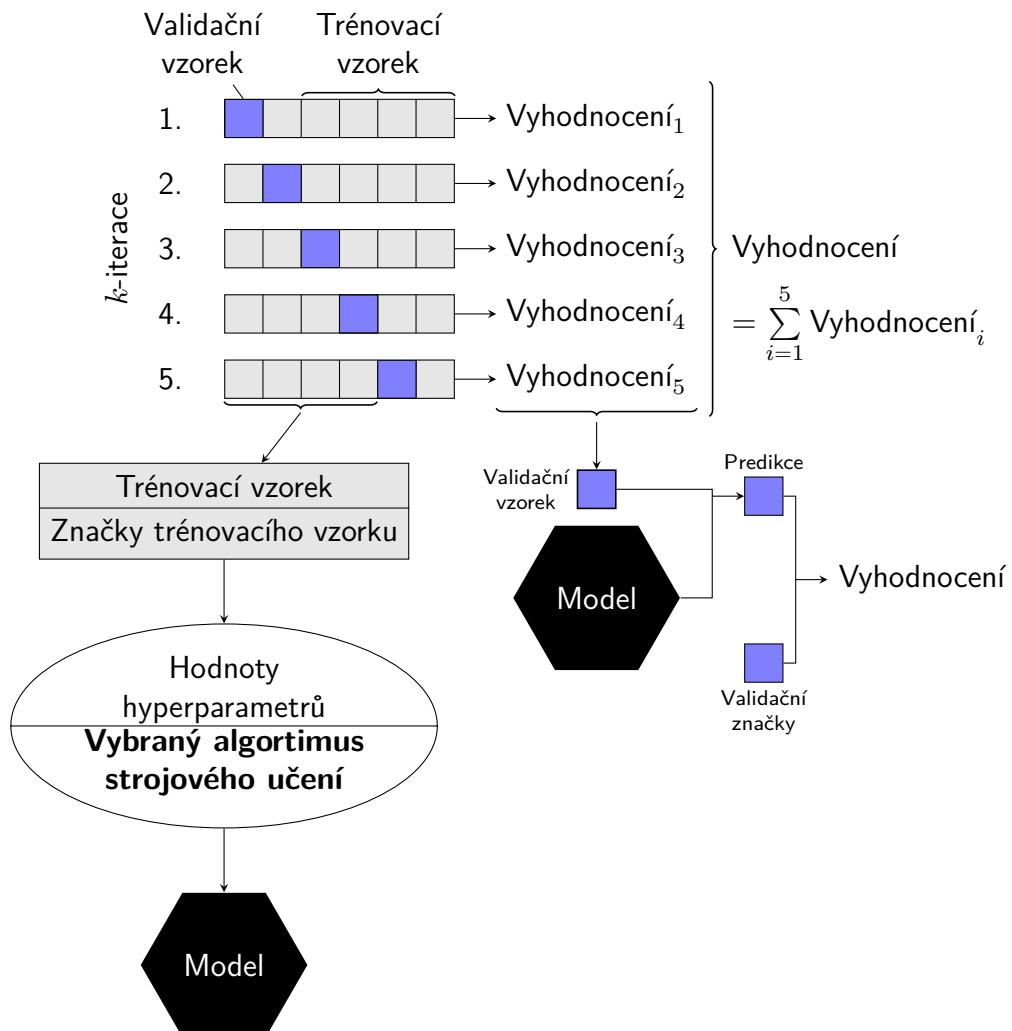
Učení s učitelem je typ strojového učení, během kterého se využívají právě taková trénovací data, která mají anotovanou výstupní proměnnou. Úkolem je zde approximovat mapovací funkci h , která predikuje výstupní proměnnou na základě vstupní proměnné X . K approximaci mapovací funkce jsou použita označená trénovací data, která se skládají z n párů vstupních a výstupních proměnných. Cílem je získat přesné predikce jak pro trénovací, tak pro úplně nová data. Formálně lze tedy tvrdit, že hledáme funkci:

$$h : \mathbb{R}^d \rightarrow \mathcal{C} \quad (2.1)$$

tak, že pro každou novou dvojici vstupu a výstupu (x, y) vybranou z \mathcal{P} platí $h(X) \approx y$, kde \mathbb{R}^d je d -rozměrný příznakový prostor a \mathcal{C} je prostor všech možných anotací. Zároveň předpokládáme, že tyto dvojice pocházejí z neznámého rozdělení \mathcal{P} [167].

2.6.1.2 Učení bez učitele

Cílem učení bez učitele je najít vzory v neanotovaných datech bez definovaného výstupu. Výsledkem tohoto typu učení mohou být struktury nebo vztahy v datech. Vyhodnocování výkonu natrénovaného modelu je v tomto případě, bez označených dat, často náročné. Běžnou úlohou pro tento typ učení je shlukování, které seskupuje podobné data do shluků. Shlukování se používá například pro segmentaci obrazových dat a provádí se pomocí algoritmů, jako je hustotní prostorové shlukování (DBSCAN), k-means nebo hierarchické shlukování.



Obrázek 2.14: Obecné schéma procesu trénování modelu a optimalizací hyperparametrů s využitím k-násobné křížové validace [169]

2.6.2 Trénování a testování modelů

Vyhodnocování modelů strojového učení je pro jejich úspěšnost klíčové. Aby bylo zajištěno, že model dokáže efektivně predikovat i nová data, nikoli pouze data využita během jeho trénování, provádí se tzv. *train-test* rozdělení. To zahrnuje ponechání

části dat jako testovací množiny, kterou model během trénování nepoužil, a její následné použití k vyhodnocení schopnosti modelu generalizace porovnáním jeho predikce se skutečnými hodnotami.

Běžně se využívá rozdelení trénovací a testovací množiny v poměru 80:20 z náhodně vybraných dat. Dále se někdy využívá validační množina (15-20 % trénovací množiny) pro účely ladění hyperparametrů. Nejúspěšnější model se na základě validační množiny natrénuje pomocí nalezených hyperparametrů. Nakonec se model vyhodnotí na dosud nevyužité testovací množině. Hyperparametry a jejich optimalizace jsou rozebrány v samostatné podkapitole 2.6.3.

2.6.2.1 Křížová validace

Přístup rozdelení dat z předchozí sekce je efektivní, ale opomíjí jeden problém: existuje mnoho možných kombinací trénovací a testovací sady a tato metoda zkoumá pouze jednu. Data mohla být tedy náhodně rozdělena nereprezentativním způsobem. Odpovídá na tento problém je křížová validace (anglicky cross-validation, CV), která eliminuje závislost na rozdelení dat. Cílem křížové validace je vyhodnotit a porovnat výkon různých modelů na stejném datovém souboru a najít tak optimální nastavení hyperparametrů pro daný model.

Křížová validace se skládá ze tří hlavních kroků: rozdelení datového souboru na k částí, trénování modelu na $k - 1$ částech dat a vyhodnocování výkonu modelu na zbývající (validace) části dat. Tyto kroky se opakují n krát, přičemž každá část dat se použije jednou jako validace. Výsledkem křížové validace je průměrný výkon modelu na všech k částech validace. Existuje celá řada způsobů provedení křížové validace: K-Fold, Leave One Out (LOO), Stratified Shuffle Split, Leave P Groups Out, a další, které byly již popsány v [166].

Křížová validace má řadu výhod oproti jiným metodám optimalizace hyperparametrů, jako je například mřížkové nebo náhodné vyhledávání popsané v dalších kapitolách. Mezi tyto výhody patří:

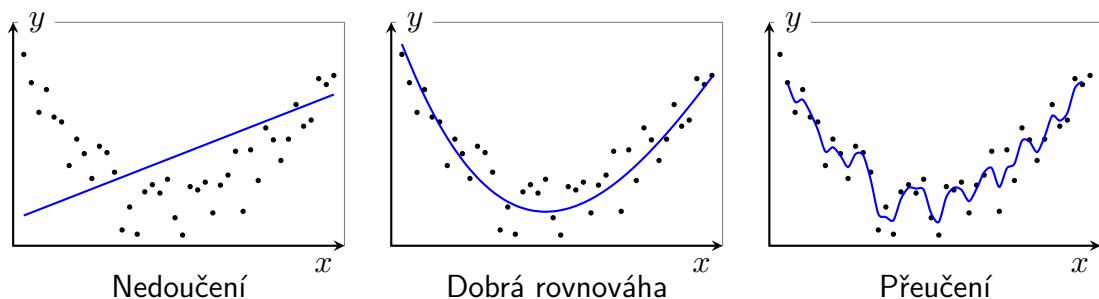
- Objektivní hodnocení výkonu modelu na stejných datech [170].
- Minimalizace rizika přeучení [171].
- Efektivní využití všech dat k hodnocení výkonu modelu [172].

V praxi se křížová validace často používá pro optimalizaci hyperparametrů nejen jednoho, ale i více modelů současně a následně porovnání jejich výkonu.

2.6.2.2 Přeučení a nedoučení

Přeučení (anglicky overfitting) a nedoučení (anglicky underfitting) jsou dva hlavní problémy, které se mohou vyskytnout při trénování modelů strojového učení. Tyto problémy ovlivňují schopnost modelu generalizovat na nová data, což způsobuje snížení jeho přesnosti.

K přeučení dochází, když model příliš pečlivě přizpůsobuje svůj výstup trénovacím datům a nezachycuje skutečné vztahy v datech. Vzniká tak velmi složitý model, což vede k vyššímu rozptylu a snížené vypořídací schopnosti. Přeučení je charakterizováno výrazným rozdílem mezi výkonností modelu na trénovací a testovací množině, známým jako generalizační mezera (anglicky Generalization Gap). Tento rozdíl je způsoben vysokou schopností modelu zapamatovat si specifické detaily trénovacích dat, místo aby zachycoval požadované vzorce [173].



Obrázek 2.15: Příklad nedoučeného modelu s vysokým biasem vlevo, přeučeného modelu s vysokým rozptylem vpravo a dobře přizpůsobeného modelu uprostřed [174]

Těmto problémům lze předcházet různými způsoby, například:

- Použití vhodných metod regularizace (např. L1 nebo L2 regularizace).
- Použití vhodného algoritmu strojového učení (např. kNN má tendenci k nedoučení, zatímco složité modely jako např. neuronové sítě k přeučení).
- Použití CV k hodnocení výkonu modelu a optimalizaci hyperparametrů.
- Zvýšení počtu trénovacích dat.

2.6.3 Optimalizace hyperparametrů

Ve strojovém učení jsou hyperparametry (HP) nastaveny před trénováním a nejsou určeny učícím algoritmem. Tyto parametry musí být zadány jako vstupy a jejich určení může být stěžejním faktorem, protože různé problémy vyžadují různé přístupy. Proces hledání optimální konfigurace modelu se označuje jako optimalizace hyperparametrů (HPO).

Metoda vyhledávání v mřížce (anglicky Grid Search Method), je běžným způsobem optimalizace hyperparametrů. Definuje sadu diskrétních hodnot pro každý hyperparametr a pro každou kombinaci vyhodnocuje ztrátovou funkci modelu. Za optimální je považována konfigurace s nejnižší validační ztrátou. Počet vyhodnocení však rychle roste s počtem hyperparametrů, tudíž je tato metoda vhodná pouze pro jednoduché modely, u nichž není trénování a hodnocení výpočetně náročné [175].

Alternativou k mřížkovému vyhledávání je náhodné vyhledávání (anglicky Random Search Method). Namísto úplného vyhodnocení všech kombinací jako v předešlé metodě kontroluje pouze určitý počet náhodných vzorků z hyperparametrického prostoru. Tato metoda je efektivnější než prohledávání v mřížce, přičemž poskytuje srovnatelné výsledky [175–177]. Existují i další způsoby HPO mezi které se řadí například bayesovská optimalizace, genetické algoritmy nebo využití neuronových sítí. Jejich využití přichází v úvahu zejména u více-dimenzionálních problémů [175, 178].

2.6.4 Kombinování modelů

Kombinované modely (anglicky Ensemble Models) skládají předpovědi z více různých základních modelů, aby se zvýšila přesnost predikce. Toho lze dosáhnout zprůměrováním predikce u regrese nebo výběrem nejčastější predikce u klasifikace. Váhu předpovědi každého základního modelu lze upravovat na základě jeho individuální přesnosti. Klíčovým faktorem úspěchu kombinovaných modelů je různorodost a nezávislost základních modelů, které lze dosáhnout pomocí různých trénovacích dat, hyperparametrů nebo algoritmů. Ačkoli tomu tak není vždy, četné studie ukázaly, že kombinované modely často dosahují lepších výsledků než jednotlivé základní modely [179].

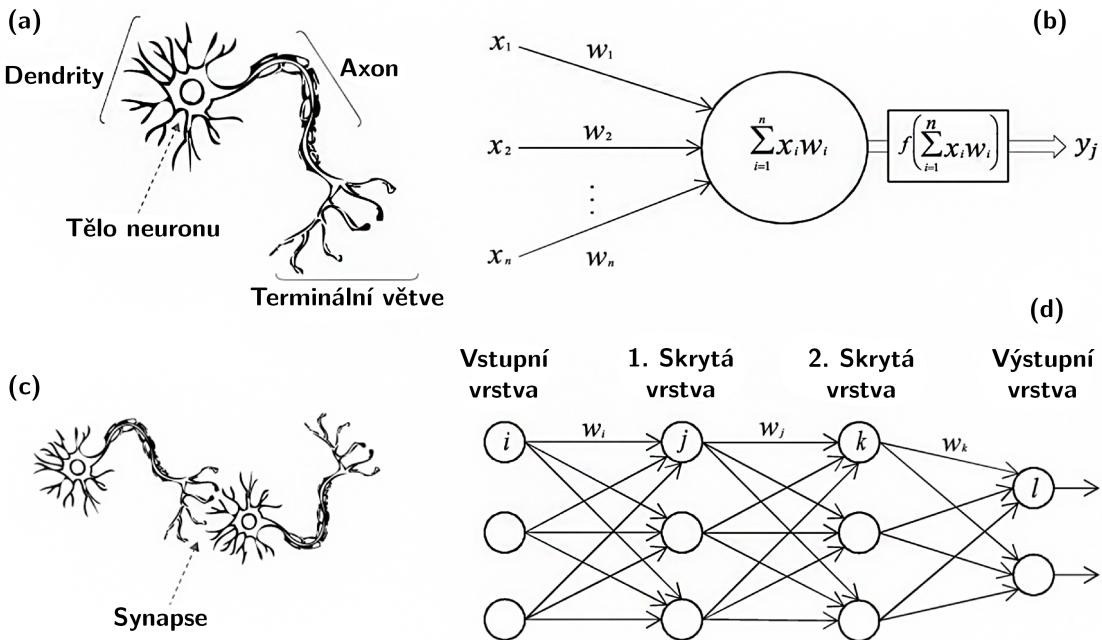
2.6.5 Hodnocení modelů

K hodnocení modelu lze použít různé metriky v závislosti na dané úloze. Vyhodnocování natrénovaného modelu je klíčovým aspektem procesu strojového učení. Vzhledem k tomu, že se tato práce zabývá především úlohou klasifikace učení s učitelem, nebudou zde popsány všechny hodnotící metriky. Vybrané a použité metriky jsou blíže popsány v samotných metodách, v kapitole ??.

2.6.6 Umělé neuronové sítě

Umělé neuronové sítě (anglicky Artificial Neural Networks, ANN) jsou významným nástrojem pro strojové učení a jsou často používány pro řešení složitých úloh, jako jsou klasifikace, regrese, segmentace obrazu a jazykové zpracování. Jedná se výpočetní modely, které napodobují strukturu biologických neuronů. Stejně jako biologické

neurony zpracovávají ANN vstupy, přenášejí impulsy a vytvářejí výstupy na základě aktivačních funkcí. Učení probíhá upravováním ANN vah spojení mezi neurony pomocí optimalizačních algoritmů.



Obrázek 2.16: Biologický neuron ve srovnání s umělou neuronovou sítí: **(a)** lidský neuron; **(b)** umělý neuron; **(c)** biologická synapse; a **(d)** synapse ANN. (Upraveno a převzato z [180])

V průběhu let se ANN významně rozvinuly a byly použity k řešení široké škály úloh. Dnes hrají umělé neuronové sítě klíčovou roli v různých akademických i komerčních aplikacích při řešení problémů, které jiné metody nezvládají. Historie a základní koncepty ANN, mezi které patří například perceptrony nebo zpětná propagace a gradientní sestup byly již rozebrány v [166–168].

2.6.6.1 Ztrátová funkce

Začátkem této podkapitoly o strojovém učení (viz 2.6.1.1) byla definována funkce h , před jejímž hledáním je potřeba učinit předpoklad o jaký typ funkce se jedná (lineární, polynomická, aj.). Tímto předpokladem vzniká vymezení na určitý prostor hypotéz, označovaný \mathcal{H} , které velmi ovlivňuje generalizaci.

S vymezením přichází na řadu ztrátová funkce $\mathcal{L} : \mathcal{H} \rightarrow \mathbb{R}$, jež přiřazuje ztrátu každému $h \in \mathcal{H}$. Ztrátu si lze představit jako číslo, které vypovídá o tom jak přesně je nalezená h approximována vzhledem k použitým datům. Se ztrátovou funkcí tak vzniká nový optimalizační problem:

$$\arg \min_{h \in \mathcal{H}} \mathcal{L}(h) = \arg \min_{h \in \mathcal{H}} \frac{1}{n} \sum_{i=1}^n l(\mathbf{x}_i, y|h) \quad (2.2)$$

kde \mathcal{L} je ztráta pro danou h v rámci používaných dat a l je ztráta pro dvojici vstupu a výstupu při dané h . Díky takovému způsobu hodnocení je umožněno modelu se učit. Existuje řada ztrátových funkcí, jejichž použití závisí na typu problému (regrese, klasifikace, aj.). Tyto funkce společně s detailnějším popisem optimalizačního problému již byly popsány v [167].

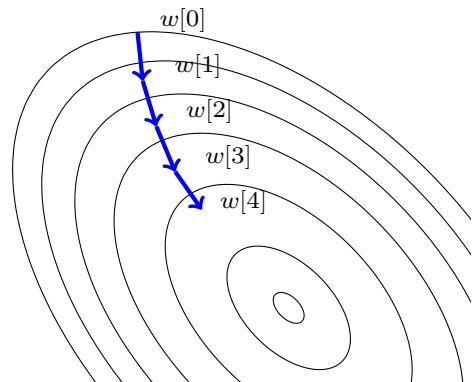
2.6.6.2 Numerická optimalizace

Obecně je numerická optimalizace technika, která se používá k nalezení optimálního řešení výpočetně náročných problémů. Ve strojovém učení se numerická optimalizace často používá k optimalizaci parametrů modelu. V rámci ANN se k optimalizaci vah spojení mezi neurony běžně využívá gradientní sestup (GD) v různých podobách.

Algoritmus 1: Gradientní sestup

```

Vstup: vahy  $w_0$ , # iterací  $T$ 
Výstup: konečné vahy  $w_T$ 
1 for  $t \in \{0, \dots T - 1\}$  do
2   odhad  $\nabla \mathcal{L}(w_t)$ 
3   výpočet  $\Delta w_t = -\nabla \mathcal{L}(w_t)$ 
4   výběr rychlosti učení  $\gamma$ 
5    $w_{t+1} := w_t + \gamma \Delta w_t$ 
6 end
7 return  $w_T$ 
```



Obrázek 2.17: Postup GD [181]

Výše lze vidět obecný popis gradientního sestupu (Algoritmus 1). Jeho cílem je najít minimum funkce tím, že se postupně pohybuje v opačném směru gradientu funkce. Gradient je vektor, který ukazuje směr největšího nárůstu funkce. Při pohybu v opačném směru tohoto vektoru, nastává oblast s největší změnou funkce a lze tedy minimalizovat cílovou funkci. Postupné kroky v opačném směru gradientu funkce vedou k nalezení optimálního řešení. Na Obr. 2.17 je vizualizována přirozená aktualizace vah gradientního sestupu ve výstupním prostoru (pro náhodně inicializovanou síť). Jednotlivé vrstevnice znázorňují množiny úrovní hodnot ztrátové funkce podél vertikálního a horizontálního směru. Uprostřed vrstevnic se nachází minimum ztrátové funkce. Z algoritmu výše lze aktualizaci vah GD popsat následovně:

$$w_{t+1} = w_t - \gamma \nabla L(w_t) \quad (2.3)$$

kde w_t je aktuální hodnota vektoru vah v čase t , γ je rychlosť učení (anglicky Learning Rate) a $\nabla L(w_t)$ je gradient cílové funkce v čase t . Různé volby rychlosti učení γ a techniky odhadu pro $\nabla \mathcal{L}(w)$ mohou vést k různým implementacím. Gradientní sestup má proto řadu variant, včetně stochastického gradientního sestupu a mini-batch gradientního sestupu, které se liší v způsobu, jakým jsou gradienty vypočítávány a aktualizovány. Tyto algoritmy již popsalo Goodfellow et al. v [168].

2.6.6.3 Aktivační funkce

Aktivační funkce jsou jednou z nejdůležitějších součástí ANN. Tyto funkce zpracovávají vstupní signály a generují výstupy neuronů, které se dále šíří do dalších vrstev sítě. Musí také splňovat některé předpoklady jako je diferencovatelnost. Aktivační funkce musí být také nelineární, aby se rozšířil rozsah mapovacích funkcí, které lze approximovat. Existují různé aktivační funkce, které mají své výhody a nevýhody. Jejich výběr je podstatnou součástí procesu optimalizace hyperparametrů [168, 182].

Tabulka 2.3: Vybrané aktivační funkce [183]

Název	Funkce	Derivace	Obrázek
Sigmoid	$\sigma(x) = \frac{1}{1+e^{-x}}$	$f'(x) = f(x)(1-f(x))^2$	
Softmax	$f(x) = \frac{e^x}{\sum_i e^x}$	$f'(x) = \frac{e^x}{\sum_i e^x} - \frac{(e^x)^2}{(\sum_i e^x)^2}$	
tanh	$\sigma(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$	$f'(x) = 1 - f(x)^2$	
ReLU	$f(x) = \begin{cases} 0 & \text{if } x < 0 \\ x & \text{if } x \geq 0. \end{cases}$	$f'(x) = \begin{cases} 0 & \text{if } x < 0 \\ 1 & \text{if } x \geq 0. \end{cases}$	

Logistická funkce, neboli sigmoida, je jednou z nejstarších aktivačních funkcí a má tvar S-křivky. Sigmoida má nelineární charakter, což umožnuje neuronové síti modelovat složité vztahy mezi vstupy a výstupy. Nicméně, sigmoida má některé nevýhody, mezi které patří tzv. „vanishing gradient“, kdy se gradient funkce blíží nule, což brání učení sítě. Tato funkce také může způsobit saturaci neuronů, což znamená, že se jejich výstupy blíží k hodnotě 0 nebo 1, a brání tak dalšímu učení [182].

Hyperbolická funkce tangens (tanh) je podobná sigmoidě, ale má symetrický tvar s rozsahem mezi -1 a 1. Tanh může být lepší volbou než sigmoida pro určité typy sítí, protože umožňuje výstupy neuronů, které jsou jak kladné, tak záporné [182].

Aktivační funkce ReLU (anglicky Rectified Linear Unit) vrací vstupní hodnotu, pokud je kladná, a nulu, pokud je záporná. Jedná se o velmi populární a efektivní funkci, která umožňuje rychlé učení sítí. Navíc, ReLU může snížit výskyt saturace neuronů a dříve zmíněného problému – „vanishing gradient“. Nicméně, tato funkce může mít problém s tzv. „mrtvými neurony“, kdy neuron má výstup vždy roven nule a stává se tak neaktivní [182, 184].

Leaky ReLU je modifikace ReLU, která řeší problém „mrtvých neuronů“ tím, že má nenulovou hodnotu pro záporné vstupy. Existuje řada dalších aktivačních funkcí,

jako je softmax, která se často používá jako aktivační funkce pro poslední vrstvu neuronové sítě a používá se v úlohách klasifikace [182].

2.6.6.4 Regularizace

Z předešlých kapitol vyplývá, že jedním z hlavních cílů učení neuronové sítě je minimalizace chyby predikce. Často ale dochází k přeúčení neuronová sítě, tedy sít se naučí velmi přesně předpovídat data použitá pro trénování, ale ztrácí schopnost generalizace. To je způsobeno tím, že síť se snaží přizpůsobit se každému jednotlivému trénovacímu datovému bodu a následně nedokáže předpovídat data, která se od těch trénovacích liší. K tomuto jevu dochází, protože neuronová síť má příliš mnoho parametrů (viz 2.6.2.2). Řešením tohoto problému je použití regularizace. Regularizace je technika, která snižuje rozptyl modelu sítě, a snaží se tak minimalizovat riziko přeúčení. Existuje několik technik regularizace, z nichž nejčastěji používanými jsou L1 a L2 regularizace, dropout a early stopping.

Metody regularizace L1 a L2 omezují optimalizační metody během procesu minimalizace ztrátové funkce modelu. Tato omezení penalizují váhy, což vede ke zjednodušení modelu. Při L1 regularizaci se k nákladové funkci přidává regularizační člen, který je součtem absolutních hodnot vah. Tento přístup způsobí, že některé příznaky jsou považovány za méně důležité a je jim přiřazena nulová váha, čímž se model účinně zjednoduší. Váhy byly dříve indexovány na základě neuronů a vrstev, které spojují. U L2 je zaveden regularizační člen za účelem minimalizace součtu čtverců vah. Tento přístup nevede k vynulování vah, ale snižuje je o faktor úměrný jejich velikosti během každé iterace gradientního sestupu [166, 168].

Dropout je metoda, která náhodně „*vypne*“ některé neurony v síti během trénování, což má za následek omezení relací mezi neurony a snížení rizika přeúčení. Early stopping je technika, která sleduje vývoj chyby při trénování sítě na validačním datasetu a zastaví trénování, jakmile se chyba na validačním datasetu začne zvyšovat. Umožňuje tak včasné ukončení trénování a minimalizaci rizika přeúčení [166, 168].

KAPITOLA **3**

Cíle práce

Hlavním cílem diplomové práce je návrh a realizace metod pro hodnocení kognitivní zátěže z biosignálů současně s vyhodnocením vlivu extrémního prostředí na její projevy. Hodnocenými biosignály jsou konkrétně elektrická srdeční aktivita, respirační aktivita a elektrodermální aktivita. Extrémním prostředím je v kontextu diplomové práce myšlena vesmírná analogová mise.

Metody

4.1 Mise DIANA

Tato diplomová práce těží z již druhé vesmírné analogové mise, která simulovala přistání na měsíci a uskutečnila se v rámci projektu Hydronaut v létě roku 2022. Jednotlivé kompartmenty mise měly následující role: řídící věž byla stanoviště na Zemi, mateřská loď obíhala na oběžné dráze Měsíce a přistávací modul byl na povrchu Měsíce. Blíže jsou dílčí kompartmenty popsány v následujících sekcích.

Mise primárně sloužila pro zkoumání vlivu osobnostních charakteristik a vnějších faktorů na dynamiku týmu při dlouhodobém pobytu v ICE prostředí (projekt TAČR ÉTA č. TL05000228). Mise DIANA byla podpořena Evropskou kosmickou agenturou, vzhledem k jejímu potenciálu pro výcvik astronautů simulací extrémního prostředí.

4.1.1 Projekt Hydronaut

Projekt Hydronaut začal jako podvodní komora, která se postupně proměnila v laboratoř s celým logistickým a vědeckým zařízením. Nyní slouží pro různorodé výzkumné účely, včetně zkoumání vlivu izolace a extrémního prostředí na psychiku člověka a testování technologií za extrémního tlaku.

4.1.2 Výběr posádky

Výběr posádky pro misi DIANA začal s půlročním předstihem v podobě týmové a individuální diagnostiky posádky. Tato část byla primárně realizována psychologickým týmem Filozofické fakulty Univerzity Palackého v Olomouci. Byly využity neuropsychologické, dotazníkové a škálové metody, přičemž také proběhly motivační rozhovory na téma pobytu v ICE prostředí. Výsledky testů byly zároveň použity pro ladění všech psychologických nástrojů a aspektů pro samotnou misi včetně realizace mise samotné.

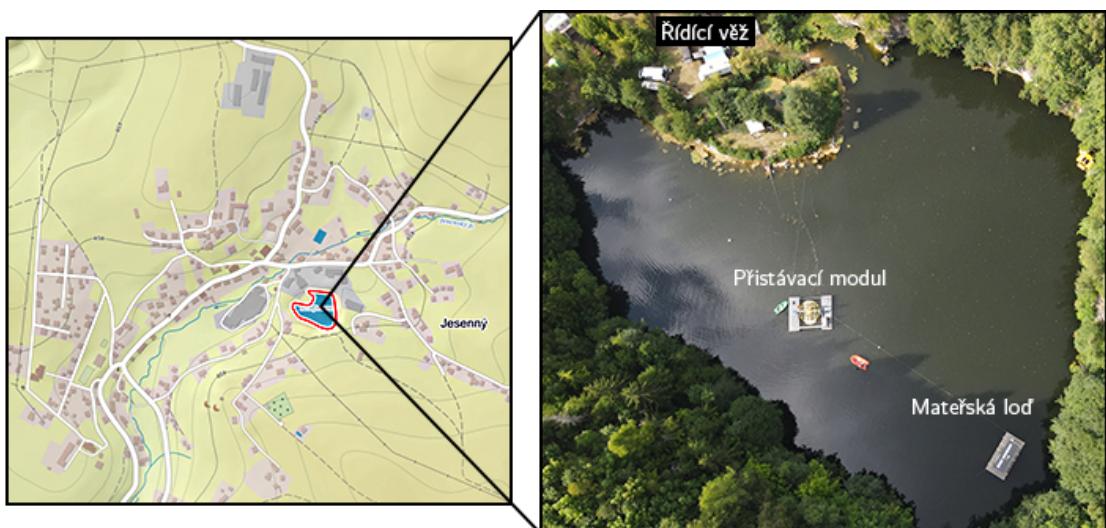
Při této příležitosti také proběhly i různorodé technické testy. Všechny výsledky byly důležité primárně pro přípravu detailního programu celé mise tak, aby co nejdůvěrohodněji simulovala pobyt v ICE prostředí, včetně minutového harmonogramu zaměřeného na technické, lékařské, psychologické a sociální hlediska pobytu. Harmonogram je dále popsán v sekci 4.1.6.1.

4.1.3 Posádka pro misi DIANA

Pro misi DIANA byla vybraná šestice členů posádky. Tři jedinci pro mateřskou loď a další tři pro podvodní stanici (přistávací modul). Vybraný vzorek se skládal z mužů ve věkovém rozmezí 25-58 let, kteří předem podstoupili vstupní lékařskou prohlídku. Výběr proběhl na základě preselekce popsáne v předchozí sekci. Žádnému jedinci nebyla diagnostikována žádná kardiovaskulární onemocnění, ani jiné zdravotní problémy, které by mohly být stěžejní pro misi. V rámci posádky přistávacího modulu se jednalo o trénované potápěče vzhledem k saturacnímu pobytu po hladinou.

4.1.4 Popis lokality a podmínky prostředí

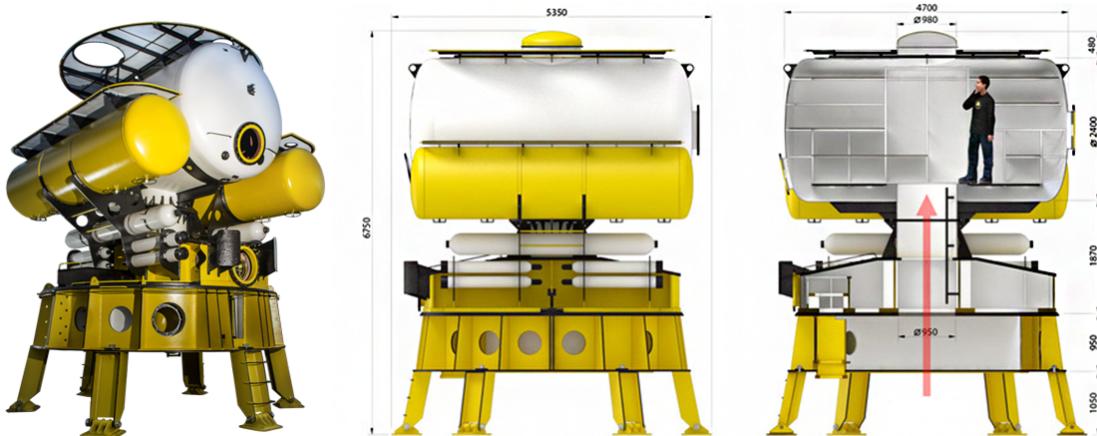
Stanice H03 DeepLab je lokalizována v Lomu Jesenný. Obec Jesenný se nachází severovýchodně od Prahy v okrese Semily, v Libereckém kraji. Jedná se zatopený vápencový lom o rozloze 130x90 m a maximální hloubce 13,5 m. Vzhledem k tomu, že mise probíhala pod vodní hladinou, tak nadále nebude uveden geologický kontext lokality. V průběhu celého experimentu byly příznivé podmínky počasí a nevyskytly se žádné extrémní události.



Obrázek 4.1: Detail a lokalita lomu v obci Jesenný (zdroj mapového podkladu: Mapy.cz)

4.1.5 Hlubinná laboratoř H03 DeepLab

Hydronaut H03 DeepLab je jedinečná výzkumná podvodní laboratoř pro výcvik posádek v ICE podmírkách. Stanice byla zřízena tak, aby umožnila dlouhodobý pobyt tří členů posádky pod vodní hladinou, přičemž její konstrukce kombinuje kesonový a ponorkový princip. Díky této unikátní laboratoři bylo tak umožněno vytvořit podmínky pro dlouhodobý výzkum a sledování vlivu například tlaku, vlhkosti, stresu, umělého osvětlení a izolovaného prostředí na člověka nebo použité materiály a vybavení. V rámci mise DIANA plnila stanice roli přistávacího modulu.



Obrázek 4.2: Hlubinná laboratoř H03 DeepLab a její schéma (zdroj: Hydronaut Project a.s.)

4.1.5.1 Vybavení stanice

Po hardwarové stránce je stanice vybavena systémy pro monitorování stavu prostředí uvnitř habitatu a pro monitorování fyziologických funkcí jednotlivých členů posádky. Součástí je také systém pro přenos dat do řídícího stanoviště.

Pro potřeby například komunikace nebo monitorování fyziologických dat je stanice vybavena i potřebným softwarem, který je obalen škálovatelným palubním systémem. Tento systém umožňuje vizualizaci, administraci a hodnocení měrených veličin (data prostředí, biomedicínská data) společně s obousměrnou komunikací se všemi zapojenými účastníky s možností volby různých komunikačních omezení (např. pro potřeby simulace výpadku komunikace). Vybrané dílkové části vybavení stanice jsou detailněji popsány v následujících sekcích.

4.1.5.2 Řízení stanice a mise

Stanice H03 DeepLab má hlavní komunikační systém zvaný *Common Tongue*. Ten zajišťuje komunikaci mezi posádkou a podpůrným týmem a umožňuje živé sledování životních funkcí posádky a vnitřního prostředí. Pomocí tohoto systému byli subjektům experimentu zadávány úkoly, které jsou sledovány za účelem vyhodnocení změn chování sledováním vlivu stresu na soustředění a výkonnost mozku.

4.1.5.3 Monitorování atmosféry habitatu

Jedním z důležitých východisek pobytu v habitatu jsou podmínky prostředí, které je nezbytné nepřetržitě a spolehlivě monitorovat. Jednou z těchto podmínek je atmosféra pro jejíž monitorování slouží systém založený na platformě slowRIO (slow remote IO controller) vyvinutý ve spolupráci s Fakultou strojní (FS ČVUT) na projektu Hydronaut. Systém monitoruje a poskytuje data prostředí – mikroklima: absolutní tlak, relativní vlhkost, teplota vzduchu, teplota vody, čidlo O_2 , čidlo CO_2 , čidlo H_2 , čidlo CH_4 , intenzita osvětlení, barva osvětlení a další. Data jsou posílána do palubního počítače.

4.1.6 Infrastruktura mise

Povaha a náročnost stanovených cílů mise se vyžádaly komplexní infrastrukturu pro podporu celého výzkumného procesu. V této podsekci je uveden stručný přehled některých součástí infrastruktury včetně harmonogramu mise.

4.1.6.1 Harmonogram mise

Harmonogram mise byl základním dokumentem, který definoval všechny činnosti v průběhu mise. Harmonogram byl rozepsaný na úroveň minut pro každého jednotlivého člena posádky. Ukázku harmonogramu lze vidět na Obr. 4.3.

	DATE	4. DEN - PONDĚLÍ															
	Hour of Mission	64	65	66	67												
Vysvětlivky:	CET	8:00	8:15	8:30	8:45	9:00	9:15	9:30	9:45	10:00	10:15	10:30	10:45	11:00	11:15	11:30	11:45
EVA	VĚŽ	hlídka								briefing	poslouchá						
hlídání																	
systémové aktivity	MOTHER SHIP																
zdravotní aktivity	MS commander	snídaně	FBMI	prohlídka	briefing	briefing	Velitel: NASA (EVA 1) + obed										
psychologický program	crewmember 2	snídaně	FBMI	rostliny	coord.	prohlídka	briefing	briefing	briefing	briefing	briefing	briefing	briefing	exchan	obed		
rostliny	crewmember 3	snídaně	FBMI	prohlídka	briefing	briefing	briefing	briefing	briefing	briefing	briefing	briefing	briefing	exchan	obed		
spánek																	
jídlo	LANDING MODULE																
volno	LM commander	hygiëna	snídaně	FBMI	prohlídka	briefing	příprava na EVA 2										
FBMI	crewmember 2	hygiëna	snídaně	FBMI	rostliny	prohlídka	briefing							exchan			
	crewmember 3	hygiëna	snídaně	FBMI	prohlídka	briefing								exchan			

Obrázek 4.3: Ukázka části harmonogramu mise

Spolu s harmonogramem byly vytvořeny další dva dokumenty. První z nich byl plán směn a druhý byl dokument, do kterého se zaznamenávaly všechny významné události. Plán směn byl vytvořen interně pro každou instituci, jež byla součástí mise. Každá směna sloužila primárně za účelem monitorování a dokumentace mise.

4.1.6.2 Řídicí věž

Řídicí věž hrála v rámci mise DIANA roli stanoviště na Zemi. Komunikovala tedy se základnou (mateřskou lodí) v souvislosti s prováděním výzkumných a vzdělávacích programů. Zároveň zde bylo umístěno monitorovací zařízení posádky, které nepřetržitě sbíralo data a dokumentační a komunikační zařízení.



Obrázek 4.4: Monitorování posádky v řídicí věži během mise DIANA (zdroj: Hydronaut Project a.s.)

4.1.6.3 Povrchová jednotka

Povrchová jednotka byla složena z vedoucího týmu (tři členové stejně jako v podvodním habitatu), který řídil polohu stanice a systémy podpory života. Zároveň se povrchová jednotka starala o regulaci specifických parametrů v závislosti na průběhu mise. Během mise DIANA hrála tato jednotka roli mateřské lodi, jež sloužila jako stanoviště a kritické zázemí pro velitele posádky. Z tohoto místa probíhalo ovládání stanice H03 DeepLab.

4.1.7 Neuropsychofyziologická baterie

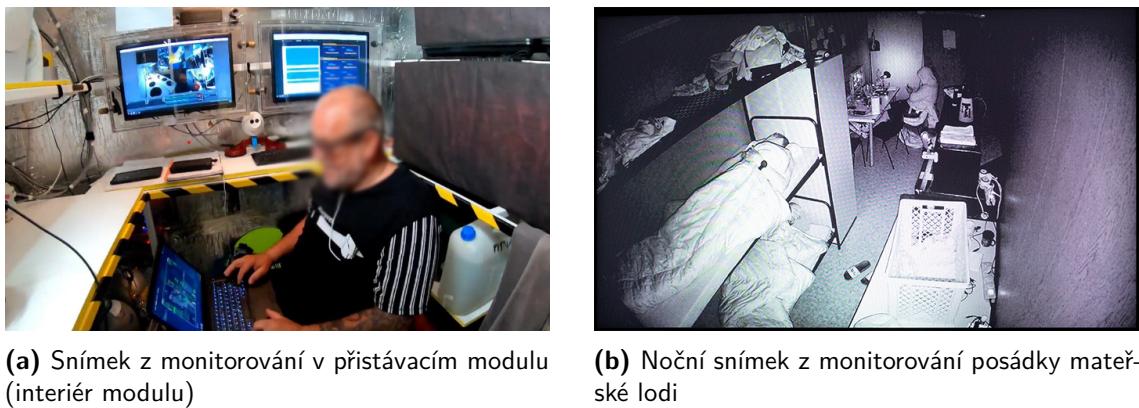
Neuropsychofyziologická stimulace a diagnostika jedinců byla během mise realizována prostřednictvím následujících nástrojů:

1. **Kognitivní úlohy v prostředí NEUROP-III** — posádka opakovaně podstoupila náročné diagnostické kognitivní úlohy, zvláště zaměřené na sledování exekutivních funkcí primárně v oblasti impulzivního chování, riskování, interference nebo inhibice ve smyslu Go-NOGO.
2. **Subjektivní hodnocení pomocí NASA TLX** — jedná se o dlouholetý standard pro měření subjektivního vnímání mentální zátěže vzhledem ke

konkrétním úkolům v pěti dimenzích: mentální náročnost, fyzická náročnost, časová náročnost, výkonnost, snaha a frustrace. Posádka byla tímto hodnocena během celé mise každý den.

4.1.8 Monitorování a měření posádky

Během celého průběhu mise byla posádka neustále monitorována kamerovým systémem a měřena pomocí validovaných biometrických zařízení, které poskytovaly palubnímu počítači následující údaje o stavu posádky: tepová frekvence, dechová frekvence, kožní vodivost. Měření biosignálů je blíže popsáno v další sekci. Zároveň byly pomocí kamerových záznamů detekovány emoce posádky z výrazů tváře. Na Obr. 4.4 lze vidět snímky z monitorování posádky během mise DIANA.



Obrázek 4.5: Snímky z monitorování posádky během mise DIANA (zdroj: Hydronaut Project a.s.)

Data z biometrických jednotek byla pomocí bezdrátové sítě WLAN (Wi-Fi 2,4 Ghz) přenášena na datový server a ukládána do InfluxDB. Ostatní kompartmenty mise, tak mohly živě sledovat fyziologický stav posádky. Díky real-time vizualizaci bylo také možné dohlížet na správností měření biologických signálů. Předcházelo se tak situacím jako: nesprávně nalepené či odlepené elektrody, přítomnost elektromagnetického rušení ovlivňujícího měření nebo výpadky způsobené problémy s bezdrátovým připojením.

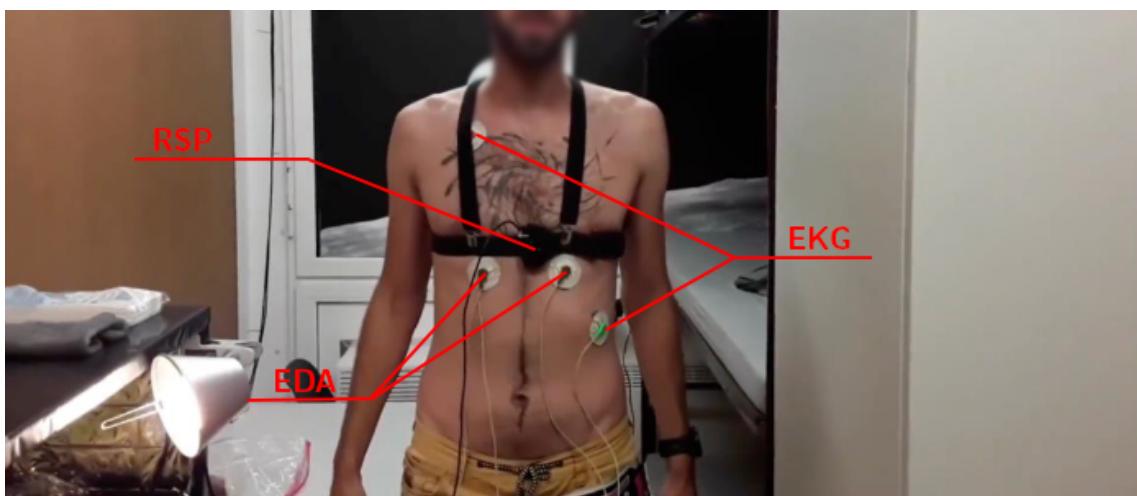
4.1.8.1 InfluxDB

InfluxDB¹⁰ je open-source platforma poskytující databázi pro časové řady. Zahrnuje rozhraní (API) pro standardní databázové dotazy. Součástí je i grafické uživatelské rozhraní (GUI) s modulárními uživatelskými panely pro monitorování dat v reálném čase. Tato platforma (InfluxDB OSS 2.4) byla využita v rámci mise k uchovávání a vizualizaci dat.

¹⁰<https://www.influxdata.com>

4.1.8.2 Měření biosignálů

V minulé sekci byla zmínka o biometrických datech jako například tepová a dechová frekvence. Tyto data byla získána pomocí biometrických jednotek, které však neměří přímo tyto fyziologické indikátory ale biologické signály, konkrétně srdeční, respirační a elektrodermální aktivitu. Tyto biosignály byly měřeny u šesti jedinců, konkrétně u posádky mateřské lodi a přistávacího modulu. V následující sekci je detailněji rozebráno měřící zařízení.



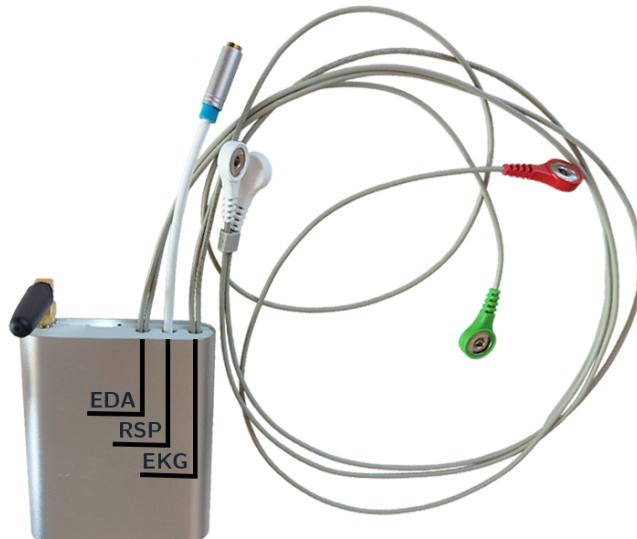
Obrázek 4.6: Ukázka měřících čidel na těle člena posádky uvnitř mateřské lodi

4.1.8.3 Měřící zařízení

Pro měření biosignálu během mise byly použity validované telemedicínské jednotky BoRec (Body Recorder), které již dlouhodobě vyvíjíme ve výzkumné skupině Biomechaniky a asistivních technologií na Fakultě biomedicínského inženýrství (FBMI), ČVUT v Praze. Vzorkovací frekvence zařízení je 250 Hz. Zařízení lze vidět na Obr. 4.7.

Respirační aktivita byla měřena pomocí takzvaného dechového pásu, založeného na tenzometrickém principu. Elektrodermální aktivita byla měřena pomocí dvou elektrod na hrudi. Toto místo bylo pro potřeby mise vybráno na základě studie [146]. Elektrická srdeční aktivita byla měřena využitím jednosvodového systému, přičemž byl svod zaznamenáván v konfiguraci II. Jednotka včetně snímačů biosignálů také obsahuje tlakové a gyroakcelometrické senzory.

Bezdrátové připojení jednotek je zajištěno díky standardu IEEE 802.11 (Wi-Fi 2,4 GHz). Komunikační protokol mezi zařízením a klientem na straně počítače je Modbus TCP [185], který umožňuje přístup k senzorům jednotky a stažení dat z cyklických redundantních vyrovnávacích pamětí. Každá jednotka má svou vlastní jedinečnou MAC adresu a očekává adresu IP od serveru DHCP. Klient na PC má přístup ke všem snímačům místní sítě.



Obrázek 4.7: Telemedicínská jednotka BoRec použita během mise

4.1.9 Studie

Měření dat probíhalo pod Filozofickou fakultou Univerzity Palackého v Olomouci (FF UPOL). Všichni probandi poskytli informované souhlasy pro část diagnostickou i pro samotný experiment (viz Příloha ??). Informované souhlasy umožňují anonymizované využití dat. Získání dat pod FF UPOL probíhalo podle etického metakodexu Evropské federace psychologických asociací (EFPA). Informované souhlasy jsou i ke všem nahrávkám obrazových dat a rozhovorů členů posádky. Bezpečí participantů bylo jištěno v několika technických rovinách prostřednictvím hlavního řešitele *1st Cloud Republic a.s.* projektu TL05000228.

4.2 Použité datasety

Pro účely diplomové práce bylo použito několik veřejně dostupných datasetů včetně dat z mise DIANA. V následujících sekcích jsou stručně rozebrány jednotlivé datasety, přičemž první dva sloužily primárně pro účely hodnocení kognitivní zátěže.

4.2.1 WESAD

Dataset WESAD [186] (*Wearable Stress and Affect Detection*) je multimodální dataset navržený pro výzkum v oblasti hodnocení stresu a emocí za použití nositelných senzorů. Tento dataset byl vytvořen s cílem přispět k vývoji pokročilých algoritmů strojového učení pro analýzu fyziologických signálů a rozpoznání emocí. WESAD obsahuje data získaná od 15 účastníků, přičemž každý z nich prošel sérií experimentů v laboratorních podmínkách.

Data byla v datasetu získána ze dvou nositelných zařízení. Prvním zařízením byl *RespiBAN*¹¹, nositelný senzor umístěný na hrudi se vzorkovací frekvencí 700 Hz, který zaznamenával elektrokardiogram, elektrodermální aktivitu, elektromyogram, respirační signál, a teplotu těla. Druhé zařízení byl chytrý náramek *Empatica E4*¹², který zaznamenává krevní tlak (64 Hz), elektrodermální aktivitu (4 Hz), teplotu těla (4 Hz) a tříosou akceleraci (32 Hz). Experiment, který byl proveden pro sběr dat, zahrnoval celkem čtyři fáze:

1. **Základní úroveň (Baseline condition)** — účastník byl požádán, aby seděl/stál v klidu po dobu 20 minut.
2. **Stresový úkol (Stress condition)** — účastník musel pět minut přednášet před publikem a poté vyřešit matematický úkol, který byl navržen tak, aby vyvolal stres.
3. **Relaxační úkol (Amusement condition)** — účastník sledoval komediální video, které mělo vyvolat příjemné emoce.
4. **Řízená meditace (Meditation)** — účastník prováděl řízenou meditaci, jejíž cílem bylo navození do stavu blízkého neutrálnímu afektivnímu stavu.

WESAD poskytuje časově synchronizovaná, předzpracovaná a anotovaná data z těchto nositelných senzorů. Pro účely diplomové práce byly použity signály ze zařízení *RespiBAN*, konkrétně srdeční, respirační a elektrodermální aktivita. Pro úlohy hodnocení kognitivní zátěže byla základní úroveň označena jako klidový stav a stresové úkoly byly označeny jako stav kognitivní zátěže.

4.2.2 CLAS

Dataset CLAS [187] (*Cognitive Load, Affect, and Stress Recognition*) je podobně jako WESAD multimodální dataset vytvořený pro výzkum v oblasti rozpoznávání kognitivní zátěže a emocí za použití nositelných senzorů a dalších datových zdrojů. Dataset zahrnuje data získaná od 62 účastníků, kteří byli vystaveni různým úkolům a podnětům navrženým tak, aby vyvolaly různé úrovně kognitivní zátěže a emocí. Mezi tyto podněty patřily například matematické úlohy nebo Stroopův test. Každý účastník byl zároveň měřen i v klidu (dataset označuje jako Baseline). Během přechodů mezi jednotlivými úkoly bylo účastníkům puštěno neutrální video nebo byl účastník požádán, aby si vyplnil dotazník (dataset označuje jako Neutral).

Fyziologická data v rámci tohoto datasetu byla měřena zařízením *Shimmer3*¹³ se vzorkovací frekvencí 256 Hz. Mezi měrené biologické signály patří elektrokardiogram,

¹¹Zařízení *RespiBAN* již není vyráběno

¹²<https://www.empatica.com/research/e4>

¹³<https://shimmersensing.com>

elektrodermální aktivita a fotoplethysmogram. Pro úlohy hodnocení kognitivní zátěže byl Baseline stav označen jako klidový stav a stresové úkoly byly označeny jako stav kognitivní zátěže.

4.2.3 Data z vesmírné analogové mise DIANA

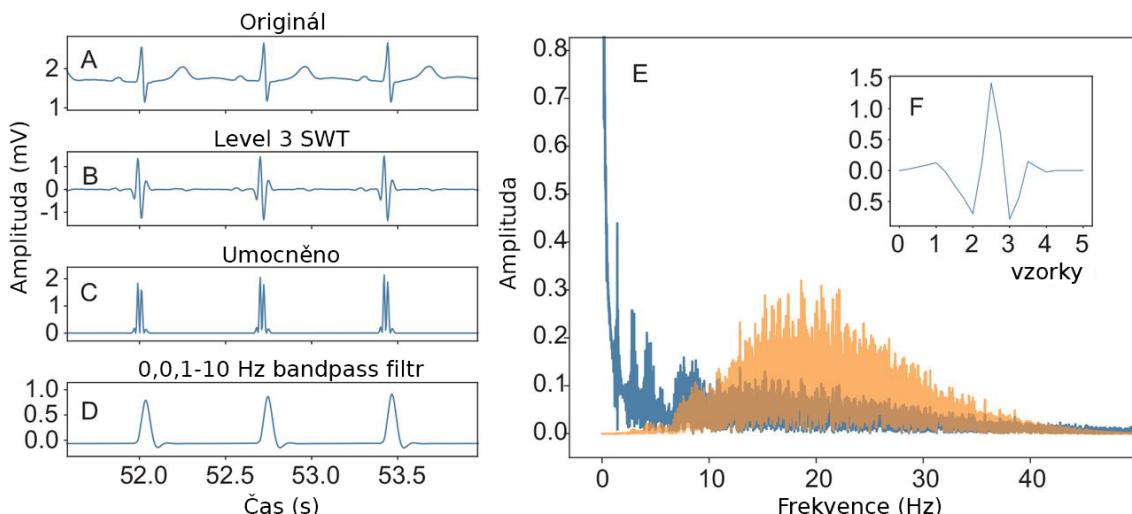
Pro potřeby diplomové práce poskytla FF UPOL data z vesmírné analogové mise DIANA. Součástí dat jsou týdenní 24 hodinové záznamy biologických signálů, kamerových záznamů a anotace v podobě časů kognitivních úloh pro každého člena posádky. Využitými signály v této práci jsou elektrokardiogram spolu s elektrodermální a respirační aktivitou.

4.3 Zpracování biosignálů

Důležitým krokem při analýze biosignálů je jejich zpracování. V této sekci jsou popsány použité algoritmy, které byly implementovány v programovacím jazyce Python, využitím knihovny *Neurokit2* (viz sekce 4.3.3).

4.3.1 Zpracování elektrické srdeční aktivity

Pro zpracování EKG záznamů byla implementována metoda podle Kalidase a Tamila [188], která je založena na stacionární vlnkové transformaci (SWT). Metoda vychází z populárního Pan-Tompkinsova [189] algoritmu ale pro odstranění šumu a zvýraznění QRS komplexů používá SWT namísto pásmové propusti. Stacionární vlnková transformace je metoda rozkladu signálu na jednotlivá frekvenční pásma pomocí mateřské vlnky [190]. Metoda byla zvolena na základě následující sekce 4.3.1.1.



Obrázek 4.8: A-D) Kroky zpracování EKG pro algoritmus podle Kalidase a Tamila [188] **E)** Frekvenční spektrum nefiltrovaného EKG se vzorkovací frekvencí 250 Hz (modrá) a EKG po SWT 3. řádu (oranžová). **F)** vlnka rodiny Daubechies 3. řádu. (Upraveno a převzato z [110])

V tomto algoritmu se stacionární vlnková transformace provádí na EKG signálu využitím Daubechiesové vlnky třetího rádu. Po provedení SWT se extrahují koeficienty, které se následně vyčíslí na čtverec. Následně je využito filtrace pásmovou propustí ke zvýšení citlivosti a přesnosti detekce. Postup detekce R vln na filtrovaném signálu je pak totožná s detekcí Pan-Tompkinsova algoritmu [189]. Jednotlivé částí zpracování lze vidět na Obr. 4.8.

4.3.1.1 Metodika výběru QRS detektoru

Vzhledem k tomu, že neexistuje žádný jednotný standard či systematický postup pro zpracování EKG a výběr „správného“ QRS detektoru pro určitou aplikaci, tak bylo v rámci této práce realizováno statistické porovnání populárních algoritmů. Jakožto měřítko přesnosti QRS detekce algoritmu bylo vycházeno z výpočtu absolutní vzdálenosti od původní „skutečné“ polohy R vlny. Pro benchmarking detektorů byly tedy použity následující anotované datasety:

Tabulka 4.1: Vybrané datasety pro benchmarking QRS detektorů z PhysioNetu [191]

Dataset	Probandi
MIT-BIH Arrhythmia Database [192]	48
MIT-BIH Normal Sinus Rhythm Database [193]	18
Glasgow University Database [194]	25
Fantasia Database [195]	40
Lobachevsky University Electrocardiography Database [196]	200
Simultaneous physiological measurements with five devices at different cognitive and physical loads [197]	13
Pulse Transit Time PPG Dataset [198]	22

Byly vybrány různorodé datasety za účelem zjištění adaptability algoritmu. Pro statistické zpracování bylo využito lineárních smíšených modelů (LMM). Použité statistické metody jsou podrobněji popsány v kapitole 4.7. Pro srovnání metod byl v programovacím jazyce R vytvořen následující statistický model:

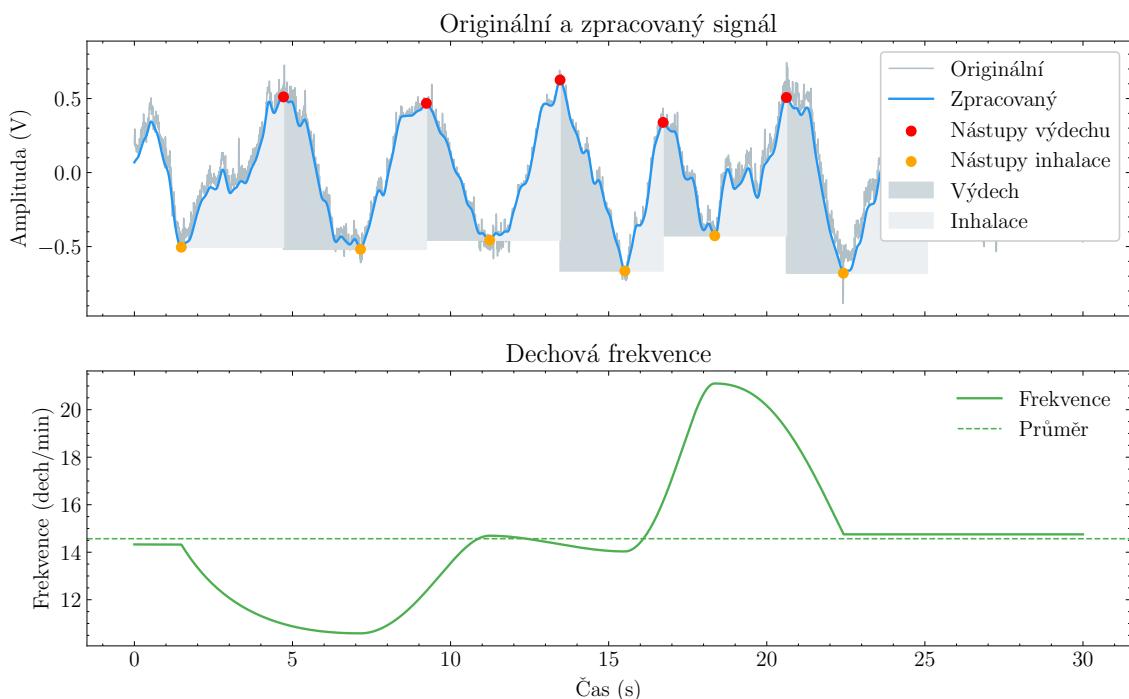
$$\text{Skóre} = \beta_0 + \beta_1 \text{Metoda} + u_{\text{Dataset}} + u_{\text{Participant}} + \epsilon \quad (4.1)$$

který specifikuje lineární smíšený model pomocí funkce `lmer` z balíku `lme4`¹⁴. Model byl použit k predikci závislé proměnné Skóre na fixním efektu *Metoda* a dvou náhodných efektech: *Dataset* a *Participant*. Dále problematice této sekce není věnována pozornost, jelikož není předmětem této práce.

¹⁴<https://github.com/lme4/lme4>

4.3.2 Zpracování respirační aktivity

Pro zpracování respirační aktivity byl implementován algoritmus [159], který je založen na průchodech nulou (ZC, Zero-Crossing). Originální signál je nejdříve filtrován pásmovou propustí pro odstranění stejnosměrné složky, aby bylo možné spolehlivě detekovat ZC. K tomu byla využita pásmová propust 0,05–3 Hz, která zároveň zachovává dechové frekvence menší než tři a vyšší než 180 dechů za minutu. Následně jsou pomocí logických operací detekovány indexy náběžných a sestupných průchodů nulou, mezi kterými došlo k hledání lokálních extrémů.



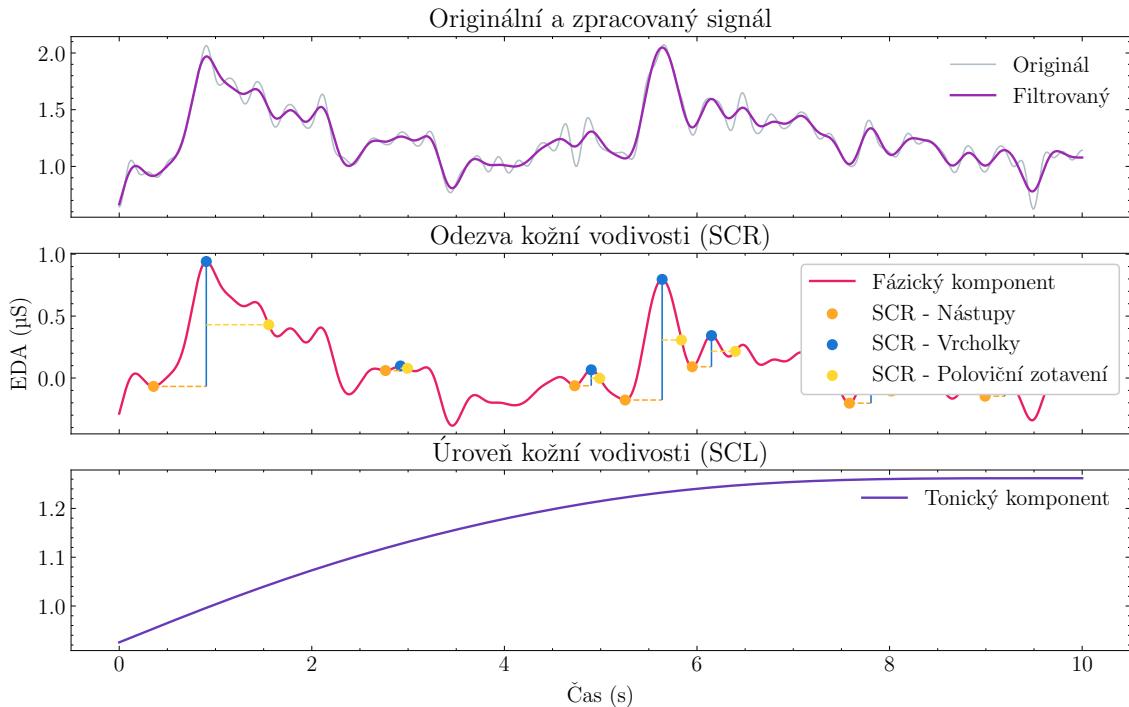
Obrázek 4.9: Příklad zpracování RSP pomocí implementované metody

Zachovány jsou ve výsledku pouze ty extrémy, které mají minimální vertikální vzdálenost od svého přímého souseda, tudíž kritérium pro detekci odlehlých hodnot bylo definováno v absolutním rozdílu amplitud mezi sousedními extrémy. Aplikace metody na reálném signálu lze vidět na Obrázku 4.9.

4.3.3 Zpracování elektrodermální aktivity

Zpracování elektrodermální aktivity vychází z metod [199] a [200]. Signál je nejdříve filtrován Butterworthovou horní propustí 4. řádu s mezní frekvencí 3 Hz. Následně je ze signálu extrahována fázická a tonická složka pomocí dolní a horní propusti o mezních frekvencích 0,05 Hz.

Dále byl použit Savitzky-Golayův frekvenčně neselektivní filtr k dalšímu vyhlazení fázické složky za účelem hledání SCR vrcholků. K detekci vrcholků byla



Obrázek 4.10: Příklad zpracování EDA pomocí implementovaných metod

využita funkce `find_peaks()` z knihovny Scipy¹⁵. Kritérium pro detekci vrcholků bylo definováno jako konzistentní nárůst o 0,5s následovaný stejným poklesem. Výsledek aplikované metody lze vidět na Obrázku 4.10.

Neurokit

Knihovna *Neurokit2*, na jejíž vývoji se podílíme¹⁶, poskytuje pokročilé metody pro zpracování a vizualizaci biosignálu. Jednotlivé metody zároveň nabízejí možnost si vybrat z mnoha implementovaných algoritmů. V této práci byla knihovna použita pro zpracování respirační, elektrodermální a elektrické srdeční aktivity včetně zpracování a výpočet HRV parametrů.

4.4 Zpracování a analýza dat z mise DIANA

V následující sekci je popsána metodika zpracování a analýzy dat z vesmírné analogové mise DIANA. Data z mise byla poskytnuta v podobě komprimovaného záložního souboru obsahující snímek databáze InfluxDB (viz sekce 4.1.8.1). Tento snímek byl použit pro obnovu databáze, která obsahovala veškeré data s časovými značkami. Pro export a práci s daty byla využita Python knihovna *InfluxDB-Python*¹⁷, jež poskytuje rozhraní mezi InfluxDB a programovacím jazykem Python.

¹⁵<https://docs.scipy.org>

¹⁶<https://neuropsychology.github.io/NeuroKit/authors.html>

¹⁷<https://github.com/influxdata/influxdb-python>

4.4.1 Zpracování exportovaných segmentů biosignálů

Pro každého člena posádky byly exportovány segmenty biosignálů o délce 30s s 50% překryvem na základě poznatků v [201–205]. Zpracování biosignálu vycházelo z metodiky popsané v sekci 4.3. U každého segmentu proběhlo hodnocení jeho kvality podle dvou kritérií:

- Hodnocení kvality EKG signálu pomocí heuristické fúze a fuzzy komplexního hodnocení podle [206].
- Hodnocení detekovaných R vln z hlediska časové kontroly náhlých nefyziologických změn v po sobě jdoucích R-R intervalech.

Segmenty které vykazovali nežádoucí anomálie v rámci hodnotících kritérií byly vyřazeny. Ze segmentů bylo dále vypočteno následně přes 100 různých parametrů pro účely analýzy dat. Mezi tyto parametry patřily například běžné statistické charakteristiky (průměr, medián, směrodatná odchylka a další) nebo nelineární a časové HRV parametry. Zpracované segmenty byly zároveň anotovány, a to z hlediska spánkového cyklu. Dále byly identifikovány a označeny v časech kognitivních testů. Z časových důvodu nebyly pro účely této práce ostatní aktivity během mise anotovány, i přes dostupnost kamerových záznamů. Seznam všech počítaných parametrů je součástí přílohy v souboru `all_params.csv`.

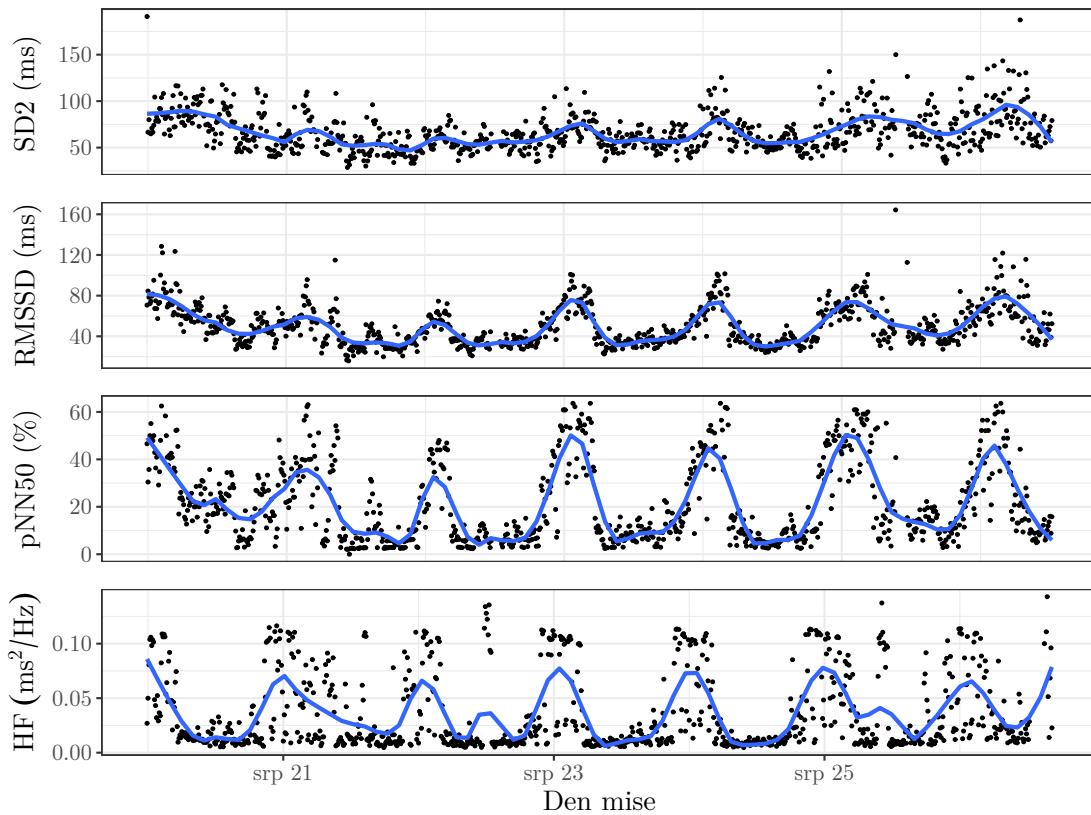
4.4.2 Čistění dat

Ze souborů vypočtených parametrů byly vynechány všechny parametry, jejichž sloupce obsahovali `NaN` hodnoty. Dále byly parametry korelovány a odstranili se ty, které byly vzájemně dokonale korelované ($|r| > 0,999$). Poté se odstranili odlehlé hodnoty na základě absolutní odchylky mediánu od mediánu.

4.4.3 Sledované veličiny

Pro účely analýzy NPF adaptace subjektů v průběhu mise byly na základě [207, 208] vybrány a sledovány především následující HRV parametry:

- **SD2** — Směrodatná odchylka Poincarého grafu podél přímky totožnosti.
- **RMSD** — Odmocnina ze středního kvadratického rozdílu mezi po sobě následujícími N–N intervaly.
- **pNN50** — Procento po sobě následujících N–N intervalů, které se od sebe liší o více než 50 ms.
- **HF** — Vysokofrekvenční složka výkonu variability srdeční frekvence.



Obrázek 4.11: Příklad průběhu sledovaných veličin během týdne. Jedná se o agregované hodnoty mediánem za každých 10 minut. Data jsou proložena využitím loess regrese ($\alpha = 0,01$).

4.4.4 Analýza dat mise

Vzhledem k nereprezentativnosti a nepopsanosti dat byly primárně pro potřeby jejich analýzy namísto statistických testů a dalších nástrojů použity zejména vizuální metody. Pro zobrazení denního vývoje v rámci sledovaných parametrů byly vypočtené parametry agregovány mediánem na úrovni hodin i dnů. Vizualizace byla v tomto případě spojena i s výsledky statistického modelování popsáno v následující sekci. Pro účely vizuální analýzy byly použity i krabicové grafy.

Dále byly identifikovány, exportovány a vizualizovány segmenty biosignálů v časech, kdy subjekt vykonával NPF baterii testů. Segmenty byly vizualizovány také využitím krabicových grafů. Výsledky v rámci vizuálních analýz se nacházejí v sekci 5.2 a dále jsou probírány v samotné diskuzi.

4.4.5 Statistické modelování

Ke zkoumání vztahu mezi vybraným sledovaným parametrem napříč jednotlivými dny v rámci obou skupin, mateřské lodi a přistávacího modulu, byl vytvořen víceúrovňový lineární smíšený model. Nechť Y je vektor odezvy (tj. „vybraný sledovaný parametr“). Po zahrnutí interakce dnů a skupin lze lineární smíšený model zjednodušeně a

vektorově vyjádřit následovně:

$$Y = \beta_0 + \beta_1 d + \beta_2 s + \beta_3 ds + u_0 + u_1 d + \epsilon, \quad \epsilon \sim \mathcal{N}(0, \sigma^2) \quad (4.2)$$

kde β_i jsou vektory koeficientů fixních efektů, ϵ je člen reziduální chyby a d, s označují fixní efekty den a skupinu. Náhodné efekty jsou označeny jako u_0, u_1 . Dále je přítomna zmíněna interakce v podobě zahrnutí interakčního členu $d \cdot s$. To znamená, že kromě samostatného modelování vlivu „dne“ a „skupiny“ model zohledňuje také případnou interakci mezi nimi. Jinými slovy, model počítá s možností, že vliv „dne“ na proměnnou odezvy (závislou proměnnou) se může lišit v závislosti na úrovni „skupiny“. Zároveň díky zvoleným náhodným efektům je dovoleno individuálním rozdílům u každého subjektu na úrovni dnů.

Výsledky modelování jsou uvedeny v sekci 5.2.2 a rozebrány v diskuzi. Modelování bylo realizováno v programovém jazyce R. Vzhledem k tomu, že se lineární smíšené modely řadí mezi statistické metody, tak jsou samostatně popsány v sekci 4.7.

4.5 Explorační analýza a předzpracování datasetů

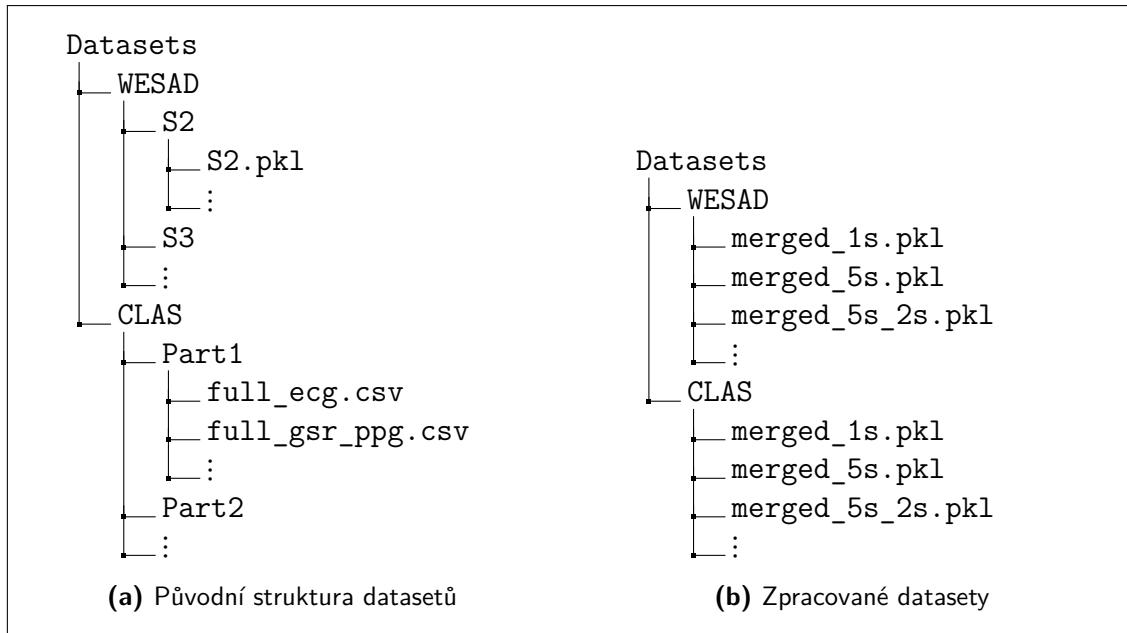
V této sekci je rozebrán proces zpracování a zkoumání souborů dat, konkrétně datasetů CLAS a WESAD, jehož cílem bylo identifikovat vzorce, vztahy a trendy, které nemusí být okamžitě zřejmé. Cílem explorační analýzy bylo získat poznatky a vytvořit hypotézy o datech, které napomáhali při tvorbě paradigmatu hodnocení CL.

4.5.1 Předzpracování datasetů

Z datasetů byly extrahovány potřebné biosignály, které byly následně zpracovány a normalizovány na úrovní subjektů. Metodika zpracování vychází ze sekce 4.3. Normalizace byla provedena škálováním biosignálů tak, aby měly průměrnou hodnotu nula a směrodatnou odchylku jedna. To bylo dosaženo odečtením střední hodnoty biosignálu od každé jeho hodnoty a následným vydělením směrodatnou odchylkou.

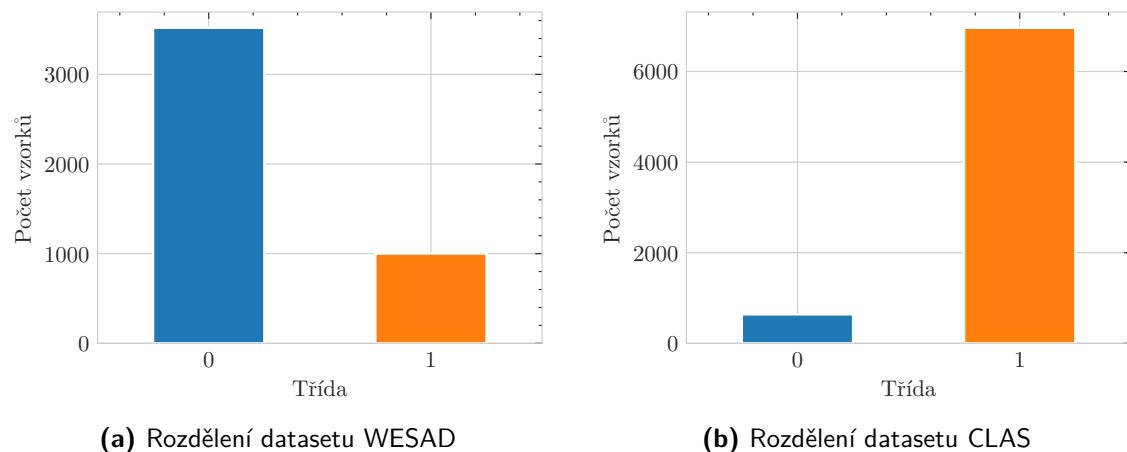
Vzhledem k tomu, že dataset CLAS neobsahuje signál RSP, byl tento signál vytvořen pomocí metody EDR (ECG-Derived Respiration). Jedná se o extrakci informace o dýchání z elektrokardiogramu. Knihovna *Neurokit2* poskytuje implementaci algoritmu podle [209], jež byla pro tyto účely použita.

Následně byly všechny signály segmentovány na 5s, 5s s 50% překryvem a 1s úseky. Z těchto segmentů byly poté vytvořeny příznaky pro účely strojového učení. Blíže je tvorba těchto příznaků a jejich využití popsáno v sekci 4.6. Byly ponechány pouze ty segmenty, které svojí třídou korespondovaly žádanému kognitivnímu stavu.

**Obrázek 4.12:** Porovnání struktury původních a zpracovaných datasetů

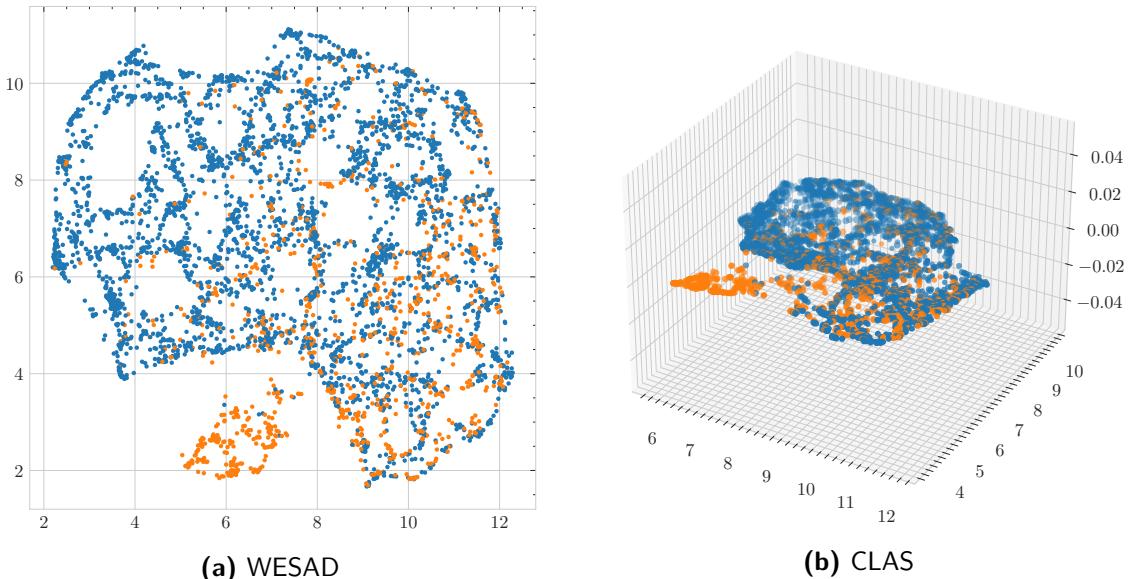
4.5.2 Explorace dat

Oba datasety byly po předzpracování zkoumány pomocí nástrojů knihovny *Pandas* v programovacích jazycce Python. Datasety tak byly popsány například základními statistickými údaji, kde byla brána primárně zřetel na rozdělení tříd. Na Obr. 4.13 lze tak vidět, že oba datasety vykazují výraznou nevyváženosť tříd. Dále byly korelovány jednotlivé signály datasetů, bylo nahlíženo na jejich distribuce, a byly vyšetřeny případné záporné nebo neplatné hodnoty. Tato šetření byla provedena i na individuální úrovni. Celý postup s vizualizovanými výsledky se nachází v datové příloze, v podobě interaktivního prostředí Jupyter Notebook¹⁸ s názvem souboru `exploratory_analysis_example`.

**Obrázek 4.13:** Srovnání rozdělení tříd vybraných datasetů. Třída 0 vyjadřuje klidový stav a třída 1 vyjadřuje kognitivní zátěž.

¹⁸<https://jupyter.org>

Během explorace dat byla také zkoumána separovatelnost dat v nízkodimenziálních prostorech použitím techniky UMAP [210] (Uniform Manifold Approximation and Projection) právě pro redukci dimenzionality. Cílem bylo vizualizovat soubor dat ve formě nižších dimenzí k získání přehledu o rozdělení tříd a nadhled nad smyslem a rozpoložení dat. Výsledky této vizualizace je možné vidět na Obr. 4.14, kde jsou oranžově vyznačeny body, jež odpovídají kognitivní zátěži.



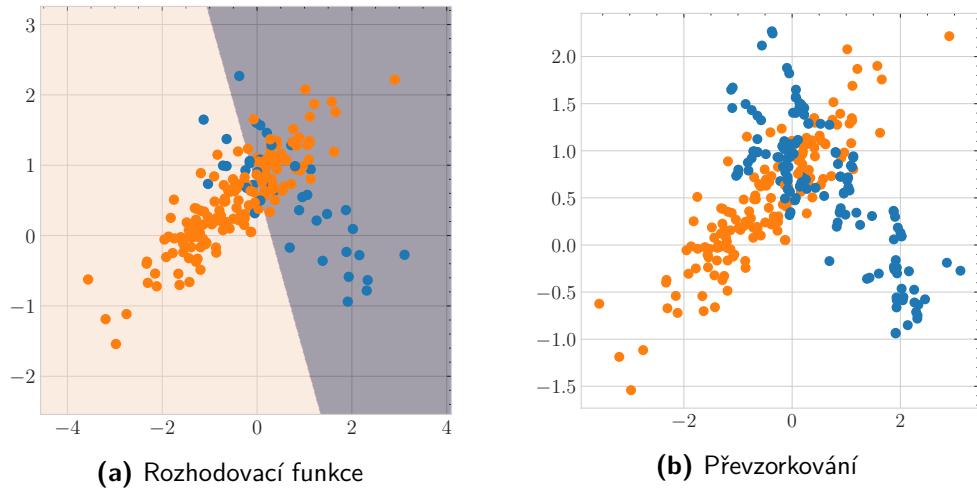
Obrázek 4.14: Vizualizace UMAP projekcí extrahovaných příznaků z datasetu WESAD do 2D (vlevo) a 3D latentního prostoru (vpravo). Oranžově třída 1 a modře třída 0

V metodě bylo využito Euklidovské vzdálenostní metriky s hodnotou 0,1 a počtem sousedních bodů 15. Tyto nízké hodnoty byly zvoleny pro účely zachycení lokální struktury dat (potenciálně na úkor celkového obrazu), jak ukazuje Obr. 4.14. Výsledek 3D projekcí naznačuje potencionální lineární separovatelnost u malé části souboru. U zbytku souboru by bylo oddělení pravděpodobně zřetelnější ve vyšších dimenzích a možná nebude lineární. V úvahu tak přichází strojové učení.

4.5.3 Augmentace dat využitím SMOTE-Tomek

Vzhledem k nevyváženosti tříd byla zvolena augmentace dat pomocí techniky SMOTE-Tomek [211]. Jedná se o hybridní metodu vzorkování, která kombinuje SMOTE [212] (Synthetic Minority Oversampling Technique) a algoritmus *Tomek Links*.

SMOTE je běžně používaná technika pro generování syntetických vzorků minoritní třídy vytvářením nových instancí, které jsou podobné existujícím instancím minoritní třídy. Metoda funguje tak, že vybere instanci minoritní třídy a najde k jejích nejbližších sousedů v prostoru příznaků. Poté generuje nové syntetické instance interpolací mezi vybranou instancí a jejími k sousedy.



Obrázek 4.15: Ukázka převzorkování metodou SMOTE-Tomek

Metoda SMOTE-Tomek kombinuje algoritmy SMOTE a Tomek Links. Nejprve dojde k nadzorkování menšinové třídy pomocí SMOTE a poté k podvzorkování většinové třídy odstraněním takzvaných „Tomek Links“. Nechť $\|x_i - x_j\|$ označuje euklidovskou vzdálenost mezi x_i a x_j , kde x_i označuje vzorek, který patří do menšinové třídy, a x_j označuje vzorek, který patří do většinové třídy. Pokud žádný vzorek x_k nesplňuje následující podmínu:

$$\|x_i - x_k\| < \|x_i - x_j\| \vee \|x_j - x_k\| < \|x_i - x_j\| \quad (4.3)$$

pak dvojice (x_i, x_j) je „Tomek Link“. Metoda byla implementována v programovacím jazyce Python využitím knihovny *imbalanced-learn*¹⁹. Výsledné augmentované soubory dat se poté použily k tréninku klasifikačních modelů.

4.6 Hodnocení CL využitím vícerozměrných časoprostorových kauzálních vzorů

V této podkapitole je popsán postup realizace multimodálního přístupu pro hodnocení kognitivní zátěže pomocí periferních biosignálů (EKG, RSP, EDA), které bylo vytvořeného v rámci této diplomové práce.

4.6.1 Formulace problému

V předešlé sekci byl popsán proces předzpracování dat, jehož výsledkem je nová multidimensionální množina segmentovaných fyziologických signálů \mathcal{F} . Dimenze této množiny je rovna počtu snímaných signálů, lze tedy dál hovořit jako o kanálech

¹⁹<https://imbalanced-learn.org>

c. Vybraný segment z kanálu c reprezentuje časovou řadu, jejíž každý vzorek je zachycen v určitém čase t , a představuje průběh fyziologické události (NPF událost).

V rámci jednotlivých pozorovaných fyziologických událostí X^i , lze modelovat časově kauzální vztahy, které lze díky Grangerově kauzalitě (viz sekce 4.7.2) matematicky popsat unikátním orientovaným grafem $G = (V, E)$ – definovanou uspořádanou množinou vrcholů a hran. Tím je umožněno temporální kódování specifického příčinného kognitivního stavu pro konkrétní segment vybraného kanálu c . Nelze však předpokládat, že je tak zachycena veškerá komplexní dynamika, která je ve biosignálech přítomna, včetně toho, že nemusí být plně zachyceny interakce napříč kanály c .

Tento problém je kompenzován použitím vícerozměrných časoprostorových vzorů (GAF, Gramian Angular Fields) odvozených z Gramových matic. Tyto vzory zachycují určitý druh temporální i prostorové korelace v rámci fyziologických událostí. V následujících sekcích je dále popsána tvorba zmíněných příznaků společně s jejich aplikací v rámci strojového učení.

4.6.2 Tvorba kauzálních vícerozměrných matic

Pro zachycení časově kauzálních relací v použitých biosignálech byl zvolen přístup Kopula-Granger s Lasso (ℓ_1) regularizací, který kombinuje koncept Grangerovy kauzality s teorií kopulí. Zmíněné přístupy spadají do oblasti statistických metod, a proto jsou dále jednotlivé popsány v sekci 4.7.

Vytvoření kauzální matice je založeno na použití fyziologické události X^i definované v minulé sekci, ze které lze uplatněním Kopula-Granger metody získat robustní odhad koeficientů vektorů β_i pro test Grangerovy kauzality využitím regresní úlohy. K tomu je ale potřeba vyřešit následující optimalizační problém [213, 214]:

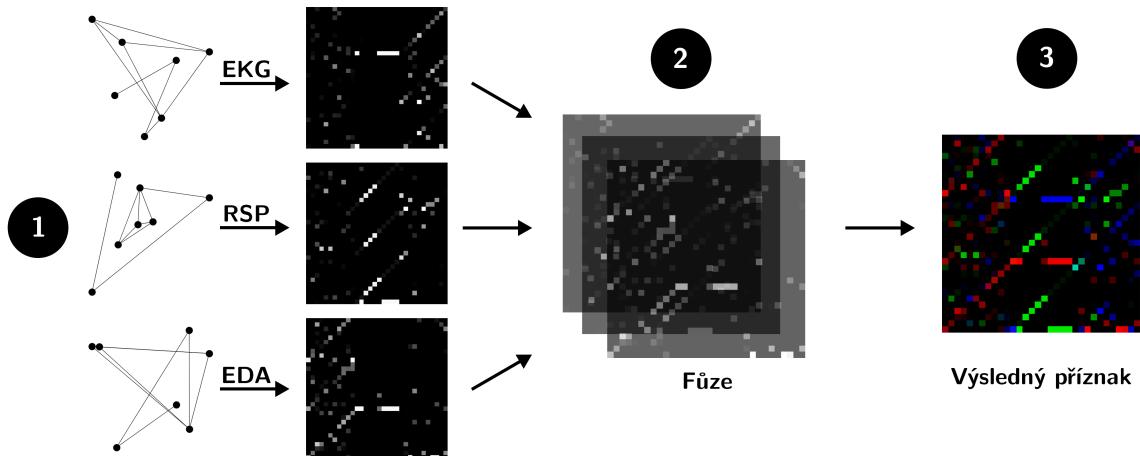
$$\min_{\beta_i} \sum_{t=L+1}^T \left| X_t^i - \sum_{j=1}^p (X_{t,\text{lag}}^j) \cdot (\beta_i^j)' \right|^2 + \lambda \|\beta_i\|_1, \quad (4.4)$$

kde λ je penalizační parametr ovlivňující řídkost vektoru β_i , L je maximální časové zpoždění (lag) a $X_{t,\text{lag}}^j$ jsou předchozí hodnoty řady X^j v čase $[t-L, t-1]$. Podle definice Kopula-Granger modelu [213, 214] lze dále uplatnit faktorizaci na základě modelu vektorové autoregresce (VAR) s koeficienty $B = \beta_i^j$ následovně:

$$p_Z(z) = \mathcal{N}(z(1, \dots, L)) \times \prod_{j=1}^n \prod_{t=L+1}^T p_{\mathcal{N}} \left(z_j(t); \sum_{t=1}^n \beta_{i,j}^T z_i^{t,\text{lag}}, \sigma_j \right) \quad (4.5)$$

kde $p_{\mathcal{N}}(z; \mu, \sigma)$ je Gaussova funkce se střední hodnotou μ a rozptylem σ^2 , $z_i^{t,\text{lag}}$ jsou předchozí hodnoty z_i do času t a β_i^j je vektor koeficientů modelujících vliv časové řady z_j na cílovou časovou řadu. Kauzalita je tedy definována časovou řadou z_j ,

jež je příčinou z_i pokud je alespoň jedna hodnota vektoru β_i^j nenulová ve smyslu statistické významnosti (viz 4.7.2).



Obrázek 4.16: Diagram tvorby kauzálních vícerozměrných matic. 1) Aplikace Kopula-Granger metody pro vybraný segment všech kanálů c. 2) Kombinace výsledných kauzálních matic do jednoho trojrozměrného pole. 3) Výsledný příznak ve smyslu RGB obrázku

Kopula-Granger metodu lze primárně shrnout do dvou kroků: odhadnutí marginální distribuční funkce vybrané časové řady X^i jako \hat{F}_i a mapování pozorovaných hodnot fyziologické události v čase t do kopula prostoru jako $Z_i^t = \Phi^{-1}(\hat{F}_i(X_t^i))$, kde Φ je kumulativní distribuční funkce (CDF) Gaussova rozdělení. V neposlední řadě lze konstruovat temporální kauzální graf analýzou relací mezi Z_i^t . Pro účely tvorby grafického řešení v podobě kauzální matice $T \times T$ obsahující odhadky koeficientů $\hat{\beta}_i$ byla adaptována regularizovaná regrese podle [215]. Nechť vybraná fyziologická událost $X^i = \{x_t^i : t = 0, \dots, T\}$, poté lze získat koeficienty následovně:

$$\hat{\beta}_i(\lambda) = \arg \min_{\beta_i} \left(\sum_{t=1}^T \|x_i^t - X_{t,L}^{lag} \beta_i\|^2 + \lambda \|\beta_i\|_1 \right) \quad (4.6)$$

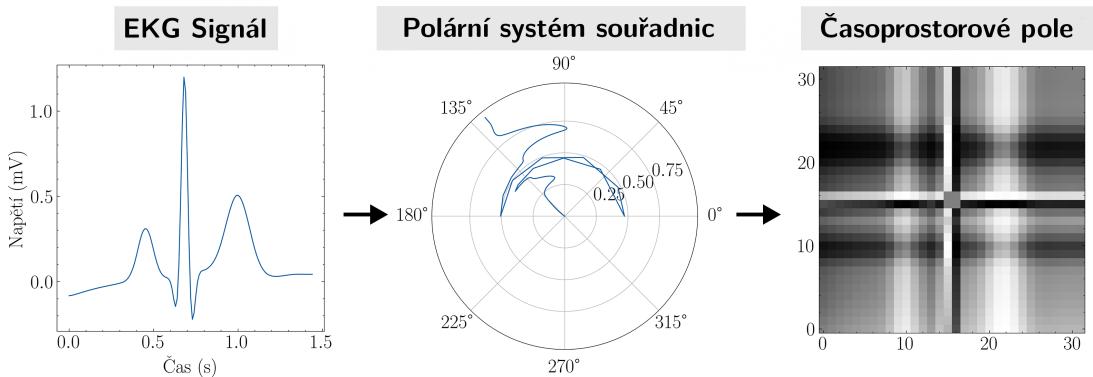
kde $X_{t,L}^{lag}$ reprezentuje spojený vektor všech zpožděných pozorování s maximálním zpožděním L až do času t . Tvorba kauzálních matic byla realizována v programovém prostředí Matlab s využitím knihovny *GLMNET*²⁰, která umožňuje specifikovat různé typy regresních modelů. Hodnota časového zpoždění byla určena na základě Akaikeho informačního kritéria (AIC) jako $L = 4$. Během každého výpočtu bylo pomocí zmíněné knihovny realizováno i automatické ladění hodnot penalizačního parametru $\lambda \in m_i$, kde $m_i = 10^{a+(i-1)d}$ pro $i = 1, 2, \dots, 6$ a $d = \frac{b-a}{n-1}$. Hodnoty a a b byly nastaveny na -3 a 2.

²⁰https://hastie.su.domains/glmnet_matlab

4.6.3 Konstrukce časoprostorových polí

Bylo realizováno mapování segmentů všech kanálů c do prostorové domény (GAF), jež zachovává časové závislosti. Wang and Oates [216] představili koncept této metody transformace časové řady do 2D obrazu v roce 2015. Vzhledem k dříve definované fyziologické události, tedy vybrané časové řadě $X^i = \{x_1^i, x_2^i, \dots, x_t^i\}$ z kanálu c zahrnuje konstrukce GAF nejdříve normalizaci na interval $[-1; 1]$:

$$\tilde{x}_t = \frac{(x_t - \max(X^i)) + (x_t - \min(X^i))}{\max(X^i) - \min(X^i)} \quad (4.7)$$



Obrázek 4.17: Ukázka GAF mapování na EKG segmentu

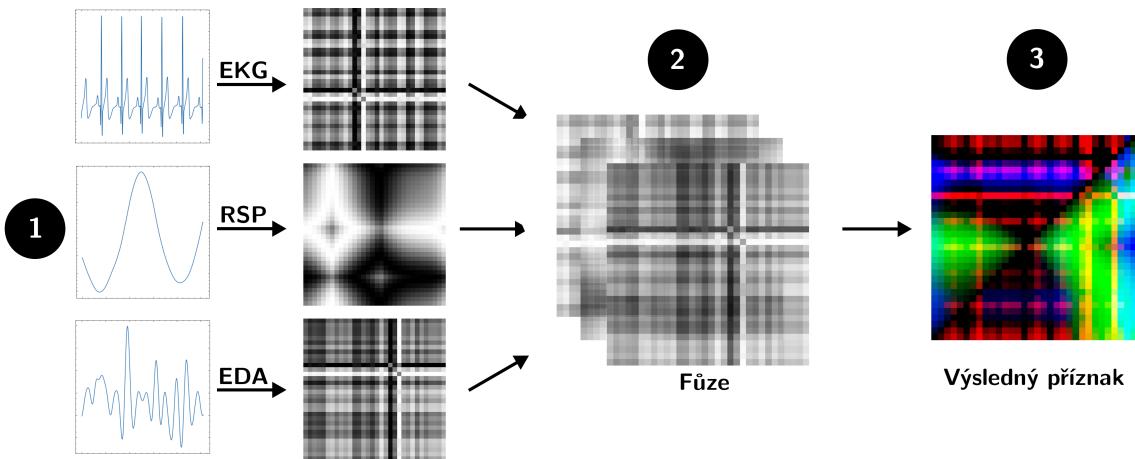
Dále jsou normalizovaná data časové řady převedeny do polárních souřadnic výpočtem úhlové složky θ_i a radiální složky r_i pro každý vzorek \tilde{x}_t :

$$\begin{cases} \theta_i = \arccos(\tilde{x}_t), & -1 \leq \tilde{x}_t \leq 1, \tilde{x}_t \in \tilde{X}^i \\ r_i = \frac{t}{N}, & t \in N \end{cases} \quad (4.8)$$

kde t je časová značka vzorku fyziologické události a N je konstantní faktor pro regulaci rozpětí polárního souřadného systému. Jinými slovy, časová značka představuje poloměr a arkus kosinus hodnoty časové řady úhel. Lze zde hovořit o bijektivní transformaci, jež zachovává časovou závislost pomocí souřadnice r .

Po transformaci přeškálované časové řady do polárního souřadnicového systému lze využít úhlovou perspektivu, v tomto případě s ohledem na trigonometrický rozdíl mezi jednotlivými body (GADF, Gramian angular field difference), k identifikaci temporální korelace v rámci různých časových intervalů:

$$GADF = [\sin(\phi_i - \phi_j)] \quad (4.9)$$



Obrázek 4.18: Diagram tvorby časoprostorových vzorů. 1) Aplikace GAF mapování pro vybraný segment všech kanálů c. 2) Kombinace výsledných polí do jednoho trojrozměrného pole. 3) Výsledný příznak kódující temporální korelace fyziologické události v prostorové doméně

Ve výsledku je tedy časoprostorový vzor definován následující $T \times T$ maticí, která je kvazi-Gramovou maticí:

$$GADF = \begin{bmatrix} \sin(\phi_1 - \phi_1) & \sin(\phi_1 - \phi_2) & \cdots & \sin(\phi_1 - \phi_n) \\ \sin(\phi_2 - \phi_1) & \sin(\phi_2 - \phi_2) & \cdots & \sin(\phi_2 - \phi_n) \\ \vdots & \vdots & \ddots & \vdots \\ \sin(\phi_n - \phi_1) & \sin(\phi_n - \phi_2) & \cdots & \sin(\phi_n - \phi_n) \end{bmatrix} \quad (4.10)$$

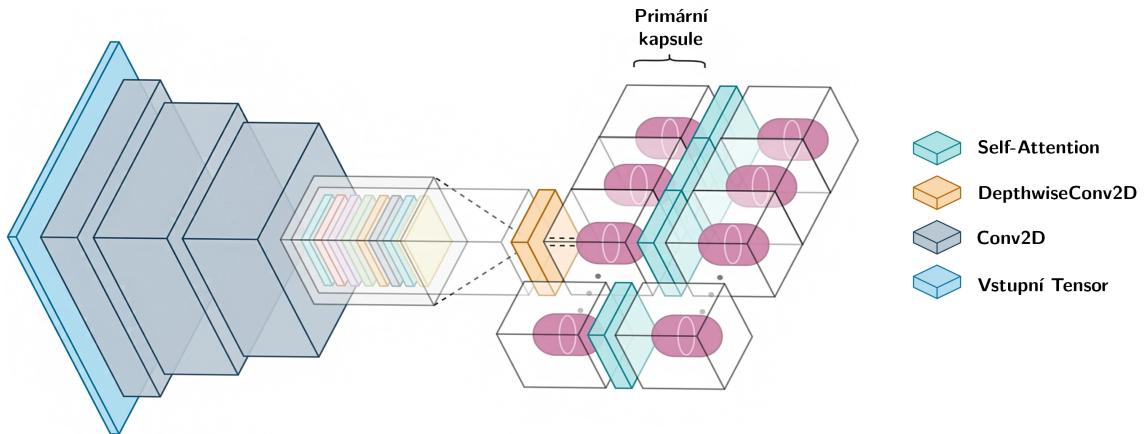
kde každý prvek odpovídá sinové funkci úhlového sinusového rozdílu v různých časových bodech. Výpočet a tvorba těchto příznaků, časoprostorových vzorů, byla implementována v programovacím jazyce Python.

4.6.4 Kapsulární neuronová síť

Pro potřeby realizace úloh klasifikace (resp. hodnocení kognitivní zátěže), byla navržena architektura kapsulární neuronové sítě postavená na řešení, které představili Mazzia et al. [217], *Efficient-CapsNet*. Celkovou architekturu lze vidět na obrázku 4.19.

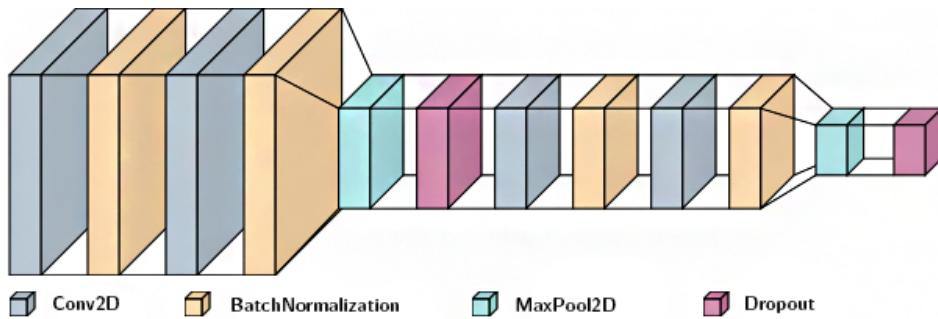
Zjednodušeně, v případě použití jednoho příznaku, je vstupem modelu obraz, který lze reprezentovat jako tenzor X s tvarem $H \times W \times C$, kde H , W a C jsou výška, šířka a kanály. V našem případě se jedná o synergické spojení dvou sad příznaků vyplývajících z minulých sekcí, kauzálních matic $X_{COG} \in \mathbb{R}^{T \times T \times C}$ a časoprostorových vzorů $X_{GAF} \in \mathbb{R}^{T \times T \times C}$. Vstupním tenzorem je tedy příznak $X \in \mathbb{R}^{2 \times T \times T \times C}$. Než se vstup dostane k primární kapsulové vrstvě, tak je provedena extrakce lokálních vlastností ze vstupu X pomocí sady několika typů vrstev²¹:

²¹Jednotlivé vrstvy jsou pojmenovány podle korespondujícího názvu v *TensorFlow* a *Keras API*



Obrázek 4.19: Schematické znázornění architektury sítě *Efficient-CapsNet* (Upraveno a převzato z [218])

- **Conv2D** — Tato vrstva vytváří konvoluční jádro, které je konvolvováno se vstupem vrstvy a vytváří tenzor výstupů. V podstatě se jedná o sadu naučitelných filtrů. Každý filtr transformuje část obrazu (definovanou velikostí jádra) pomocí filtru jádra. Matice jádrového filtru se aplikuje na celý obraz. Filtry lze chápat jako transformaci obrazu.
- **BatchNormalization** — Tato vrstva aplikuje normalizaci, která udržuje průměrný výstup blízko nule a směrodatnou odchylku výstupu blízko jedné.
- **MaxPool2D** — Tato vrstva funguje jednoduše jako filtr pro podvzorkování. Podívá se na 2 sousední pixely a vybere maximální hodnotu. Slouží ke snížení výpočetní náročnosti a do jisté míry také ke snížení přeúčení.
- **Dropout** — Dropout je regularizační metoda, při níž je část uzlů ve vrstvě náhodně ignorována (nastaveny na nulu) pro každý tréninkový vzorek. Tím se náhodně vynechá část sítě a síť je nucena učit se funkce distribuovaným způsobem. Tato technika také zlepšuje generalizaci a snižuje přeúčení.



Obrázek 4.20: První část sítě (H_{Conv}), která mapuje vstupní obraz na prostor vyšší dimenze

Každý výstup konvoluční vrstvy l se tedy skládá z konvoluční operace s určitou rozměrovou velikostí kernelů k a počtem příznakových map f . U konvolučních vrstev byla použita aktivační funkce ReLU k přidání nelinearity do sítě:

$$F^{l+1}(X^l) = \text{ReLU}(\text{Conv}_{k \times k}(X^l)) \quad (4.11)$$

Celkově si lze první část sítě představit jako jednu funkci H_{Conv} , která mapuje vstupní obraz do prostoru s vyšší dimenzí, což usnadňuje tvorbu kapslí²². Tuto první část sítě lze vidět na Obr. 4.20. Následně je pak využito hloubkově oddělitelné konvoluce, ze které je získána vrstva primárních kapslí $S_{n,d}^l$ kde n^l a d^l jsou počty primárních kapslí a jejich jednotlivé rozměry l -té vrstvy. Základním prvkem sítě tedy již není jeden neuron, ale vektorová výstupní kapsle, která by měla zachovávat svojí orientaci a délku. To je realizováno pomocí „squash“ aktivační funkce:

$$\text{squash}(s_n^l) = \left(1 - \frac{1}{e^{\|s_n^l\|}}\right) \frac{s_n^l}{\|s_n^l\|} \quad (4.12)$$

kde s_n^l označuje právě jednu kapsli. Detailně koncept kapsulární sítě popsal Hinton [219]. Kapsulární neuronová síť byla implementována v programovacím jazyce Python využitím knihoven *TensorFlow*²³ a *Keras*²⁴. Počet filtrů konvolučních vrstev byl zvolen 32, 64, 64 a 128 v pořadí, tak jak jdou za sebou ve schématu 4.20. Velikosti kernelů byly zvoleny 5, 3, 3 a 3. MaxPool2D vrstvy byly přidány k zajištění kombinace lokálních rysů příznaků a učení se tak jeho globálnějším rysům.

4.6.5 Self-attention směrování

Kapsulární síť byla také v této práci zvolena, vzhledem k její architektuře napodobující lidskou biologii, a tím pádem schopností lépe modelovat komplexní vztahy v datech. To vyplývá z použitého nového přístupu neiterativního paralelního směrování kapslí, které bylo představeno a popsáno v [217].

4.6.6 Marginální ztrátová funkce

V případě této práce se jedná o binární klasifikační problém, pro který by se za normálních okolností použila ztrátová funkce ve smyslu binární nebo kategorické křížové entropie. Tyto ztrátové funkce ale nezachycují sémantiku vektorů, jak je používána v kapslích. Pro tyto potřeby byla využita marginální ztrátová funkce, kde v případě klasifikace více tříd, je pro každou třídu reprezentovanou kapslí n^L

²²„Kapsle“ označuje skupinu neuronů, která společně představuje instanci parametru specifické entity nebo části obrazu

²³<https://www.tensorflow.org>

²⁴<https://keras.io>

v poslední vrstvě L vypočtena pravděpodobnost existence určité třídy následovně:

$$\mathcal{L}_{n^L} = T_{n^L} \max(0, m^+ - \|u_n^L\|)^2 + \lambda (1 - T_{n^L}) \max(0, \|u_n^L\| - m^-)^2 \quad (4.13)$$

kde T_{n^L} je rovno jedné, pokud je přítomna třída n^L , a m^+ , m^- a λ jsou laditelné hyperparametry. Nakonec jsou sečteny jednotlivé ztrátové funkce \mathcal{L}_{n^L} pro získání konečného „skóre“ ve fázi trénování.

4.6.7 Trénování a evaluace modelů

Trénování a evaluace modelů bylo realizováno využitím programovacího jazyka Python znovu ve spojení s interaktivním prostředím Jupyter Notebook. Pro tvorbu modelů byly využity dříve zmíněné knihovny *TensorFlow* a *Keras*. Trénování bylo akcelerováno pomocí grafické karty NVIDIA GeForce RTX 4080 s využitím *CUDA Toolkitu*²⁵ společně s *CuDNN*²⁶ (NVIDIA CUDA® Deep Neural Network library) knihovnou. Pro účely trénování byly datasety rozděleny vždy v poměru 8:2 na trénovací a testovací množinu, přičemž validace probíhala během trénování využitím testovací množiny (resp. validační). Všechny uvedené přesnosti ve výsledcích jsou tím pádem validační přesnosti, nikoli trénovací. Pro trénování byl využit optimalizační algoritmus Adam s učící rychlostí 5×10^{-4} . Trénování probíhalo po dobu 100 epoch a batch size byl nastaven na 256. Pro zajištění rychlé konvergence optimalizátoru a co nejblíže globálnímu minimu ztrátové funkce, byla použita metoda žíhání (annealing) rychlosti učení (LR, learning rate). Aby byla zachována výhoda rychlého času výpočtu s vysokým LR, byla dynamicky snižována LR každých x kroků (epoch) v závislosti na tom, zda je to nutné (když se nezlepšuje přesnost). Bylo také realizováno kombinační srovnání příznaků ve smyslu použitých biosignálů. Veškeré výsledky jsou uvedeny v sekci 5.3. Bylo realizováno i srovnání se současným stavem. K evaluaci modelů byly využity hodnotící metriky, které jsou popsány v sekci 4.7.5.

4.7 Statistické metody

V této sekci jsou stručně popsány statistické metody použité pro účely této práce. Zvolení a vhodnost konkrétních metod pro účely hodnocení kognitivní zátěže je rozebráno v samotné diskuzi.

4.7.1 Lineární smíšené modely

Pro hodnocení dat z mise DIANA bylo využito LMM. Tyto modely představují flexibilní statistický nástroj pro analýzu dat s korelovanými nebo vnořenými

²⁵<https://developer.nvidia.com/cuda-toolkit-archive>

²⁶<https://developer.nvidia.com/cudnn>

strukturami. Jedná se o rozšíření lineárních regresních modelů, které umožňují zahrnutí jak fixních, tak náhodných efektů.

Základní myšlenkou za LMM je modelování vztahu mezi závislou proměnnou Y a jedním nebo více nezávislými proměnnými X , zatímco bere v úvahu skutečnost, že data mohou mít hierarchickou strukturu, s pozorováními vnořenými v různých skupinách. To se provádí specifikací lineární rovnice, která zahrnuje jak fixní, tak náhodné efekty (resp. vektory těchto veličin):

$$Y = \beta_0 + \sum \beta_i X_i + u + \epsilon \quad (4.14)$$

kde β_0 je intercept, β je vektor koeficientů pro fixní efekty, u je vektor náhodných efektů a ϵ je chybový člen. Předpokládá se, že náhodný efekt u se řídí normálním rozdelením se střední hodnotou nula a rozptylem σ_u^2 a že je nezávislý na chybovém členu ϵ , který se rovněž řídí normálním rozdelením se střední hodnotou nula a rozptylem σ_ϵ^2 .

V případě například pozorování závislé proměnné Y_{ij} pro i -té pozorování v j -té skupině bude náhodný efekt u představovat variabilitu mezi skupinami a je do modelu zahrnut proto, aby zohlednil skutečnost, že pozorování v rámci jedné skupiny si budou pravděpodobně podobnější než pozorování v jiných skupinách. Problematika LMM je každopádně velmi obsáhla a překračuje rozsahem tuto práci. Rozebrána byla podrobně už v literatuře [220].

4.7.2 Grangerova kauzalita

Grangerova kauzalita byla v této práci použita, k hodnocení příčinných vztahů v rámci fyziologických signálů a k zachycení jejich interakcí v závislosti na čase. Grangerovo pojetí vychází z myšlenky, že příčina by měla být nápomocná při předpovídání budoucích vlivů, a to nad rámec toho, co lze předpovědět pouze na základě jejich vlastních minulých hodnot [221].

Formálně, časová řada X je nazvana „Grangerovou kauzalitou“ jiné časové řady Y , jestliže regrese pro Y z hlediska minulých hodnot Y a X je statisticky významně přesnější než regrese pouze minulých hodnot Y . Nechť $\{x_t\}_{t=1}^T$ jsou zpožděné vzorky řady X a $\{y_t\}_{t=1}^T$ řady Y (dále jen jako vektory \vec{x}_t a \vec{y}_t). Poté je prvním krokem Grangerova testu následující regrese [222]:

$$\begin{aligned} y_t &\approx A \cdot y_{t-1} + B \cdot \vec{x}_{t-1} \\ y_t &\approx A \cdot y_{t-1} \end{aligned} \quad (4.15)$$

po které je možné aplikovat různé statistické testy pro získání p-hodnoty a následně je možné rozhodnout o výše zmíněné statistické významné přesnosti.

Běžně se Grangerova kauzalita aplikuje v rámci modelování časových řad ve smyslu kombinatorického testování všech příznaků za účely konstrukce výstupního příznakového kauzálního grafu (resp. kauzální matice, viz sekce 4.6). Takové řešení by ale pro poměrně velký počet fyziologických příznaků bylo extrémně výpočetně náročné, a proto bylo dále uznáno za nevhodné.

Řešením se zde naskytla regrese, kterou lze využít pro identifikaci podmnožiny příznaků, na které je daný příznak podmíněně závislý. To vychází z faktu, že nejlepší regresor pro danou proměnnou s nejmenší kvadratickou chybou bude mít teoreticky nenulové koeficienty pouze pro proměnné v okolí²⁷ [213, 222]. Pro tento regresní problém byl zvolen Lasso algoritmus, jež je uveden do souvislosti v následující sekci.

4.7.3 Lasso regrese

Lasso (Least Absolute Shrinkage and Selection Operator) je široce používaná technika lineární regrese pro výběr a regularizaci proměnných využitím ℓ_1 penalizačního člena. Formálně, výstup \vec{w} minimalizuje součet průměrné kvadratické chyby regrese pro y :

$$\vec{w} = \arg \min \frac{1}{n} \sum_{(\vec{x}, y) \in X} |\vec{w} \cdot \vec{x} - y|^2 + \lambda \|\vec{w}\|_1 \quad (4.16)$$

kde X je vstupní příznak, n je počet vzorků v X a λ je penalizační člen určující míru regularizace koeficientů. S rostoucí hodnotou λ se více koeficientů smrští směrem k nule, což vede k řídkému modelu s menším počtem prediktorů a naopak [223]. Ve smyslu tvorby kauzálních matic poskytuje Lasso množinu časových proměnných, které při regresi y_t podle zpožděných proměnných $x_{t'}$, kde $t' = \{t-T, \dots, t-1\}$ pro všechna $x \in X$, nabývají právě nenulového koeficientu Grangerovy kauzality.

Nicméně Bahadori a Liu dokázali v [224], že Grangerova kauzalita je v rámci použití vícerozměrných dat inkonzistentní a není dobře schopna zachytit nelineární vztahy nebo složité struktury závislostí. Vzhledem k tomu, že data využívané v této práci jsou vícerozměrná a reprezentují biosignály, v rámci kterých mohou existovat právě nelineární vztahy nebo komplexní hierarchické relace, byl využit přístup Kopula-Granger. S využitím Lasso ukázali v [224] jeho konzistence na vícerozměrných datech i jeho schopnost efektivně zachytit nelinearitu v datech (viz sekce 4.6.2).

4.7.4 Teorie kopulí

Vzhledem k využití Kopula-Granger přístupu pro tvorbu vícerozměrných kauzálních matic je žádoucí stručně představit kopula funkce. V teorii pravděpodobnosti a statistice je kopule C vícerozměrnou kumulativní distribuční funkcí, jež popisuje závislost mezi jednotlivými marginálními distribucemi a poskytuje způsob jak

²⁷Statisticky „okolí“ proměnné implikuje podmnožinu proměnných, které s ní úzce souvisejí.

modelovat právě společnou distribuci náhodných veličin bez specifikace samotných distribucí těchto veličin. Formálně, je $C : [0, 1]^d \rightarrow [0, 1]$ d -dimenzionální kopulou, pokud je C sdílenou CDF d -dimenzionálního náhodného vektoru na jednotkové krychli $[0, 1]^d$ s rovnoměrnými marginály. Základem teorie kopulí je Sklarův teorém, který říká, že jakákoli více-dimenzionální distribuce může být zapsána jako kopule aplikovaná na její marginální distribuce:

Teorém 4.1 (Sklarův teorém) *Nechť F je vícerozměrná distribuční funkce s marginálními distribucemi F_1, F_2, \dots, F_n . Pak existuje kopule C taková, že:*

$$F(x_1, x_2, \dots, x_n) = C(F_1(x_1), F_2(x_2), \dots, F_n(x_n)) \quad (4.17)$$

Kopule C je jednoznačná, pokud marginální distribuce F_1, F_2, \dots, F_n jsou spojité.

Kopula-Granger model (resp. Grangerův Non-paranormální model, G-NPN), v rámci kterého jsou v této práci kopula funkci mapovány marginální distribuce na úrovni fyziologických událostí do kopula prostoru, je popsán v sekci 4.6.2. Pro shrnutí vychází tento model z následujících kroků [214]:

1. Nalezení empirického marginálního rozdělení pro fyziologickou událost \hat{F}_i .
2. Mapování pozorování do kopula prostoru: $\hat{f}_i(x_t^i) = \hat{\mu}_i + \hat{\sigma}_i \cdot \Phi^{-1}(\hat{F}_i(x_t^i))$.
3. Nalezení Grangerovy kauzality v rámci $\hat{f}_i(x_t^i)$.

přičemž je dále brán v potaz Winsorizovaný²⁸ odhad použité distribuční funkce, podle [224], aby se zabránilo velkým číslům $\Phi^{-1}(0^+)$ ²⁹ and $\Phi^{-1}(1^-)$:

$$\tilde{F}_j = \begin{cases} \delta_n, & \text{if } \hat{F}(x^j) < \delta_n \\ \hat{F}(x^j) & \text{if } \delta_n \leq \hat{F}(x^j) < 1 - \delta_n \\ (1 - \delta_n) & \text{if } \hat{F}(x^j) > 1 - \delta_n. \end{cases} \quad (4.18)$$

4.7.5 Metriky hodnocení v strojovém učení

Pro potřeby porovnání a vyhodnocení výkonnosti (přesnosti) realizovaných modelů strojového učení bylo zvoleno několik hodnotících metrik. Tato kapitola se zabývá použitými metrikami v této práci a jejich významem při posuzování modelů.

²⁸Winsorizace nebo Winsorova transformace je transformace statistických dat omezením extrémních hodnot, aby se snížil vliv případných odlehlych hodnot

²⁹ Φ^{-1} je inverzní kumulativní distribuční funkce standardního normálního rozdělení.

4.7.5.1 Přesnost

Přesnost je měřítkem, které hodnotí schopnost modelu správně předpovídat označení tříd v souboru dat. Vypočítá se jako poměr počtu správných předpovědí k celkovému počtu předpovědí provedených modelem:

$$\text{Přesnost} = \frac{\text{Počet správně predikovaných tříd}}{\text{Celkový počet predickí}} = \frac{TP + TN}{TP + TN + FP + FN} \quad (4.19)$$

kde TP, TN, FP a FN představují počet pravdivě pozitivních, pravdivě negativních, falešně pozitivních a falešně negativních výsledků.

Přesnost je často používanou metrikou pro hodnocení modelů, protože poskytuje jednoduché měřítko toho, jak dobře model celkově funguje. Vysoká hodnota přesnosti naznačuje, že model je schopen správně předpovídat velkou část souboru dat, zatímco nízká hodnota přesnosti naznačuje, že model není příliš efektivní při predikci tříd. Tato metrika však může být zavádějící ve chvíli, kdy jsou třídy nevyvážené. V takových případech může mít model, který vždy předpovídá většinovou třídu, vysokou hodnotu přesnosti, i když si vede špatně u menšinové třídy.

4.7.5.2 Pravdivě pozitivní míra

Pravdivě pozitivní míra (TPR, true positive rate), neboli senzitivita, je podíl pravdivě pozitivních předpovědí (TP) z celkového počtu pozitivních předpovědí (TP + falešně negativní předpovědi, tedy TP + FN). Matematicky je přesnost definována jako:

$$TPR = \frac{TP}{TP + FN} \quad (4.20)$$

Vysoké TPR znamená, že model dobře identifikuje pozitivní případy a minimalizuje falešně negativní, zatímco nízké TPR naznačuje, že model není příliš účinný při identifikaci pozitivních tříd.

4.7.5.3 Pravdivě negativní míra

Pravdivě negativní míra (TNR, true negative rate), neboli specificita, označuje podíl skutečně negativních případů, které jsou správně identifikovány jako negativní. Jinými slovy, TNR měří schopnost modelu správně identifikovat negativní třídu a lze vypočítat:

$$TNR = \frac{TN}{TN + FP} \quad (4.21)$$

Vysoké TNR znamená, že model dobře identifikuje negativní třídy a minimalizuje falešně pozitivní výsledky, zatímco nízké TNR naznačuje, že model není příliš účinný při identifikaci negativních případů.

4.7.5.4 Křivka ROC

ROC (Receiver Operating Characteristic) křivka je grafická metoda pro vyhodnocení výkonosti binárního klasifikačního modelu. Tato křivka zobrazuje vztah mezi dvěma parametry: TPR a falešnou pozitivní mírou (FPR, false positive rate). TPR odpovídá přesnosti modelu při detekci pozitivních případů, zatímco FPR zahrnuje chybně klasifikované negativní případy.

ROC křivka se skládá z mnoha bodů, přičemž každý bod představuje jinou úroveň rozhodovacího prahu (threshold) pro klasifikaci pozitivních a negativních případů. TPR a FPR se poté vypočítávají pro každý z těchto prahů a vykreslí se na grafu. Ideální křivka ROC je tvořena body s TPR rovnoměrně rostoucími k jedné a FPR rovnoměrně rostoucími k nule, což by znamenalo, že model dokáže rozlišovat mezi pozitivními a negativními případy s vysokou přesností. Křivka se používá například k porovnávání výkonu různých klasifikačních modelů. Vyšší oblast pod křivkou (AUC, Area Under Curve) indikuje, že model má lepší výkon, zatímco nižší AUC může naznačovat, že model má menší přesnost.

KAPITOLA 5

Výsledky

V následující kapitole jsou uvedeny výsledky zpracování a analýzy dat z analogové vesmírné mise DIANA včetně výsledků experimentů strojového učení. Kapitola je primárně rozdělena na tři části, přičemž první sekce 5.1 uvádí pouze srovnání QRS detektorů (viz 4.3.1.1). Další část je věnována prezentaci výsledků zpracování dat z mise, primárně ve formě grafických výstupů jako je například vývoj sledovaných statistických veličin během mise a v rámci baterie NPF testů. V této části jsou také uvedeny výsledky ze statistického modelování využitím LMM (viz sekce 4.4.5).

V poslední části jsou uvedeny výsledky experimentů strojového učení, které byly realizovány využitím metody navržené v rámci této práce. Samotná metoda je detailně popsána v sekci 4.6. Zároveň je zde uvedeno i srovnání navržené metody se současným stavem a její experimentální ověření na datech z mise DIANA.

5.1 Srovnání QRS detektorů

V následující tabulce jsou prezentovány výsledky srovnání QRS detektorů. Tabulka uvádí odhady marginálních středních hodnot vysvětlující proměnné na úrovni faktoru „Metoda“. Střední hodnota zde představuje výši chyby detektoru.

Tabulka 5.1: Výsledky výpočtu marginálních středních hodnot QRS detektorů

Detektor	Střední hodnota	SE	95% CI
*Kalidas [188]	0,016	0,005	0,007 – 0,025
Christov [225]	0,025	0,005	0,015 – 0,034
Nabian [226]	0,025	0,005	0,016 – 0,034
Rodrigues [227]	0,029	0,005	0,019 – 0,038
Pantompkins [189]	0,038	0,005	0,029 – 0,048
Elgendi [228]	0,058	0,005	0,049 – 0,068
Gamboa [229]	0,109	0,008	0,093 – 0,125

* Označuje detektor použitý v této práci

5.2 Analýza dat z mise DIANA

Ze zpracovaných biosignálů v rámci dat z mise DIANA byly vypočteny statistické veličiny (viz sekce 4.4.3), jejichž průměr a směrodatná odchylka pro začátek, prostředek a konec experimentu jsou uvedeny v Tabulce 5.2. Vzhledem k síťovým a komunikačním problémům byly první den data pro Lander1 nespolehlivá nebo chybějící. V tabulce tedy pro subjekt Lander1 jsou hodnoty pro 1. den vypočítané za den druhý.

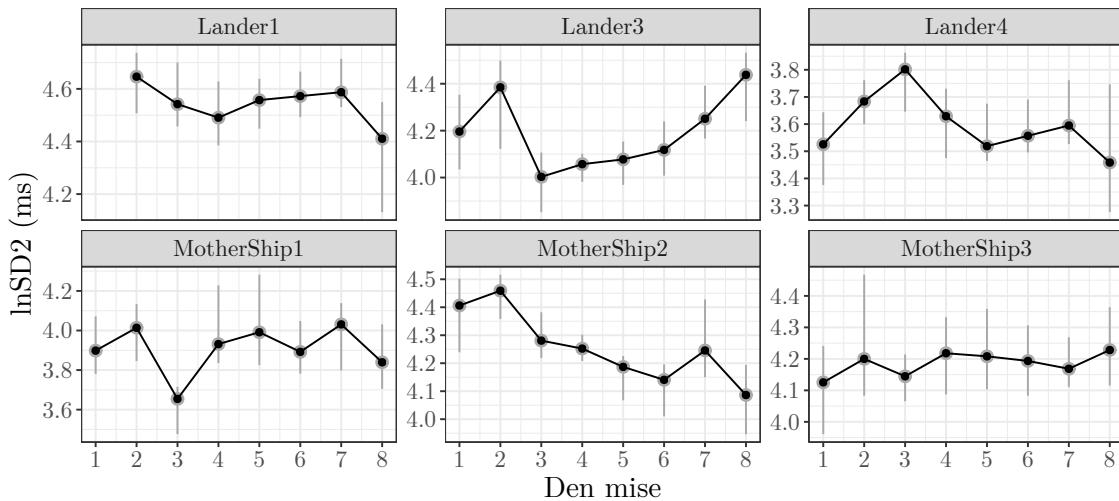
Tabulka 5.2: Individuální HRV reakce všech analogových astronautů v průběhu mise DIANA

Subjekt	Parametr	1. den		4. den		8. den	
		Průměr	SD	Průměr	SD	Průměr	SD
Lander1	SD2 (ms)	102,48	31,27	94,38	29,74	89,43	35,11
	RMSSD (ms)	78,67	20,3	72,11	16,44	63,76	20,35
	pNN50 (%)	28,29	8,25	27,21	6,68	20,93	9,18
	HF (ms ² /Hz)	0,03	0,01	0,03	0,02	0,03	0,02
Lander2	SD2 (ms)	66,53	22,66	58,02	11,35	84,63	28,7
	RMSSD (ms)	51,82	18,35	42,86	14,32	65,61	21,36
	pNN50 (%)	19,96	13,32	17,04	15,61	27,75	18,59
	HF (ms ² /Hz)	0,03	0,02	0,04	0,02	0,04	0,01
Lander3	SD2 (ms)	33,63	8,59	37,18	8,74	34,68	12,43
	RMSSD (ms)	30,27	9,68	32,49	9,01	31,09	20,71
	pNN50 (%)	2,99	1,67	3,68	1,7	2,95	1,99
	HF (ms ² /Hz)	0,05	0,03	0,03	0,02	0,04	0,03
MotherShip1	SD2 (ms)	53,87	20,23	60,36	22,83	49,7	17,18
	RMSSD (ms)	43,16	22,05	46,45	24,87	35,83	19,17
	pNN50 (%)	13,26	11,37	18,49	17,69	12,12	13,12
	HF (ms ² /Hz)	0,03	0,03	0,03	0,02	0,02	0,02
MotherShip2	SD2 (ms)	89,13	25,75	73,65	18,59	61,12	14,6
	RMSSD (ms)	71,13	23,37	57,12	15,53	45,8	8,35
	pNN50 (%)	35,68	15,61	27,53	11,5	16,88	7,23
	HF (ms ² /Hz)	0,04	0,03	0,03	0,02	0,03	0,02
MotherShip3	SD2 (ms)	62,35	15,05	68,49	16,47	72,27	18,4
	RMSSD (ms)	52,13	16,55	62,55	20,6	54,29	15,72
	pNN50 (%)	29,42	16,05	34,54	16,65	26,44	14,3
	HF (ms ² /Hz)	0,05	0,04	0,06	0,04	0,03	0,02

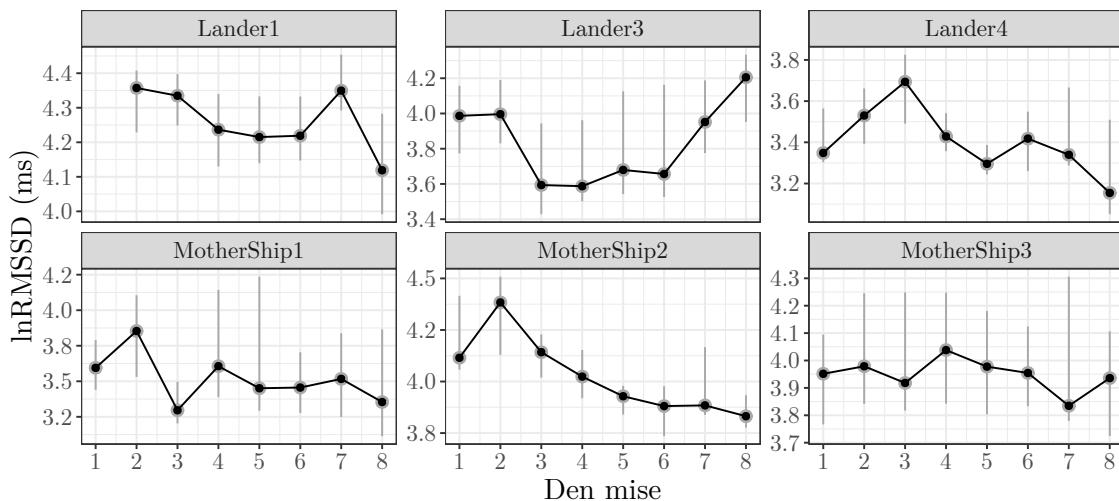
U Lander1 jsou vzhledem ke ztrátě dat v rámci prvního dne uvedeny výsledky vypočítané z druhého dne.

Označení subjektů vyplývá z experimentální skupiny, ve které se nacházeli. Pro jedince v materšské lodi je používáno označení „MotherShip“. V rámci skupiny přistávacího modulu je používáno označení „Lander“. Dále jsou vizualizovány průběhy jednotlivých sledovaných veličin v podobě bodových rozsahů pro každý den.

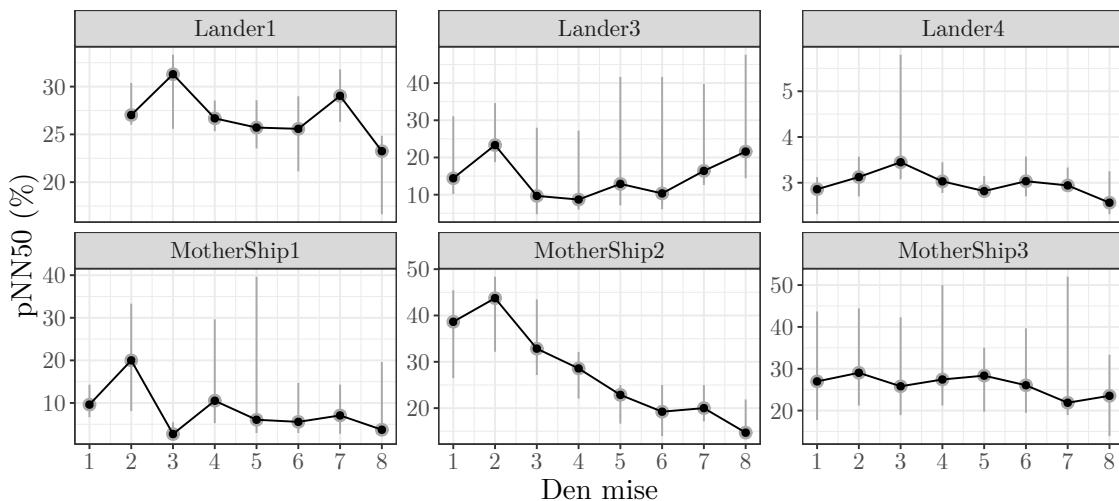
Jednotlivé body představují medián parametru vypočtený za patřičný den. Šedé rozsahy odpovídají hornímu a dolnímu kvartilu. V případě, že se u názvu sledovaného parametru nachází předpona „ln“, jedná se o přirozený logaritmus dané veličiny.



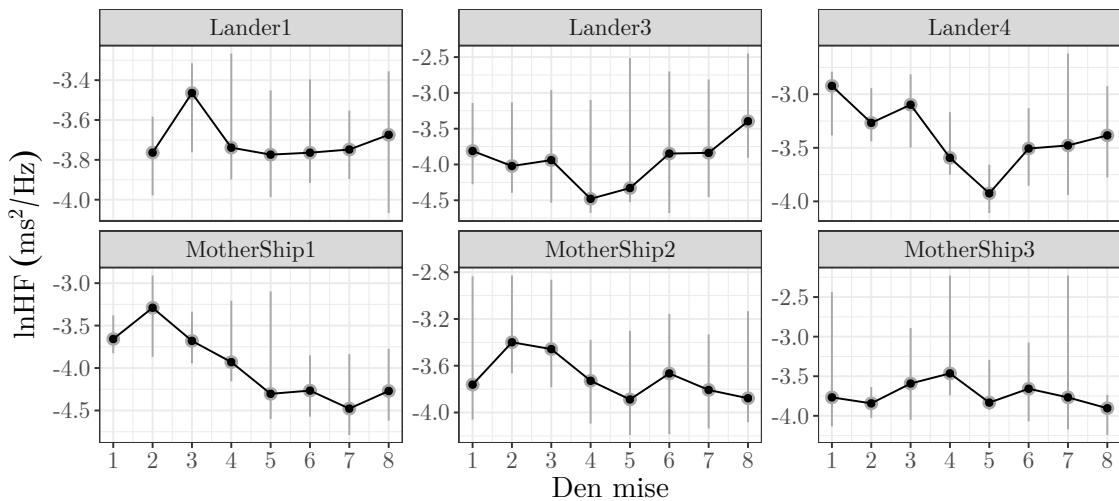
Obrázek 5.1: Medián, horní a dolní kvartil (šedý rozsah) hodnot SD2 pro jednotlivé dny



Obrázek 5.2: Medián, horní a dolní kvartil (šedý rozsah) hodnot RMSSD pro jednotlivé dny



Obrázek 5.3: Medián, horní a dolní kvartil (šedý rozsah) hodnot pNN50 pro jednotlivé dny



Obrázek 5.4: Medián, horní a dolní kvartil (šedý rozsah) hodnot HF pro jednotlivé dny

5.2.1 Sledované veličiny během NPF stimulace

Všichni jedinci byli během mise vystaveni NPF stimulaci ve formě baterie kognitivních testů využitím nástroje Neurop (viz sekce 4.1.7). Testování proběhlo dle harmonogramu mise jehož příklad lze vidět na Obr. 4.3. Skupina přistávacího modulu podstoupila testování třikrát v průběhu mise. Jednotlivá testování pro tuto skupinu jsou dále v této sekci značeny následovně: F – první testování, M – druhé testování a L – třetí testování. V Tabulce 5.3 jsou uvedeny výsledky vypočtených sledovaných veličin pro jednotlivá testování v rámci skupiny přistávacího modulu, konkrétně průměr a směrodatná odchylka.

Tabulka 5.3: Individuální HRV reakce analogových astronautů přistávacího modulu během neuropsychologické stimulace sadou kognitivních testů

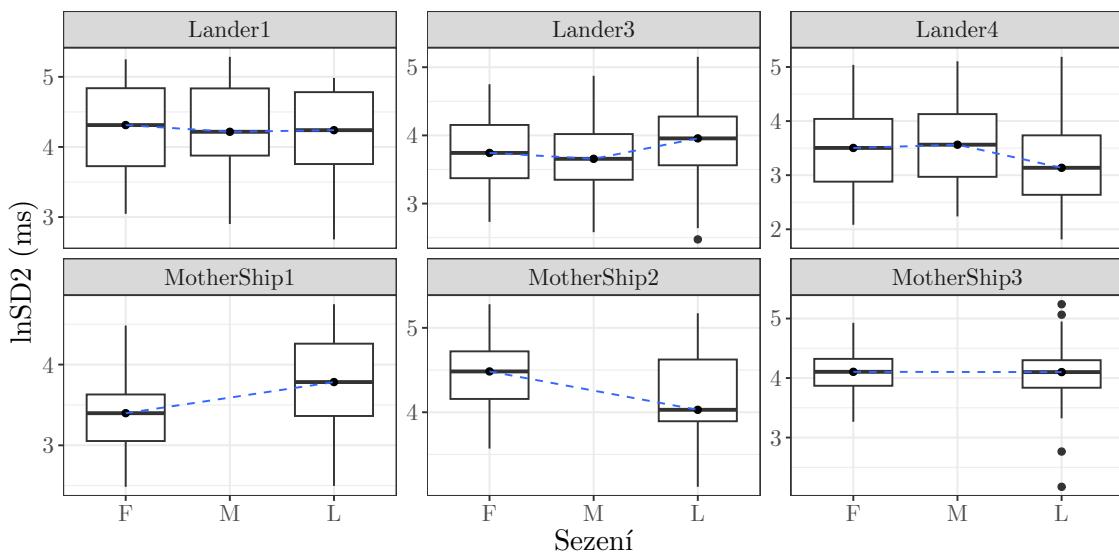
Subjekt	Parametr	F		M		L		
		Průměr	SD	Průměr	SD	Průměr	SD	
Lander1	SD2	(ms)	83,26	45,84	83,48	43,76	78,22	40,53
	RMSSD	(ms)	74,14	44,08	80,67	45,11	71,23	42,12
	pNN50	(%)	18,42	14,09	24,02	14,27	13,46	12,07
	HF	(ms ² /Hz)	0,04	0,03	0,05	0,04	0,03	0,03
Lander2	SD2	(ms)	48,01	22,92	45,09	24,59	58,08	31,14
	RMSSD	(ms)	30,89	13,43	38,71	22,29	47,38	28,91
	pNN50	(%)	5,41	6,12	7,07	6,77	11,74	8,68
	HF	(ms ² /Hz)	0,03	0,03	0,04	0,03	0,04	0,04
Lander3	SD2	(ms)	43,97	33,01	44,47	31,31	32,24	24,33
	RMSSD	(ms)	41,92	34,36	42,74	31,12	31,17	25,94
	pNN50	(%)	2,97	3,83	4,04	4,53	2,01	3,02
	HF	(ms ² /Hz)	0,06	0,04	0,06	0,04	0,05	0,04

U jedinců ze skupiny mateřské lodi bylo testování během mise provedeno pouze dvakrát. První testování je tedy označeno jako F a druhé jako L. Výsledky vypočtených sledovaných veličin v rámci jednotlivých testování pro tuto skupinu jsou uvedeny v Tabulce 5.4.

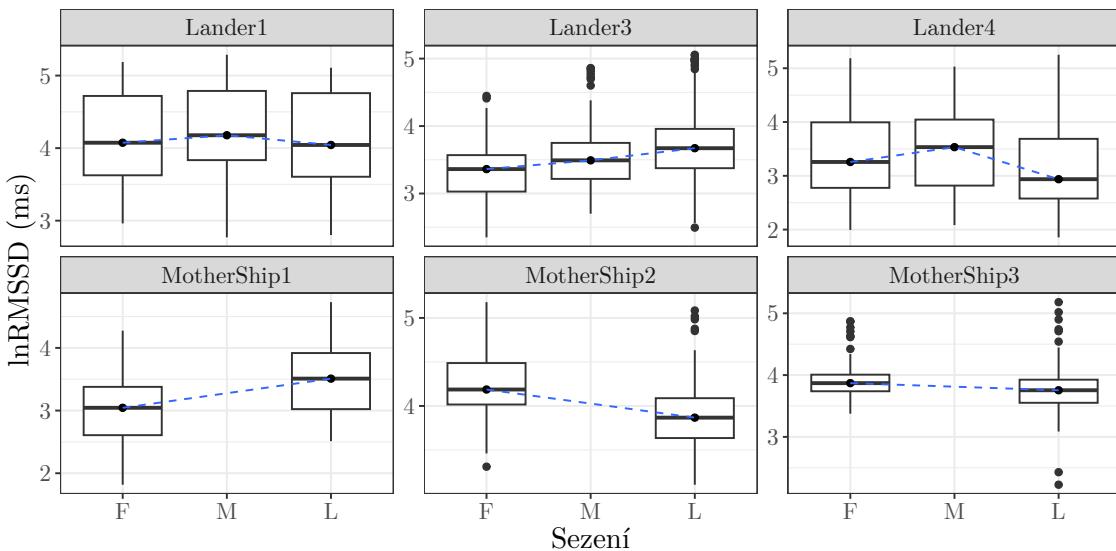
Tabulka 5.4: Individuální HRV reakce analogových astronautů mateřské lodi během neuropsychologické stimulace sadou kognitivních testů

Subjekt	Parametr	F		L	
		Průměr	SD	Průměr	SD
MotherShip1	SD2	(ms)	31,63	14,12	51,07
	RMSSD	(ms)	22,99	11,9	41,28
	pNN50	(%)	2,56	3,89	5,68
	HF	(ms^2/Hz)	0,04	0,04	0,02
MotherShip2	SD2	(ms)	94,54	38,23	72,81
	RMSSD	(ms)	76,61	33,23	56,12
	pNN50	(%)	33,55	11,62	22,64
	HF	(ms^2/Hz)	0,03	0,03	0,03
MotherShip3	SD2	(ms)	64,67	22,84	64,52
	RMSSD	(ms)	50,88	15,73	46,57
	pNN50	(%)	23,68	6,88	17,55
	HF	(ms^2/Hz)	0,03	0,02	0,02

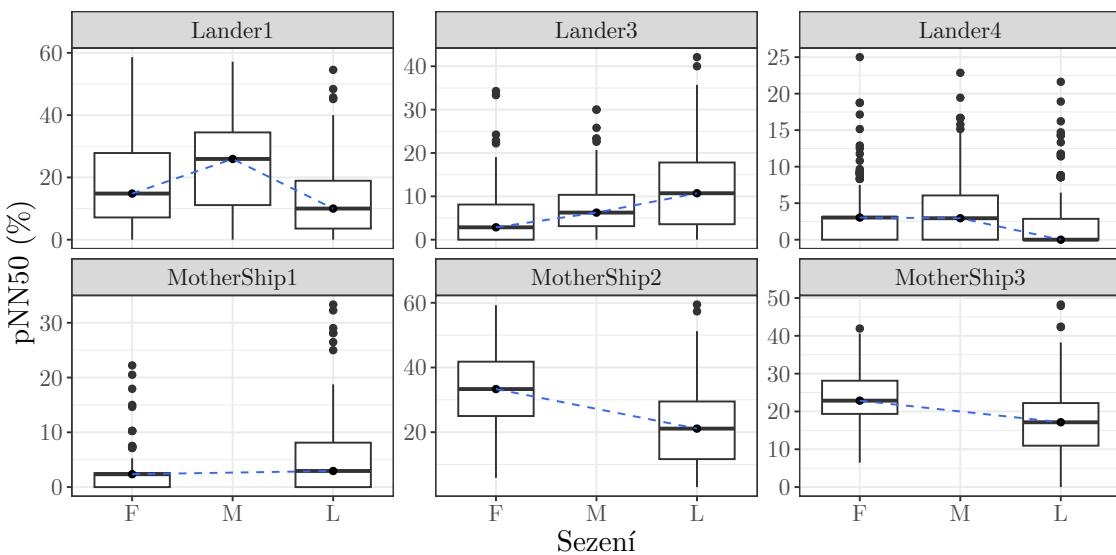
Jak již bylo popsáno v sekci 4.4, každé sezení, během kterého jedinec podstoupil NPF stimulaci sadou kognitivních testů, bylo na úrovni zaznamenaných biosignálů během testování segmentováno a zpracováno. Ve zbytku této sekce jsou vizualizovány zpracovaná data jednotlivých testování pro každého jedince ve formě krabicových grafů pro všechny sledované veličiny.



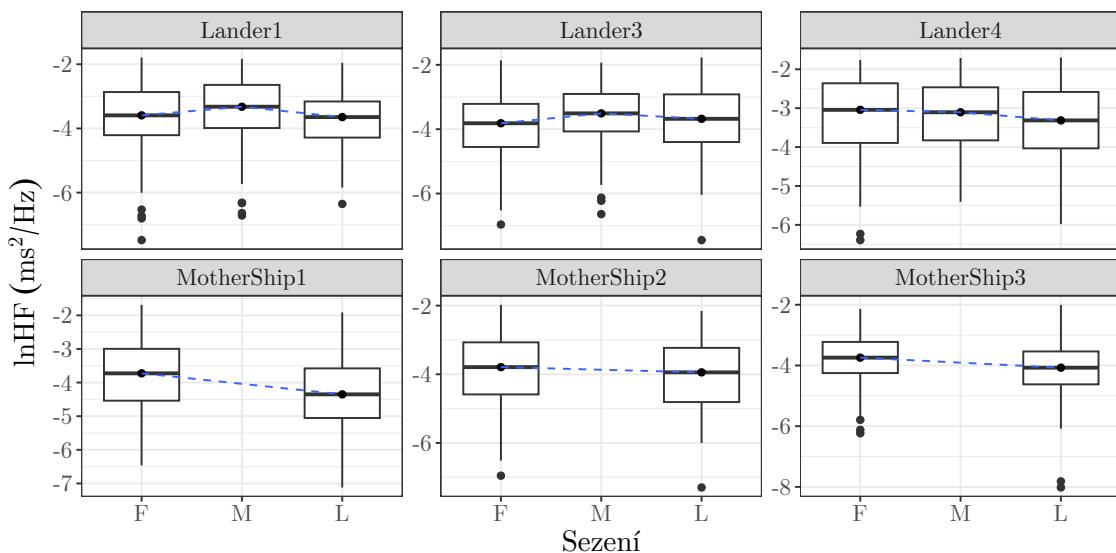
Obrázek 5.5: Krabicové grafy pro parametr SD2 během jednotlivých NPF testování



Obrázek 5.6: Krabicové grafy pro parametr RMSSD během jednotlivých NPF testování



Obrázek 5.7: Krabicové grafy pro parametr pNN50 během jednotlivých NPF testování



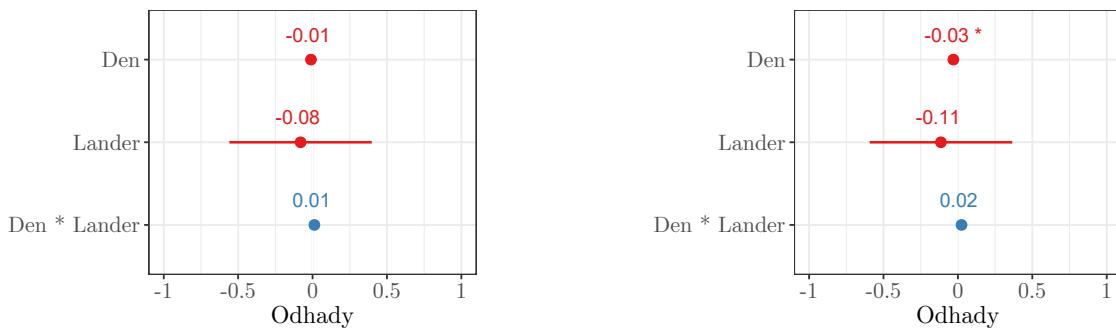
Obrázek 5.8: Krabicové grafy pro parametr HF během jednotlivých NPF testování

5.2.2 Statistické modelování

V této sekci jsou uvedeny výsledky statistického modelování sledovaných veličin využitím lineárních smíšených modelů (viz sekce 4.4.5 a 4.7.1). V Tabulce 5.5 jsou uvedeny výsledky LMM pro parametry SD2 a RMSSD. V tabulkách označuje proměnná N_{id} počet pozorovaných subjektů.

Tabulka 5.5: Fixní efekty lineárních smíšených modelů pro parametry SD2 a RMSSD

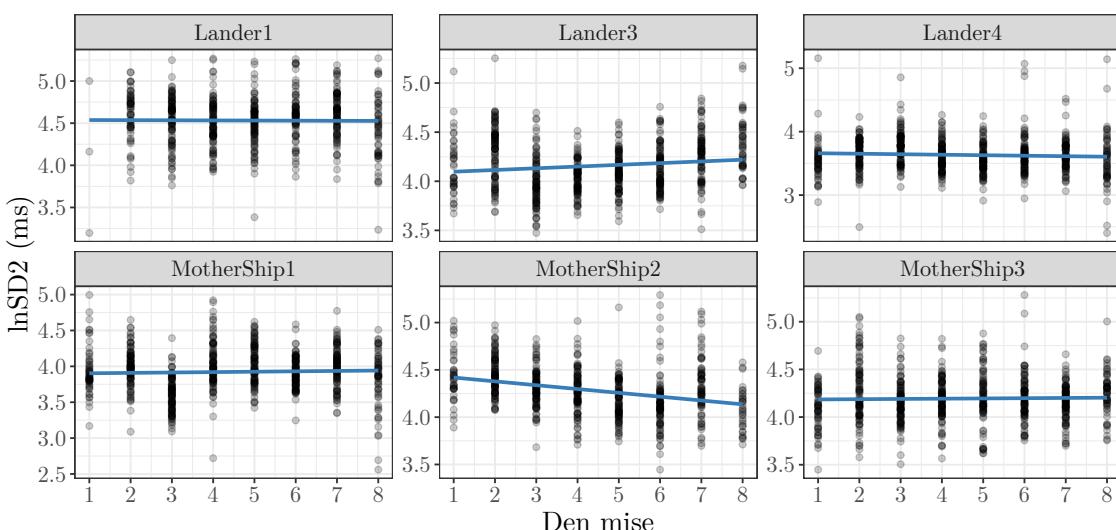
Prediktor	lnSD2			lnRMSSD		
	Odhad	95% CI	p	Odhad	95% CI	p
(Intercept)	4,18	2,88 – 5,48	<0,001	4,01	3,70 – 4,33	<0,001
Den	-0,01	-0,03 – 0,01	0,318	-0,03	-0,05 – 0,00	0,023
Skupina Lander	-0,08	-0,56 – 0,40	0,742	-0,11	-0,55 – 0,35	0,654
Den × skupina Lander	0,01	-0,02 – 0,04	0,424	0,02	-0,01 – 0,05	0,244
N_{id}		6			6	
Počet pozorování		3870			3866	



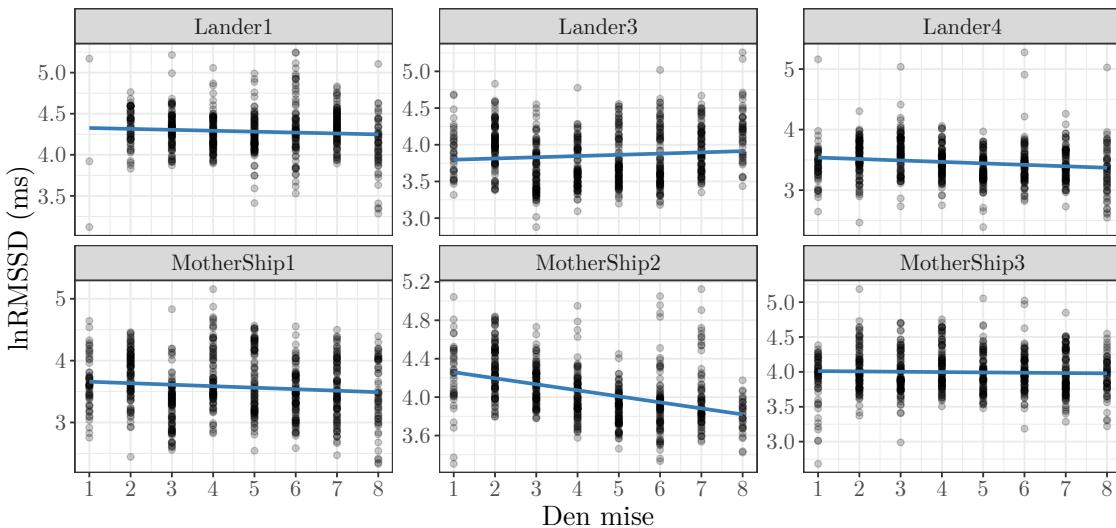
(a) Pro parametr SD2

(b) Pro parametr RMSSD

Obrázek 5.9: Vizualizace odhadů (fixních efektů) navržených modelů



Obrázek 5.10: Grafická reprezentace modelu pro parametr SD2 na individuální úrovni

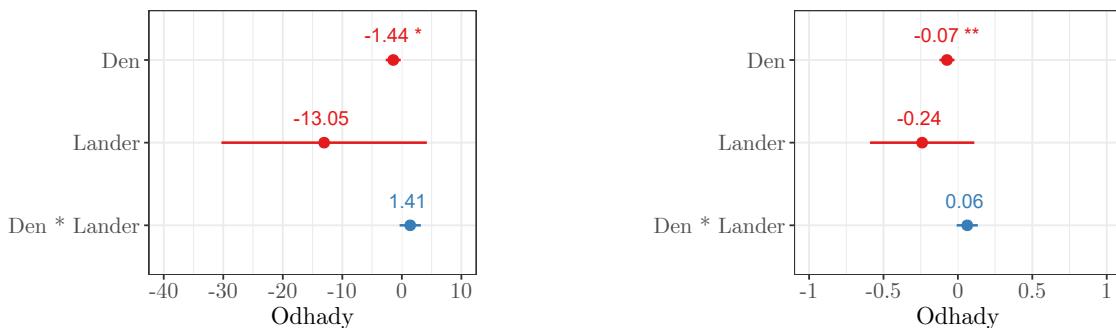


Obrázek 5.11: Grafická reprezentace modelu pro parametr RMSSD na individuální úrovni

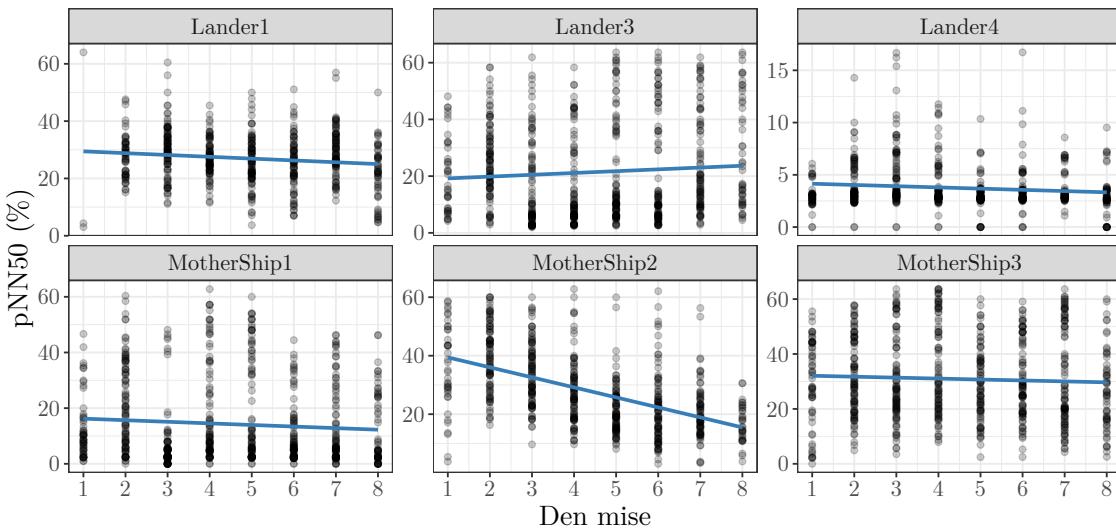
V Tabulce 5.6 jsou uvedeny výsledky modelování pro parametry pNN50 a HF. V tabulkách opět označuje proměnná N_{id} počet pozorovaných subjektů. Byly vytvořeny i grafické reprezentace fixních efektů pro každý model zvlášť včetně příkladů grafů modelů lineárních smíšených efektů v rámci každého subjektu. Všechny grafy jsou uvedeny v návaznosti na patřičnou tabulkou výsledků LMM.

Tabulka 5.6: Fixní efekty lineárních smíšených modelů pro parametry pNN50 a HF

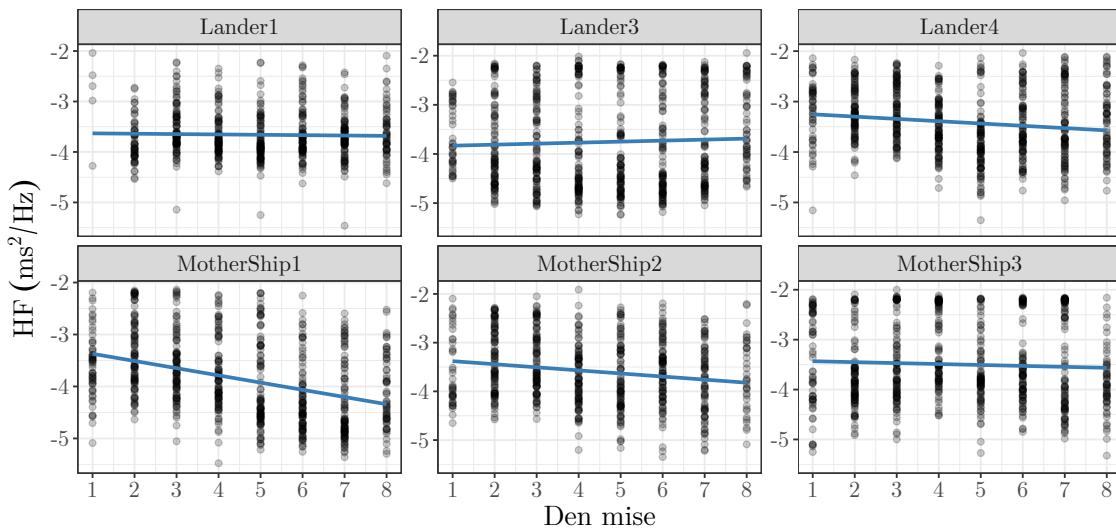
Prediktor	pNN50			lnHF		
	Odhad	95% CI	p	Odhad	95% CI	p
(Intercept)	30,69	18,50 – 43,88	<0,001	-3,32	-3,57 – -3,07	<0,001
Den	-1,44	-2,70 – -0,19	0,024	-0,07	-0,12 – -0,02	0,004
Skupina Lander	-13,05	-30,30 – 4,20	0,138	-0,24	-0,59 – 0,11	0,179
Den × skupina Lander	1,41	-0,38 – 3,19	0,122	0,06	0,01 – 0,13	0,083
N_{id}	6			6		
Počet pozorování	3874			3974		



Obrázek 5.12: Vizualizace odhadů (fixních efektů) navržených modelů



Obrázek 5.13: Grafická reprezentace modelu pro parametr pNN50 na individuální úrovni



Obrázek 5.14: Grafická reprezentace modelu pro parametr HF na individuální úrovni

5.3 Modely pro hodnocení kognitivní zátěže

V této sekci jsou prezentovány výsledky části strojového učení. Nejprve jsou uvedeny výsledky trénování modelů využitím navržené metody pro hodnocení kognitivní zátěže (viz sekce 4.6). Výsledky jsou uvedeny zvláště pro každý benchmarkovací dataset a poté pro sjednocené datasety. Popis jednotlivých datasetů se nachází v sekci 4.2.

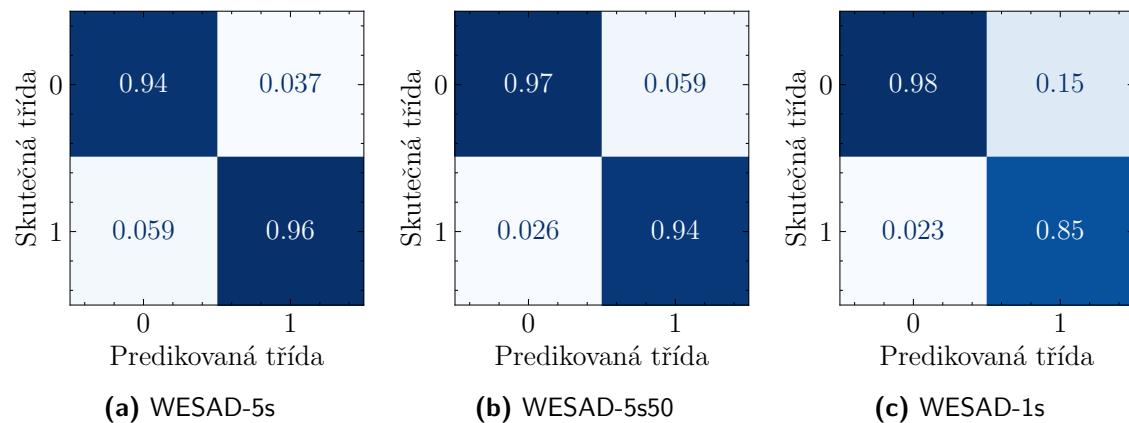
Poslední dvě části sekce jsou věnovány porovnání navrženého řešení se současným stavem a experimentálnímu ověření řešení. Ověření je realizováno na datech z analogové vesmírné mise DIANA, konkrétně na úsecích, kdy byl subjekt podroben NPF stimulaci. Všechny experimenty jsou součásti přílohy diplomové práce.

5.3.1 Hodnocení přesnosti modelů pro WESAD

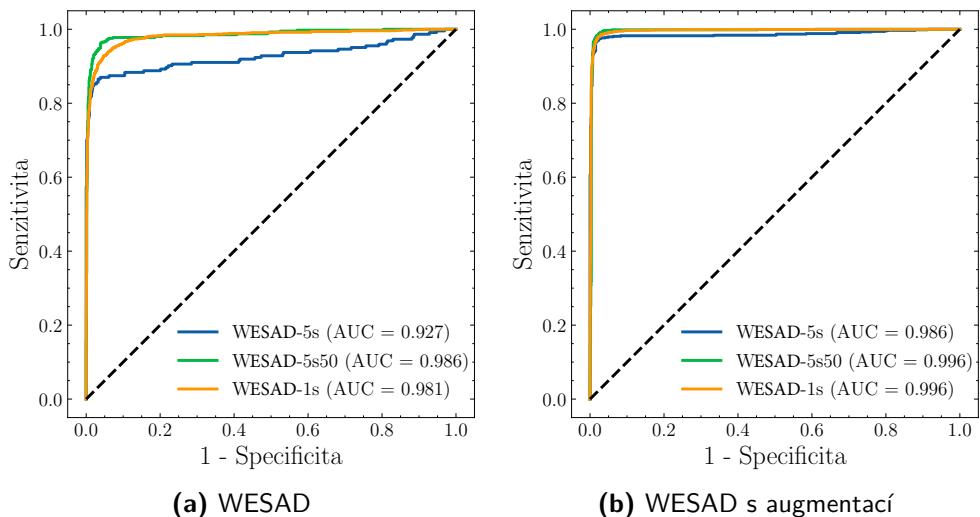
V této sekci jsou uvedeny výsledky z trénování modelů na datasetu WESAD v podobě vybraných hodnotících metrik (viz sekce 4.7.5), matic záměn a ROC křivek. Matice záměn byly normalizovány na relativní četnosti v rámci sloupců. Matice pro augmentované (Aug.) verze datasetů jsou uvedeny v příloze ??.

Tabulka 5.7: Výsledky hodnocení přesnosti modelů WESAD (Acc. = přesnost)

Model	Aug.	Acc.	Test acc.	TPR	TNR	AUC
WESAD-5s	Ne	99,75 %	95,46 %	95,21 %	90,07 %	0,926
	Ano	99,91 %	97,73 %	97,51 %	97,54 %	0,986
WESAD-5s50	Ne	99,93 %	96,84 %	95,63 %	94,57 %	0,986
	Ano	99,97 %	98,25 %	98,06 %	98,06 %	0,996
WESAD-1s	Ne	99,45 %	95,25 %	91,60 %	93,81 %	0,981
	Ano	99,73 %	96,66 %	95,61 %	95,23 %	0,996



Obrázek 5.15: Matice záměn pro WESAD modely (0 = klidový stav, 1 = CL stav)



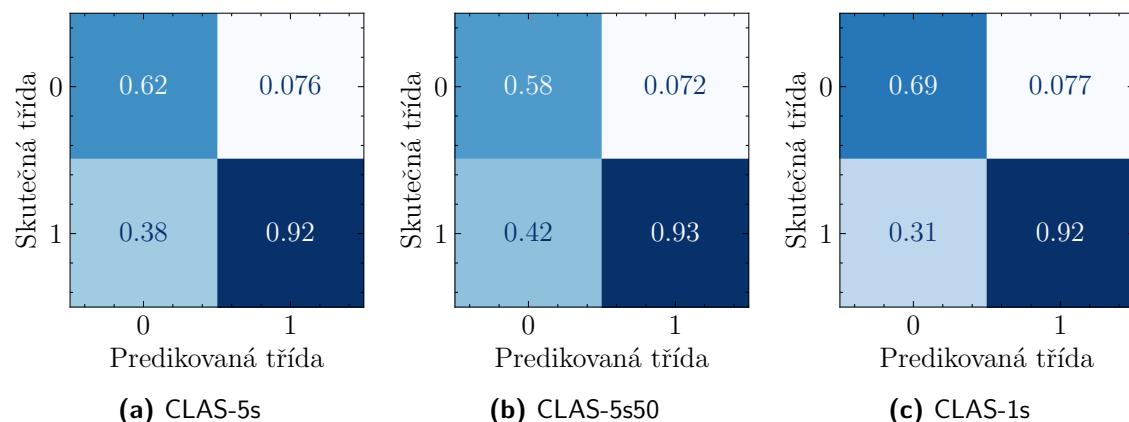
Obrázek 5.16: ROC křivky pro WESAD modely

5.3.2 Hodnocení přesnosti modelů pro CLAS

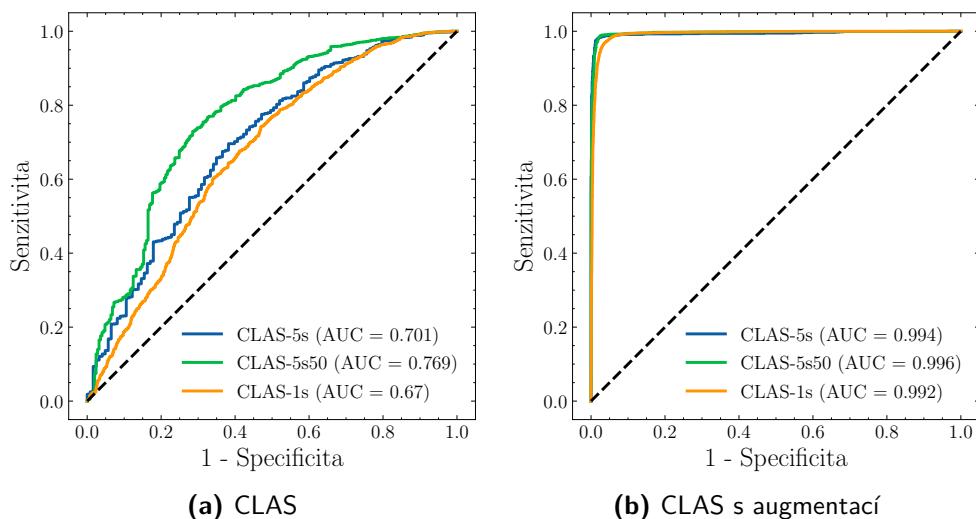
V této sekci jsou uvedeny výsledky z trénování modelů na datasetu CLAS v podobě vybraných hodnotících metrik (viz sekce 4.7.5), matic záměn a ROC křivek. Matice záměn byly normalizovány na relativní četnosti v rámci sloupců. Matice pro augmentované (Aug.) verze datasetů jsou uvedeny v příloze ??.

Tabulka 5.8: Výsledky hodnocení přesnosti modelů CLAS (Acc. = přesnost)

Model	Aug.	Acc.	Test acc.	TPR	TNR	AUC
CLAS-5s	Ne	99,35 %	91,79 %	77,67 %	54,14 %	0,994
	Ano	99,91 %	97,45 %	97,21 %	97,17 %	0,994
CLAS-5s50	Ne	99,43 %	92,17 %	75,99 %	57,68 %	0,756
	Ano	99,89 %	97,87 %	97,66 %	97,65 %	0,996
CLAS-1s	Ne	97,91 %	92,04 %	81,29 %	53,67 %	0,667
	Ano	98,21 %	96,55 %	96,46 %	96,46 %	0,992



Obrázek 5.17: Matice záměn pro CLAS modely (0 = klidový stav, 1 = CL stav)



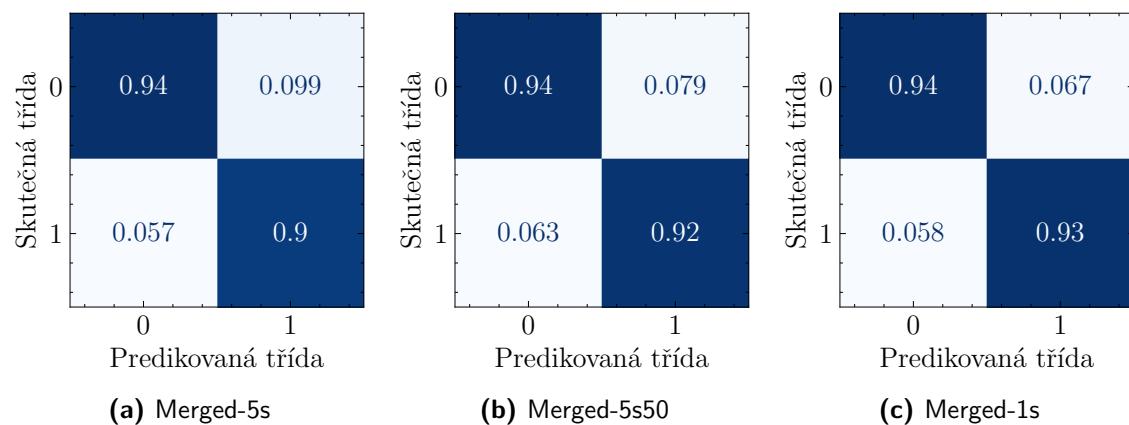
Obrázek 5.18: ROC křivky pro CLAS modely

5.3.3 Hodnocení přesnosti modelů pro sjednocená data

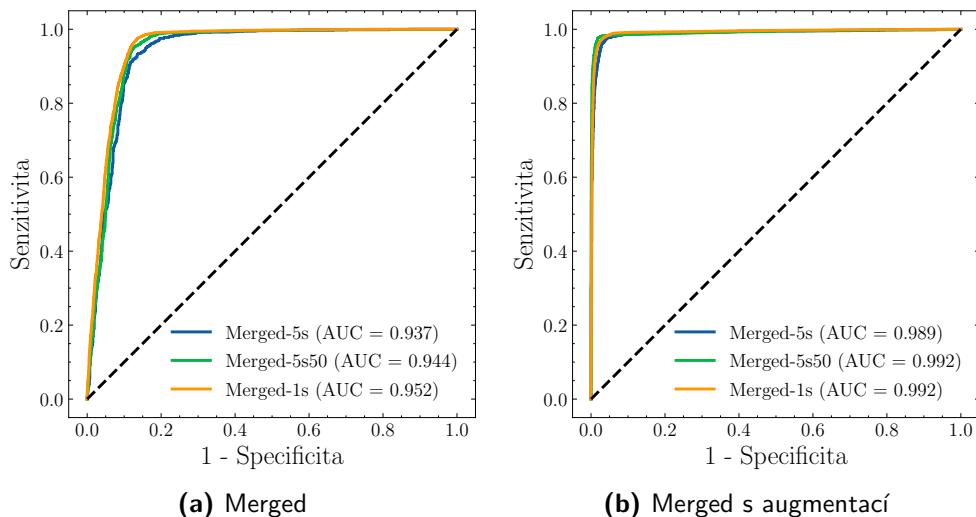
V této sekci jsou uvedeny výsledky z trénování modelů na sloučených datesetech (dále jen Merged) v podobě vybraných hodnotících metrik (viz sekce 4.7.5), matic záměn a ROC křivek. Matice záměn byly normalizovány na relativní četnosti v rámci sloupců. Matice pro augmentované (Aug.) verze datasetů jsou v příloze ??.

Tabulka 5.9: Výsledky hodnocení přesnosti modelů Merged (Acc. = přesnost)

Model	Aug.	Acc.	Test acc.	TPR	TNR	AUC
Merged-5s	Ne	98,65 %	91,96 %	92,16 %	88,63 %	0,937
	Ano	99,74 %	96,16 %	95,89 %	95,90 %	0,989
Merged-5s50	Ne	98,81 %	92,96 %	92,91 %	90,70 %	0,944
	Ano	99,73 %	97,55 %	96,99 %	96,88 %	0,991
Merged-1s	Ne	96,65 %	93,61 %	93,77 %	91,99 %	0,952
	Ano	99,16 %	97,24 %	97,13 %	97,12 %	0,992



Obrázek 5.19: Matice záměn pro CLAS modely (0 = klidový stav, 1 = CL stav)



Obrázek 5.20: ROC křivky pro Merged modely

5.3.4 Srovnání na úrovni použitých modalit

V následující tabulce jsou uvedeny výsledky z trénování na sloučených datasetech (Merged-5s) s různými kombinacemi modalit pro účely porovnání jejich významnosti.

Tabulka 5.10: Výsledky hodnocení důležitosti využitých modalit pro hodnocení kognitivní zátěže v rámci modelu Merged-5s (Acc. = přesnost)

Modality	Acc.	Test acc.	TPR	TNR	AUC
EKG, RSP, EDA	98,65 %	91,96 %	92,16 %	88,63 %	0,937
EKG, RSP	96,17 %	90,52 %	84,88 %	74,52 %	0,865
EKG, EDA	97,41 %	91,75 %	87,91 %	79,89 %	0,895
EKG	95,99 %	89,57 %	77,31 %	76,05 %	0,766
RSP	91,47 %	87,96 %	50,12 %	50,06 %	0,511
EDA	92,23 %	89,07 %	42,68 %	45,46 %	0,519

5.3.5 Srovnání se současným stavem

Navržené řešení v této práci bylo porovnáno s vybranými dosavadními přístupy, jež využívají strojového učení pro rozpoznání kognitivní zátěže. Srovnání lze vidět v Tab. 5.11. Všechna řešení využívají minimálně jednu modalitu (primárně EKG).

Tabulka 5.11: Výsledky srovnání s dosavadními přístupy

Autor	Dataset	Okno	Test acc.	Rok
Feradov et al. [230]	CLAS	30s	84 %	2020
Ahmad et al. [231]	WESAD	1s	72 %	2021
Garg et al. [232]	WESAD	10s	84 %	2021
Rabbani et al. [233]	WESAD	10s	87 %	2022
Zhu et al. [234]	CLAS	30s	86 %	2022
*Quadrini et al. [235]	WESAD	60s	91 %	2022
Chatterjee et al. [236]	WESAD	30s	94 %	2022
Dair et al. [237]	WESAD	10s	69 %	2023
Rashid et al. [238]	WESAD	30s	93 %	2023
Galarraga et al. [239]	WESAD	20s	90 %	2023
Henry et al. [240]	WESAD	6s	81 %	2023
*Yong et al. [241]	CLAS	5s	82 %	2023
Singh et al. [242]	WESAD	5s	91 %	2023
Autor práce	WESAD	5s	97 %	2023
Autor práce	CLAS	5s	92 %	2023
Autor práce	WESAD	1s	95 %	2023
Autor práce	WESAD	1s	92 %	2023

* Označuje řešení, ve kterých bylo využito GAF příznaků

5.3.6 Testování na datech z mise DIANA

KAPITOLA 6

Diskuse

KAPITOLA 7

Závěr

7.1 Budoucí práce

Bibliografie

1. HARRISON, Albert A.; CONNORS, Mary M. Groups in Exotic Environments. In: BERKOWITZ, Leonard (ed.) [online]. Academic Press, 1984, sv. 18, s. 49–87 [cit. 2021-04-08]. Advances in Experimental Social Psychology. ISSN 0065-2601. Dostupné z DOI: [https://doi.org/10.1016/S0065-2601\(08\)60142-2](https://doi.org/10.1016/S0065-2601(08)60142-2).
2. BELL, Suzanne T.; FISHER, David M.; BROWN, Shanique G.; MANN, Kristin E. An Approach for Conducting Actionable Research With Extreme Teams. *Journal of Management* [online]. 2018, roč. 44, č. 7, s. 2740–2765 [cit. 2021-04-08]. Dostupné z DOI: 10.1177/0149206316653805.
3. STACHOWSKI, Alicia A; KAPLAN, Seth A; WALLER, Mary J. The benefits of flexible team interaction during crises. *Journal of Applied Psychology* [online]. 2009, roč. 94, č. 6, s. 1536 [cit. 2021-04-08]. Dostupné z DOI: 10.1037/a0016903.
4. YU, Tieying; SENGUL, Metin; LESTER, Richard H. Misery loves company: The spread of negative impacts resulting from an organizational crisis. *Academy of Management Review* [online]. 2008, roč. 33, č. 2, s. 452–472 [cit. 2021-04-08]. Dostupné z DOI: 10.5465/amr.2008.31193499.
5. GARDNER, Heidi K. Performance pressure as a double-edged sword: Enhancing team motivation but undermining the use of team knowledge. *Administrative Science Quarterly* [online]. 2012, roč. 57, č. 1, s. 1–46 [cit. 2021-04-08]. Dostupné z DOI: 10.1177/0001839212446454.
6. STAAL, Mark A. Stress, Cognition, and Human Performance: A Literature Review and Conceptual Framework. In: [online]. 2013 [cit. 2021-04-08]. Dostupné z: <https://ntrs.nasa.gov/citations/20060017835>.
7. HANNAH, Sean T.; UHL-BIEN, Mary; AVOLIO, Bruce J.; CAVARRETTA, Fabrice L. A framework for examining leadership in extreme contexts. *The Leadership Quarterly* [online]. 2009, roč. 20, č. 6, s. 897–919 [cit. 2021-06-12]. ISSN 1048-9843. Dostupné z DOI: <https://doi.org/10.1016/j.leaqua.2009.09.006>. The Leadership Quarterly Yearly Review of Leadership.
8. HÄLLGREN, Markus; ROULEAU, Linda; ROND, Mark de. A Matter of Life or Death: How Extreme Context Research Matters for Management and Organization Studies. *Academy of Management Annals* [online]. 2018, roč. 12, č. 1, s. 111–153 [cit. 2021-06-15]. Dostupné z DOI: 10.5465/annals.2016.0017.
9. GOLDEN, Simon J.; CHANG, Chu-Hsiang (Daisy); KOZLOWSKI, Steve W.J. Teams in isolated, confined, and extreme (ICE) environments: Review and integration. *Journal of Organizational Behavior* [online]. 2018, roč. 39, č. 6, s. 701–715 [cit. 2021-06-16]. Dostupné z DOI: <https://doi.org/10.1002/job.2288>.

10. PAGEL, J. I.; CHOUKÈR, A. Effects of isolation and confinement on humans-implications for manned space explorations. *Journal of Applied Physiology*. 2016, roč. 120, č. 12, s. 1449–1457. Dostupné z DOI: 10.1152/japplphysiol.00928.2015. PMID: 26846554.
11. TAYLOR, Lee; WATKINS, Samuel L.; MARSHALL, Hannah; DASCOMBE, Ben J.; FOSTER, Josh. The impact of different environmental conditions on cognitive function: A focused review. *Frontiers in Physiology* [online]. 2016, roč. 6, s. 372 [cit. 2021-06-14]. ISSN 1664042X. Dostupné z DOI: 10.3389/FPHYS.2015.00372.
12. WINNARD, Andrew; SCOTT, Jonathan; WATERS, Nathan; VANCE, Martin; CAPLAN, Nick. Effect of Time on Human Muscle Outcomes During Simulated Microgravity Exposure Without Countermeasures—Systematic Review. *Frontiers in Physiology* [online]. 2019, roč. 10 [cit. 2021-04-08]. ISSN 1664042X. Dostupné z DOI: 10.3389/fphys.2019.01046.
13. ZHANG, Fan; DE DEAR, Richard; HANCOCK, Peter. Effects of moderate thermal environments on cognitive performance: A multidisciplinary review. *Applied Energy* [online]. 2019, roč. 236, s. 760–777 [cit. 2021-04-08]. ISSN 0306-2619. Dostupné z DOI: <https://doi.org/10.1016/j.apenergy.2018.12.005>.
14. MAYNARD, M Travis; KENNEDY, Deanna M; RESICK, Christian J. Teamwork in extreme environments: Lessons, challenges, and opportunities. *Journal of organizational behavior* [online]. 2018, roč. 39, č. 6, s. 695–700 [cit. 2021-06-14]. ISSN 1099-1379. Dostupné z DOI: 10.1002/JOB.2302.
15. DRISKELL, Tripp; SALAS, Eduardo; DRISKELL, James E. Teams in extreme environments: Alterations in team development and teamwork. *Human Resource Management Review* [online]. 2018, roč. 28, s. 434–449 [cit. 2021-06-09]. ISSN 1053-4822. Dostupné z DOI: 10.1016/J.HRMR.2017.01.002.
16. WICKMAN, Leslie; TSAI, Annie; WALTERS, Raymond. Isolation and Confinement Issues in Long Duration Spaceflight. In: [online]. 2008, s. 1–9 [cit. 2021-06-12]. Dostupné z DOI: 10.1109/AERO.2008.4526654.
17. STUSTER, Jack W. Bold endeavors: behavioral lessons from polar and space exploration. *Gravitational and Space Research* [online]. 2007, roč. 13, č. 2 [cit. 2021-06-14]. Dostupné z: <http://gravitationalandspaceresearch.org/index.php/journal/article/view/244/243>.
18. KALEAGASI, Bartu. *Space Technology under NASA and SpaceX* [online]. 2017. [cit. 2021-06-24]. Dostupné z: <https://bartukaleagasi.files.wordpress.com/2017/01/space-technology-under-nasa-and-spacex.pdf>.
19. SALOTTI, Jean-Marc; HEIDMANN, Richard. Roadmap to a human Mars mission. *Acta Astronautica* [online]. 2014, roč. 104, č. 2, s. 558–564 [cit. 2021-06-16]. ISSN 0094-5765. Dostupné z DOI: <https://doi.org/10.1016/j.actaastro.2014.06.038>. Future of Space Exploration: Towards the Stars.
20. VISCIO, Maria Antonietta; GARGIOLI, Eugenio; HOFFMAN, Jeffrey A.; MAGGIORE, Paolo; MESSIDORO, Andrea; VIOLA, Nicole. A methodology for innovative technologies roadmaps assessment to support strategic decisions for future space exploration. *Acta Astronautica* [online]. 2014, roč. 94, č. 2, s. 813–833 [cit. 2021-06-16]. ISSN 0094-5765. Dostupné z DOI: <https://doi.org/10.1016/j.actaastro.2013.10.004>.

21. MOGILEVER, Nicolette B.; ZUCCARELLI, Lucrezia; BURLES, Ford; IARIA, Giuseppe; STRAPAZZON, Giacomo; BESSONE, Loredana; COFFEY, Emily B.J. Expedition cognition: A review and prospective of subterranean neuroscience with spaceflight applications. *Frontiers in Human Neuroscience* [online]. 2018, roč. 12, s. 407 [cit. 2021-06-15]. ISSN 16625161. Dostupné z DOI: [10.3389/FNHUM.2018.00407](https://doi.org/10.3389/fnhum.2018.00407).
22. BUGUET, Alain. Sleep under extreme environments: Effects of heat and cold exposure, altitude, hyperbaric pressure and microgravity in space. *Journal of the Neurological Sciences* [online]. 2007, roč. 262, s. 145–152 [cit. 2021-04-08]. ISSN 0022510X. Dostupné z DOI: [10.1016/J.JNS.2007.06.040](https://doi.org/10.1016/J.JNS.2007.06.040).
23. WILLIAMS, David; KUIPERS, Andre; MUKAI, Chiaki; THIRSK, Robert. Acclimation during space flight: Effects on human physiology. *CMAJ* [online]. 2009, roč. 180, s. 1317–1323 [cit. 2021-04-08]. ISSN 14882329. Dostupné z DOI: [10.1503/CMAJ.090628](https://doi.org/10.1503/CMAJ.090628).
24. ROY-O'REILLY, Meaghan; MULAVARA, Ajitkumar; WILLIAMS, Thomas. A review of alterations to the brain during spaceflight and the potential relevance to crew in long-duration space exploration. *npj Microgravity* 2021 7:1 [online]. 2021, roč. 7, č. 1, s. 1–9 [cit. 2021-06-15]. ISSN 2373-8065. Dostupné z DOI: [10.1038/s41526-021-00133-z](https://doi.org/10.1038/s41526-021-00133-z).
25. STRANGMAN, Gary E.; SIPES, Walter; BEVEN, Gary. Human cognitive performance in spaceflight and analogue environments. *Aviation Space and Environmental Medicine* [online]. 2014, roč. 85, s. 1033–1048 [cit. 2021-04-18]. ISSN 00956562. Dostupné z DOI: [10.3357/ASEM.3961.2014](https://doi.org/10.3357/ASEM.3961.2014).
26. MORPHEW, Ephimia. Psychological and human factors in long duration spaceflight. *McGill Journal of Medicine* [online]. 2001, roč. 6, č. 1 [cit. 2021-06-16]. Dostupné z DOI: [10.26443/mjm.v6i1.555](https://doi.org/10.26443/mjm.v6i1.555).
27. STEIN, Thomas P. Weight, muscle and bone loss during space flight: another perspective. *European Journal of Applied Physiology* [online]. 2012, roč. 113, s. 2171–2181 [cit. 2021-06-18]. Dostupné z: <https://link.springer.com/article/10.1007/s00421-012-2548-9>.
28. GROEMER, Gernot; OZDEMIR, Seda. Planetary Analog Field Operations as a Learning Tool. *Frontiers in Astronomy and Space Sciences* [online]. 2020, roč. 7 [cit. 2021-06-19]. ISSN 2296-987X. Dostupné z DOI: [10.3389/fspas.2020.00032](https://doi.org/10.3389/fspas.2020.00032).
29. BARKASZI, Irén; TAKÁCS, Endre; CZIGLER, István; BALÁZS, László. Extreme Environment Effects on Cognitive Functions: A Longitudinal Study in High Altitude in Antarctica. *Frontiers in Human Neuroscience* [online]. 2016, roč. 10 [cit. 2021-04-08]. ISSN 1662-5161. Dostupné z DOI: [10.3389/fnhum.2016.00331](https://doi.org/10.3389/fnhum.2016.00331).
30. LUGG, D.; SHEPANEK, M. Space analogue studies in Antarctica. *Acta Astronautica* [online]. 1999, roč. 44, č. 7, s. 693–699 [cit. 2021-06-19]. ISSN 0094-5765. Dostupné z DOI: [https://doi.org/10.1016/S0094-5765\(99\)00068-5](https://doi.org/10.1016/S0094-5765(99)00068-5). Pacific RIM: A Rapidly Expanding Space Market.
31. SCHNEIDER, Stefan; ABELN, Vera; POPOVA, Julia; FOMINA, Elena; JACUBOWSKI, Amrei; MEEUSEN, Romain; STRÜDER, Heiko K. The influence of exercise on prefrontal cortex activity and cognitive performance during a simulated space flight to Mars (MARS500). *Behavioural Brain Research* [online]. 2013, roč. 236, s. 1–7 [cit. 2021-06-19]. ISSN 0166-4328. Dostupné z DOI: <https://doi.org/10.1016/j.bbr.2012.08.022>.

32. WANG, Yue; JING, Xiaolu; LV, Ke; WU, Bin; BAI, Yanqiang; LUO, Yuejia; CHEN, Shanguang; LI, Yinghui. During the Long Way to Mars: Effects of 520 Days of Confinement (Mars500) on the Assessment of Affective Stimuli and Stage Alteration in Mood and Plasma Hormone Levels. *PLOS ONE* [online]. 2014, roč. 9, č. 4, s. 1–9 [cit. 2021-06-19]. Dostupné z DOI: 10.1371/journal.pone.0087087.
33. TREMBANIS, Arthur C; FORREST, Alex L; MILLER, Douglas C; LIM, Darlene SS; GERNHARDT, Michael L; TODD, William L. Multiplatform ocean exploration: Insights from the NEEMO space analog mission. *Marine Technology Society Journal* [online]. 2012, roč. 46, č. 4, s. 7–19 [cit. 2021-06-20]. Dostupné z DOI: 10.1109/BIA48344.2019.8967457.
34. KOUTNIK, Andrew P.; FAVRE, Michelle E.; NOBOA, Karina; SANCHEZ-GONZALEZ, Marcos A.; MOSS, Sara E.; GOUBRAN, Bishoy; ARI, Csilla; POFF, Angela M.; ROGERS, Chris Q.; DEBLASI, Janine M.; SAMY, Bishoy; MOUSSA, Mark; SERRADOR, Jorge M.; D'AGOSTINO, Dominic P. Human Adaptations to Multiday Saturation on NASA NEEMO. *Frontiers in Physiology* [online]. 2021, roč. 11 [cit. 2021-06-20]. ISSN 1664-042X. Dostupné z DOI: 10.3389/fphys.2020.610000.
35. KJELL LINGREN, NASA Astronaut. *NEEMO 22 Photo Gallery* [online]. 2017. [cit. 2021-06-20]. Dostupné z: <https://www.flickr.com/photos/40054892@N06/albums/72157683015049201>.
36. HYDRONAUT. *H03 DeepLab* [online]. 2020. [cit. 2021-06-23]. Dostupné z: <https://hydronaut.eu/cs>.
37. SÁZEL, Miloš; BOHÁČEK, Pavel. Saturační potápění – projekt Hydronaut. *Occupational Medicine / Pracovní Lékarství* [online]. 2014, roč. 66, č. 2/3, s. 85–89 [cit. 2021-06-20]. ISSN 00326291. Dostupné z: <https://search.ebscohost.com/login.aspx?direct=true&db=a9h&AN=102280881&site=ehost-live&scope=site>.
38. MOORE, Steven; DILDA, Valentina; MORRIS, Tiffany; YUNGHER, Don; MACDOUGALL, Hamish; WOOD, Scott. Long-duration spaceflight adversely affects post-landing operator proficiency. *Scientific Reports* [online]. 2019, roč. 9 [cit. 2021-06-23]. Dostupné z DOI: 10.1038/s41598-019-39058-9.
39. DE LA TORRE, Gabriel G. Cognitive Neuroscience in Space. *Life* [online]. 2014, roč. 4, č. 3, s. 281–294 [cit. 2021-06-23]. ISSN 2075-1729. Dostupné z DOI: 10.3390/life4030281.
40. OMBERGEN, Angelique Van; JILLINGS, Steven; JEURISSEN, Ben; TOMILOVSKAYA, Elena; RUMSHISKAYA, Alena; LITVINOVA, Liudmila; NOSIKOVA, Inna; PECHENKOVA, Ekaterina; RUKAVISHNIKOV, Ilya; MANKO, Olga; DANYLICHÉV, Sergey; RÜHL, R. Maxine; KOZLOVSKAYA, Inessa B.; SUNAERT, Stefan; PARIZEL, Paul M.; SINITSYN, Valentin; LAUREYS, Steven; SIJBERS, Jan; EULENBURG, Peter zu; WUYTS, Floris L. Brain ventricular volume changes induced by long-duration spaceflight. *Proceedings of the National Academy of Sciences* [online]. 2019, roč. 116, č. 21, s. 10531–10536 [cit. 2021-06-23]. Dostupné z DOI: 10.1073/pnas.1820354116.
41. PECHENKOVA, Ekaterina; NOSIKOVA, Inna; RUMSHISKAYA, Alena; LITVINOVA, Liudmila; RUKAVISHNIKOV, Ilya; MERSHINA, Elena; SINITSYN, Valentin; VAN OMBERGEN, Angelique; JEURISSEN, Ben; JILLINGS, Steven; LAUREYS, Steven; SIJBERS, Jan; GRISHIN, Alexey; CHERNIKOVA, Ludmila; NAUMOV, Ivan; KORNILOVA, Ludmila; WUYTS, Floris L.; TOMILOVSKAYA, Elena; KOZLOVSKAYA, Inessa. Alterations of Functional Brain Connectivity After Long-Duration Spaceflight as Revealed by fMRI. *Frontiers in Physiology* [online]. 2019, roč. 10 [cit. 2021-06-23]. ISSN 1664-042X. Dostupné z DOI: 10.3389/fphys.2019.00761.

42. ROBERTS, Donna; ALBRECHT, Moritz; COLLINS, Heather; ASEMANI, Davud; CHATTERJEE, A.; SPAMPINATO, M.; ZHU, Xun; CHIMOWITZ, Marc; ANTONUCCI, Michael. Effects of Spaceflight on Astronaut Brain Structure as Indicated on MRI. *New England Journal of Medicine* [online]. 2017, roč. 377, s. 1746–1753 [cit. 2021-06-23]. Dostupné z DOI: 10.1056/NEJMoa1705129.
43. DEMERTZI, Athena; VAN OMBERGEN, Angelique; TOMILOVSKAYA, Elena; JEURISSEN, Ben; PECHENKOVA, Ekaterina; DI PERRI, Carol; LITVINOVA, Liudmila; AMICO, Enrico; RUMSHISKAYA, A.; RUKAVISHNIKOV, Ilya; SIJBERS, Jan; SINITSYN, Valentin; KOZLOVSKAYA, Inessa; SUNAERT, Stefan; PARIZEL, Paul; VAN DE HEYNING, Paul; LAUREYS, Steven; WUYTS, Floris. Cortical reorganization in an astronaut's brain after long-duration spaceflight. *Brain structure & function* [online]. 2015, roč. 221 [cit. 2021-06-23]. Dostupné z DOI: 10.1007/s00429-015-1054-3.
44. KRAMER, Larry A.; HASAN, Khader M.; STENGER, Michael B.; SARGSYAN, Ashot; LAURIE, Steven S.; OTTO, Christian; PLOUTZ-SNYDER, Robert J.; MARSHALL-GOEBEL, Karina; RIASCOS, Roy F.; MACIAS, Brandon R. Intracranial Effects of Microgravity: A Prospective Longitudinal MRI Study. *Radiology* [online]. 2020, roč. 295, č. 3, s. 640–648 [cit. 2021-06-23]. Dostupné z DOI: 10.1148/radiol.2020191413. PMID: 32286194.
45. CORREIA, Manning J. Neuronal plasticity: adaptation and readaptation to the environment of space. *Brain Research Reviews* [online]. 1998, roč. 28, č. 1, s. 61–65 [cit. 2021-06-23]. ISSN 0165-0173. Dostupné z DOI: [https://doi.org/10.1016/S0165-0173\(98\)00043-5](https://doi.org/10.1016/S0165-0173(98)00043-5).
46. KOPPELMANS, Vincent; BLOOMBERG, Jacob; MULAVARA, Ajitkumar; SEIDLER, Rachael. Brain structural plasticity with spaceflight. *npj Microgravity* [online]. 2016, roč. 2 [cit. 2021-06-23]. Dostupné z DOI: 10.1038/s41526-016-0001-9.
47. KOPPELMANS, Vincent; BLOOMBERG, Jacob J.; DE DIOS, Yiri E.; WOOD, Scott J.; REUTER-LORENZ, Patricia A.; KOFMAN, Igor S.; RIASCOS, Roy; MULAVARA, Ajitkumar P.; SEIDLER, Rachael D. Brain plasticity and sensorimotor deterioration as a function of 70 days head down tilt bed rest. *PLOS ONE* [online]. 2017, roč. 12, č. 8, s. 1–23 [cit. 2021-06-23]. Dostupné z DOI: 10.1371/journal.pone.0182236.
48. HODKINSON, P.D.; ANDERTON, R.A.; POSSELT, B.N.; FONG, K.J. An overview of space medicine. *British Journal of Anaesthesia*. 2017, roč. 119, s. i143–i153. ISSN 0007-0912. Dostupné z DOI: <https://doi.org/10.1093/bja/aex336>.
49. BREM, Christian; LUTZ, Jürgen; VOLLMAR, Christian; FEUERECKER, Matthias; STREWE, Claudia; NICHIPORUK, Igor; VASSILIEVA, Galina; SCHELLING, Gustav; CHOUKÉR, Alexander. Changes of brain DTI in healthy human subjects after 520 days isolation and confinement on a simulated mission to Mars. *Life Sciences in Space Research* [online]. 2020, roč. 24, s. 83–90 [cit. 2021-06-23]. ISSN 2214-5524. Dostupné z DOI: <https://doi.org/10.1016/j.lssr.2019.09.004>.
50. STAHN, Alexander; GUNGA, Hanns-Christian; KOHLBERG, Eberhard; GALLINAT, Jürgen; DINGES, David; KÜHN, Simone. Brain Changes in Response to Long Antarctic Expeditions. *New England Journal of Medicine* [online]. 2019, roč. 381, s. 2273–2275 [cit. 2021-06-23]. Dostupné z DOI: 10.1056/NEJMc1904905.
51. SWELLER, John. Cognitive Load During Problem Solving: Effects on Learning. *Cognitive Science* [online]. 1988, roč. 12, č. 2, s. 257–285 [cit. 2021-06-24]. Dostupné z DOI: https://doi.org/10.1207/s15516709cog1202_4.

52. SWELLER, John; VAN MERRIENBOER, Jeroen J. G.; PAAS, Fred. Cognitive Architecture and Instructional Design. *Educational Psychology Review* [online]. 1998, roč. 10, s. 251– [cit. 2021-06-24]. Dostupné z DOI: 10.1023/a:1022193728205.
53. SWELLER, J. Cognitive load theory: Recent theoretical advances. *Cognitive Load Theory* [online]. 2010, s. 29–47 [cit. 2021-06-24]. Dostupné z DOI: 10.1017/CBO9780511844744.004.
54. CHEN, Fang; ZHOU, Jianlong; WANG, Yang; YU, Kun; ARSHAD, Syed; KHAWAJI, Ahmad; CONWAY, Dan. *Robust Multimodal Cognitive Load Measurement* [online]. 2016. [cit. 2021-06-24]. ISBN 978-3-319-31698-7. Dostupné z DOI: 10.1007/978-3-319-31700-7.
55. HAAPALAINEN, Eija; KIM, SeungJun; FORLIZZI, Jodi F.; DEY, Anind K. Psycho-Physiological Measures for Assessing Cognitive Load. In: *Proceedings of the 12th ACM International Conference on Ubiquitous Computing* [online]. Copenhagen, Denmark: Association for Computing Machinery, 2010, s. 301–310 [cit. 2021-06-24]. UbiComp '10. ISBN 9781605588438. Dostupné z DOI: 10.1145/1864349.1864395.
56. VANNESTE, Pieter; RAES, Annelies; MORTON, Jessica; BOMBEKE, Klaas; VAN ACKER, Bram; LARMUSEAU, Charlotte; DEPAEPE, Fien; VAN DEN NOORTGATE, Wim. Towards measuring cognitive load through multimodal physiological data. *Cognition, Technology & Work* [online]. 2021, roč. 23 [cit. 2021-06-24]. Dostupné z DOI: 10.1007/s10111-020-00641-0.
57. THAYER, Julian F.; HANSEN, Anita L.; SAUS-ROSE, Evelyn; JOHNSEN, Bjorn Helge. Heart Rate Variability, Prefrontal Neural Function, and Cognitive Performance: The Neurovisceral Integration Perspective on Self-regulation, Adaptation, and Health. *Annals of Behavioral Medicine* [online]. 2009, roč. 37, č. 2, s. 141–153 [cit. 2021-06-24]. ISSN 0883-6612. Dostupné z DOI: 10.1007/s12160-009-9101-z.
58. GJORESKI, Martin; LUSTREK, Mitja; GAMS, Matjaz; GJORESKI, Hristijan. Monitoring stress with a wrist device using context. *Journal of Biomedical Informatics*. 2017, roč. 73. Dostupné z DOI: 10.1016/j.jbi.2017.08.006.
59. DE LA CRUZ, Feliberto; SCHUMANN, Andy; KÖHLER, Stefanie; REICHENBACH, Jürgen; WAGNER, Gerd; BÄR, Karl-Jürgen. The relationship between heart rate and functional connectivity of brain regions involved in autonomic control. *NeuroImage*. 2019, roč. 196. Dostupné z DOI: 10.1016/j.neuroimage.2019.04.014.
60. BROUWER, Anne-Marie; ZANDER, Thorsten; ERP, Jan; KORTELING, J.E. (Hans); BRONKHORST, Adelbert. Using neurophysiological signals that reflect cognitive or affective state: Six recommendations to avoid common pitfalls. *Frontiers in Neuroscience*. 2015, roč. 9. Dostupné z DOI: 10.3389/fnins.2015.00136.
61. ANTONENKO, Pavlo "Pasha"; PAAS, Fred; GRABNER, Roland; GOG, Tamara. Using Electroencephalography to Measure Cognitive Load. *Educational Psychology Review*. 2010, roč. 22, s. 425–438. Dostupné z DOI: 10.1007/s10648-010-9130-y.
62. WEL, Pauline; STEENBERGEN, Henk. Pupil dilation as an index of effort in cognitive control tasks: A review. *Psychonomic Bulletin & Review*. 2018, roč. 25. Dostupné z DOI: 10.3758/s13423-018-1432-y.
63. SETZ, Cornelia; ARNRICH, Bert; SCHUMM, Johannes; LA MARCA, Roberto; TRÖSTER, Gerhard; EHLERT, Ulrike. Discriminating Stress From Cognitive Load Using a Wearable EDA Device. *IEEE Transactions on Information Technology in Biomedicine*. 2010, roč. 14, č. 2, s. 410–417. Dostupné z DOI: 10.1109/TITB.2009.2036164.

64. HERBORN, Katherine; GRAVES, James; JEREM, Paul; EVANS, Neil; NAGER, Ruedi; MCCAFFERTY, Dominic; MCKEEGAN, Dorothy. Skin temperature reveals the intensity of acute stress. *Physiology & behavior*. 2015, roč. 152. Dostupné z DOI: 10.1016/j.physbeh.2015.09.032.
65. JERČIĆ, Petar; SENNERSTEN, Charlotte; LINDLEY, Craig. Modeling cognitive load and physiological arousal through pupil diameter and heart rate. *Multimedia Tools and Applications*. 2020, roč. 79. Dostupné z DOI: 10.1007/s11042-018-6518-z.
66. SOLHJOO, Soroosh; HAIGNEY, Mark; MCBEE, Elexis; VAN MERRIENBOER, Jeroen J. G.; SCHUWIRTH, Lambert; ARTINO, Anthony; BATTISTA, Alexis; RATCLIFFE, Temple; LEE, Howard; DURNING, Steven. Heart Rate and Heart Rate Variability Correlate with Clinical Reasoning Performance and Self-Reported Measures of Cognitive Load. *Scientific Reports*. 2019, roč. 9, s. 1–9. Dostupné z DOI: 10.1038/s41598-019-50280-3.
67. GRASSMANN, Mariel; VLEMINCX, Elke; LEUPOLDT, Andreas; MITTELSTÄDT, Justin; VAN DEN BERGH, Omer. Respiratory Changes in Response to Cognitive Load: A Systematic Review. *Neural Plasticity*. 2016, roč. 2016, s. 1–16. Dostupné z DOI: 10.1155/2016/8146809.
68. F., Kramer A. Physiological metrics of mental workload : A review of recent progress. *Multiple-task Performance*. 1991, s. 279–328. Dostupné také z: <https://cir.nii.ac.jp/crid/1572543024796401024>.
69. WANG, Chixiang; GUO, Junqi. A data-driven framework for learners' cognitive load detection using ECG-PPG physiological feature fusion and XGBoost classification. *Procedia Computer Science*. 2019, roč. 147, s. 338–348. ISSN 1877-0509. Dostupné z DOI: 10.1016/j.procs.2019.01.234.
70. SCHNOTZ, Wolfgang; KÜRSCHNER, Christian. A Reconsideration of Cognitive Load Theory. *Educational Psychology Review*. 2007, roč. 19, č. 4, s. 469–508. ISSN 1573-336X. Dostupné z DOI: 10.1007/s10648-007-9053-4.
71. HART, Sandra G. Nasa-Task Load Index (NASA-TLX); 20 Years Later. *Proceedings of the Human Factors and Ergonomics Society Annual Meeting*. 2006, roč. 50, č. 9, s. 904–908. Dostupné z DOI: 10.1177/154193120605000909.
72. GIANNAKAKIS, Giorgos; GRIGORIADIS, Dimitris; GIANNAKAKI, Katerina; SIMANTIRAKI, Olympia; RONIOTIS, Alexandros; TSIKNAKIS, Manolis. Review on Psychological Stress Detection Using Biosignals. *IEEE Transactions on Affective Computing*. 2022, roč. 13, č. 1, s. 440–460. ISSN 1949-3045. Dostupné z DOI: 10.1109/TAFFC.2019.2927337.
73. ISHAQUE, Syem; KHAN, Naimul; KRISHNAN, Sri. Trends in Heart-Rate Variability Signal Analysis. *Frontiers in Digital Health* [online]. 2021, roč. 3 [cit. 2023-02-23]. Dostupné z: <https://www.frontiersin.org/articles/10.3389/fdgth.2021.639444>.
74. ROHILA, Ashish; SHARMA, Ambalika. Correlation between heart rate variability features. *2020 7th International Conference on Signal Processing and Integrated Networks, SPIN 2020*. 2020, s. 669–674. ISBN 9781728154756. Dostupné z DOI: 10.1109/SPIN48934.2020.9071381.
75. PHAM, Tam; LAU, Zen Juen; CHEN, S. H. Annabel; MAKOWSKI, Dominique. Heart rate variability in psychology: A review of hrv indices and an analysis tutorial. *Sensors*. 2021, roč. 21, č. 12. ISSN 14248220. Dostupné z DOI: 10.3390/S21123998.
76. BOUNY, Pierre; ARSAC, Laurent M; TOURÉ CUQ, Emma; DESCHODT-ARSAC, Veronique. Entropy and Multifractal-Multiscale Indices of Heart Rate Time Series to Evaluate Intricate Cognitive-Autonomic Interactions. *Entropy (Basel, Switzerland)*. 2021, roč. 23, č. 6. ISSN 1099-4300. Dostupné z DOI: 10.3390/e23060663.

77. HWANG, Bosun; YOU, Jiwoo; VAESSEN, Thomas; MYIN-GERMEYS, Inez; PARK, Cheolsoo; ZHANG, Byoung-Tak. Deep ECGNet: An Optimal Deep Learning Framework for Monitoring Mental Stress Using Ultra Short-Term ECG Signals. *Telemedicine journal and e-health : the official journal of the American Telemedicine Association* [online]. 2018, roč. 24 10, s. 753–772 [cit. 2023-02-23]. Dostupné z: <https://www.liebertpub.com/doi/full/10.1089/tmj.2017.0250>.
78. HE, Jiayuan; LI, Ke; LIAO, Xiaoli; ZHANG, Ping; JIANG, Ning. Real-Time Detection of Acute Cognitive Stress Using a Convolutional Neural Network From Electrocardiographic Signal. *IEEE Access* [online]. 2019, roč. 7, s. 42710–42717 [cit. 2023-02-23]. Dostupné z DOI: 10.1109/ACCESS.2019.2907076.
79. OSKOOEI, Ali; CHAU, Sophie Mai; WEISS, Jonas R. M.; SRIDHAR, Arvind; MART'INEZ, Mar'ia Rodr'iguez; MICHEL, Bruno. DeStress: Deep Learning for Unsupervised Identification of Mental Stress in Firefighters from Heart-rate Variability (HRV) Data. *ArXiv* [online]. 2019, roč. abs/1911.13213 [cit. 2023-02-23]. Dostupné z: <https://arxiv.org/abs/1911.13213>.
80. CHO, Dongrae; HAM, Jinsil; OH, Jooyoung; PARK, Jeanho; KIM, Sayup; LEE, Nak-Kyu; LEE, Boreom. Detection of Stress Levels from Biosignals Measured in Virtual Reality Environments Using a Kernel-Based Extreme Learning Machine. *Sensors* [online]. 2017, roč. 17, č. 10, s. 2435 [cit. 2023-02-23]. ISSN 1424-8220. Dostupné z DOI: 10.3390/s17102435.
81. APPELHANS, Bradley M.; LUECKEN, Linda J. Heart Rate Variability as an Index of Regulated Emotional Responding. *Review of General Psychology*. 2006, roč. 10, č. 3, s. 229–240. ISSN 1089-2680. Dostupné z DOI: 10.1037/1089-2680.10.3.229.
82. BUTLER, Emily A.; WILHELM, Frank H.; GROSS, James J. Respiratory sinus arrhythmia, emotion, and emotion regulation during social interaction. *Psychophysiology*. 2006, roč. 43, č. 6, s. 612–622. ISSN 1469-8986. Dostupné z DOI: 10.1111/j.1469-8986.2006.00467.x.
83. INGJALDSSON, Jon T; LABERG, Jon C; THAYER, Julian F. Reduced heart rate variability in chronic alcohol abuse: relationship with negative mood, chronic thought suppression, and compulsive drinking. *Biological Psychiatry*. 2003, roč. 54, č. 12, s. 1427–1436. ISSN 0006-3223. Dostupné z DOI: 10.1016/S0006-3223(02)01926-1.
84. LANE, Richard D. Neural Substrates of Implicit and Explicit Emotional Processes: A Unifying Framework for Psychosomatic Medicine. *Psychosomatic Medicine*. 2008, roč. 70, č. 2, s. 214. ISSN 0033-3174. Dostupné z DOI: 10.1097/PSY.0b013e3181647e44.
85. MELZIG, Christiane A.; WEIKE, Almut I.; HAMM, Alfons O.; THAYER, Julian F. Individual differences in fear-potentiated startle as a function of resting heart rate variability: Implications for panic disorder. *International Journal of Psychophysiology*. 2009, roč. 71, č. 2, s. 109–117. ISSN 0167-8760. Dostupné z DOI: 10.1016/j.ijpsycho.2008.07.013.
86. THAYER, Julian F.; BROSSHOT, Jos F. Psychosomatics and psychopathology: looking up and down from the brain. *Psychoneuroendocrinology*. 2005, roč. 30, č. 10, s. 1050–1058. ISSN 0306-4530. Dostupné z DOI: 10.1016/j.psyneuen.2005.04.014.
87. HANSEN, Anita Lill; JOHNSEN, Bjørn Helge; THAYER, Julian F. Vagal influence on working memory and attention. *International Journal of Psychophysiology*. 2003, roč. 48, č. 3, s. 263–274. ISSN 0167-8760. Dostupné z DOI: 10.1016/S0167-8760(03)00073-4.

88. JOHNSEN, Bjørn Helge; THAYER, Julian F; LABERG, Jon C; WORMNES, Bjørn; RAADAL, Magne; SKARET, Erik; KVALE, Gerd; BERG, Einar. Attentional and physiological characteristics of patients with dental anxiety. *Journal of Anxiety Disorders*. 2003, roč. 17, č. 1, s. 75–87. ISSN 0887-6185. Dostupné z DOI: [10.1016/S0887-6185\(02\)00178-0](https://doi.org/10.1016/S0887-6185(02)00178-0).
89. SAUS, Evelyn-Rose; JOHNSEN, Bjørn Helge; EID, Jarle; RIISEM, Per Ketil; ANDERSEN, Rune; THAYER, Julian F. The Effect of Brief Situational Awareness Training in a Police Shooting Simulator: An Experimental Study. *Military Psychology*. 2006, roč. 18, č. sup1, S3–S21. ISSN 0899-5605. Dostupné z DOI: [10.1207/s15327876mp1803s_2](https://doi.org/10.1207/s15327876mp1803s_2).
90. BROSSCHOT, Jos F.; VAN DIJK, Eduard; THAYER, Julian F. Daily worry is related to low heart rate variability during waking and the subsequent nocturnal sleep period. *International Journal of Psychophysiology*. 2007, roč. 63, č. 1, s. 39–47. ISSN 0167-8760. Dostupné z DOI: [10.1016/j.ijpsycho.2006.07.016](https://doi.org/10.1016/j.ijpsycho.2006.07.016).
91. LIAO, Duanping; CARNETHON, Mercedes; EVANS, Gregory W.; CASCIO, Wayne E.; HEISS, Gerardo. Lower Heart Rate Variability Is Associated With the Development of Coronary Heart Disease in Individuals With Diabetes: The Atherosclerosis Risk in Communities (ARIC) Study. *Diabetes*. 2002, roč. 51, č. 12, s. 3524–3531. ISSN 0012-1797. Dostupné z DOI: [10.2337/diabetes.51.12.3524](https://doi.org/10.2337/diabetes.51.12.3524).
92. THAYER, J. F.; FISCHER, J. E. Heart rate variability, overnight urinary norepinephrine and C-reactive protein: evidence for the cholinergic anti-inflammatory pathway in healthy human adults. *Journal of Internal Medicine*. 2009, roč. 265, č. 4, s. 439–447. ISSN 1365-2796. Dostupné z DOI: [10.1111/j.1365-2796.2008.02023.x](https://doi.org/10.1111/j.1365-2796.2008.02023.x).
93. THAYER, Julian F.; LANE, Richard D. The role of vagal function in the risk for cardiovascular disease and mortality. *Biological Psychology*. 2007, roč. 74, č. 2, s. 224–242. ISSN 0301-0511. Dostupné z DOI: [10.1016/j.biopsych.2005.11.013](https://doi.org/10.1016/j.biopsych.2005.11.013).
94. GORMAN, Jack M.; SLOAN, Richard P. Heart rate variability in depressive and anxiety disorders. *American Heart Journal*. 2000, roč. 140, č. 4, Supplement, S77–S83. ISSN 0002-8703. Dostupné z DOI: [10.1067/mhj.2000.109981](https://doi.org/10.1067/mhj.2000.109981).
95. KEMP, Andrew H.; QUINTANA, Daniel S. The relationship between mental and physical health: Insights from the study of heart rate variability. *International Journal of Psychophysiology*. 2013, roč. 89, č. 3, s. 288–296. ISSN 0167-8760. Dostupné z DOI: [10.1016/j.ijpsycho.2013.06.018](https://doi.org/10.1016/j.ijpsycho.2013.06.018).
96. KEMP, Andrew H.; QUINTANA, Daniel S.; FELMINGHAM, Kim L.; MATTHEWS, Slade; JELINEK, Herbert F. Depression, Comorbid Anxiety Disorders, and Heart Rate Variability in Physically Healthy, Unmedicated Patients: Implications for Cardiovascular Risk. *PLOS ONE*. 2012, roč. 7, č. 2, e30777. ISSN 1932-6203. Dostupné z DOI: [10.1371/journal.pone.0030777](https://doi.org/10.1371/journal.pone.0030777).
97. GIANAROS, PJ. Brain-body pathways to cardiovascular disease risk. In: *Herbert Weiner Early Career Award Lecture, 66th Annual Meeting of the American Psychosomatic Society, Baltimore, MD, March*. 2008.
98. BEISSNER, Florian; MEISSNER, Karin; BÄR, Karl-Jürgen; NAPADOW, Vitaly. The Autonomic Brain: An Activation Likelihood Estimation Meta-Analysis for Central Processing of Autonomic Function. *Journal of Neuroscience*. 2013, roč. 33, č. 25, s. 10503–10511. ISSN 0270-6474, ISSN 1529-2401. Dostupné z DOI: [10.1523/JNEUROSCI.1103-13.2013](https://doi.org/10.1523/JNEUROSCI.1103-13.2013).

99. THAYER, Julian F; LANE, Richard D. A model of neurovisceral integration in emotion regulation and dysregulation. *Journal of Affective Disorders*. 2000, roč. 61, č. 3, s. 201–216. ISSN 0165-0327. Dostupné z DOI: 10.1016/S0165-0327(00)00338-4.
100. THAYER, Julian F.; LANE, Richard D. Claude Bernard and the heart–brain connection: Further elaboration of a model of neurovisceral integration. *Neuroscience & Biobehavioral Reviews*. 2009, roč. 33, č. 2, s. 81–88. ISSN 0149-7634. Dostupné z DOI: 10.1016/J.NEUBIOREV.2008.08.004.
101. SHAFFER, Fred; MCCRATY, Rollin; ZERR, Christopher L. A healthy heart is not a metronome: an integrative review of the hearts anatomy and heart rate variability. *Frontiers in psychology*. 2014, roč. 5, s. 1040. ISSN 1664-1078. Dostupné z DOI: 10.3389/fpsyg.2014.01040.
102. RAICHLE, Marcus E.; MACLEOD, Ann Mary; SNYDER, Abraham Z.; POWERS, William J.; GUSNARD, Debra A.; SHULMAN, Gordon L. A default mode of brain function. *Proceedings of the National Academy of Sciences*. 2001, roč. 98, č. 2, s. 676–682. Dostupné z DOI: 10.1073/pnas.98.2.676.
103. NAGAI, Y; CRITCHLEY, H. D; FEATHERSTONE, E; TRIMBLE, M. R; DOLAN, R. J. Activity in ventromedial prefrontal cortex covaries with sympathetic skin conductance level: a physiological account of a “default mode” of brain function. *NeuroImage*. 2004, roč. 22, č. 1, s. 243–251. ISSN 1053-8119. Dostupné z DOI: 10.1016/j.neuroimage.2004.01.019.
104. SMITH, Ryan; THAYER, Julian F.; KHALSA, Sahib S.; LANE, Richard D. The hierarchical basis of neurovisceral integration. *Neuroscience & Biobehavioral Reviews*. 2017, roč. 75, s. 274–296. ISSN 0149-7634. Dostupné z DOI: 10.1016/J.NEUBIOREV.2017.02.003.
105. LUJAN, Matthew R.; PEREZ-POZUELO, Ignacio; GRANDNER, Michael A. Past, Present, and Future of Multisensory Wearable Technology to Monitor Sleep and Circadian Rhythms. *Frontiers in Digital Health*. 2021, roč. 3. ISSN 2673-253X. Dostupné také z: <https://www.frontiersin.org/articles/10.3389/fdgth.2021.721919>.
106. ŠTEJFA, Miloš. *Kardiologie: 3., přepracované a doplněné vydání*. 1. elektronické vydání. Grada, 2006. ISBN 978-80-247-7034-5.
107. WEINHAUS, Anthony J.; ROBERTS, Kenneth P. Anatomy of the Human Heart. In: *Handbook of Cardiac Anatomy, Physiology, and Devices* [online]. Totowa, NJ: Humana Press, 2005, s. 51–79 [cit. 2021-02-27]. ISBN 978-1-58829-443-2. Dostupné z DOI: 10.1007/978-1-59259-835-9_4.
108. ČIHÁK, Radomír. Anatomie 3. In: Třetí, upravené a doplněné vydání. Praha: Grada, 2016, s. 7–79. ISBN 9788024756363.
109. GOLDBERGER, Ary L.; GOLDBERGER, Zachary D.; SHVILKIN, Alexei. Goldberger's Clinical Electrocardiography: A Simplified Approach. In: 9th edition. Philadelphia: Elsevier Inc., 2017. ISBN 9780323508773.
110. PORR, Bernd; HOWELL, Luis. R-peak detector stress test with a new noisy ECG database reveals significant performance differences amongst popular detectors. *bioRxiv* [online]. 2019 [cit. 2023-02-24]. Dostupné z DOI: 10.1101/722397.
111. FATISSON, Julien; OSWALD, Victor; LALONDE, François. Influence diagram of physiological and environmental factors affecting heart rate variability: an extended literature overview. *Heart International*. 2016, roč. 11, e32–e40.
112. HAYANO, Junichiro; YUDA, Emi. Pitfalls of assessment of autonomic function by heart rate variability. *Journal of physiological anthropology*. 2019, roč. 38, č. 1, s. 1–8.

113. BIGGER, J.Thomas; ALBRECHT, Paul; STEINMAN, Richard C.; ROLNITZKY, Linda M.; FLEISS, Joseph L.; COHEN, Richard J. Comparison of time- and frequency domain-based measures of cardiac parasympathetic activity in Holter recordings after myocardial infarction. *The American Journal of Cardiology*. 1989, roč. 64, č. 8, s. 536–538. ISSN 0002-9149. Dostupné z DOI: [https://doi.org/10.1016/0002-9149\(89\)90436-0](https://doi.org/10.1016/0002-9149(89)90436-0).
114. MALIK, M.; CAMM, A. J.; BIGGER, J. T.; BREITHARDT, G.; CERUTTI, S.; COHEN, R. J.; COUMEL, P.; FALLEN, E. L.; KENNEDY, H. L.; KLEIGER, R. E.; LOMBARDI, F.; MALLIANI, A.; MOSS, A. J.; ROTTMAN, J. N.; SCHMIDT, G.; SCHWARTZ, P. J.; SINGER, D. H. Heart rate variability. Standards of measurement, physiological interpretation, and clinical use. *European Heart Journal*. 1996, roč. 17, č. 3, s. 354–381. ISSN 0195668X. Dostupné z DOI: 10.1093/OXFORDJOURNALS.EURHEARTJ.A014868.
115. ACHARYA, U. Rajendra; JOSEPH, K. Paul; KANNATHAL, N.; LIM, Choo Min; SURI, Jasjit S. Heart rate variability: A review. *Medical and Biological Engineering and Computing*. 2006, roč. 44, č. 12, s. 1031–1051. ISSN 01400118. Dostupné z DOI: 10.1007/S11517-006-0119-0.
116. CICCONE, Anthony B.; SIEDLIK, Jacob A.; WECHT, Jill M.; DECKERT, Jake A.; NGUYEN, Nhuquynh D.; WEIR, Joseph P. Reminder: RMSSD and SD1 are identical heart rate variability metrics. *Muscle & Nerve*. 2017, roč. 56, č. 4, s. 674–678. Dostupné z DOI: <https://doi.org/10.1002/mus.25573>.
117. PHAM, Tam; LAU, Zen Juen; SH ANNABEL CHEN, PhD; MAKOWSKI, Dominique. *Unveiling the Structure of Heart Rate Variability (HRV) Indices: A Data-driven Meta-clustering Approach*. PsyArXiv, [b.r.]. Dostupné z DOI: 10.31234/OSF.IO/MWA6X.
118. LEITE, Marcelli R; RAMOS, Ercy Mara C; KALVA-FILHO, Carlos A; RODRIGUES, Fernanda Maria M; FREIRE, Ana Paula CF; TACAO, Guilherme Y; TOLEDO, Alessandra C de; CECÍLIO, Michel J; VANDERLEI, Luiz Carlos M; RAMOS, Dionei. Correlation between heart rate variability indexes and aerobic physiological variables in patients with COPD. *Respirology*. 2015, roč. 20, č. 2, s. 273–278.
119. PENG, Rong-Chao; ZHOU, Xiao-Lin; LIN, Wan-Hua; ZHANG, Yuan-Ting. Extraction of heart rate variability from smartphone photoplethysmograms. *Computational and mathematical methods in medicine*. 2015, roč. 2015.
120. DORMANN, Carsten F; ELITH, Jane; BACHER, Sven; BUCHMANN, Carsten; CARL, Gudrun; CARRÉ, Gabriel; MARQUÉZ, Jaime R García; GRUBER, Bernd; LAFOURCADE, Bruno; LEITÃO, Pedro J et al. Collinearity: a review of methods to deal with it and a simulation study evaluating their performance. *Ecography*. 2013, roč. 36, č. 1, s. 27–46.
121. GUZIK, Przemyslaw; PISKORSKI, Jaroslaw; AWAN, Kokab; KRAUZE, Tomasz; FITZPATRICK, Michael; BARANCHUK, Adrian. Obstructive sleep apnea and heart rate asymmetry microstructure during sleep. *Clinical Autonomic Research*. 2013, roč. 23, s. 91–100.
122. BRENNAN, Michael; PALANISWAMI, Marimuthu; KAMEN, Peter. Poincaré plot interpretation using a physiological model of HRV based on a network of oscillators. *American Journal of Physiology-Heart and Circulatory Physiology*. 2002, roč. 283, č. 5, H1873–H1886. Dostupné z DOI: 10.1152/ajpheart.00405.2000. PMID: 12384465.
123. BOUCSEIN, Wolfram. Electrodermal activity: Second edition. *Electrodermal Activity: Second Edition*. 2012, roč. 9781461411260, s. 1–618. ISBN 9781461411260. Dostupné z DOI: 10.1007/978-1-4614-1126-0.
124. CRITCHLEY, Hugo D. Electrodermal responses: What happens in the brain. *Neuroscientist*. 2002, roč. 8, č. 2, s. 132–142. ISSN 10738584. Dostupné z DOI: 10.1177/107385840200800209.

125. TRONSTAD, Christian; AMINI, Maryam; BACH, Dominik R; MARTINSEN, Ørjan G. Current trends and opportunities in the methodology of electrodermal activity measurement. *Physiological Measurement*. 2022, roč. 43, č. 2, 02TR01. ISSN 0967-3334. Dostupné z DOI: [10.1088/1361-6579/AC5007](https://doi.org/10.1088/1361-6579/AC5007).
126. FREDRIKSON, Mats; FURMARK, Tomas; OLSSON, Maria Tillfors; FISCHER, Håkan; ANDERSSON, Jesper; LÅNGSTRÖM, Bengt. Functional neuroanatomical correlates of electrodermal activity: A positron emission tomographic study. *Psychophysiology*. 1998, roč. 35, č. 2, s. 179–185. ISSN 1469-8986, ISSN 0048-5772. Dostupné z DOI: [10.1111/1469-8986.3520179](https://doi.org/10.1111/1469-8986.3520179).
127. BUCHWALD, Mikolaj; KUPINSKI, Szymo; BYKOWSKI, Adam; MARCINKOWSKA, Joanna; RATAJCZYK, Dawid; JUKIEWICZ, Marcin. Electrodermal activity as a measure of cognitive load: A methodological approach. *Signal Processing - Algorithms, Architectures, Arrangements, and Applications Conference Proceedings, SPA*. 2019, roč. 2019-September, s. 175–179. ISBN 9788362065363. ISSN 23260319. Dostupné z DOI: [10.23919/SPA.2019.8936745](https://doi.org/10.23919/SPA.2019.8936745).
128. CARUELLE, Delphine; GUSTAFSSON, Anders; SHAMS, Poja; LERVIK-OLSEN, Line. The use of electrodermal activity (EDA) measurement to understand consumer emotions – A literature review and a call for action. *Journal of Business Research*. 2019, roč. 104, s. 146–160. ISSN 01482963. Dostupné z DOI: [10.1016/J.JBUSRES.2019.06.041](https://doi.org/10.1016/J.JBUSRES.2019.06.041).
129. SÁNCHEZ-REOLID, Roberto; LÓPEZ, María T.; FERNÁNDEZ-CABALLERO, Antonio. Machine Learning for Stress Detection from Electrodermal Activity: A Scoping Review. 2020. Dostupné z DOI: [10.20944/PREPRINTS202011.0043.V1](https://doi.org/10.20944/PREPRINTS202011.0043.V1).
130. BLECHERT, Jens; PEYK, Peter; LIEDLGRUBER, Michael; WILHELM, Frank H. ANSLAB: Integrated multichannel peripheral biosignal processing in psychophysiological science. *Behavior Research Methods*. 2016, roč. 48, č. 4, s. 1528–1545. ISSN 1554-3528. Dostupné z DOI: [10.3758/s13428-015-0665-1](https://doi.org/10.3758/s13428-015-0665-1).
131. BAHAUDDIN SIKDER, Md Saif Bin; MD. SALIMULLAH, Shah; AHMED, Inkeyad; HOSSAIN, Delowar; RAJIB, Moshiul Alam; WADUD, Kishwar. Galvanic Skin Response Based Cognitive Load Measurement for Online Exams. *2021 5th International Conference on Electrical Information and Communication Technology, EICT 2021*. 2021. ISBN 9781665409063. Dostupné z DOI: [10.1109/EICT54103.2021.9733564](https://doi.org/10.1109/EICT54103.2021.9733564).
132. GHADERYAN, Peyvand; ABBASI, Ataollah; EBRAHIMI, Afshin. Time-varying singular value decomposition analysis of electrodermal activity: A novel method of cognitive load estimation. *Measurement*. 2018, roč. 126, s. 102–109. ISSN 0263-2241. Dostupné z DOI: [10.1016/J.MEASUREMENT.2018.05.015](https://doi.org/10.1016/J.MEASUREMENT.2018.05.015).
133. HOSSAIN, Delowar; SALIMULLAH, Shah Md; CHOWDHURY, Abrar Nayeem; NESHAD HASAN, Syed Md; KABIR, Erfan; MAHMUDI, Rahi; ISLAM, Mahbubul. Measurement of cognitive load for writing tasks using galvanic skin response. *ACM International Conference Proceeding Series*. 2019, s. 122–126. ISBN 9781450376990. Dostupné z DOI: [10.1145/3362966.3362976](https://doi.org/10.1145/3362966.3362976).
134. NOURBAKHSH, Nargess; WANG, Yang; CHEN, Fang; CALVO, Rafael A. Using Galvanic Skin Response for Cognitive Load Measurement in Arithmetic and Reading Tasks. *Proceedings of the 24th Australian Computer-Human Interaction Conference on - OzCHI '12*. 2012. ISBN 9781450314381. Dostupné z DOI: [10.1145/2414536](https://doi.org/10.1145/2414536).

135. PAAS, Fred; TUOVINEN, Juhani E.; TABBERS, Huib; VAN GERVEN, Pascal W.M. Cognitive load measurement as a means to advance cognitive load theory. *Educational Psychologist*. 2003, roč. 38, č. 1, s. 63–71. ISSN 00461520. Dostupné z DOI: 10.1207/S15326985EP3801_8.
136. POSADA-QUINTERO, Hugo F.; FLORIAN, John P.; ORJUELA-CAÑÓN, Alvaro D.; CHON, Ki H. Electrodermal activity is sensitive to cognitive stress under water. *Frontiers in Physiology*. 2018, roč. 8, č. JAN, s. 1128. ISSN 1664042X. Dostupné z DOI: 10.3389/FPHYS.2017.01128/BIBTEX.
137. SHI, Yu; RUIZ, Natalie; TAIB, Ronnie; CHOI, Eric; CHEN, Fang. Galvanic skin response (GSR) as an index of cognitive load. *Conference on Human Factors in Computing Systems - Proceedings*. 2007, s. 2651–2656. ISBN 1595936424. Dostupné z DOI: 10.1145/1240866.1241057.
138. SHIMOMURA, Yoshihiro; YODA, Takumi; SUGIURA, Koji; HORIZUCHI, Akinori; IWANAGA, Koichi; KATSUURA, Tetsuo. Use of frequency domain analysis of skin conductance for evaluation of mental workload. *Journal of Physiological Anthropology*. 2008, roč. 27, č. 4, s. 173–177. ISSN 18806791. Dostupné z DOI: 10.2114/JPA2.27.173.
139. KARA ROGERS SENIOR EDITOR, B.S. *The Respiratory System*. Britannica Educational Pub., 2010. The Human Body. ISBN 978-1-61530-147-8. Dostupné také z: <https://books.google.cz/books?id=jo5ETXP1WGYC>.
140. AYRES, Paul; LEE, Joy Yeonjoo; PAAS, Fred; MERRIËNBOER, Jeroen J. G. van. The Validity of Physiological Measures to Identify Differences in Intrinsic Cognitive Load. *Frontiers in Psychology*. 2021, roč. 12. ISSN 1664-1078. Dostupné také z: <https://www.frontiersin.org/articles/10.3389/fpsyg.2021.702538>.
141. MIRVIS, David M; GOLDBERGER, Ary L. Electrocardiography. *Heart disease*. 2001, roč. 1, s. 82–128. Dostupné také z: <http://www.doctor33.it/cont/download-center-files/17519/cap-electrocardiography-x20968allp1.pdf>.
142. YAO, Qihang; WANG, Ruxin; FAN, Xiaomao; LIU, Jikui; LI, Ye. Multi-class Arrhythmia detection from 12-lead varied-length ECG using Attention-based Time-Incremental Convolutional Neural Network. *Information Fusion*. 2020, roč. 53, s. 174–182. ISSN 1566-2535. Dostupné z DOI: 10.1016/j.inffus.2019.06.024.
143. BAIG, Mirza Mansoor; GHOLAMHOSSEINI, Hamid; CONNOLLY, Martin J. A comprehensive survey of wearable and wireless ECG monitoring systems for older adults. *Medical & Biological Engineering & Computing*. 2013, roč. 51, č. 5, s. 485–495. ISSN 1741-0444. Dostupné z DOI: 10.1007/s11517-012-1021-6.
144. MAJUMDER, Sumit; CHEN, Leon; MARINOV, Ognian; CHEN, Chih-Hung; MONDAL, Tapas; DEEN, M. Jamal. Noncontact Wearable Wireless ECG Systems for Long-Term Monitoring. *IEEE Reviews in Biomedical Engineering*. 2018, roč. 11, s. 306–321. ISSN 1941-1189. Dostupné z DOI: 10.1109/RBME.2018.2840336.
145. SERHANI, Mohamed Adel; T. EL KASSABI, Hadeel; ISMAIL, Heba; NUJUM NAVAZ, Alramzana. ECG Monitoring Systems: Review, Architecture, Processes, and Key Challenges. *Sensors*. 2020, roč. 20, č. 66, s. 1796. ISSN 1424-8220. Dostupné z DOI: 10.3390/s20061796.
146. DOOREN, Marieke van; VRIES, J. J. G. (Gert-Jan) de; JANSSEN, Joris H. Emotional sweating across the body: Comparing 16 different skin conductance measurement locations. *Physiology & Behavior*. 2012, roč. 106, č. 2, s. 298–304. ISSN 0031-9384. Dostupné z DOI: 10.1016/j.physbeh.2012.01.020.

147. VAVRINSKY, Erik; STOPJAKOVA, Viera; KOPANI, Martin; KOSNACOVA, Helena. The Concept of Advanced Multi-Sensor Monitoring of Human Stress. *Sensors*. 2021, roč. 21, č. 1010, s. 3499. ISSN 1424-8220. Dostupné z DOI: [10.3390/s21103499](https://doi.org/10.3390/s21103499).
148. LI, Shanshi; SUNG, Billy; LIN, Yuxia; MITAS, Ondrej. Electrodermal activity measure: A methodological review. *Annals of Tourism Research*. 2022, roč. 96, s. 103460. ISSN 0160-7383. Dostupné z DOI: [10.1016/j.annals.2022.103460](https://doi.org/10.1016/j.annals.2022.103460).
149. POSADA-QUINTERO, Hugo F.; CHON, Ki H. Innovations in Electrodermal Activity Data Collection and Signal Processing: A Systematic Review. *Sensors*. 2020, roč. 20, č. 22, s. 479. ISSN 1424-8220. Dostupné z DOI: [10.3390/s20020479](https://doi.org/10.3390/s20020479).
150. MASSARONI, Carlo; NICOLÒ, Andrea; LO PRESTI, Daniela; SACCHETTI, Massimo; SILVESTRI, Sergio; SCHENA, Emiliano. Contact-Based Methods for Measuring Respiratory Rate. *Sensors*. 2019, roč. 19, č. 44, s. 908. ISSN 1424-8220. Dostupné z DOI: [10.3390/s19040908](https://doi.org/10.3390/s19040908).
151. MASSARONI, Carlo; NICOLÒ, Andrea; SACCHETTI, Massimo; SCHENA, Emiliano. Contactless Methods for Measuring Respiratory Rate: A Review. *IEEE Sensors Journal*. 2021, roč. 21, č. 11, s. 12821–12839. ISSN 15581748. Dostupné z DOI: [10.1109/JSEN.2020.3023486](https://doi.org/10.1109/JSEN.2020.3023486).
152. LIU, Haipeng; ALLEN, John; ZHENG, Dingchang; CHEN, Fei. Recent development of respiratory rate measurement technologies. *Physiological Measurement*. 2019, roč. 40, č. 7, 07TR01. ISSN 0967-3334. Dostupné z DOI: [10.1088/1361-6579/ab299e](https://doi.org/10.1088/1361-6579/ab299e).
153. DE FAZIO, Roberto; STABILE, Marco; DE VITTORIO, Massimo; VELÁZQUEZ, Ramiro; VISCONTI, Paolo. An Overview of Wearable Piezoresistive and Inertial Sensors for Respiration Rate Monitoring. *Electronics*. 2021, roč. 10, č. 1717, s. 2178. ISSN 2079-9292. Dostupné z DOI: [10.3390/electronics10172178](https://doi.org/10.3390/electronics10172178).
154. LEUBE, Julian; ZSCHOCKE, Johannes; KLUGE, Maria; PELIKAN, Luise; GRAF, Antonia; GLOS, Martin; MÜLLER, Alexander; BARTSCH, Ronny P.; PENZEL, Thomas; KANTELHARDT, Jan W. Reconstruction of the respiratory signal through ECG and wrist accelerometer data. *Scientific Reports*. 2020, roč. 10, č. 11, s. 14530. ISSN 2045-2322. Dostupné z DOI: [10.1038/s41598-020-71539-0](https://doi.org/10.1038/s41598-020-71539-0).
155. NAM, Seungyoon; BAUTISTA, John Lorenzo; HAHM, Chanyoung; SHIN, Hyunsoon. Recognition of Respiratory Instability using a Photoplethysmography of Wrist-watch type Wearable Device. *IEIE Transactions on Smart Processing & Computing*. 2022, roč. 11, č. 2, s. 97–104.
156. ZSCHOCKE, Johannes; LEUBE, Julian; GLOS, Martin; SEMYACHKINA-GLUSHKOVSAYA, Oxana; PENZEL, Thomas; BARTSCH, Ronny P.; KANTELHARDT, Jan W. Reconstruction of Pulse Wave and Respiration From Wrist Accelerometer During Sleep. *IEEE Transactions on Biomedical Engineering*. 2022, roč. 69, č. 2, s. 830–839. ISSN 1558-2531. Dostupné z DOI: [10.1109/TBME.2021.3107978](https://doi.org/10.1109/TBME.2021.3107978).
157. ESCABÍ, Monty A. 10 - BIOSIGNAL PROCESSING. In: *Introduction to Biomedical Engineering (Second Edition)*. Ed. ENDERLE, John D.; BLANCHARD, Susan M.; BRONZINO, Joseph D. Boston: Academic Press, 2005, s. 549–625. Biomedical Engineering. ISBN 978-0-12-238662-6. Dostupné z DOI: [10.1016/B978-0-12-238662-6.50012-4](https://doi.org/10.1016/B978-0-12-238662-6.50012-4).
158. KARAGIANNIS, Alexandros; CONSTANTINOU, Philip; VOUYIOUKAS, Demosthenes; KARAGIANNIS, Alexandros; CONSTANTINOU, Philip; VOUYIOUKAS, Demosthenes. *Biomedical Time Series Processing and Analysis Methods: The Case of Empirical Mode Decomposition*. IntechOpen, 2011. ISBN 978-953-307-555-6. Dostupné z DOI: [10.5772/20906](https://doi.org/10.5772/20906).

159. KHODADAD, D.; NORDEBO, S.; MÜLLER, B.; WALDMANN, A.; YERWORTH, R.; BECHER, T.; FRERICHS, I.; SOPHOCLEOUS, L.; KAAM, A. van; MIEDEMA, M.; SEIFNARAGHI, N.; BAYFORD, R. Optimized breath detection algorithm in electrical impedance tomography. *Physiological Measurement*. 2018, roč. 39, č. 9, s. 094001. ISSN 0967-3334. Dostupné z DOI: 10.1088/1361-6579/aad7e6.
160. POWER, Jonathan D.; LYNCH, Charles J.; DUBIN, Marc J.; SILVER, Benjamin M.; MARTIN, Alex; JONES, Rebecca M. Characteristics of respiratory measures in young adults scanned at rest, including systematic changes and “missed” deep breaths. *NeuroImage*. 2020, roč. 204, s. 116234. ISSN 1053-8119. Dostupné z DOI: 10.1016/j.neuroimage.2019.116234.
161. SUBRAMANIAN, Sandya; BARBIERI, Riccardo; BROWN, Emery N. A Systematic Method for Preprocessing and Analyzing Electrodermal Activity. In: *2019 41st Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC)*. 2019, s. 6902–6905. ISSN 1558-4615. Dostupné z DOI: 10.1109/EMBC.2019.8857757.
162. KRISHNAN, Sridhar; ATHAVALE, Yashodhan. Trends in biomedical signal feature extraction. *Biomedical Signal Processing and Control*. 2018, roč. 43, s. 41–63. ISSN 1746-8094. Dostupné z DOI: 10.1016/j.bspc.2018.02.008.
163. FOSTER, Kenneth R.; KOPROWSKI, Robert; SKUFCA, Joseph D. Machine learning, medical diagnosis, and biomedical engineering research - commentary. *BioMedical Engineering OnLine*. 2014, roč. 13, č. 1, s. 94. ISSN 1475-925X. Dostupné z DOI: 10.1186/1475-925X-13-94.
164. KORDING, Konrad Paul; BENJAMIN, Ari S.; FARHOODI, Roozbeh; GLASER, Joshua I. *The Roles of Machine Learning in Biomedical Science*. National Academies Press (US), 2018. Dostupné také z: <https://www.ncbi.nlm.nih.gov/books/NBK481619/>.
165. STRZELECKI, Michał; BADURA, Paweł. Machine Learning for Biomedical Application. *Applied Sciences*. 2022, roč. 12, č. 44, s. 2022. ISSN 2076-3417. Dostupné z DOI: 10.3390/app12042022.
166. GERON, Aurelien. *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems*. 3rd. O'Reilly Media, Inc., 2022. ISBN 9781098125974.
167. MURPHY, Kevin P. *Machine Learning: A Probabilistic Perspective*. The MIT Press, 2012. ISBN 0262018020.
168. GOODFELLOW, Ian; BENGIO, Yoshua; COURVILLE, Aaron. *Deep Learning*. MIT Press, 2016. <http://www.deeplearningbook.org>.
169. *Plot with polygons, ellipses, squares and rectangles* [online]. 2019. [cit. 2022-06-18]. Dostupné z: <https://tex.stackexchange.com/a/507813/289947>.
170. EFRON, Bradley; TIBSHIRANI, R. J. *An Introduction to the Bootstrap*. 1st edition. New York: Chapman a Hall/CRC, 1993. ISBN 978-0-412-04231-7.
171. ANGUITA, Davide; GHIO, Alessandro; ONETO, Luca; PARRA, Xavier; REYES-ORTIZ, Jorge Luis et al. A public domain dataset for human activity recognition using smartphones. In: *Esann*. 2013, sv. 3, s. 3.
172. KOHAVI, Ron. A study of cross-validation and bootstrap for accuracy estimation and model selection. In: *Proceedings of the 14th international joint conference on Artificial intelligence - Volume 2*. San Francisco, CA, USA: Morgan Kaufmann Publishers Inc., 1995, s. 1137–1143. IJCAI'95. ISBN 978-1-55860-363-9.

173. GHOJOGH, Benyamin; CROWLEY, Mark. *The Theory Behind Overfitting, Cross Validation, Regularization, Bagging, and Boosting: Tutorial*. arXiv, 2019. Dostupné z DOI: 10.48550/ARXIV.1905.12787.
174. *Adding text to a graphic in tikz* [online]. 2020. [cit. 2022-06-18]. Dostupné z: <https://tex.stackexchange.com/a/562199/289947>.
175. LIASHCHYNSKYI, Petro; LIASHCHYNSKYI, Pavlo. Grid Search, Random Search, Genetic Algorithm: A Big Comparison for NAS. *CoRR*. 2019, roč. abs/1912.06059. Dostupné z arXiv: 1912.06059.
176. ANGGORO, Dimas Aryo; MUKTI, Salsa Sasmita. Performance Comparison of Grid Search and Random Search Methods for Hyperparameter Tuning in Extreme Gradient Boosting Algorithm to Predict Chronic Kidney Failure. *Int. J. Intell. Eng. Syst.* 2021, roč. 14, č. 6, s. 198–207.
177. BERGSTRA, James; BENGIO, Yoshua. Random search for hyper-parameter optimization. *The Journal of Machine Learning Research*. 2012, roč. 13, č. null, s. 281–305. ISSN 1532-4435.
178. ALIBRAHIM, Hussain; LUDWIG, Simone A. Hyperparameter Optimization: Comparing Genetic Algorithm against Grid Search and Bayesian Optimization. In: *2021 IEEE Congress on Evolutionary Computation (CEC)*. 2021, s. 1551–1559. Dostupné z DOI: 10.1109/CEC45853.2021.9504761.
179. PARKER, Wendy S. Ensemble modeling, uncertainty and robust predictions. *WIREs Climate Change*. 2013, roč. 4, č. 3, s. 213–223. Dostupné z DOI: <https://doi.org/10.1002/wcc.220>.
180. SUZUKI, Kenji. *Artificial Neural Networks - Architectures and Applications*. 2013. ISBN 978-953-51-0935-8. Dostupné z DOI: 10.5772/3409.
181. *Plotting the gradient descent?* [online]. 2019. [cit. 2022-06-18]. Dostupné z: <https://tex.stackexchange.com/questions/497165/plotting-the-gradient-descent>.
182. SHARMA, Sagar; SHARMA, Simone; ATHAIYA, Anidhya. Activation functions in neural networks. *Towards Data Sci* [online]. 2017, roč. 6, č. 12, s. 310–316 [cit. 2022-06-24]. Dostupné z: https://www.ijeast.com/papers/310-316_Tesma412_IJEAST.pdf.
183. *How to format table with images?* [online]. 2018. [cit. 2022-06-18]. Dostupné z: <https://tex.stackexchange.com/questions/431200/how-to-format-table-with-images>.
184. NAIR, Vinod; HINTON, Geoffrey E. Rectified linear units improve restricted boltzmann machines. In: *Proceedings of the 27th International Conference on International Conference on Machine Learning*. Madison, WI, USA: Omnipress, 2010, s. 807–814. ICML’10. ISBN 978-1-60558-907-7. Dostupné také z: <https://dl.acm.org/doi/10.5555/3104322.3104425>.
185. *Modicon Modbus Protocol Reference Guide*. U.S.A, North Andover, Massachusetts, 1996. Dostupné také z: https://modbus.org/docs/PI_MBUS_300.pdf.
186. SCHMIDT, Philip; REISS, Attila; DUERICHE, Robert; MARBERGER, Claus; VAN LAERHOVEN, Kristof. Introducing WESAD, a Multimodal Dataset for Wearable Stress and Affect Detection. In: *Proceedings of the 20th ACM International Conference on Multimodal Interaction* [online]. Boulder, CO, USA: Association for Computing Machinery, 2018, s. 400–408 [cit. 2021-06-18]. ICMI ’18. ISBN 9781450356923. Dostupné z DOI: 10.1145/3242969.3242985.
187. MARKOVA, Valentina; GANCHEV, Todor; KALINKOV, Kalin. CLAS: A Database for Cognitive Load, Affect and Stress Recognition. In: *2019 International Conference on Biomedical Innovations and Applications (BIA)* [online]. 2019, s. 1–4 [cit. 2021-06-18]. Dostupné z DOI: 10.1109/BIA48344.2019.8967457.

188. KALIDAS, Vignesh; TAMIL, Lakshman. Real-time QRS detector using Stationary Wavelet Transform for Automated ECG Analysis. In: *2017 IEEE 17th International Conference on Bioinformatics and Bioengineering (BIBE)* [online]. 2017, s. 457–461 [cit. 2021-06-18]. Dostupné z DOI: 10.1109/BIBE.2017.00-12.
189. PAN, Jiapu; TOMPKINS, Willis J. A Real-Time QRS Detection Algorithm. *IEEE Transactions on Biomedical Engineering* [online]. 1985, roč. BME-32, č. 3, s. 230–236 [cit. 2021-06-24]. Dostupné z DOI: 10.1109/TBME.1985.325532.
190. NASON, G. P.; SILVERMAN, B. W. The Stationary Wavelet Transform and some Statistical Applications. In: *Wavelets and Statistics*. Ed. ANTONIADIS, Anestis; OPPENHEIM, Georges. New York, NY: Springer, 1995, s. 281–299. Lecture Notes in Statistics. ISBN 978-1-4612-2544-7. Dostupné z DOI: 10.1007/978-1-4612-2544-7_17.
191. GOLDBERGER, A. L.; AMARAL, L. A. N.; GLASS, L.; HAUSDORFF, J. M.; IVANOV, P. Ch.; MARK, R. G.; MIETUS, J. E.; MOODY, G. B.; PENG, C.-K.; STANLEY, H. E. PhysioBank, PhysioToolkit, and PhysioNet: Components of a New Research Resource for Complex Physiologic Signals. *Circulation*. 2000, roč. 101, č. 23, e215–e220. Circulation Electronic Pages: <http://circ.ahajournals.org/content/101/23/e215.full> PMID:1085218; doi: 10.1161/01.CIR.101.23.e215.
192. MOODY, G.B.; MARK, R.G. The impact of the MIT-BIH Arrhythmia Database. *IEEE Engineering in Medicine and Biology Magazine* [online]. 2001, roč. 20, č. 3, s. 45–50 [cit. 2021-06-18]. Dostupné z DOI: 10.1109/51.932724.
193. THE BETH ISRAEL DEACONESS MEDICAL CENTER, The Arrhythmia Laboratory. *The MIT-BIH Normal Sinus Rhythm Database*. physionet.org, 1990. Dostupné z DOI: 10.13026/C2NK5R.
194. HOWELL, L.; PORR, B. *High precision ECG Database with annotated R peaks, recorded and filmed under realistic conditions* [online]. 2018. [cit. 2021-06-18]. Dostupné z DOI: 10.5525/gla.researchdata.716. University of Glasgow.
195. IYENGAR, N.; PENG, C. K.; MORIN, R.; GOLDBERGER, A. L.; LIPSITZ, L. A. Age-related alterations in the fractal scaling of cardiac interbeat interval dynamics. *American Journal of Physiology-Regulatory, Integrative and Comparative Physiology* [online]. 1996, roč. 271, č. 4, R1078–R1084 [cit. 2021-06-18]. Dostupné z DOI: 10.1152/ajpregu.1996.271.4.R1078. PMID: 8898003.
196. KALYAKULINA, Alena; YUSIPOV, Igor; MOSKALENKO, Viktor; NIKOLSKIY, Alexander; KOSONOGOV, Konstantin; OSIPOV, Gregory; ZOLOTYKH, Nikolai; IVANCHENKO, Mikhail. LUDB: A New Open-Access Validation Tool for Electrocardiogram Delineation Algorithms. *IEEE Access* [online]. 2020, roč. 8, s. 186181–186190 [cit. 2021-06-18]. Dostupné z DOI: 10.1109/ACCESS.2020.3029211.
197. VOLLMER, M.; BLÄSING, D.; REISER, J. E.; NISSER, M.; BUDER, A. *Simultaneous physiological measurements with five devices at different cognitive and physical loads (version 1.0.0)* [online]. 2020. [cit. 2021-06-18]. Dostupné z DOI: 10.13026/chd5-t946. PhysioNet.
198. MEHRGARDT, P.; KHUSHI, M.; POON, S.; WITHANA, A. *Pulse Transit Time PPG Dataset (version 1.1.0)* [online]. 2022. [cit. 2021-06-18]. Dostupné z DOI: 10.13026/jpan-6n92. PhysioNet.

199. HALEM, Sjoerd van; ROEKEL, Eeske van; KROENCKE, Lara; KUPER, Niclas; DENISSEN, Jaap. Moments that Matter? On the Complexity of using Triggers Based on Skin Conductance to Sample Arousing Events within an Experience Sampling Framework. *European Journal of Personality* [online]. 2020, roč. 34, č. 5, s. 794–807 [cit. 2021-06-18]. Dostupné z DOI: 10.1002/per.2252.
200. POSADA-QUINTERO, Hugo; FLORIAN, John; ORJUELA-CAÑÓN, Alvaro; CORRALES, Tomás; CHARLESTON-VILLALOBOS, Sonia; CHON, Kaye. Power Spectral Density Analysis of Electrodermal Activity for Sympathetic Function Assessment. *Annals of Biomedical Engineering* [online]. 2016, roč. 44 [cit. 2021-06-18]. Dostupné z DOI: 10.1007/s10439-016-1606-6.
201. CASTALDO, R.; MONTESINOS, L.; MELILLO, P.; JAMES, C.; PECCHIA, L. Ultra-short term HRV features as surrogates of short term HRV: a case study on mental stress detection in real life. *BMC Medical Informatics and Decision Making*. 2019, roč. 19, č. 1, s. 12. ISSN 1472-6947. Dostupné z DOI: 10.1186/s12911-019-0742-y.
202. KIM, Jin Woong; SEOK, Hyeyon Seok; SHIN, Hangsik. Is Ultra-Short-Term Heart Rate Variability Valid in Non-static Conditions? *Frontiers in Physiology*. 2021, roč. 12. ISSN 1664-042X. Dostupné také z: <https://www.frontiersin.org/articles/10.3389/fphys.2021.596060>.
203. PECCHIA, Leandro; CASTALDO, Rossana; MONTESINOS, Luis; MELILLO, Paolo. Are ultra-short heart rate variability features good surrogates of short-term ones? State-of-the-art review and recommendations. *Healthcare Technology Letters*. 2018, roč. 5, č. 3, s. 94–100. ISSN 2053-3713. Dostupné z DOI: 10.1049/htl.2017.0090.
204. SHAFFER, Fred; MEEHAN, Zachary M.; ZERR, Christopher L. A Critical Review of Ultra-Short-Term Heart Rate Variability Norms Research. *Frontiers in Neuroscience*. 2020, roč. 14. ISSN 1662-453X. Dostupné také z: <https://www.frontiersin.org/articles/10.3389/fnins.2020.594880>.
205. TERVONEN, Jaakko; PETTERSSON, Kati; MÄNTYJÄRVI, Jani. Ultra-Short Window Length and Feature Importance Analysis for Cognitive Load Detection from Wearable Sensors. *Electronics*. 2021, roč. 10, č. 55, s. 613. ISSN 2079-9292. Dostupné z DOI: 10.3390/electronics10050613.
206. ZHAO, Zhidong; ZHANG, Yefei. SQI Quality Evaluation Mechanism of Single-Lead ECG Signal Based on Simple Heuristic Fusion and Fuzzy Comprehensive Evaluation. *Frontiers in Physiology*. 2018, roč. 9. ISSN 1664-042X. Dostupné také z: <https://www.frontiersin.org/articles/10.3389/fphys.2018.00727>.
207. PEREIRA, Tânia; ALMEIDA, Pedro R.; CUNHA, João P. S.; AGUIAR, Ana. Heart rate variability metrics for fine-grained stress level assessment. *Computer Methods and Programs in Biomedicine*. 2017, roč. 148, s. 71–80. ISSN 0169-2607. Dostupné z DOI: 10.1016/j.cmpb.2017.06.018.
208. SHAFFER, Fred; GINSBERG, J. P. An Overview of Heart Rate Variability Metrics and Norms. *Frontiers in Public Health*. 2017, roč. 5. ISSN 2296-2565. Dostupné také z: <https://www.frontiersin.org/articles/10.3389/fpubh.2017.00258>.
209. GENT, Paul van; FARAH, Haneen; NES, Nicole van; AREM, Bart van. HeartPy: A novel heart rate algorithm for the analysis of noisy signals. *Transportation Research Part F: Traffic Psychology and Behaviour*. 2019, roč. 66, s. 368–378. ISSN 1369-8478. Dostupné z DOI: 10.1016/j.trf.2019.09.015.

210. MCINNES, Leland; HEALY, John; MELVILLE, James. *UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction* [online]. arXiv, 2018 [cit. 2021-06-24]. Dostupné z DOI: 10.48550/ARXIV.1802.03426.
211. BATISTA, Gustavo; BAZZAN, Ana; MONARD, Maria-Carolina. Balancing Training Data for Automated Annotation of Keywords: a Case Study. In: *WOB*. 2003, s. 18.
212. CHAWLA, N. V.; BOWYER, K. W.; HALL, L. O.; KEGELMEYER, W. P. SMOTE: Synthetic Minority Over-sampling Technique. *Journal of Artificial Intelligence Research*. 2002, roč. 16, s. 321–357. ISSN 1076-9757. Dostupné z DOI: 10.1613/jair.953.
213. SCHINDLER, Katerina. *Granger Lasso Causal Models in Higher Dimensions - Application to Gene Expression Regulatory Networks*. 2013.
214. *Decision Making: Uncertainty, Imperfection, Deliberation and Scalability*. Softcover reprint of the original 1st ed. 2015 edition. Springer, 2016. ISBN 978-3-319-35020-2.
215. LIU, Yan; BAHADORI, Taha; LI, Hongfei. Sparse-GEV: Sparse Latent Space Model for Multivariate Extreme Value Time Serie Modeling. 2012, č. arXiv:1206.4685. Dostupné z DOI: 10.48550/arXiv.1206.4685.
216. WANG, Zhiguang; OATES, Tim. Imaging Time-Series to Improve Classification and Imputation. 2015, č. arXiv:1506.00327. Dostupné z DOI: 10.48550/arXiv.1506.00327.
217. MAZZIA, Vittorio; SALVETTI, Francesco; CHIABERGE, Marcello. Efficient-CapsNet: capsule network with self-attention routing. *Scientific Reports*. 2021, roč. 11, č. 11, s. 14634. ISSN 2045-2322. Dostupné z DOI: 10.1038/s41598-021-93977-0.
218. ZHOU, Houliang; KAN, Chen. Tensor-Based ECG Anomaly Detection toward Cardiac Monitoring in the Internet of Health Things. *Sensors*. 2021, roč. 21, č. 1212, s. 4173. ISSN 1424-8220. Dostupné z DOI: 10.3390/s21124173.
219. HINTON, Geoffrey E.; KRIZHEVSKY, Alex; WANG, Sida D. Transforming Auto-Encoders. In: HONKELA, Timo; DUCH, Włodzisław; GIROLAMI, Mark; KASKI, Samuel (ed.). *Artificial Neural Networks and Machine Learning – ICANN 2011*. Berlin, Heidelberg: Springer, 2011, s. 44–51. Lecture Notes in Computer Science. ISBN 978-3-642-21735-7. Dostupné z DOI: 10.1007/978-3-642-21735-7_6.
220. WEST, Brady T.; WELCH, Kathleen B.; GALECKI, Andrzej T. *Linear Mixed Models: A Practical Guide Using Statistical Software*. CRC Press, 2022. ISBN 978-1-00-059827-8.
221. GRANGER, C. W. J. Investigating Causal Relations by Econometric Models and Cross-spectral Methods. *Econometrica*. 1969, roč. 37, č. 3, s. 424–438. ISSN 0012-9682. Dostupné z DOI: 10.2307/1912791.
222. ARNOLD, Andrew; LIU, Yan; ABE, Naoki. Temporal causal modeling with graphical granger methods. In: *Proceedings of the 13th ACM SIGKDD international conference on Knowledge discovery and data mining*. New York, NY, USA: Association for Computing Machinery, 2007, s. 66–75. KDD '07. ISBN 978-1-59593-609-7. Dostupné z DOI: 10.1145/1281192.1281203.
223. TIBSHIRANI, Robert. Regression Shrinkage and Selection Via the Lasso. *Journal of the Royal Statistical Society: Series B (Methodological)*. 1996, roč. 58, č. 1, s. 267–288. ISSN 2517-6161. Dostupné z DOI: 10.1111/j.2517-6161.1996.tb02080.x.
224. BAHADORI, Mohammad Taha; LIU, Yan. An Examination of Practical Granger Causality Inference. In: *Proceedings of the 2013 SIAM International Conference on Data Mining (SDM)*. Society for Industrial a Applied Mathematics, 2013, s. 467–475. Proceedings. ISBN 978-1-61197-262-7. Dostupné z DOI: 10.1137/1.9781611972832.52.

225. CHRISTOV, Ivaylo I. Real time electrocardiogram QRS detection using combined adaptive threshold. *BioMedical Engineering OnLine*. 2004, roč. 3, č. 1, s. 28. ISSN 1475-925X. Dostupné z DOI: 10.1186/1475-925X-3-28.
226. NABIAN, Mohsen; YIN, Yu; WORMWOOD, Jolie; QUIGLEY, Karen S.; BARRETT, Lisa F.; OSTADABBAS, Sarah. An Open-Source Feature Extraction Tool for the Analysis of Peripheral Physiological Data. *IEEE journal of translational engineering in health and medicine*. 2018, roč. 6, s. 2800711. ISSN 2168-2372. Dostupné z DOI: 10.1109/JTEHM.2018.2878000.
227. RODRIGUES, Tiago; SAMOUTPHONH, Sirisack; SILVA, Hugo; FRED, Ana. A Low-Complexity R-peak Detection Algorithm with Adaptive Thresholding for Wearable Devices. In: *2020 25th International Conference on Pattern Recognition (ICPR)*. 2021, s. 1–8. ISSN 1051-4651. Dostupné z DOI: 10.1109/ICPR48806.2021.9413245.
228. ELGENDI, Mohamed; JONKMAN, Mirjam; DE BOER, Friso. Frequency Bands Effects on QRS Detection. In: 2010, s. 431. ISBN 978-989-674-018-4.
229. GAMBOA, Hugo. *Multi-modal behavioral biometrics based on HCI and electrophysiology*. 2008. Dis. pr. Universidade Técnica de Lisboa.
230. FERADOV, Firgan; GANCHEV, Todor; MARKOVA, Valentina. Automated Detection of Cognitive Load from Peripheral Physiological Signals based on Hjorth's Parameters. In: *2020 International Conference on Biomedical Innovations and Applications (BIA)*. 2020, s. 85–88. Dostupné z DOI: 10.1109/BIA50171.2020.9244287.
231. AHMAD, Zeeshan; RABBANI, Suha; ZAFAR, Muhammad Rehman; ISHAQUE, Syem; KRISHNAN, Sridhar; KHAN, Naimul. Multi-level Stress Assessment from ECG in a Virtual Reality Environment using Multimodal Fusion. 2021, č. arXiv:2107.04566. Dostupné z DOI: 10.48550/arXiv.2107.04566.
232. GARG, Prerna; SANTHOSH, Jayasankar; DENGEL, Andreas; ISHIMARU, Shoya. Stress Detection by Machine Learning and Wearable Sensors. In: *26th International Conference on Intelligent User Interfaces - Companion*. New York, NY, USA: Association for Computing Machinery, 2021, s. 43–45. IUI '21 Companion. ISBN 978-1-4503-8018-8. Dostupné z DOI: 10.1145/3397482.3450732.
233. RABBANI, Suha; KHAN, Naimul. Contrastive Self-Supervised Learning for Stress Detection from ECG Data. *Bioengineering*. 2022, roč. 9, č. 88, s. 374. ISSN 2306-5354. Dostupné z DOI: 10.3390/bioengineering9080374.
234. ZHU, Lili; SPACHOS, Petros; GREGORI, Stefano. Multimodal Physiological Signals and Machine Learning for Stress Detection by Wearable Devices. In: *2022 IEEE International Symposium on Medical Measurements and Applications (MeMeA)*. 2022, s. 1–6. Dostupné z DOI: 10.1109/MeMeA54994.2022.9856558.
235. QUADRINI, Michela; DABERDAKU, Sebastian; BLANDA, Alessandro; CAPUCCIO, Antonino; BELLANOVA, Luca; GERARD, Gianluca. Stress Detection from Wearable Sensor Data Using Gramian Angular Fields and CNN. In: PASCAL, Poncelet; IENCO, Dino (ed.). *Discovery Science*. Cham: Springer Nature Switzerland, 2022, s. 173–183. Lecture Notes in Computer Science. ISBN 978-3-031-18840-4. Dostupné z DOI: 10.1007/978-3-031-18840-4_13.
236. CHATTERJEE, Debatri; DUTTA, Souvik; SHAIKH, Rahul; SAHA, Sanjoy Kumar. A lightweight deep neural network for detection of mental states from physiological signals. *Innovations in Systems and Software Engineering*. 2022. ISSN 1614-5054. Dostupné z DOI: 10.1007/s11334-022-00470-6.

237. DAIR, Zachary; DOCKRAY, Samantha; O'REILLY, Ruairi. Inter and Intra Signal Variance in Feature Extraction and Classification of Affective State. In: LONGO, Luca; O'REILLY, Ruairi (ed.). *Artificial Intelligence and Cognitive Science*. Cham: Springer Nature Switzerland, 2023, s. 3–17. Communications in Computer and Information Science. ISBN 978-3-031-26438-2. Dostupné z DOI: [10.1007/978-3-031-26438-2_1](https://doi.org/10.1007/978-3-031-26438-2_1).
238. RASHID, Nafiu; MORTLOCK, Trier; FARUQUE, Mohammad Abdullah Al. Stress Detection using Context-Aware Sensor Fusion from Wearable Devices. *IEEE Internet of Things Journal*. 2023, s. 1–1. ISSN 2327-4662. Dostupné z DOI: [10.1109/JIOT.2023.3265768](https://doi.org/10.1109/JIOT.2023.3265768).
239. SAGASTIBELTZA GALARRAGA, Nagore; SALAZAR RAMÍREZ, Asier; MARTÍNEZ RODRÍGUEZ, Raquel; JODRÁ LUQUE, José Luis; MUGUERZA RIVERO, Javier Francisco. Automatic detection of the mental state in responses towards relaxation. 2023. ISSN 1433-3058. Dostupné z DOI: [10.1007/s00521-022-07435-7](https://doi.org/10.1007/s00521-022-07435-7).
240. HENRY, John; LLOYD, Huw; TURNER, Martin; KENDRICK, Connah. On the robustness of machine learning models for stress and anxiety recognition from heart activity signals. 2023. Dostupné z DOI: [10.36227/techrxiv.21688352.v2](https://doi.org/10.36227/techrxiv.21688352.v2).
241. YONG, Zirui; SU, Guoxin; LI, Xiaohu; SUN, Lingyun; LI, Zejian; LI, Liu. Recognizing Cognitive Load by a Hybrid Spatio-Temporal Causal Model from Multivariate Physiological Data. In: AMINI, Massih-Reza; CANU, Stéphane; FISCHER, Asja; GUNS, Tias; KRALJ NOVAK, Petra; TSOUMAKAS, Grigorios (ed.). *Machine Learning and Knowledge Discovery in Databases*. Cham: Springer Nature Switzerland, 2023, s. 318–334. Lecture Notes in Computer Science. ISBN 978-3-031-26422-1. Dostupné z DOI: [10.1007/978-3-031-26422-1_20](https://doi.org/10.1007/978-3-031-26422-1_20).
242. SINGH, Ghanapriya; PHUKAN, Orchid Chetia; KUMAR, Ravinder. Stress recognition with multi-modal sensing using bootstrapped ensemble deep learning model. *Expert Systems*. [B.r.], roč. n/a, č. n/a, e13239. Dostupné z DOI: <https://doi.org/10.1111/exsy.13239>.